1. 动态结构计量经济学导论

Robert A. Miller

DSE at UCL

2025 年 6 月

背景

为什么要做结构计量？

- **内在一致性**……
  - 面临约束的理性个体
  - 不确定性被视为一个概率分布
  - 均衡（竞争均衡、纳什均衡的精炼、最优合约）
  - 数据生成过程（视样本为来自模型总体）
  - 估计（以大数定律 LLN 和中心极限定理 CLT 为基础）
- **简洁与透明**……
  - 每一步都可以独立验证
  - 更少的随意性（但什么才算数值上的零？）
- **因果关系**……
  - 一个基于模型的概念
  - 基于明确假设的经济学框架
  - 因果计量：有效工具变量是一个开放性问题
- **反事实预测**……
  - 由模型推导得出
  - 严格来说只适用于模型本身

背景

异质性……

- 异质性启发并丰富了**理论**，也使之更复杂……
  - 专业化分工与贸易
  - 同质总体内部的社会互动似乎很有限
- **动态**环境中的异质性……
  - 物质资本投资……以及消费/储蓄决策
  - 人力资本投资
  - 能力衰退与死亡
  - 信息的逐步揭示
- 异质总体下的**推断**……
  - 使汇总数据的解读变得复杂
  - 若可观测，则有助于识别
  - 若不可观测，则使估计变得复杂

背景

政策评估……

- 没有模型，我们如何进行**政策评估**？
  - （我不知道。）
- 模型的参数是否应当**由所研究的总体来决定**？
  - （至少这难道不是理想状态吗？）
- 模型**不现实**，还能有用吗？
  - （实验室里的大鼠和小鼠真的就是人吗？）
- 什么是现实……就是接受既有的**正统观念**吗？
  - （由谁来决定什么是现实的？）
- 什么是研究……就是**挑战**正统观念吗？
  - （也许是为了创造价值？）

从哪里开始

数据

- 数据通常是一个个体样本，记录了这些个体的部分信息：
  - 背景特征
  - 选择
  - 这些选择带来的结果。
- 采用这种方法时，进行预测和检验假设会面临哪些挑战？

1. 经济模型中的选择与结果，通常是我们希望估计的模型底层参数的非线性函数。
2. 有关背景、选择和结果的数据变量，可能并不能完整描述与模型相关的全部内容。

原型模型

选择

- 每期 $t \in \{1, 2, \ldots, T\}$（其中 $T \leq \infty$），个体在 J 个互斥的行动中进行选择。
- 若在 t 期采取行动 $j \in \{1, \ldots, J\}$，则 d_{jt} 等于 1，否则等于 0：

$$d_{jt} \in \{0, 1\}$$

$$\sum_{j=1}^{J} d_{jt} = 1$$

- 在抽象层面上，假设选择互斥并无大碍：两种共享部分特征、但其他特征不同的选择组合，可以看作两个不同的选择。

原型模型

信息与状态

- 假设 t 期采取的行动可能依赖于状态 $z_t \in Z$。
- 当 Z 有限时，记 $f_{jt}(z_{t+1}|z_t)$ 为 t 期采取行动 j 时，$t+1$ 期出现 z_{t+1} 的概率。
- 例如，在上面的例子中，设 $z_t = (w_t, k_t)$，其中：
  - $k_t \in \{0, 1, \ldots\}$ 为 t 期之前的生育数
  - $w_t \equiv d_{1,t-1} + d_{2,t-1}$；因此若女性在 $t-1$ 期工作，则 $w_t = 1$，否则 $w_t = 0$。
- 若子女数最多为 5、工作经验有 3 个水平，加上年龄（比如 50 年），状态数为 750。再加入 4 个教育水平（高中以下、高中、上过大学、大学毕业）和 3 个种族类别，状态数增至 9000。

原型模型

规模大但稀疏的矩阵

- 当 Z 有限时，每个 (j,t) 都对应一个 $Z \times Z$ 的转移矩阵。
- 在上面的例子中，这些矩阵有 $9{,}000^2 = 8100$ 万个单元格。
- 在许多应用中，这些矩阵是稀疏的。
- 假设家庭的子女数每次只能增加一个。
- 工作经验每次最多只能变动一个单位。
- 因此，从 (w_t, k_t) 出发，最多只能转移到六个单元格：

$$\left\{ \begin{array}{l} (w_t, k_t), (w_t, k_t + 1), (w_t + 1, k_t), \\ (w_t + 1, k_t + 1), (w_t - 1, k_t), (w_t - 1, k_t + 1) \end{array} \right\}$$

- 所以，一个转移矩阵最多只有 54,000 个非零元素，而且所有非零元素都等于 1。
- 状态空间建模是一门艺术……还是机器学习的任务？

原型模型

偏好与期望效用

- 个体在 t 期选择 j 的当期收益由 z_t 决定，而 z_t 在 t 期期初向个体揭示。

- t 期采取行动 j 的当期收益为 $u_{jt}(z_t)$。
- 给定每期 $t \in \{1, 2, \ldots, T\}$、每个状态 $z_t \in Z$ 下的选择 $(d_{1t}, \ldots, d_{Jt})$，个体的期望效用为：

$$E\left\{\sum_{t=1}^{T}\sum_{j=1}^{J}\beta^{t-1}d_{jt}u_{jt}(z_t)\,|z_1\right\}$$

其中 $\beta \in (0, 1)$ 为主观贴现因子；在每一期 t，期望都是对 $z_2, \ldots, z_T$ 求取的。

- 形式上，如果 u 带有下标 t，β 就是多余的。
- 我们通常引入几何贴现因子，使效用的无穷和有界，从而保证最优化问题是适定的。

原型模型

价值函数

- 将 t 期的最优决策写成决策规则 $d_t^o(z_t)$，其元素为 $d_{jt}^o(z_t)$。
- 令 $V_t(z_t)$ 表示 t 期的价值函数，其前提是个体按最优决策规则行事：

$$V_t(z_t) \equiv E\left[\sum_{\tau=t}^{T}\sum_{j=1}^{J}\beta^{\tau-t}d_{j\tau}^o\left(z_\tau\right)u_{j\tau}\left(z_\tau\right)|z_t\right]$$

- 用 $t+1$ 期表示：

$$\beta V_{t+1}(z_{t+1}) \equiv \beta E\left\{\sum_{\tau=t+1}^{T}\sum_{j=1}^{J}\beta^{\tau-t-1}d_{j\tau}^o\left(z_\tau\right)u_{j\tau}\left(z_\tau\right)|z_{t+1}\right\}$$

原型模型

递归表示

- 根据 Bellman（1958）的最优性原理，当 Z 有限时可得：

$$
\begin{aligned}
V_t(z_t) &= \sum_{j=1}^{J} d_{jt}^{o} u_{jt}(z_t) \\
&\quad + \sum_{j=1}^{J} d_{jt}^{o} \sum_{z \in Z} E\left[\sum_{\tau=t+1}^{T} \sum_{j=1}^{J} \beta^{\tau-t} d_{j\tau}^{o}\left(z_\tau\right) u_{j\tau}(z_\tau) \,|z \right] f_{jt}\left(z|z_t\right) \\
&= \sum_{j=1}^{J} d_{jt}^{o} \left[u_{jt}(z_t) + \beta \sum_{z \in Z} V_{t+1}(z) f_{jt}\left(z|z_t\right) \right]
\end{aligned}
$$

原型模型

最优化

- 当 T 有限时，为求得最优解，先在最后一期求解一个静态问题，得到所有 $z_T \in Z$ 下的 $d_T^o(z_T)$。
- 运用逆向归纳，选择 $i \in \{1, \ldots, J\}$ 以最大化：

$$u_{it}(z_t) + E\left\{ \sum_{\tau=t+1}^{T} \sum_{j=1}^{J} \beta^{\tau-t-1} d_{j\tau}^o(z_\tau)\, u_{j\tau}(z_\tau) \,|z_t, d_{it} = 1 \right\}$$

- 在平稳的无限期情形下，可以假设 $u_{jt}(z) \equiv u_j(z)$，且对所有 (j, z) 有 $u_j(z) < \infty$。
- 于是每期的期望效用有界，压缩映射定理适用，由此可证明：当 T 足够大时，$d_t^o(z) \to d^o(z)$。

异质性与推断

所有异质性均可观测时的模型估计

- 令 $v_{jt}(z_t)$ 表示任一行动 $j \in \{1, \ldots, J\}$ 的流量收益，加上从 $t+1$ 期起按最优方式行事的预期未来效用：

$$v_{jt}(z_t) \equiv u_{jt}(z_t) + \beta \sum_{z \in Z} V_{t+1}(z) f_{jt}(z|z_t)$$

- 根据定义：

$$d_{jt}^{o}(z_t) \equiv I\{v_{jt}(z_t) \geq v_{kt}(z_t) \forall\ k\}$$

- 假设我们观测到个体 $n \in \{1, \ldots, N\}$ 在各期 $t \in \{1, \ldots, T\}$ 的状态 z_{nt} 与决策 $d_{nt} \equiv (d_{n1t}, \ldots, d_{nJt})$。
- 能否利用这样的数据推断模型的原始要素：
  1. $f_{jt}(z_{t+1}|z_t)$ 的一致估计量，可以由 (t, j, z_t) 单元中转移到 z_{t+1} 的观测所占比例得到。
  2. 对 (t, z_t) 处 d_{nt} 的每个观测，共有 $(J-1)\sum_{n=1}^{N} I\{z_{nt} = z_t\}$ 个不等式，将映射 $v_{jt}(z_t)$ 与 $v_{kt}(z_t)$ 两两联系起来。
  3. 能否由 $v_{jt}(z_t)$ 的值递归地推出 $u_{jt}(z_t)$ 的值？

异质性与推断

为什么要在数据分析中引入不可观测异质性

- 注意：若数据集中具有相同 (t, z_t) 的两个人作出了不同的决策，比如 j 和 k，则 $v_{jt}(z_t) = v_{kt}(z_t)$。用这种方式对数据建模会带来两个潜在问题：

  1. 在大型数据集中很容易想象：对每个选择 $j \in \{1, \ldots, J\}$ 和每个 (t, z_t)，至少有一个样本个体 n 令 $d_{njt} = 1$。若如此，我们会断定总体在所有选择之间都无差异，于是模型没有经验内容，因为任何行为都无法被排除。

  2. 这种方法没有利用“某些选择比其他选择更可能发生”这一信息；也就是说，样本在 (t, z_t) 处采取不同选择的比例可能各不相同，有些选择经常被观测到，另一些则可能极少出现。

- 基于这两个原因，把所有异质性都视为可观测、并试图预测个体的决策，并不是一种很有前景的数据分析方法。

异质性与推断

不可观测异质性

- 一个更温和的目标，是预测选择的概率分布，并对“个体能观测到、而数据分析者观测不到”的因素取边际。
- 预测总体（而非个体）的行为，在本质上消除了宏观经济学与微观经济学之间的差别。
- 现在假设状态可以划分为可观测的部分 x_t 与不可观测的部分 ϵ_t。
- 于是 $z_t \equiv (x_t, \epsilon_t)$。
- 假设数据由随机变量序列 $(X_1, D_1, \ldots, X_T, D_T)$ 的 N 次独立同分布抽取构成。
- 第 n 个观测为 $\left\{x_1^{(n)}, d_1^{(n)}, \ldots, x_T^{(n)}, d_T^{(n)}\right\}$，其中 $n \in \{1, \ldots, N\}$.

异质性与推断

数据生成过程

- 给定 (x_t, ϵ_t) 且最优行动为 j，将 $(x_{t+1}, \epsilon_{t+1})$ 的混合概率（密度）记为：

$$H_{jt}\left(x_{t+1}, \epsilon_{t+1} \left| x_t, \epsilon_t \right.\right) \equiv d_{jt}^{o}\left(x_t, \epsilon_t\right) f_{jt}\left(x_{t+1}, \epsilon_{t+1} \left| x_t, \epsilon_t \right.\right)$$

- 给定 x_1，$\left\{d_1, x_2, \ldots, d_{T-1}, x_T, d_T\right\}$ 的概率为：

$$\Pr\left\{d_1, x_2, \ldots, d_{T-1}, x_T, d_T \left| x_1 \right.\right\} =$$

$$\int_{\epsilon_T} \cdots \int_{\epsilon_1} \left[\begin{array}{l} g\left(\epsilon_1 \left| x_1 \right.\right) \sum_{j=1}^{J} d_{jT} d_{jT}^{o}\left(x_T, \epsilon_T\right) \times \\ \prod_{t=1}^{T-1} \sum_{j=1}^{J} d_{jt} H_{jt}\left(x_{t+1}, \epsilon_{t+1} \left| x_t, \epsilon_t \right.\right) \end{array} \right] d\epsilon_1 \ldots d\epsilon_T$$

其中 $g(\epsilon_1|x_1)$ 是给定 x_1 时 ϵ_1 的条件密度。

异质性与推断

极大似然估计

- 令 $\theta \in \Theta$ 唯一地标记所考虑的 $u_{jt}(z_t)$、$f_{jt}(z_{t+1}|z_t)$ 与 β 的一种设定。
- 给定 $x_1^{(n)}$，设 $\left\{d_1^{(n)}, x_2^{(n)}, \ldots, , d_T^{(n)}\right\}_{n=1}^{N}$ 的生成参数为 $\theta_0 \in \Theta$.
- 极大似然（ML）估计量 θ_{ML} 选择 $\theta \in \Theta$，在给定初始条件时最大化观测结果的联合概率：

$$\theta_{ML} \equiv \arg\max_{\theta \in \Theta} \left\{ N^{-1} \sum_{n=1}^{N} \log \left(\Pr \left\{ d_1^{(n)}, x_2^{(n)}, \ldots, x_T^{(n)}, d_T^{(n)} \,\middle|\, x_1^{(n)}; \theta \right\} \right) \right\}$$

- 最早的应用沿用了这一思路：
  - **Robert Miller**（JPE 1984）研究工作变动……个体对工作匹配的非货币收益进行信念更新
  - **Kenneth Wolpin**（JPE 1984）研究生育……女性有不同的不可观测类型

异质性与推断

积分还是模拟

- **Ariel Pakes**（Econometrica 1986）在专利续期研究中引入模拟，以代替数值积分。
- 已有大量研究致力于处理多重积分，我明天会讨论其中的一部分。

- 明天 **Victor Aguirregabiria** 关于固定效应的讲座，提供了应对这一挑战的新方法。

条件独立框架

条件独立假设

- **John Rust**（Econometrica 1987）在 Harold Zurcher 一文中引入条件独立假设，从而完全免去了积分。

- 给定 (x_t, ϵ_t) 时，$t+1$ 期状态的联合混合密度函数记为 $g_{t,x,\epsilon}(x_{t+1}, \epsilon_{t+1}|x_t, \epsilon_t)$，它满足条件独立假设：

$$g_{t,j,x,\epsilon}\left(x_{t+1}, \epsilon_{t+1}\,|x_t, \epsilon_t\right) = g_{t+1}\left(\epsilon_{t+1}|x_{t+1}\right) f_{jt}\left(x_{t+1}|x_t\right)$$

  其中：

  - $g_t(\epsilon_t|x_t)$ 是扰动项的条件密度
  - $f_{jt}(x_{t+1}|x)$ 是给定 (j,t) 时 x 的转移概率。

- 这一假设在动态离散选择模型的估计中被广泛采用。

条件独立框架

有界且可加可分的偏好

- 记贴现因子为 $\beta \in (0,1)$；给定 (x_t, ϵ_t)，在 t 期采取行动 j 的当期收益为 $u_{jt}(x_t) + \epsilon_{jt}$。
- 为保证横截性条件成立，假设对每个 $(j,x) \in \{1,\ldots,J\} \times \{1,\ldots,X\}$，$\{u_{jt}(x)\}_{t=1}^{T}$ 都是有界序列，下式亦然：

$$\left\{ \int \max\left\{ |\epsilon_{1t}|, \ldots, |\epsilon_{Jt}| \right\} g_t\left(\epsilon_t | x_t\right) d\epsilon_t \right\}_{t=1}^{T}$$

- 每期期初，个体观测到 (x_t, ϵ_t) 的实现值，并选择 d_t 来依次最大化：

$$E\left\{ \sum_{\tau=t}^{T} \sum_{j=1}^{J} \beta^{\tau-1} d_{j\tau} \left[u_{j\tau}(x_\tau) + \epsilon_{j\tau} \right] | x_t, \epsilon_t \right\} \tag{1}$$

其中，期望是在给定 (x_t, ϵ_t) 时，对未来实现值 $x_{t+1}, \ldots, x_T$ 与 $\epsilon_{t+1}, \ldots, \epsilon_T$ 求取的。

条件独立框架

最优化

- 将 t 期的最优决策规则记为 $d_t^o(x_t, \epsilon_t)$，其第 j 个元素为 $d_{jt}^o(x_t, \epsilon_t)$，并将社会剩余函数定义为：

$$V_t(x_t) \equiv E\left\{\sum_{\tau=t}^{T}\sum_{j=1}^{J}\beta^{\tau-t-1}d_{j\tau}^o\left(x_\tau, \epsilon_\tau\right)\left(u_{j\tau}(x_\tau) + \epsilon_{j\tau}\right)\right\}$$

- 条件价值函数 $v_{jt}(x_t)$ 定义为：

$$v_{jt}(x_t) \equiv u_{jt}(x_t) + \beta\sum_{x=1}^{X} V_{t+1}(x) f_{jt}\left(x|x_t\right)$$

- 将 $d_{jt}^o(x_t, \epsilon)$ 对 $\epsilon \equiv (\epsilon_1, \ldots, \epsilon_J)$ 积分，可定义条件选择概率（CCP）：

$$p_{jt}(x_t) \equiv E\left[d_{jt}^o\left(x_t, \epsilon\right)|x_t\right] = \int d_{jt}^o\left(x_t, \epsilon\right) g_t\left(\epsilon\,|x_t\right) d\epsilon$$

推广到动态马尔可夫博弈

参与人、选择与状态变量

- 考虑一个有 I 个（可数）参与人的动态博弈：
  1. $d_t^{(i)} \equiv \left(d_{t1}^{(i)}, \ldots, d_{tJ}^{(i)}\right)$：参与人 i 在 t 期的选择。
  2. $d_t \equiv \left(d_t^{(1)}, \ldots, d_t^{(I)}\right)$：$t$ 期所有参与人的选择。
  3. $d_t^{(-i)} \equiv \left(d_t^{(1)}, \ldots, d_t^{(i-1)}, d_t^{(i+1)}, \ldots, d_t^{(I)}\right)$：$t$ 期除 i 以外所有人的选择。
  4. x_t：t 期博弈状态变量的取值。
  5. $F(x_{t+1}|x_t, d_t)$：给定 (x_t, d_t) 时 x_{t+1} 的转移概率。
  6. $F_j\left(x_{t+1}\middle|x_t, d_t^{(-i)}\right) \equiv F\left(x_{t+1}\middle|x_t, d_t^{(-i)}, d_{jt}^{(i)} = 1\right)$：给定 x_t、参与人 i 选择 j、其他所有人选择 $d_t^{(-i)}$ 时 x_{t+1} 的转移概率。

推广到动态马尔可夫博弈

收益、信息与 CCP

- 参与人 i 从博弈中获得的贴现收益总和为：

$$\sum_{t=1}^{T}\sum_{j=1}^{J}\beta^{t-1}d_{jt}^{(i)}\left[U_{j}^{(i)}\left(x_{t},d_{t}^{(-i)}\right)+\epsilon_{jt}^{(i)}\right]$$

其中：

1. $U_{j}^{(i)}\left(x_{t},d_{t}^{(-i)}\right)$ 取决于所有参与人的选择。
2. $\epsilon_{t}^{(i)}\equiv\left(\epsilon_{1t}^{(i)},\ldots,\epsilon_{Jt}^{(i)}\right)$ 在不同 i 之间独立同分布（iid），密度为 $g\left(\epsilon_{t}^{(i)}|x_{t}\right)$。
3. $d_{t}^{(-i)}$ 与 $\epsilon_{t}^{(-i)}$ 均不为 i 所观测。

- 类比单个决策者的设定，定义：

1. $p_{j}^{(i)}(x_{t})=\int d_{j}^{(i)}\left(x_{t},\epsilon_{t}^{(i)}\right)g\left(\epsilon_{t}^{(i)}\right)d\epsilon_{t}^{(i)}$ 为参与人 i 在 t 期选择 j 的 CCP。
2. $P\left(d_{t}^{(-i)}|x_{t}\right)=\prod_{i'=1,i'\neq i}^{I}\left(\sum_{j=1}^{J}d_{jt}^{(i')}p_{j}^{(i')}(x_{t})\right)$ 为其他所有参与人在 t 期选择 $d_{t}^{(-i)}$ 的 CCP。

推广到动态马尔可夫博弈

均衡的定义

- 若对每个 $\left(i, x_t, \epsilon_t^{(i)}\right)$，$d_j^{(i)}\left(x_t, \epsilon_t^{(i)}\right)$ 都是个体最优化问题 (1) 的解，

  则 $\left(p_1^{(i)}(x_t), \ldots, p_J^{(i)}(x_t)\right)$ 构成一个均衡，其中：

$$u_j^{(i)}(x_t) = \sum_{d_t^{(-i)}} P\left(d_t^{(-i)} | x_t\right) U_j^{(i)}\left(x_t, d_t^{(-i)}\right) \tag{2}$$

  以及：

$$f_j^{(i)}\left(x_{t+1} \middle| x_t^{(i)}\right) = \sum_{d_t^{(-i)}} P\left(d_t^{(-i)} \middle| x_t^{(i)}\right) F_j\left(x_{t+1} \middle| x_t, d_t^{(-i)}\right) \tag{3}$$

- 分析这种形式的动态博弈时：
  1. 用 (2) 解释 $u_j^{(i)}(x_t)$，用 (3) 解释 $f_j^{(i)}\left(x_{t+1} \middle| x_t^{(i)}\right)$
  2. 在估计中，把最优反应函数看作一个动态离散选择最优化问题的解，这个问题嵌在数据生成过程（DGP）所实现的均衡之中。

- **在估计算法中嵌套均衡求解**：
  - 用嵌套不动点算法（例如 NFXP）把模型求解整合进估计程序
  - 得到极大似然估计量。
  - 是实现渐近有效的一种途径。
  - 而且不动点算法还可以兼作反事实的求解工具。
- **Bertel Schjerning 以及之后的 Fedor Iskhakov**，将在今天晚些时候讲授这一方法。

“百花齐放……百家争鸣”

我们应当如何求解和估计动态模型？

- **将推断与模型求解分离**：
  - 利用模型的数据生成过程（无需求解模型）来确定识别并得到估计
  - 给出识别条件。
  - 得到的估计效率较低，但速度快得多。
  - 计算反事实时仍需求解模型。
- 我将在下一讲中采用这种方法。

- **校准方法**：
  - 通常把样本变异与总体概率割裂开来。
  - 可以完全省去估计这一步。
  - 利用已发表实证研究中的数值来量化模型的解，有时称为校准。

  - 通常不给出估计精度。
  - 侧重关键约束与模型矩。

“百花齐放……百家争鸣”

我们应当如何求解和估计动态模型？

- 学者们的争论……
- 与这场争论相关的因素可能包括：
  - 数据的类型，包括数据量
  - 模型的复杂程度
  - 估计结果对底层假设的敏感程度
  - 评估精度时，样本变异是否是重要因素
  - 具体的政策问题是什么
- 这一讨论先放一放，等更清楚地了解每种方法的内容后再说。

公交车发动机（Rust，1987）

一个更新问题

- Zurcher 先生最大化收益的期望贴现和：

$$E\left\{\sum_{t=1}^{\infty}\beta^{t-1}\left[d_{t2}(\theta_1 x_t+\theta_2 s+\epsilon_{t2})+d_{t1}\epsilon_{t1}\right]\right\}$$

其中：

  - 若 Zurcher 更换发动机，则 $d_{t1}=1$ 且 $x_{t+1}=1$
  - 若他保留发动机，则 $d_{t2}=1$，公交车里程增加为 $x_{t+1}=x_t+1$

  - 公交车还因固定特征 $s\in\{0,1\}$ 而有所不同。
  - 选择特定冲击 ϵ_{tj} 独立同分布，服从第一类极值分布（T1EV）。

- 将每个选择的条件价值函数定义为：

$$v_j(x,s)=\begin{cases}\beta V(1,s) & \text{若} j=1\\ \theta_1 x+\theta_2 s+\beta V(x+1,s) & \text{若} j=2\end{cases}$$

其中 $V(x,s)$ 表示社会剩余函数。

公交车发动机

数据生成过程与 CCP

- 假设数据是 N 辆公交车 $n \in \{1, \ldots, N\}$ 的横截面观测，记录了：
  - 固定特征 s_n，
  - 发动机里程 x_n，
  - 以及维护决策 (d_{n1}, d_{n2})。
- 令 $p_1(x, s)$ 表示给定 x 和 s 时更换发动机的条件选择概率（CCP）。
- 平稳性与 T1EV 意味着对所有 t：

$$\begin{aligned} p_1(x, s) &\equiv \int_{\epsilon_t} d_1^o(x, s, \epsilon_t)\, g(\epsilon_t)\, d\epsilon_t \\ &= \int_{\epsilon_t} \mathbf{1}\{\epsilon_{t2} - \epsilon_{t1} \leq v_1(x, s) - v_2(x, s)\}\, g(\epsilon_t \,|x_t)\, d\epsilon_t \\ &= \{1 + \exp[v_2(x, s) - v_1(x, s)]\}^{-1} \end{aligned}$$

- 按照前面描述的步骤，可以基于这个方程构造 ML 估计量。

公交车发动机

利用更新性质

- 上一讲表明，若 ϵ_{jt} 服从 T1EV，则对所有 (x, s, j)：

$$V(x,s) = v_j(x,s) - \ln\left[p_j(x,s)\right] + 0.57\ldots$$

- 因此，不更换发动机的条件价值函数为：

$$\begin{aligned} v_2(x,s) &= \theta_1 x + \theta_2 s + \beta V(x, s+1) \\ &= \theta_1 x + \theta_2 s + \beta\left\{v_1\left(x+1, s\right) - \ln\left[p_1(x+1,s)\right] + 0.57\ldots\right\} \end{aligned}$$

- 类似地：

$$v_1(x,s) = \beta V(1,s) = \beta\left\{v_1(1,s) - \ln\left[p_1(1,s)\right] + 0.57\right\}\ldots$$

- 由于给定 s 时，发动机里程是影响公交车价值的唯一因素：

$$v_1(x+1,s) = v_1(1,s)$$

公交车发动机

用 CCP 表示延续价值之差

- 因此：

$$v_2(x,s) - v_1(x,s) = \theta_1 x + \theta_2 s + \beta \ln\left[p_1(1,s)\right] - \beta \ln\left[p_1(x+1,s)\right]$$

- 所以：

$$\begin{aligned} p_1(x,s) &= \frac{1}{1+\exp\left[v_2(x,s) - v_1(x,s)\right]} \\ &= \frac{1}{1+\exp\left\{\theta_1 x + \theta_2 s + \beta \ln\left[\frac{p_1(1,s)}{p_1(x+1,s)}\right]\right\}} \end{aligned}$$

- 直观地说，当期更换的 CCP 就是一个带偏移项的静态模型的 CCP。

- 偏移项借助刻画未来最优更换行为的未来 CCP，反映延续价值的差异。

公交车发动机

CCP 估计

- 考虑如下 CCP 估计量：
  1. 由相对频率构造 $p_1(x,s)$ 的第一阶段估计量：

$$\hat{p}_1(x,s) \equiv \frac{\sum_{n=1}^{N} d_{n1} I(x_n = x) I(s_n = s)}{\sum_{n=1}^{N} I(x_n = x) I(s_n = s)}$$

  2. 将 $\hat{p}_1(x,s)$ 作为附带参数代入似然函数，用 logit 估计 $(\theta_1, \theta_2, \beta)$：

$$\frac{d_{n1} + d_{n2} \exp\left(\theta_1 x_n + \theta_2 s_n + \beta \ln\left[\frac{\hat{p}_1(1,s_n)}{\hat{p}_1(x_n+1,s_n)}\right]\right)}{1 + \exp\left(\theta_1 x_n + \theta_2 s_n + \beta \ln\left[\frac{\hat{p}_1(1,s_n)}{\hat{p}_1(x_n+1,s_n)}\right]\right)}$$

  3. 修正 $p_1(x,s)$ 的第一阶段估计给 $(\theta_1, \theta_2, \beta)$ 的标准误带来的影响。

- 注意，在第二阶段中，$\ln\left[\frac{\hat{p}_1(1,s_n)}{\hat{p}_1(x_n+1,s_n)}\right]$ 作为数据中个体特定的成分进入 logit，系数 β 的进入方式与 θ_1、θ_2 相同。

蒙特卡洛研究（Arcidiacono and Miller，2011）

对公交车发动机问题的修改

- 假设公交车类型 $s \in \{0, 1\}$ 的权重相等。
- 两个状态变量影响发动机的磨损：
  1. 累计总里程：

$$x_{1,t+1} = \begin{cases} \Delta_t \text{ 若} d_{1t} = 1 \\ x_{1t} + \Delta_t \text{ 若} d_{2t} = 1 \end{cases}$$

  2. 公交车的永久性路线特征 x_2，它系统地影响每期新增的里程。

- 更具体地，我们假设：
  - $\Delta_t \in \{0, 0.125, \ldots, 24.875, 25\}$ 取自离散化的截断指数分布，其中：

$$f(\Delta_t | x_2) = \exp\left[-x_2(\Delta_t - 25)\right] - \exp\left[-x_2(\Delta_t - 24.875)\right]$$

  - x_2 是 0.01 的倍数，取自 0.25 到 1.25 之间的离散等概率分布。

蒙特卡洛研究

在面板估计中加入公交车车龄

- 令 θ_{0t} 表示与车龄相关的其他维护成本。
- 这一修改使最优化问题变为非平稳的。
- 保留与更换发动机的收益之差为：

$$u_{t2}(x_{t1}, s) - u_{t1}(x_{t1}, s) \equiv \theta_{0t} + \theta_1 \min\{x_{t1}, 25\} + \theta_2 s$$

- 记 $x_t \equiv (x_{1t}, x_2)$，这意味着：

$$\begin{aligned} v_{t2}(x_t, s) - v_{t1}(x_t, s) &= \theta_{0t} + \theta_1 \min\{x_{t1}, 25\} + \theta_2 s \\ &\quad + \beta \sum_{\Delta_t \in \Lambda} \left\{ \ln \left[\frac{p_{1t}(\Delta_t, s)}{p_{1t}(x_{1t} + \Delta_t, s)} \right] \right\} f(\Delta_t | x_2) \end{aligned}$$

蒙特卡洛研究

摘自 Arcidiacono and Miller（2011）的表 1

	DGP (1)	FIML (2)	CCP (3)
θ_0 (intercept)	2	2.0100	1.9911
		(0.0405)	(0.0399)
θ_1 (mileage)	−0.15	−0.1488	−0.1441
		(0.0074)	(0.0098)
θ_2 (unobs. state)	1	0.9945	0.9726
		(0.0611)	(0.0668)
β (discount factor)	0.9	0.9102	0.9099
		(0.0411)	(0.0554)
Time (minutes)		130.29	0.078
		(19.73)	(0.0041)