5. 有限依赖与不可观测异质性

Robert A. Miller

DSE at UCL

2025 年 7 月

导论

动机

- 动态离散选择模型的估计之所以复杂，是因为需要计算预期的未来收益。

- 当有限依赖成立时，这些复杂性会得到缓解。
- 直观地说，若从不同初始选择出发的两个加权（非最优）选择序列，在 $\rho + 1$ 期之后生成相同的状态变量分布，则 ρ 期依赖成立。

- 利用有限依赖性质，可以减少需要估计的 CCP 数量。

- 大多数实证应用都具有有限依赖性质。
- 在条件独立假设下，即使不设定效用函数，有限依赖也具有经验内容（可以检验）。
- 有限依赖性质取决于状态转移函数，而与最优化行为无关。

导论

框架

- $t \in \{1, \ldots, T\}$ 表示时间，其中 $T \leq \infty$。
- $x_t \in \{1, \ldots, X\} \equiv \mathcal{X}$ 是 t 期的状态，其中 $\mathcal{X}$ 为有限集。
- $j \in \{1, \ldots, J\}$ 是一个（互斥的）选择。
- 若在 t 期选择 j，则 $d_{jt} = 1$，否则 $d_{jt} = 0$。
- $f_{jt}(x_{t+1}|x_t)$ 是在给定 x_t 且 $d_{jt} = 1$ 时，$t+1$ 期出现 x_{t+1} 的概率。

- $\epsilon_t \equiv (\epsilon_{1t}, \ldots, \epsilon_{Jt})$ 具有连续支撑，在各期之间独立同分布，概率密度为 $g(\epsilon_t)$，且满足 $E[\max\{\epsilon_{1t}, \ldots, \epsilon_{Jt}\}] \leq \bar{\epsilon} < \infty$。
- 给定某个 $\beta \in (0, 1)$，个体依次选择向量 $d_t \equiv (d_{1t}, \ldots, d_{Jt})$ 以最大化：

$$E\left\{\sum_{t=1}^{T}\sum_{j=1}^{J}\beta^{t-1}d_{jt}\left[u_{jt}(x_t) + \epsilon_{jt}\right]\right\} \tag{1}$$

- $d_t^o(x_t, \epsilon_t)$ 是最优决策规则，其第 j 个元素为 $d_{jt}^o(x_t, \epsilon_t)$。
- $p_t(x_t) \equiv (p_{1t}(x_t), \ldots, p_{Jt}(x_t))$ 为 CCP，其中：

$$p_{jt}(x_t) \equiv \int d_{jt}^o(x_t, \epsilon_t) g(\epsilon_t) d\epsilon_t \tag{2}$$

- $V_t(x_t)$ 是事前价值函数，定义为：

$$V_t(x_t) \equiv E\left\{ \sum_{\tau=t}^{T} \sum_{j=1}^{J} \beta^{\tau-t} d_{j\tau}^o(x_\tau, \epsilon_\tau) (u_{j\tau}(x_\tau) + \epsilon_{j\tau}) \right\}$$

- 行动 j 的条件价值函数定义为：

$$v_{jt}(x_t) = u_{jt}(x_t) + \beta \sum_{x_{t+1}=1}^{X} V_{t+1}(x_{t+1}) f_{jt}(x_{t+1}|x_t) \tag{3}$$

- 行动 j 的条件价值函数修正项定义为：

$$\psi_j[p_t(x)] \equiv V_t(x) - v_{jt}(x) \tag{4}$$

- 我们定义了一个权重序列 $\{\omega_{k\tau}(x_\tau, j, t)\}_{(k,\tau)=(1,t+1)}^{(J,t+\rho)}$，满足：

$$|\omega_{k\tau}(x_\tau, j, t)| < \infty \text{ 且 } \sum_{k=1}^{J} \omega_{k\tau}(x_\tau, j, t) = 1$$

- 为强调权重序列可能依赖于 (j, x_t, t)，我们也可以写成：

$$\omega_{k\tau}(x_\tau, j, x_t, t) \text{ 而非 } \omega_{k\tau}(x_\tau, j, t)$$

- 类似地，回顾 $\kappa_{t+1}(x_{t+1}|j, x_t, t) \equiv f_{jt}(x_{t+1}|x_t)$，以及：

$$\kappa_{\tau+1}(x_{\tau+1}|j, x_t, t) \equiv \sum_{x_\tau=1}^{X} \sum_{k=1}^{J} \omega_{k\tau}(x_\tau, j, t) f_{k\tau}(x_{\tau+1}|x_\tau) \kappa_\tau(x_\tau|j, x_t, t) \tag{5}$$

- 为更明确起见，我们也可以写成：

$$\kappa_{\tau+1}^{(\omega)}(x_{\tau+1}|j, x_t, t) \text{ 而非 } \kappa_{\tau+1}(x_{\tau+1}|j, x_t, t)$$

导论

把有限期逐项展开的条件价值函数表示

- 第二讲给出的表示意味着：

$$v_{jt}(x_t) = V_t(x) - \psi_j[p_t(x_t)] = \tag{6}$$

$$\left\{ \begin{array}{l} u_{jt}(x_t) + \sum_{x=1}^{X} \beta^{\rho+1} V_{t+\rho+1}(x) \kappa_{t+\rho+1}(x|j, x_t, t) \\ + \sum_{\tau=t+1, k=1, x_\tau=1}^{t+\rho, J, X} \beta^{\tau-t} \left[\begin{array}{l} u_{k\tau}(x_\tau) \\ +\psi_k[p_\tau(x_\tau)] \end{array} \right] \left[\begin{array}{l} \omega_{k\tau}(x_\tau, j, t) \\ \times \kappa_\tau(x_\tau|j, x_t, t) \end{array} \right] \end{array} \right\}$$

- 在这一表述中：
  - $V_{t+\rho+1}(x)$ 刻画了在 $t+\rho+1$ 期到达 x 之后的价值。
  - $\kappa_{t+\rho+1}(x|j, x_t, t) \equiv \kappa^{(\omega)}_{t+\rho+1}(x|j, x_t, t)$ 是从 (t, x_t) 出发、遵循 $\{\omega_{k\tau}(x_\tau, j, t)\}^{(J,t+\rho)}_{(k,\tau)=(1,t+1)}$ 而到达 x 的概率。
  - $\psi_k[p_\tau(x_\tau)]$ 是对非最优行为的修正项。

有限依赖

定义

- 若存在一对决策权重序列，则称选择对 $\{i, j\}$ 在 (t, x_t) 处表现出 ρ 期依赖（ρ-period dependence）：

$$\{\omega_{k\tau}(x_\tau, i, t)\}_{(k,\tau)=(1,t+1)}^{(J,t+\rho)} \text{ 与 } \{\omega_{k\tau}(x_\tau, j, t)\}_{(k,\tau)=(1,t+1)}^{(J,t+\rho)}$$

使得对所有 $x_{t+\rho+1} \in \{1, \ldots, X\}$：

$$\kappa_{t+\rho+1}(x_{t+\rho+1} | i, x_t, t) = \kappa_{t+\rho+1}(x_{t+\rho+1} | j, x_t, t)$$

- 有限依赖：
  1. 当 $T < \infty$ 时，对 $\rho = T - t$ 平凡地成立；只有当 $\rho < T - t$ 时才值得关注。
  2. 通过同时以参与人为条件，可推广到博弈。
  3. 可能对某些选择对成立而对另一些不成立，也可能只在某些状态下成立。
  4. 可以定义为以混合选择开始序列，而不仅仅是确定性的行动；本分析可推广到这种更一般的情形。

有限依赖

表示效用

- 若 (i, j, x_t, t) 存在有限依赖，则：

$$u_{jt}(x_t) + \psi_j[p_t(x_t)] - u_{it}(x_t) - \psi_i[p_t(x_t)] =$$

$$\sum_{(k,\tau,x_\tau)=(1,t+1,1)}^{(J,t+\rho,X)} \beta^{\tau-t} \left\{ \begin{array}{l} u_{k\tau}(x_\tau) \\ +\psi_k[p_\tau(x_\tau)] \end{array} \right\} \left[\begin{array}{l} \omega_{k\tau}(x_\tau, i, t)\kappa_\tau(x_\tau|i, x_t, t) \\ -\omega_{k\tau}(x_\tau, j, t)\kappa_\tau(x_\tau|j, x_t, t) \end{array} \right] \tag{7}$$

- 推导这个方程的步骤：
  - 在 (6) 中用 $V_t(x) - \psi_j[p_t(x_t)]$ 替换 $v_{jt}(x)$
  - 对 i 写出类似的方程
  - 将得到的两个方程相减
  - 注意 $V_t(x)$ 项与 $V_{t+\rho+1}(x)\kappa_{t+\rho+1}(x|x_t, j, t)$ 项相互抵消。

有限依赖的简单例子

终止性选择

- 终止性选择会结束该参与人的最优化问题或博弈。

- 它们在实证应用中相当常见。
- 假设第一个选择是终止性选择，则 $u_{1t}(x_t)$ 可以解释为在 (t, x_t) 作出该选择时的最终收益。
- 对所有 (x, i) 及 $k \neq 1$ 令 $\omega_{k,t+1}(t, x_{t+1}, i) = 0$，式 (7) 化简为：

$$\begin{aligned} & u_{1t}(x_t) + \psi_1[p_t(x_t)] - u_{jt}(x_t) - \psi_j[p_t(x_t)] \\ = & \sum_{x_{t+1}=1}^{X} \beta \left\{ u_{1,t+1}(x_{t+1}) + \psi_1 \left[p_{t+1}(x_{t+1}) \right] \right\} f_{jt}(x_{t+1}|x_t) \end{aligned}$$

有限依赖的简单例子

更新性选择在实证应用中也相当常见

- 类似地，更新性选择使下一期状态变量的概率分布不依赖于当前状态。

- 若第一个选择是更新性选择，则对所有 $j \in \{1, \ldots, J\}$：

$$\begin{aligned}
\sum_{x_{t+1}=1}^{X} f_{1,t+1}(x_{t+2}|x_{t+1}) f_{jt}(x_{t+1}|x_t) &= \sum_{x_{t+1}=1}^{X} f_{1,t+1}(x_{t+2}) f_{jt}(x_{t+1}|x_t) \\
&= f_{1,t+1}(x_{t+2}) \sum_{x_{t+1}=1}^{X} f_{jt}(x_{t+1}|x_t) \\
&= f_{1,t+1}(x_{t+2}) \qquad (8)
\end{aligned}$$

- 此时式 (7) 意味着：

$$\begin{aligned}
& u_{1t}(x_t) + \psi_1[p_t(x_t)] - u_{jt}(x_t) - \psi_j[p_t(x_t)] \\
= & \sum_{x=1}^{X} \beta \{u_{1,t+1}(x) + \psi_1[p_{t+1}(x)]\} [f_{jt}(x|x_t) - f_{1t}(x|x_t)]
\end{aligned}$$

有限依赖的简单例子

两期有限依赖的例子

- 当 $\rho > 1$ 时，有限依赖如何发挥作用？
- 考虑如下劳动供给与人力资本模型。
- 在 T 期中的每一期，个体选择：
  - $d_{2t} = 1$：工作
  - $d_{1t} = 1$：待在家中。
- 她通过工作积累人力资本 x_t：
  - 若 $d_{1t} = 1$，则 $x_{t+1} = x_t$。
  - 若 $d_{2t} = 1$ 且 $t > 1$，则 $x_{t+1} = x_t + 1$。
  - 若 $d_{j=2,t=1} = 1$，则

$$x_2 = \begin{cases} 2，\text{概率为 } 0.5 \\ 1，\text{概率为 } 0.5 \end{cases}$$

- 总之，人力资本只随工作每次增加一个单位，但第一期例外，此时可能跳升到 2。

有限依赖的简单例子

在劳动供给例子中建立有限依赖

- 当 $t > 1$ 时，可以通过在接下来两期中工作一期，使 $x_{t+2} = x_t + 1$，从而实现一期依赖：
  - 若 $d_{2t} = 1$，令 $\omega_{1,t+1}(x_{t+1} = x_t + 1, j = 2, t) = 1$。
  - 若 $d_{1t} = 1$，令 $\omega_{2,t+1}(x_{t+1} = x_t, j = 1, t) = 1$。
- 当 $t = 1$ 时，可以通过 $x_3 = 2$ 实现两期依赖：
  - $t = 1$ 时待在家中（令 $d_{11} = 1$），然后连续工作两期：

$$\begin{aligned} 1 &= \omega_{k=2,\tau=2}(x_2 = 0, j = 1, t = 1) \\ &= \omega_{k=2,\tau=3}(x_3 = 1, j = 1, t = 1) \end{aligned}$$

  - $t = 1$ 时工作（令 $d_{21} = 1$），且仅当人力资本在 $t = 1$ 增加一个单位时，才在 $t = 2$ 工作：

$$\begin{aligned} 1 &= \omega_{k=1,\tau=2}(x_2 = 2, j = 2, t = 1) \\ &= \omega_{k=2,\tau=2}(x_2 = 1, j = 2, t = 1) \\ &= \omega_{k=1,\tau=3}(x_2 = 3, j = 2, t = 1) \end{aligned}$$

有限依赖的简单例子

非平稳搜寻模型

- 考虑一个简单的搜寻模型，其中所有工作都是临时性的，只持续一期。
- 每期 $t \in \{1, \ldots, T\}$，个体可以：
  - 令 $d_{1t} = 1$，待在家中
  - 或令 $d_{2t} = 1$，申请临时工作。
- 求职者以概率 λ_t 成功，即工作机会到达率随时间变化。
- 经验 $x \in \{1, \ldots, X\}$ 每工作一期增加一个单位，最多到 X，且不会折旧。

有限依赖的简单例子

该搜寻模型中的有限依赖

- 对所有满足 $x_t < X$ 的 (x_t, t)，令：
  - $d_{1t} = 1$（待在家中），然后以如下权重“申请工作”：

$$\begin{aligned} \lambda_t / \lambda_{t+1} &= \omega_{k=2,t+1}(x_t, j = 1, t) \\ &= 1 - \omega_{k=1,t+1}(x_t, j = 1, t) \end{aligned}$$

  - $d_{2t} = 1$（寻找工作），然后待在家中：

$$\omega_{k=1,t+1}\left(x_t, j = 2, t\right) = \omega_{k=1,t+1}\left(x_t + 1, j = 2, t\right) = 1$$

- 这一对序列实现了一期依赖，因为：

$$\kappa_3\left(x_{t+3} \middle| j = 1, x_t, t\right) = \kappa_3\left(x_{t+3} \middle| j = 2, x_t, t\right) = \begin{cases} 1 - \lambda_t, & \text{若 } x_{t+3} = x_t \\ \lambda_t, & \text{若 } x_{t+3} = x_t + 1 \end{cases}$$

- 注意，若 $\lambda_t > \lambda_{t+1}$，则 $\omega_{k=2,t+1}(x_t, j = 1, t) > 1$，且：

$$\omega_{k=1,t+1}(x_{t+1}, j = 1, t) = 1 - \lambda_t / \lambda_{t+1} < 0$$

估计

估计框架

- 假设数据包含状态变量与决策的 N 个观测，记为 $\{d_{nt_n}, x_{nt_n}, x_{n,t_n+1}\}_{n=1}^{N}$，抽样于时间范围 $t \in \{1, \ldots, S\}$ 之内。

- 为便于说明，假设在 $t \in \{1, \ldots, S\}$ 中抽到每个 $x \in \{1, \ldots, X\}$ 的概率都严格为正。
- 在该时间范围内有 M 个不同的有限依赖实例。
- 假设每一对选择都包含第一个选择。
- 将这 M 条路径记为 (j_m, x_m, t_m, ρ_m)，$m \in \{1, \ldots, M\}$。
- 假设：
  - $g(\epsilon_t)$ 已知。
  - $\theta \equiv (\theta_1, \ldots, \theta_K) \in \Theta$，$\Theta$ 是 R^K 中的闭凸集。
  - $u_{jt}(x) \equiv \mu_{jt}(x, \theta)$，其中 $\mu_{jt}(x, \theta)$ 是已知函数。
  - M 个有限依赖实例足以实现识别。

估计

最小距离（MD）估计量的简约形式

- 对所有 $(t, x, j) \in \{1, \ldots, S\} \times \{1, \ldots, X\} \times \{1, \ldots, J\}$：
  - 定义

$$\widehat{p}_{jt}(x) \equiv \frac{\sum_{n=1}^{N} 1\{d_{nt_nj} = 1\} 1\{t_n = t\} 1\{x_{nt_n} = x\}}{\sum_{n=1}^{N} 1\{t_n = t\} 1\{x_{nt_n} = x\}}$$

  - 估计 XJT 维的 CCP 向量 $p \equiv (p_{11}(1), \ldots, p_{JS}(X))'$，其估计 $\widehat{p}$ 由 $\widehat{p}_{jt}(x)$ 构成。
  - 在第一阶段同样用 $\widehat{f}_{jt}(x)$ 估计 $f_{jt}(x)$，例如使用单元估计量（与 CCP 估计量类似）。

估计

MD 估计量

- 定义 $y(p,f) \equiv (y_1(p,f),\ldots,y_M(p,f))'$，其中：

$$y_m(p,f) \equiv \psi_1[p_{t_m}(x_m)] - \psi_{j_m}[p_{t_m}(x_m)]$$
$$+ \sum_{\tau=t_m+1}^{t_m+\rho_m} \sum_{k=1}^{J} \sum_{x_\tau=1}^{X} \beta^{\tau-t_m} \psi_k[p_\tau(x_\tau)] \left[\begin{array}{l} \omega_{k\tau}(x_\tau,1,t_m)\kappa_\tau(x_\tau|1,x_m,t_m) - \\ \omega_{k\tau}(x_\tau,j_m,t_m)\kappa_\tau(x_\tau|j_m,x_m,t_m) \end{array} \right]$$

以及 $Z(p,f,\theta) \equiv (Z_1(p,f,\theta),\ldots,Z_M(p,f,\theta))'$，其中：

$$Z_m(p,f,\theta) \equiv \mu_{j_m,t_m}(x_m,\theta)$$
$$- \sum_{\tau=t_m+1}^{t_m+\rho_m} \sum_{k=1}^{J} \sum_{x_\tau=1}^{X} \beta_{k\tau}^{\tau-t_m} \mu_{k\tau}(x_\tau,\theta) \left[\begin{array}{l} \omega_{k\tau}(x_\tau,1,t_m)\kappa_\tau(x_\tau|1,x_m,t_m) - \\ \omega_{k\tau}(x_\tau,j_m,t_m)\kappa_\tau(x_\tau|j_m,x_m,t_m) \end{array} \right]$$

- 对任意 M 维正定矩阵 W，定义：

$$\widehat{\theta} \equiv \arg\min_{\theta} \left[y\left(\widehat{p},\widehat{f}\right) - Z\left(\widehat{p},\widehat{f},\theta\right) \right]' W \left[y\left(\widehat{p}\right) - Z\left(\widehat{p},\widehat{f},\theta\right) \right] \qquad (9)$$

最优化问题中的一期依赖

方法

- 通常用“猜测再验证”的方法来确立有限依赖。
- 不过，也存在一种确定有限期依赖的系统方法。

- 该算法在以下两个程序之间迭代：
  1. 检查由确定性选择产生的反事实结果，这些选择可能导致或排除有限依赖。
  2. 列出一个矩阵的元素以确定其秩。
- 参见：
  1. Peter Arcidiacono and Robert Miller（2019，Quantitative Economics）
  2. 另见 Jaepil Lee：“A Structural Analysis of Opioid Misuse: Health, Labor, Policy, and Misperception on Opioid Misuse Risk”（工作论文）

工作匹配与职业选择（Miller，1984）

个体收益与选择

- 放松条件独立假设，就相当于重新面对多重积分的难题。

- 考虑不可观测的信念内生演化时会发生什么。
- 在 $t \in \{0, 1, \ldots\}$ 期从事工作 $m \in \{1, 2, \ldots\}$ 的收益为：

$$x_{mt} \equiv \psi_t + \xi_m + \sigma_m \epsilon_{mt} \tag{10}$$

其中：

  - ψ_t 是生命周期趋势项，在分析中不起作用；
  - ξ_m 是工作匹配参数，取自 $N(\gamma_m, \delta_m^2)$；
  - ε_{mt} 是个体特异的 iid 扰动，取自 $N(0, 1)$

- 每期 t，个体选择一份工作 $m \in \{1, 2, \ldots\}$，其中：
  - $d_t = (d_{1t}, d_{2t}, \ldots)$ 表示她的选择，$d_{mt} \in \{0, 1\}$，且 $\sum_{m=1}^{\infty} d_{mt} = 1$.
  - 她实现的终身效用为 $\sum_{t=0}^{\infty} \sum_{m=1}^{\infty} \beta^t d_{mt} x_{mt}$

- 在 $t=0$ 时，个体看到每个 m 的 $\left(\gamma_m, \delta_m^2\right)$。
- 作出选择后，她还会看到 ψ_t，以及所有 m 的 $d_{mt}x_{mt}$。
- 她在 $t \in \{0,1,\ldots\}$ 期对工作 m 的后验信念为 $N\left(\gamma_{mt}, \delta_{mt}^2\right)$，其中：

$$\begin{aligned}\gamma_{mt,+1} &= \frac{\delta_m^{-2}\gamma_m + \sigma_m^{-2}\sum_{s=0}^{t}\left(x_{ms}-\psi_s\right)d_{ms}}{\delta_m^{-2}+\sigma_m^{-2}\sum_{s=0}^{t}d_{ms}} \\ &= \gamma_{mt} + \left(x_{mt}-\psi_t\right)/\left(\sigma_m^2\delta_{mt}^{-2}+1\right)d_{mt}\end{aligned}$$

以及

$$\delta_{m,t+1}^{-2} = \delta_m^{-2} + \sigma_m^{-2}\sum_{s=0}^{t} d_{ms} = \delta_{mt}^{-2} + \sigma_m^{-2} \tag{11}$$

- 给定对每个 $m \in M$ 的信念 $N\left(\gamma_{mt}, \delta_{mt}^2\right)$，她依次选择 d_t，以最大化期望收益之和。

最优化

利用动态分配指数（DAI）求最优

推论（来自 Gittins and Jones，1974 的定理 2）

在每个 $t \in \{1, 2, \ldots\}$，选择使下式最大的 $m \in M$ 是最优的：

$$DAI_m\left(\gamma_{mt}, \delta_{mt}\right) \equiv \sup_{\tau \geq t}\left\{\frac{E\left[\sum_{r=t}^{\tau} \beta^{r-t}\left(x_{mr}-\psi_r\right) | \gamma_{mt}, \delta_{mt}\right]}{E\left[\sum_{r=t}^{\tau} \beta^{r-t} | \gamma_{mt}, \delta_{mt}\right]}\right\}$$

- 若 τ 固定且存在完美预见，则基本比率为：
  - 收益的贴现和 $\sum_{r=t}^{\tau} \beta^{r-t}(x_{mr}-\psi_r)$
  - 除以时间的贴现和 $\sum_{r=t}^{\tau} \beta^{r-t}$。
- 例如，若项目 A 收益为 5、需要 2 期完成，项目 B 收益为 3、只需 1 期，则当且仅当下式成立时先做 A：

$$\begin{aligned} & 5+3\beta^2 > 3+5\beta \\ \iff & 5(1-\beta) > 3(1-\beta)(1+\beta) \\ \iff & DAI_A \equiv 5/(1+\beta) > 3 \equiv DAI_B \end{aligned}$$

最优化

正态分布下的贝叶斯学习

- 定义 $D(\sigma)$ 为某个（假想）工作的（标准）DAI，该工作
  - 的固定匹配参数 ξ 取自 $N(0,1)$，
  - 且收益中的随机成分为 $\sigma\varepsilon_t$。

推论（Miller，1984 的命题 4）

在该模型中：

$$DAI_m\left(\gamma_{mt},\delta_{mt}\right)=\gamma_{mt}+\delta_{mt}D\left[\left(\frac{\sigma_m}{\delta_m}\right)^2+\sum_{s=0}^{t-1}d_{ms}\right]$$

- 可以证明 $D(\cdot)$ 是递减函数，这意味着 $DAI_m\left(\gamma_{mt},\delta_{mt}\right)\uparrow$，当：
  - γ_{mt}、δ_{mt} 和 $\beta\uparrow$
  - σ_m 和 $\sum_{s=0}^{t-1}d_{ms}\downarrow$。

工作持续期的概率分布

持续期的风险率

- 假设对所有 m 有 $(\gamma_m, \delta_m, \sigma_m) = (\gamma, \delta, \sigma)$，即工作之间的所有差异都是匹配特定的，那么只需跟踪当前的工作匹配即可。(为什么 ?)

- 定义 h_t 为第 t 期的离散风险率，即在存续到 t 期的条件下，持续期在 t 期后结束的概率。则:

$$
\begin{aligned}
h_t &\equiv \Pr\left\{\gamma_t + \delta_t D\left[\left(\frac{\sigma}{\delta}\right)^2 + t, \beta\right] \leq \gamma + \delta D\left[\left(\frac{\sigma}{\delta}\right)^2, \beta\right]\right\} \\
&= \Pr\left\{\frac{\gamma_t - \gamma}{\sigma} \leq \frac{\delta}{\sigma} D\left[\left(\frac{\sigma}{\delta}\right)^2, \beta\right] - \frac{\delta_t}{\sigma} D\left[\left(\frac{\sigma}{\delta}\right)^2 + t, \beta\right]\right\} \\
&= \Pr\left\{\rho_t \leq \alpha^{-1/2} D(\alpha, \beta) - (\alpha + t)^{-1/2} D(\alpha + t, \beta)\right\}
\end{aligned}
$$

其中 $\rho_t \equiv (\gamma_t - \gamma)/\sigma$，$\alpha \equiv (\sigma/\delta)^2$，由此可得:

$$
\frac{\delta_t}{\sigma} = \frac{\left[\delta^{-2} + t\sigma^{-2}\right]^{-1/2}}{\sigma} = \left[\left(\frac{\delta}{\sigma}\right)^{-2} + t\right]^{-1/2} = (\alpha + t)^{-1/2}
$$

工作持续期的概率分布

将风险率与标准化匹配质量的分布联系起来

- 将存续至少 t 期的持续期的变换均值的概率分布定义为：

$$\Psi_t(\rho) \equiv \Pr\{\rho_t \leq \rho\} = \Pr\left\{\sigma^{-1}(\gamma_t - \gamma) \leq \rho\right\} = \Pr\{\gamma_t \leq \gamma + \rho\sigma\}$$

- 为便于理解，注意对所有 $\rho < 0$ 有 $\Psi_0(\rho) = 0$，且 $\Psi_0(0) = 1$。
- 由 h_t 与 $\Psi_t(\rho)$ 的定义：

$$\begin{aligned} h_t &= \Pr\left\{\rho_t \leq \alpha^{-1/2} D(\alpha,\beta) - (\alpha+t)^{-1/2} D(\alpha+t,\beta)\right\} \\ &= \Psi_t\left[\alpha^{-1/2} D(\alpha,\beta) - (\alpha+t)^{-1/2} D(\alpha+t,\beta)\right] \end{aligned}$$

- 为推导离散风险率，我们递归地计算 $\Psi_t(\rho)$。

工作持续期的概率分布

一期之后与标准化匹配质量有关的不等式

- 每个匹配至少存续一期：

$$\Psi_1(\rho) = \Pr\{\gamma_1 \leq \gamma + \rho\sigma\} = \Phi\left[\alpha^{1/2}(\alpha+1)^{1/2}\rho\right]$$

而持续期在下列条件下结束：

$$\rho_1 < \alpha^{-1/2} D(\alpha,\beta) - (\alpha+1)^{-1/2} D(\alpha+1,\beta) \equiv \rho_1^*$$

- 因此，一期之后结束的持续期所占比例为：

$$\begin{aligned} h_1 &= \Psi_1\left[\alpha^{-1/2} D(\alpha,\beta) - (\alpha+1)^{-1/2} D(\alpha+1,\beta)\right] \\ &= \Phi\left\{\begin{array}{l}\left[\alpha^{1/2}(\alpha+1)^{1/2}\right] \\ \times\left[\alpha^{-1/2} D(\alpha,\beta) - (\alpha+1)^{-1/2} D(\alpha+1,\beta)\right]\end{array}\right\} \\ &> 1/2 \text{（因为 } D(\cdot) \text{ 关于 } \alpha \text{ 递减）} \end{aligned}$$

新工作具有更大的信息价值，而且有一半的概率均值更高。

工作持续期的概率分布

递归计算标准化匹配质量的分布

- 沿着这一思路继续推导：

$$\Psi_2(\rho) = \frac{\int_{-\infty}^{\infty} \Phi\left[\begin{array}{l} \alpha^{1/2}(\alpha+1)^{1/2} \times \\ \left(\rho - \epsilon\left[(\alpha+1)(\alpha+2)\right]^{-1/2}\right) \end{array}\right] d\Phi(\epsilon) - h_1}{1 - h_1}$$

更一般地（见 Miller，1984 第 1112 页）：

$$\Psi_{t+1}(\rho) \equiv \frac{\int_{-\infty}^{\infty} \Psi_t\left(\rho - \epsilon\left[(\alpha+t)(\alpha+t+1)\right]^{-1/2}\right) d\Phi(\epsilon) - h_t}{1 - h_t}$$

极大似然估计

完整持续期与不完整持续期

- 假设样本是持续期 $n \in \{1, \ldots, N\}$ 的横截面，其中一些在 τ_n 期后结束（完整），另一些不完整、至少持续了 τ_n 期。令：

$$\rho(n) \equiv \begin{cases} \tau_n, & \text{若持续期完整} \\ \{\tau_n, \tau_n + 1, \ldots\}, & \text{若持续期不完整} \end{cases}$$

- 令 $p_\tau(\alpha_n, \beta_n)$ 表示贴现因子为 β_n 的个体 n，在信息因子为 α_n 的新工作中工作 τ 期后，转到同一职业中另一份新工作的无条件概率：

$$p_\tau(\alpha_n, \beta_n) \equiv h_\tau(\alpha_n, \beta_n) \prod_{s=1}^{\tau-1} [1 - h_s(\alpha_n, \beta_n)]$$

- 则样本中观测到的持续期长度的联合概率为：

$$\prod_{n=1}^{N} \sum_{\tau \in \rho(n)} p_\tau(\alpha_n, \beta_n)$$

引例

重访 Rust（1987）的公交车发动机问题

- 工作匹配例子中的积分：
  1. 相当繁琐
  2. 表明一旦工作在事前和事后都有差异，积分会多么迅速地变得难以处理。

- 可以利用 CCP 估计量来缓解这一问题。
- 回顾 Zurcher 先生的问题：
  - 更换现有发动机（$d_{1t} = 1$），或至少再保留一期（$d_{2t} = 1$）。
  - 公交车里程 x_t 遵循更新规则 $x_{t+1} = d_{1t} + d_{2t}(x_t + 1)$。
  - 暂时性的 iid 选择特定冲击 ϵ_{jt} 服从 T1EV。
  - Zurcher 依次最大化收益的期望贴现和：

$$E\left\{\sum_{t=1}^{\infty}\beta^{t-1}\left[d_{2t}(\theta_1 x_t + \theta_2 s + \epsilon_{2t}) + d_{1t}\epsilon_{1t}\right]\right\}$$

- 现在假设公交车的品牌 s 不可观测。

引例

CCP 已知时的 ML 估计（不可行）

- 为说明 EM 算法的作用，考虑一个不可行的情形：$s \in \{1, \ldots, S\}$ 不可观测，但 $p(x, s)$ 已知。
- 令 π_s 表示处于不可观测状态 s 的总体概率。
- 假设 β 已知，这个“更容易”的问题的 ML 估计量为：

$$\{\hat{\theta}, \hat{\pi}\} = \arg\max_{\theta,\pi} \sum_{n=1}^{N} \ln \left[\sum_{s=1}^{S} \pi_s \prod_{t=1}^{T} l(d_{nt}|x_{nt}, s, p, \theta) \right]$$

其中 $p \equiv p(x, s)$ 是对每个 (x, s) 指定/估计的一串概率，$l(d_{nt}|x_{nt}, s_n, p, \theta)$ 由条件价值函数的表示推出，其形式为：

$$\frac{d_{1nt} + d_{2nt} \exp(\theta_1 x_{nt} + \theta_2 s + \beta \ln [p(0, s)] - \beta \ln [p(x_{nt} + 1, s)]}{1 + \exp(\theta_1 x_{nt} + \theta_2 s + \beta \ln [p(0, s)] - \beta \ln [p(x_{nt} + 1, s)])}$$

- 对“乘积之和的对数”的总和求最大值，计算负担很重。

引例

为什么 EM 有吸引力（当 CCP 已知时）

- 与直接最大化似然函数相比，EM 算法在计算上更具吸引力。

- 记 $d_n \equiv (d_{n1}, \ldots, d_{nT})$ 与 $x_n \equiv (x_{n1}, \ldots, x_{nT})$ 为数据中观测到的公交车 n 的完整选择序列与里程序列。
- 在第 m 次迭代：

$$\begin{aligned} q_{ns}^{(m+1)} &= \Pr\left\{ s \,\middle|\, d_n, x_n, \theta^{(m)}, \pi_s^{(m)}, p \right\} \\ &= \frac{\pi_s^{(m)} \prod_{t=1}^{T} l\left(d_{nt} \middle| x_{nt}, s, p, \theta^{(m)}\right)}{\sum_{s'=1}^{S} \pi_{s'}^{(m)} \prod_{t=1}^{T} l\left(d_{nt} \middle| x_{nt}, s', p, \theta^{(m)}\right)} \end{aligned}$$

$$\pi_s^{(m+1)} = N^{-1} \sum_{n=1}^{N} q_{ns}^{(m+1)}$$

$$\theta^{(m+1)} = \arg\max_{\theta} \sum_{n=1}^{N} \sum_{s=1}^{S} \sum_{t=1}^{T} q_{ns}^{(m+1)} \ln\left[l\left(d_{nt} \middle| x_{nt}, s, p, \theta\right) \right]$$

算法首先为 $\theta^{(1)}$、$\pi^{(1)}$ 和 $p^{(1)}(\cdot)$ 设定初始值：

第 1 步 按下式计算 $q_{ns}^{(m+1)}$：

$$q_{ns}^{(m+1)} = \frac{\pi_s^{(m)} \prod_{t=1}^{T} l\left[d_{nt} | x_{nt}, s, p^{(m)}, \theta^{(m)}\right]}{\sum_{s'=1}^{S} \pi_s^{(m)} \prod_{t=1}^{T} l\left(d_{nt} | x_{nt}, s', p^{(m)}, \theta^{(m)}\right)}$$

第 2 步 按下式计算 $\pi_s^{(m+1)}$：

$$\pi_s^{(m+1)} = \frac{\sum_{n=1}^{N} q_{ns}^{(m+1)}}{N}$$

第 3 步 用下面两种规则之一更新 $p^{(m+1)}(x, s)$。

第 4 步 由下式得到 $\theta^{(m+1)}$：

$$\theta^{(m+1)} = \arg\max_{\theta} \sum_{n=1}^{N} \sum_{s=1}^{S} \sum_{t=1}^{T} q_{ns}^{(m+1)} \ln\left[l\left(d_{nt} | x_{nt}, s_n, p^{(m+1)}, \theta\right)\right.$$

引例

更新 CCP

- 在给定 x 时，对更换发动机的决策取加权平均，权重为处于不可观测状态 s 的条件概率。

第 3A 步 用下式更新 CCP：

$$p^{(m+1)}(x,s) = \frac{\sum_{n=1}^{N}\sum_{t=1}^{T} d_{1nt}\, q_{ns}^{(m+1)}\, I(x_{nt}=x)}{\sum_{n=1}^{N}\sum_{t=1}^{T} q_{ns}^{(m+1)}\, I(x_{nt}=x)}$$

- 或者在平稳的无限期模型中，利用模型中“似然函数返回更换发动机的 CCP”这一恒等式：

第 3B 步 用下式更新 CCP：

$$p^{(m+1)}(x_{nt},s_n) = I\left(d_{nt1}=1 \middle| x_{nt}, s_n, p^{(m)}, \theta^{(m)}\right)$$

蒙特卡洛模拟

有限期更新问题

- 假设 $s \in \{0, 1\}$ 的权重相等。
- 有两个可观测状态变量
  1. 累计总里程：

$$x_{1t+1} = \begin{cases} \Delta_t \text{ 若} d_{1t} = 1 \\ x_{1t} + \Delta_t \text{ 若} d_{2t} = 1 \end{cases}$$

  2. 公交车的永久性路线特征 x_2，它系统地影响每期新增的里程。

- 我们假设 $\Delta_t \in \{0, 0.125, \ldots, 24.875, 25\}$ 取自：

$$f(\Delta_t | x_2) = \exp\left[-x_2(\Delta_t - 25)\right] - \exp\left[-x_2(\Delta_t - 24.875)\right]$$

而 x_2 是 0.01 的倍数，取自 0.25 到 1.25 之间的离散等概率分布。

蒙特卡洛模拟

有限期更新问题

- 令 θ_{0t} 为总量冲击（比如代表成本波动）。
- 保留与更换发动机的当期收益之差为：

$$u_{2t}(x_{1t}, s) - u_{1t}(x_{1t}, s) \equiv \theta_{0t} + \theta_1 \min\{x_{1t}, 25\} + \theta_2 s$$

- 将可观测状态变量记为 $x_t \equiv (x_{1t}, x_2)$，上式可写为：

$$\begin{aligned} v_{2t}(x_t, s) - v_{1t}(x_t, s) &= \theta_{0t} + \theta_1 \min\{x_{1t}, 25\} + \theta_2 s \\ &\quad + \beta \sum_{\Delta_t \in \Lambda} \left\{ \ln \left[\frac{p_{1t}(0, s)}{p_{1t}(x_{1t} + \Delta_t, s)} \right] \right\} f(\Delta_t | x_2) \end{aligned}$$

蒙特卡洛模拟

Arcidiacono and Miller（2011，第 1854 页）的表 1

		s Observed		Ignoring s	s Unobserved		Time Effects	
	DGP	FIML	CCP	CCP	FIML	CCP	s Observed CCP	s Unobserved CCP
	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
θ_0 (intercept)	2	2.0100	1.9911	2.4330	2.0186	2.0280		
		(0.0405)	(0.0399)	(0.0363)	(0.1185)	(0.1374)		
θ_1 (mileage)	−0.15	−0.1488	−0.1441	−0.1339	−0.1504	−0.1484	−0.1440	−0.1514
		(0.0074)	(0.0098)	(0.0102)	(0.0091)	(0.0111)	(0.0121)	(0.0136)
θ_2 (unobs. state)	1	0.9945	0.9726		1.0073	0.9953	0.9683	1.0067
		(0.0611)	(0.0668)		(0.0919)	(0.0985)	(0.0636)	(0.1417)
β (discount factor)	0.9	0.9102	0.9099	0.9115	0.9004	0.8979	0.9172	0.8870
		(0.0411)	(0.0554)	(0.0591)	(0.0473)	(0.0585)	(0.0639)	(0.0752)
Time (minutes)		130.29	0.078	0.033	275.01	6.59	0.079	11.31
		(19.73)	(0.0041)	(0.0020)	(15.23)	(2.52)	(0.0047)	(5.71)

[a]Mean and standard deviations for 50 simulations. For columns 1–6, the observed data consist of 1000 buses for 20 periods. For columns 7 and 8, the intercept (θ_0) is allowed to vary over time and the data consist of 2000 buses for 10 periods. See the text and the Supplemental Material for additional details.

进入—退出博弈

选择变量

- 假设任一时刻一个市场中企业的最大数目有限，记为 l。
- 若一家企业退出，下一期就会为一个潜在进入者空出一个位置，该进入者可以决定是否行使这一次性期权，或者不进入。
- 每期期初，每家在位企业都可以选择退出市场或再留一期。
- 令 $d_t^{(i)} \equiv \left(d_{t1}^{(i)}, d_{t2}^{(i)}\right)$，其中 $d_{t1}^{(i)} = 1$ 表示 i 在 t 期退出或不进入市场，$d_{t2}^{(i)} = 1$ 表示 i 进入或不退出。
- 若 $d_{t2}^{(i)} = 1$ 且 $d_{t-1,1}^{(i)} = 1$，则 t 期位置 i 上的企业是一个进入者；若 $d_{t-1,2}^{(i)} = 1$，则 t 期位置 i 上的企业是在位者。

进入—退出博弈

状态变量

- 在这一应用中，状态变量有三个组成部分，$x_t = (x_1, x_{2t}, s_t)$。

- 第一个是永久性的市场特征，记为 x_1，市场内所有企业共有。每个市场抽到 x_1 各可能取值的概率相等，其中

  $x_1 \in \{1, 2, \ldots, 10\}$.

- 第二个是 x_{2t}，表示每家企业是否为在位者，$x_{2t} \equiv \{d_{t-1,2}^{(1)}, \ldots, d_{t-1,2}^{(I)}\}$。进入者需要支付启动成本，因此空位更可能由留下的企业而非进入者填补。

- 需求冲击 $s_t \in \{1, \ldots, 5\}$ 服从一阶马尔可夫链。
- 具体而言，$s_{t+1} = s_t$ 的概率固定为 $\pi \in (0, 1)$，其他各状态出现的概率相等：

$$\Pr\{s_{t+1} | s_t\} = \begin{cases} \pi \text{ 若} s_{t+1} = s_t \\ (1-\pi)/4 \text{ 若 } s_{t+1} \neq s_t \end{cases}$$

进入—退出博弈

价格与收入

- 每家在营企业生产一单位产品，因此收入（记为 y_t）就是价格。

- 价格由以下因素决定：

  1. 市场中在营企业的供给 $\sum_{i=1}^{I} d_{t2}^{(i)}$
  2. 永久性的市场特征 x_1
  3. 马尔可夫需求冲击 s_t
  4. 另一个暂时性冲击 η_t，服从 iid 标准正态分布，在进入与退出决策作出之后向各市场揭示。

- 价格方程为：

$$y_t = \alpha_0 + \alpha_1 x_1 + \alpha_2 s_t + \alpha_3 \sum_{i=1}^{I} d_{t2}^{(i)} + \eta_t$$

进入—退出博弈

给定竞争状况时的期望利润

- 我们假设成本包括一个私人观测的、选择特定的扰动项 $\epsilon_{tj}^{(i)}$，加上 $\left(x_t^{(i)}, s_t^{(i)}, d_t^{(-i)}\right)$ 的线性函数。
- 退出的在位企业，以及不进入的潜在进入者，其当期净利润为 $\epsilon_{1t}^{(i)}$。因此 $U_1^{(i)}\left(x_t^{(i)}, s_t^{(i)}, d_t^{(-i)}\right) \equiv 0$。
- 在营的当期利润是 $\left(\epsilon_{2t}^{(i)} + \eta_t\right)$ 与下式之和：

$$U_2^{(i)}\left(x_t^{(i)}, s_t^{(i)}, d_t^{(-i)}\right) \equiv \theta_0 + \theta_1 x_1 + \theta_2 s_t + \theta_3 \sum_{\substack{i'=1 \\ i' \neq i}}^{I} d_{2t}^{(i')} + \theta_4 d_{1,t-1}^{(i)}$$

其中 θ_4 是只有进入者才需支付的启动成本。

- 在均衡中 $E(\eta_t) = 0$，因此：

$$u_j^{(i)}\left(x_t, s_t\right) = \theta_0 + \theta_1 x_1 + \theta_2 s_t + \theta_3 \sum_{\substack{i'=1 \\ i' \neq i}}^{I} p_2^{(i')}\left(x_t, s_t\right) + \theta_4 d_{1,t-1}^{(i)}$$

进入—退出博弈

终止性选择性质

- 我们假设企业的私人信息 $\epsilon_{jt}^{(i)}$ 服从 T1EV。
- 在第 5 讲中我们证明了：由于退出是收益标准化为零的终止性选择，在 T1EV 下，在营的条件价值函数为：

$$\begin{aligned} v_2^{(i)}(x_t, s_t) &= u_2^{(i)}(x_t, s_t) \\ &\quad -\beta \sum_{x \in X} \sum_{s \in S} \left(\ln \left[p_1^{(i)}(x, s) \right] \right) f_2^{(i)}(x, s | x_t, s_t) \end{aligned}$$

- 于是，未来价值项仅表示为提前一期的退出概率与状态变量转移概率的函数。

进入—退出博弈

蒙特卡洛模拟

- 每个市场的企业数设为六，我们模拟了 3,000 个市场的数据。
- 贴现因子设为 $\beta = 0.9$。
- 从一个有六个潜在进入者的初始日期出发，我们求解模型，向前模拟二十期，并用最后十期估计模型。
- 这一蒙特卡洛模拟与更新问题的蒙特卡洛模拟的关键区别在于：由于竞争对手的选择会影响企业利润，条件选择概率对当期效用和状态变量的转移都有额外影响。

进入—退出博弈

蒙特卡洛模拟结果（Arcidiacono and Miller，2011）

	DGP (1)	s_t Observed (2)	Ignore s_t (3)	CCP Model (4)	CCP Data (5)	Two-Stage (6)	No Prices (7)
Profit parameters							
θ_0 (intercept)	0	0.0207	−0.8627	0.0073	0.0126	−0.0251	−0.0086
		(0.0779)	(0.0511)	(0.0812)	(0.0997)	(0.1013)	(0.1083)
θ_1 (obs. state)	0.05	−0.0505	−0.0118	−0.0500	−0.0502	−0.0487	−0.0495
		(0.0028)	(0.0014)	(0.0029)	(0.0041)	(0.0039)	(0.0038)
θ_2 (unobs. state)	0.25	0.2529		0.2502	0.2503	0.2456	0.2477
		(0.0080)		(0.0123)	(0.0148)	(0.0148)	(0.0158)
θ_3 (no. of competitors)	−0.2	−0.2061	0.1081	−0.2019	−0.2029	−0.1926	−0.1971
		(0.0207)	(0.0115)	(0.0218)	(0.0278)	(0.0270)	(0.0294)
θ_4 (entry cost)	−1.5	−1.4992	−1.5715	−1.5014	−1.4992	−1.4995	−1.5007
		(0.0131)	(0.0133)	(0.0116)	(0.0133)	(0.0133)	(0.0139)
Price parameters							
α_0 (intercept)	7	6.9973	6.6571	6.9991	6.9952	6.9946	
		(0.0296)	(0.0281)	(0.0369)	(0.0333)	(0.0335)	
α_1 (obs. state)	−0.1	−0.0998	−0.0754	−0.0995	−0.0996	−0.0996	
		(0.0023)	(0.0025)	(0.0028)	(0.0028)	(0.0028)	
α_2 (unobs. state)	0.3	0.2996		0.2982	0.2993	0.2987	
		(0.0045)		(0.0119)	(0.0117)	(0.0116)	
α_3 (no. of competitors)	−0.4	−0.3995	−0.2211	−0.3994	−0.3989	−0.3984	
		(0.0061)	(0.0051)	(0.0087)	(0.0088)	(0.0089)	
π (persistence of unobs. state)	0.7			0.7002	0.7030	0.7032	0.7007
				(0.0122)	(0.0146)	(0.0146)	(0.0184)
Time (minutes)		0.1354	0.1078	21.54	27.30	15.37	16.92
		(0.0047)	(0.0010)	(1.5278)	(1.9160)	(0.8003)	(1.6467)

Mean and standard deviations for 100 simulations. Observed data consist of 3000 markets for 10 periods with 6 firms in each market. In column 7, the CCP's are updated with the model.