含固定效应的
结构动态离散选择模型

第 6 讲
计量经济学会暑期学校
动态结构计量经济学

Victor Aguirregabiria（多伦多大学）

UCL，2025 年 7 月 1 日

引言

- 将**真实动态**（过去决策的因果效应）与持续性不可观测异质性（UH）带来的**虚假动态**区分开来，是动态模型计量经济学中的一个基本挑战。

- 短面板带来的挑战（Heckman，1981）：
  - **附带参数问题（IPP）**：把 UH 当作固定参数，会导致感兴趣参数的估计不一致。
  - **初始条件问题（ICP）**：UH 与初始条件的分布不存在非参数识别。

- 应对 ICP 导致的非参数不可识别，有两种不同的方法：
  - **随机效应（RE）**。
  - **固定效应（FE）**。

随机效应（RE）与固定效应（FE）

- **随机效应（RE）：对 UH 积分。**
  - 对 UH 与初始条件的联合分布施加参数化及有限支撑的约束，以此处理 ICP。
  - **优点**：结构参数与 UH 的分布都可以完全识别。
  - **缺点**：对 UH 的参数化约束一旦设定错误，可能给“真实动态”的估计带来严重偏误。
- **固定效应（FE）：差分掉 UH。**
  - 关注刻画“真实动态”的结构参数的识别，而不关注 UH 分布的识别。
  - **优点**：UH 采用非参数设定，真实动态的识别是稳健的。
  - **缺点**：UH 的分布不能完全识别，这限制了我们能识别的反事实。**（容易处理）**
  - **缺点**：并非所有动态模型都有一致的 FE 估计量。

结构 DDC 模型中的固定效应

- 直到最近，结构 DDC 模型的所有应用都使用 RE 模型来处理 UH。

- 之所以没有使用 FE 方法的应用，部分是因为两种普遍的看法。

1. 认为在个体具有前瞻性的结构模型中，不存在一致的 FE 估计量：**问题出在延续价值上**。

2. 认为即使结构参数可识别，也无法识别**平均边际效应（AME）**和其他反事实，因为它们取决于 UH 的分布。

- 最近的进展对这些看法提出了挑战。

FE 方法的副产品：计算上的收益

- 我们将看到，其中一种 FE 方法（条件 MLE）需要**差分掉条件选择价值函数中的延续价值**部分。
- 这意味着这种估计方法（条件 MLE）不需要求解任何动态规划问题，不需要计算现值，甚至不需要计算向前一期的期望。
- 实现条件 MLE 的计算成本不取决于状态空间的维数。

本讲内容

- 本讲介绍结构 DDC-FE 模型的最新结果。

1. Aguirregabiria, Gu, & Luo（Journal of Econometrics，2021）
   - 以滞后决策和持续时间为状态变量的结构 DDC-FE 模型的识别与估计。

2. Aguirregabiria（Econometrics Journal，2023）
   - 应用于差异化产品的动态需求

3. Aguirregabiria & Carro（Review of Economics & Statistics，2025）
   - 平均边际效应的识别。

4. Aguirregabiria, Gu, & Mira（工作论文，2025）
   - 推广到动态离散选择博弈。

提纲

1. 模型
2. 结构参数的识别。
   a. 条件似然——充分统计量方法。
   b. 函数差分。
3. 估计
   a. 条件 MLE
   b. GMM
4. 实证应用——差异化产品的动态需求。

1. 模型

模型：决策变量与状态变量

- **决策变量**：$y_{it} \in \mathcal{Y} = \{0, 1, \ldots, J\}$。
- 个体最大化 $\mathbb{E}_t \left[\sum_{s=0}^{\infty} \delta_i^s U_{i,t+s}\right]$。$U_{it}$ 为效用函数。
- U_{it} 取决于当前选择 y_{it}，以及：
- 对研究者而言的**两类不可观测变量** $(\alpha_i, \varepsilon_{it})$；
- **两类可观测状态变量**：

$$s_{it} = (z_{it}, x_{it})$$

z_{it} = 严格外生的状态变量。
x_{it} = 内生的状态变量。

模型：效用函数

- 选择备选项 j 的当期收益：

$$U_{it}(j) \quad = \quad \alpha_i(j) + \varepsilon_{it}(j) + \beta\left(j, \boldsymbol{s}_{it}\right)$$

- 收益函数 $\beta(j, \boldsymbol{s}_{it})$ 不受限制。
- **不可观测变量：**
  - 两类不可观测变量都是可加可分的。
  - $\varepsilon_{it}(j)$ 独立同分布，服从第一类极值分布；
  - **FE 模型：** $p(\alpha_i(0), \ldots, \alpha_i(J) \mid \boldsymbol{x}_{i1}, \boldsymbol{z}_{i1}, \ldots, \boldsymbol{z}_{iT})$ 不受限制。

最优决策与 CCP（以 α_i 为条件）

- 最优决策为：

$$y_{it} = \arg\max_{j \in \mathcal{Y}} \left\{ \alpha_i(j) + \varepsilon_{it}(j) + \beta(j, \mathbf{s}_{it}) + cv(j, \mathbf{s}_{it}, \boldsymbol{\alpha}_i) \right\}$$

- 其中 $cv(j, \mathbf{s}_{it}, \boldsymbol{\alpha}_i)$ 是**延续价值函数**：

$$cv(j, \mathbf{s}_{it}, \boldsymbol{\alpha}_i) \equiv \delta_i \int V(\mathbf{s}_{i,t+1}, \boldsymbol{\alpha}_i) \; f(\mathbf{s}_{i,t+1} \mid j, \mathbf{s}_{it}) \; d\mathbf{s}_{i,t+1}$$

- 不可观测变量 ε 服从第一类极值分布，这意味着如下**条件选择概率（CCP）**函数：

$$P(j|\mathbf{s}_{it}, \boldsymbol{\alpha}_i) = \frac{\exp\left\{\alpha_i(j) + \beta(j, \mathbf{s}_{it}) + cv(j, \mathbf{s}_{it}, \boldsymbol{\alpha}_i)\right\}}{\sum_{k \in \mathcal{Y}} \exp\left\{\alpha_i(k) + \beta(k, \mathbf{s}_{it}) + cv(k, \mathbf{s}_{it}, \boldsymbol{\alpha}_i)\right\}}$$

2. 结构参数的识别

模型的一个受限版本

- 为简单起见，本讲着重讨论施加了两个额外约束的模型版本的识别结果。

- R1：没有外生状态变量 z_{it}。

- R2：内生状态变量遵循确定性的转移规则：

$$x_{i,t+1} = f\left(y_{it}, x_{it}\right)$$

- 这些约束有两个重要含义。

1. 初始条件加选择路径 $\tilde{y}_i = \{x_{i1}, y_{i1}, y_{i2}, \ldots, y_{iT}\}$ 包含了选择与状态路径的全部信息。

2. 对于两对选择与状态 (j, x) 与 (j', x')，若 $f(j, x) = f(j', x')$，则它们的延续价值也相同。

FE——充分统计量方法

- 令 $\widetilde{\boldsymbol{y}} = \{\boldsymbol{x}_1, y_1, y_2, \ldots, y_T\}$ 为个体的观测历史

$$\mathbb{P}\left(\widetilde{\boldsymbol{y}}|\boldsymbol{\alpha}\right) = \prod_{t=1}^{T} \frac{\exp\left\{\alpha\left(y_t\right) + \beta\left(y_t, \boldsymbol{x}_t\right) + cv\left(f\left(y_t, \boldsymbol{x}_t\right), \boldsymbol{\alpha}\right)\right\}}{\sum_{j \in \mathcal{Y}} \exp\left\{\ \alpha\left(j\right) + \beta\left(j, \boldsymbol{x}_t\right) + cv\left(f\left(j, \boldsymbol{x}_t\right), \boldsymbol{\alpha}\right)\ \right\}} p(\boldsymbol{x}_1|\boldsymbol{\alpha})$$

- 选择历史的对数概率具有如下形式：

$$\ln \mathbb{P}\left(\widetilde{\boldsymbol{y}}|\boldsymbol{\alpha}\right) = S(\widetilde{\boldsymbol{y}})'\ g(\boldsymbol{\alpha}, \boldsymbol{\beta}) + C(\widetilde{\boldsymbol{y}})'\ \boldsymbol{\beta}$$

  其中 $S(\widetilde{\boldsymbol{y}})$ 与 $C(\widetilde{\boldsymbol{y}})$ 是统计量向量。

- 例如：
  - $\sum_{t=1}^{T} 1\{y_t = j\}$ 属于 $S(\widetilde{\boldsymbol{y}})$。
  - $\sum_{t=2}^{T} 1\{y_{t-1} = k \text{ 且} y_t = j\}$ 属于 $C(\widetilde{\boldsymbol{y}})$。

FE——充分统计量方法（2）

- 这一结构有几个重要含义。

$$\ln \mathbb{P}\left(\widetilde{\boldsymbol{y}}|\boldsymbol{\alpha}\right) = S(\widetilde{\boldsymbol{y}})' \, g(\boldsymbol{\alpha}, \boldsymbol{\beta}) + C(\widetilde{\boldsymbol{y}})' \, \boldsymbol{\beta}$$

1. $S(\widetilde{\boldsymbol{y}})$ 是 α 的充分统计量。

$$\mathbb{P}\left(\widetilde{\boldsymbol{y}} \mid \boldsymbol{\alpha}, S(\widetilde{\boldsymbol{y}})\right) = \mathbb{P}\left(\widetilde{\boldsymbol{y}} \mid S(\widetilde{\boldsymbol{y}})\right)$$

2. 若以 $S(\widetilde{\boldsymbol{y}})$ 为条件，由所有 $\widetilde{\boldsymbol{y}}$ 构成的矩阵 $C(\widetilde{\boldsymbol{y}})'$ 列满秩，则 β 可识别。

对识别更直观的描述

- 假设有两个选择历史，比如 A 和 B。对向量 β 中的每个参数，比如 β_k，都存在两个选择历史，比如 $\widetilde{\boldsymbol{y}} = A$ 与 $\widetilde{\boldsymbol{y}} = B$，使得：
  - $S(A) = S(B)$
  - $C(A) - C(B)$ 是一个向量，除了与 β_k 对应的元素 $C_k \neq 0$ 之外，其余元素都为零。

- 在这些条件下，我们有：

$$\beta_k = \frac{\log \mathbb{P}(A) - \log \mathbb{P}(B)}{C_k}$$

- 参数 β_k 由历史 A 与 B 的对数优势比识别。

延续价值带来的挑战

- 问题在于，这样的历史 A 和 B 是否存在；或者相反，$S(A) = S(B)$ 意味着 $C(\tilde{\boldsymbol{y}})$ 中已没有剩余的变异。
- 延续价值 $cv(f(y_t, \boldsymbol{x}_t), \boldsymbol{\alpha}_i)$ 以非线性（且未知）的形式依赖于 $\boldsymbol{\alpha}_i$。
- 为了差分掉/控制 $\boldsymbol{\alpha}_i$，我们需要差分掉整个延续价值。
- 但延续价值也取决于状态变量。因此，差分掉延续价值似乎意味着要控制状态变量的全部变异：**已没有剩余的变异可用来识别结构参数 β。**
- **真是这样吗？**

差分掉延续价值

- 事实证明，有一大类重要的动态模型，可以在差分掉延续价值的同时，保留状态变量的变异来识别结构参数

- 回顾：

$$v(j, \boldsymbol{x}_t, \boldsymbol{\alpha}) = \alpha(j) + \beta(j, \boldsymbol{x}_t) + cv(f(j, \boldsymbol{x}_t), \boldsymbol{\alpha})$$

- 假设转移规则 $f(\cdot)$ 使得存在两个选择—状态组合 $(y_t, \boldsymbol{x}_t)$，它们的 $\boldsymbol{x}_{t+1}$ 相同：

$$f(j, \boldsymbol{x}) = f(j', \boldsymbol{x}')$$

- 那么显然有：

$$v(j, \boldsymbol{x}, \boldsymbol{\alpha}) - v(j', \boldsymbol{x}', \boldsymbol{\alpha}) = \beta(j, \boldsymbol{x}) - \beta(j', \boldsymbol{x}')$$

- 在这个条件下，可以用 FE——充分统计量方法识别结构参数 β。

例 1：多臂老虎机模型

- 在这类模型中 $x_t = y_{t-1}$，因此：

$$x_{t+1} = f(y_t, x_t) = f(y_t, y_{t-1}) = y_t$$

- 所以 $cv(f(j, y_{t-1}), \alpha)$ 不依赖于 y_{t-1}。

$$v(j, y_{t-1}, \alpha) = \alpha(j) + \beta(j, y_{t-1}) + cv(j, \alpha)$$

- 延续价值 $cv(j, \alpha)$ 与当期效用中的 $\alpha(j)$ 项类似：它们不与状态变量 y_{t-1} 交互。

- 若 $T \geq 4$，转换成本参数 $\beta(y_t, y_{t-1})$ 可识别。

- 例如，给定选择历史 $A = (j, k, j, k)$ 与 $B = (j, j, k, k)$，我们有：

$$\beta(j, k) = \log \mathbb{P}(A) - \log \mathbb{P}(B)$$

例 2：最优更换模型

- 在这类模型中，$y_t \in \{0, 1, 2, \ldots\}$ 是投资决策，x_t 是资本存量变量，存在外生折旧：

$$x_{t+1} = f(y_t, x_t) = x_t + y_t - 1$$

- 对任意两个状态值，比如 x 与 x'，我们有：

$$[v(1, x, \boldsymbol{\alpha}) - v(0, x+1, \boldsymbol{\alpha})] - [v(1, x', \boldsymbol{\alpha}) - v(0, x'+1, \boldsymbol{\alpha})]$$

$$= [\beta(1, x) - \beta(0, x+1)] - [\beta(1, x') - \beta(0, x'+1)]$$

- 考虑到这一结构，可以构造识别 β 中参数的选择历史对 A 和 B

函数差分方法

- Bonhomme（Econometrica，2012）表明，条件似然—充分统计量方法是一种更一般的差分掉 FE 方法的特例：**函数差分**。

- 对某些面板数据模型，函数差分可以给出用 CML 无法得到的识别矩约束。

  1. 简约形式动态面板数据模型：Honoré & Weidner（REStud，2024），Dobronyi & Gu（2021），Pakel & Weidner（2023）。

  2. Aguirregabiria & Carro（REStat，2025）：动态面板数据离散选择中的平均边际效应。

  3. Aguirregabiria, Gu, & Mira（2025）：动态离散博弈。

两个重要性质（用于我们的函数差分）

性质 1

$\mathbb{P}(\boldsymbol{y}_i \mid \alpha_i, \beta)$ 是 T 阶多项式之比，变量为 $e^{\alpha_i(j)}$、$e^{cv_i(j,x)}$，$j = 1, 2, \ldots, J$。

性质 2

（积分）Bellman 方程可以表示为关于变量 $e^{\alpha_i(j)}$、$e^{cv_i(j,x)}$ 的多项式之比，其中 $j = 1, 2, ..., J$.

函数差分方法

命题 1

a. 该 FE 模型中结构参数 β 可识别的一个必要条件，是存在一个**权重函数** $\lambda(\boldsymbol{y}_i, \beta)$，使得：

$$\sum_{\boldsymbol{y}_i \in \{0,1,\ldots,J\}^T} \lambda\left(\boldsymbol{y}_i, \boldsymbol{\beta}\right) \mathbb{P}\left(\boldsymbol{y}_i \mid \boldsymbol{\alpha}_i, \boldsymbol{\beta}\right) = 0$$

对任意取值 $\alpha_i \in R^J$ 成立

b. 在这一条件下，β 满足方程：

$$\sum_{\boldsymbol{y}_i \in \{0,1,\ldots,J\}^T} \lambda\left(\boldsymbol{y}_i, \boldsymbol{\beta}\right) \mathbb{P}\left(\boldsymbol{y}_i\right) = 0$$

函数差分 (2/4)

- 命题 1 中的必要条件意味着一个方程组：它有无穷多个约束（即 α_i 的所有可能取值），而未知数只有有限的 2^{JT} 个（即权重 λ）。

- 若没有特定的结构，这个方程组无解：
  权重不存在，也就无法识别。

- **命题 2** 表明，模型具有一种特定的结构，
  使这个无穷方程组等价于一个可能有解的有限方程组。

函数差分 (3/4)

命题 2

a. 将性质 1 应用于命题 1 中的方程，得到关于变量 $e^{\alpha_i(j)}$、$e^{cv_i(j,x)}$ 的 T 阶多项式，其中
$j = 1, 2, ..., J.$

b. 由于这些变量为正，该方程对每个可能的 α_i 都有解，
当且仅当所有单项式的系数都为零。

c. 向量 $\boldsymbol{\lambda}_i \equiv \{\lambda_i(\boldsymbol{y}_i) : \forall \boldsymbol{y}_i\}$ 的解，是
下列由 JT 个线性方程、2^{JT} 个
未知数组成的方程组的解：

$$\boldsymbol{C}(\boldsymbol{\beta})\ \boldsymbol{\lambda}_i\ =\ 0$$

其中矩阵 $\boldsymbol{C}(\boldsymbol{\beta})$ 已知，并有闭式表达。

d. 若 $\text{Null}(\boldsymbol{C}(\boldsymbol{\beta}))$ 的维数 > 0，则存在求解该方程组的 λ。

函数差分——充分条件

- 命题 1 和 2 给出了获得权重 λ 的简单方法，利用这些权重构成的矩条件可以识别结构参数：

$$\sum_{\boldsymbol{y}_i \in \{0,1,\ldots,J\}^T} \lambda\left(\boldsymbol{y}_i, \boldsymbol{\beta}\right) \mathbb{P}\left(\boldsymbol{y}_i\right) = 0$$

- 充分条件要求该方程组满足一个秩**条件**。

- 注意，这个方程组可以解释为**矩条件**，
  可以用 GMM 来估计参数。

3. 结构参数的估计

条件极大似然估计量

- 回顾：选择历史 $\widetilde{\boldsymbol{y}}_i$ 的概率具有如下结构：

$$\ln \mathbb{P}\left(\widetilde{\boldsymbol{y}}_i|\boldsymbol{\alpha}_i\right) = S(\widetilde{\boldsymbol{y}}_i)'\, g(\boldsymbol{\alpha}_i) + C(\widetilde{\boldsymbol{y}}_i)'\, \boldsymbol{\beta}$$

且 $S(\widetilde{\boldsymbol{y}}_i)$ 是 α_i 的充分统计量。

- 我们通过最大化条件似然函数来估计 β：

$$\ell^C\left(\boldsymbol{\beta}\right) = \sum_{i=1}^{N} \log \mathbb{P}\left(\widetilde{\boldsymbol{y}}_i \mid S(\widetilde{\boldsymbol{y}}_i), \boldsymbol{\beta}\right)$$

其形式如下：

$$\ell^C\left(\boldsymbol{\beta}\right) = \sum_{i=1}^{N} C(\widetilde{\boldsymbol{y}}_i)'\boldsymbol{\beta} - \sum_{i=1}^{N} \ln \left[\sum_{\widetilde{\boldsymbol{y}}\ S(\widetilde{\boldsymbol{y}})=S(\widetilde{\boldsymbol{y}}_i)} \exp\left\{ C(\widetilde{\boldsymbol{y}})'\boldsymbol{\beta} \right\} \right]$$

条件极大似然估计量（2）

$$\ell^C(\boldsymbol{\beta}) = \sum_{i=1}^{N} C(\widetilde{\boldsymbol{y}}_i)'\boldsymbol{\beta} - \sum_{i=1}^{N} \ln \left[\sum_{\widetilde{\boldsymbol{y}}\ S(\widetilde{\boldsymbol{y}})=S(\widetilde{\boldsymbol{y}}_i)} \exp\left\{ C(\widetilde{\boldsymbol{y}})'\boldsymbol{\beta} \right\} \right]$$

- 这个条件似然函数有几个重要性质：

1. 它不依赖于附带参数 $\boldsymbol{\alpha}$。
2. 它是 $\boldsymbol{\beta}$ 的全局凹函数。
3. 延续价值只出现在 $g(\boldsymbol{\alpha}_i)$ 中。以 **S** 为条件，就意味着去除了延续价值。
4. 因此，条件 MLE 的计算成本不取决于状态空间的维数。

4. 实证应用

差异化产品的动态需求

洗衣液

数据

- 来自芝加哥 Kilts 中心的 NIELSEN 扫描数据。
- 时间为 2006—2019 年。目前的估计只使用 2017—2018 年。
- 超过 4 万个分布在美国各地的参与家庭。
- 丰富的人口学信息 $(\boldsymbol{w}_i)$：邮政编码、收入、年龄、教育、职业、种族、家庭规模、家庭构成、住所类型，
- 每一次购物的数据。
- 产品：洗衣液

需求参数的估计

固定效应给出了足够精确的估计（$N = 19{,}776$）。

结构参数估计值				
	FE Kernel W. CML		**RE (2 types) + $\mathbf{w}_j'\alpha(j)$**	
Parameter	*Estimate*	*(s.e.)*	*Estimate*	*(s.e.)*
γ 价格	1.7392	**(0.3018)**	1.155	**(0.1221)**
β^{sc}（习惯）品牌 1	0.3804	**(0.0290)**	0.7551	**(0.0101)**
β^{sc}（习惯）品牌 2	0.2556	**(0.0573)**	0.6695	**(0.0110)**
β^{sc}（习惯）品牌 3	0.2388	**(0.0591)**	0.7360	**(0.0162)**
β^{dep}（线性）品牌 1	0.0597	**(0.0112)**	−0.0089	**(0.0040)**
β^{dep}（线性）品牌 2	0.0611	**(0.0118)**	−0.0161	**(0.0046)**
β^{dep}（线性）品牌 3	0.0692	**(0.0172)**	−0.0208	**(0.0072)**
Hausman 检验（p 值）	0.0000			

需求参数的估计

Hausman 检验明确拒绝了随机效应模型。

结构参数估计值

	FE Kernel W. CML		**RE (2 types) + $\mathbf{w}_i'\alpha(j)$**	
Parameter	*Estimate*	*(s.e.)*	*Estimate*	*(s.e.)*
γ 价格	1.7392	(0.3018)	1.155	(0.1221)
β^{sc}（习惯）品牌 1	0.3804	(0.0290)	0.7551	(0.0101)
β^{sc}（习惯）品牌 2	0.2556	(0.0573)	0.6695	(0.0110)
β^{sc}（习惯）品牌 3	0.2388	(0.0591)	0.7360	(0.0162)
β^{dep}（线性）品牌 1	0.0597	(0.0112)	−0.0089	(0.0040)
β^{dep}（线性）品牌 2	0.0611	(0.0118)	−0.0161	(0.0046)
β^{dep}（线性）品牌 3	0.0692	(0.0172)	−0.0208	(0.0072)
Hausman 检验（p 值）	**0.0000**			

结构参数的估计

随机效应模型高估了习惯参数。

结构参数估计值

	FE Kernel W. CML		RE (2 types) + $\mathbf{w}_i'\alpha(j)$	
Parameter	*Estimate*	*(s.e.)*	*Estimate*	*(s.e.)*
γ 价格	1.7392	(0.3018)	1.155	(0.1221)
β^{sc}（习惯）品牌 1	**0.3804**	(0.0290)	**0.7551**	(0.0101)
β^{sc}（习惯）品牌 2	**0.2556**	(0.0573)	**0.6695**	(0.0110)
β^{sc}（习惯）品牌 3	**0.2388**	(0.0591)	**0.7360**	(0.0162)
β^{dep}（线性）品牌 1	0.0597	(0.0112)	−0.0089	(0.0040)
β^{dep}（线性）品牌 2	0.0611	(0.0118)	−0.0161	(0.0046)
β^{dep}（线性）品牌 3	0.0692	(0.0172)	−0.0208	(0.0072)
Hausman 检验（p 值）	0.0000			

结构参数的估计

随机效应模型给出的持续期依赖符号是错的。

结构参数估计值				
	FE Kernel W. CML		**RE (2 types) + $\mathbf{w}_i'\alpha(j)$**	
Parameter	*Estimate*	*(s.e.)*	*Estimate*	*(s.e.)*
γ 价格	1.7392	(0.3018)	1.155	(0.1221)
β^{sc}（习惯）品牌 1	0.3804	(0.0290)	0.7551	(0.0101)
β^{sc}（习惯）品牌 2	0.2556	(0.0573)	0.6695	(0.0110)
β^{sc}（习惯）品牌 3	0.2388	(0.0591)	0.7360	(0.0162)
β^{dep}（线性）品牌 1	**0.0597**	(0.0112)	**-0.0089**	(0.0040)
β^{dep}（线性）品牌 2	**0.0611**	(0.0118)	**-0.0161**	(0.0046)
β^{dep}（线性）品牌 3	**0.0692**	(0.0172)	**-0.0208**	(0.0072)
Hausman 检验（p 值）	0.0000			

需求参数的估计

随机效应模型低估了需求的价格敏感度。

结构参数估计值

	FE Kernel W. CML		RE (2 types) + $\mathbf{w}_j'\alpha(j)$	
Parameter	*Estimate*	*(s.e.)*	*Estimate*	*(s.e.)*
γ 价格	**1.7392**	(0.3018)	**1.155**	(0.1221)
β^{sc}（习惯）品牌 1	0.3804	(0.0290)	0.7551	(0.0101)
β^{sc}（习惯）品牌 2	0.2556	(0.0573)	0.6695	(0.0110)
β^{sc}（习惯）品牌 3	0.2388	(0.0591)	0.7360	(0.0162)
β^{dep}（线性）品牌 1	0.0597	(0.0112)	−0.0089	(0.0040)
β^{dep}（线性）品牌 2	0.0611	(0.0118)	−0.0161	(0.0046)
β^{dep}（线性）品牌 3	0.0692	(0.0172)	−0.0208	(0.0072)
Hausman 检验（p 值）	0.0000			

扩展

- 本文提出了一个差异化产品需求的固定效应动态面板数据模型，其中消费者具有前瞻性。

- 一些相关的扩展：

1. 依据 Aguirregabiria & Carro（2023）关于平均边际效应识别的结果，识别总体价格弹性。

2. Aguirregabiria, Gu, and Mira 中 FE 动态博弈的识别 (2022).

3. 在内生状态变量中引入随机转移。

4. 反事实