动态离散选择博弈的序贯估计

第 7 讲
计量经济学会暑期学校
动态结构计量经济学

Victor Aguirregabiria（多伦多大学）

UCL，2025 年 7 月 1 日

提纲

1. 实证动态博弈的结构

2. 马尔可夫完美均衡

3. 不完全信息动态博弈

4. 序贯估计

   4.1. NPL 估计量

   4.2. 计算 NPL 估计量的其他算法

      a. 不动点迭代。

      b. 牛顿法。

      c. 谱方法。

1. 动态博弈的结构

基本结构

- 时间是离散的，用 t 标记。
- 博弈由 N 家企业参与，用 i 标记。
- 企业选择行动，以最大化市场中利润流的期望贴现值，

$$E_t\left(\sum_{s=0}^{\infty}\delta_i^s\ \pi_{it+s}\right)$$

$\delta_i \in (0,1)$ 是贴现因子，π_{it} 是企业 i 在 t 期的利润。

- 每期 t，企业作出一项投资/动态决策：a_{it}。
- 这里我关注离散选择博弈：$a_{it} \in \mathcal{A} = \{0, 1, \ldots, J\}$

决策、状态与利润

- 当期利润 π_{it} 取决于企业自身的行动 a_{it}、其他企业的行动 $a_{-it} = \{a_{jt} : j \neq i\}$，以及状态变量向量 $\mathbf{x}_t$。

$$\pi_{it} = \pi_i \left(a_{it}, \boldsymbol{a}_{-it}, \boldsymbol{x}_t \right)$$

- $\mathbf{x}_t$ 包括：

  a. 取决于企业以往各期投资决策的内生状态变量，例如资本存量。

  b. 影响成本与消费者需求的外生状态变量。

例：产品质量上的动态竞争

- 每家企业生产一种**差异化产品**。消费者需求取决于产品质量 (k_{it}) 与价格 (p_{it})。
- 状态 $\mathbf{x}_t$ 包括：
  a. 内生的产品质量：$\mathbf{k}_t = (k_{1t}, k_{2t}, \ldots, k_{Nt})$。
  b. 影响需求或成本的外生变量：$\mathbf{z}_t = (z_{1t}, z_{2t}, \ldots, z_{Nt})$。
- 给定 $\mathbf{x}_t$，企业进行 Bertrand 价格竞争，由此决定每家企业的**Bertrand 均衡**可变利润：$r_i(\mathbf{x}_t)$。
- 总利润 π_{it} 等于 $r_i(\mathbf{x}_t)$ 减去提高质量的投资成本 $IC_i(a_{it}, k_{it})$：

$$\pi_{it} = r_i(\boldsymbol{x}_t) - IC_i(a_{it}, k_{it})$$

- 质量存量按照如下转移规则内生演化：

$$k_{i,t+1} = k_{it} + a_{it}$$

状态变量的演化

- **外生的共同知识状态变量**：服从外生的马尔可夫过程，转移概率函数为

  $f_z(z_{t+1}|z_t)$.

- **内生状态变量**：转移规则的形式取决于具体应用：
  - 市场进入：$k_{it} = a_{it-1}$，从而 $k_{i,t+1} = a_{it}$
  - 无折旧的投资：$k_{i,t+1} = k_{it} + a_{it}$。
  - 确定性折旧的投资：$k_{i,t+1} = \lambda(k_{it} + a_{it})$
  - 随机折旧的投资：$k_{i,t+1} = k_{it} + a_{it} - \xi_{i,t+1}$
- 简洁起见，用 $f_x(\mathbf{x}_{t+1}|\mathbf{a}_t, \mathbf{x}_t)$ 表示所有状态变量的转移概率函数。

2. 马尔可夫完美均衡

动态博弈中的最优决策规则

- 假设企业 i 相信，市场中的其他企业现在和将来
  – 都按照如下策略函数行事：

$$\text{对任意 } j \neq i, \quad \alpha_j(\mathcal{I}_t)$$

其中 $\mathcal{I}_t$ 是对企业在 t 期所使用信息的某种设定。更具体地说：

$$\mathcal{I}_t = \left(\mathbf{x}_t,\ \boldsymbol{a}_{t-1},\ \mathbf{x}_{t-1}, ...,\ \boldsymbol{a}_{t-p},\ \mathbf{x}_{t-p}\right)$$

- 给定这些信念 α_{-i}，企业 i 的收益为：

$$\pi_i^{\boldsymbol{\alpha}}(a_{it}, \mathbf{x}_t) \quad = \quad \pi_i\left(a_{it},\ \boldsymbol{\alpha}_{-i}(\mathbf{x}_t),\ \mathbf{x}_t\right)$$

- 状态变量的转移概率为：

$$\boldsymbol{\alpha}_{-i}(\mathcal{I}_t)\ \&\ f_x(\mathbf{x}_{t+1}|a_{it}, \boldsymbol{\alpha}_{-i}(\mathcal{I}_t), \mathbf{x}_t) \quad \Rightarrow \quad f^{\boldsymbol{\alpha}}_{\mathcal{I},i}(\mathcal{I}_{t+1}|a_{it}, \mathcal{I}_t)$$

最优反应与纳什均衡

- 给定 $\pi_i^{\alpha}(a_{it}, \mathbf{x}_t)$ 与 $f_{\mathcal{I},i}^{\alpha}(\mathcal{I}_{t+1}|a_{it}, \mathcal{I}_t)$，可以把企业 i 的最优反应定义为由如下 Bellman 方程所定义的单个决策者 DP 问题的解：

$$V_i^{\boldsymbol{\alpha}}(\mathcal{I}_t) = \max_{a_{it}} \left\{ \pi_i^{\boldsymbol{\alpha}}(a_{it}, \mathbf{x}_t) + \delta_i \int V_i^{\boldsymbol{\alpha}}(\mathcal{I}_{t+1}) \, f_{\mathcal{I},i}^{\boldsymbol{\alpha}}(\mathcal{I}_{t+1}|a_{it}, \mathcal{I}_t) \right\}$$

- 令 $BR_i(\alpha_{-i})$ 为求解该 DP 问题的最优策略函数。它是对信念 α_{-i} 的最优反应。

- 该动态博弈的**纳什均衡**由 N 个策略函数 $\{\alpha_i(\mathcal{I}_t) : i = 1, 2, \ldots, N\}$ 组成，使得对每家企业 i：

$$\alpha_i = BR_i(\boldsymbol{\alpha}_{-i})$$

也就是说：

1. 每家企业都按照自己的最优反应策略行事。
2. 信念是理性的，即与均衡中企业的实际策略一致。

马尔可夫完美均衡

- 上述纳什均衡的定义取决于信息集 $\mathcal{I}_t$ 的选择。$\mathcal{I}_t$ 有多少种可能的选择，就有多少种纳什均衡。

- 大多数动态产业组织模型假设马尔可夫完美均衡（MPE）(Maskin & Tirole, ECMA 1988; Ericson & Pakes, REStud 1995)。

- 这一解概念对应于这样的纳什均衡：**参与人的策略只是与收益相关的状态变量的函数**，$\mathcal{I}_t = \mathbf{x}_t$。

- **为什么作此限制？**
  - **理性（Maskin & Tirole）**：若其他参与人使用这类策略，则一个参与人以与收益无关的信息（例如状态变量的滞后值）为条件来调整行为，并不能获得更高的收益

  - **维数**：它降低了状态空间的维数，使用起来很方便。

马尔可夫完美均衡——定义

- 令 $\alpha = \{\alpha_i(\mathbf{x}_t) : i = 1, 2, \ldots, N\}$ 为一组策略函数。
- MPE 是由 N 个策略函数构成的 α，使得在给定其他参与人策略的情况下，每家企业都在最大化自身价值。
- 给定其他企业的策略，一家企业的决策问题是单个决策者的动态规划（DP）问题。

马尔可夫完美均衡：最优反应 DP

- 令 $V_i^{\alpha}(\mathbf{x}_t)$ 为 DP 问题的价值函数，该问题描述企业 i 对 α 中其他企业策略的最优反应。

- 这个价值函数是如下 Bellman 方程的唯一解：

$$V_i^{\boldsymbol{\alpha}}(\mathbf{x}_t) = \max_{a_{it}} \left\{ \pi_i^{\boldsymbol{\alpha}}(a_{it}, \mathbf{x}_t) + \delta_i \int V_i^{\boldsymbol{\alpha}}(\mathbf{x}_{t+1}) \; f_{x,i}^{\boldsymbol{\alpha}}(\mathbf{x}_{t+1} | a_{it}, \mathbf{x}_t) \; d\mathbf{x}_{t+1} \right\}$$

- 其中（这里假设不存在建设时滞）：

$$\pi_i^{\boldsymbol{\alpha}}(a_{it}, \mathbf{x}_t) \quad = \quad \pi_i\left(a_{it}, \; \boldsymbol{\alpha}_{-i}(\mathbf{x}_t), \; \mathbf{x}_t\right)$$

- 以及：

$$f_{x,i}^{\boldsymbol{\alpha}}(\mathbf{x}_{t+1} | a_{it}, \mathbf{x}_t) \quad = \quad f_x(\mathbf{x}_{t+1} \mid a_{it}, \; \boldsymbol{\alpha}_{-i}(\mathbf{x}_t), \; \mathbf{x}_t)$$

MPE——存在性

- Doraszelski & Satterthwaite（RAND，2010）表明，在该模型中**当 a_{it} 的选择集为离散时**，纯策略 MPE 的**存在性无法保证**。

- 保证存在性的一种可能方法是允许混合策略。然而，计算混合策略 MPE 会带来很大的计算挑战。

- 为确立存在性，Doraszelski & Satterthwaite（RAND，2010）提出**引入私人信息状态变量**。

- Ericson-Pakes 模型的这种不完全信息版本，已被大多数**实证应用所采用**。
  - 主要原因在于——正如下文所示——从计量经济学的角度看，独立同分布的私人信息冲击是一种**非常便利的不可观测变量**。

3. 不完全信息动态博弈

私人信息冲击

- $\mathbf{x}_t$ 中的状态变量在 t 期为市场中所有企业所知（共同知识）。

- 此外，企业的投资成本函数 $IC_i(.)$ 取决于一个具有两条性质的状态变量向量 ε_{it}：

  1. ε_{it} 是**企业 i 的私人信息**，其他企业不知道。

  2. ε_{it} **在时间上独立同分布，在企业间相互独立**，其 CDF G_i 在 $R^{|A|}$ 上具有全支撑。

- 策略函数现在是 $\alpha_i(\mathbf{x}_t, \varepsilon_{it})$。

- MPE 的定义与前面相同，只是策略变为 $\alpha_i(\mathbf{x}_t, \varepsilon_{it})$。

条件选择概率

- 用**条件选择概率（CCP）函数**来表示企业的策略非常方便。对任意 $(a, \mathbf{x})$：

$$P_i(a|\mathbf{x}) \equiv \Pr\left(\alpha_i(\mathbf{x}_t, \varepsilon_{it}) = a \mid \mathbf{x}_t = \mathbf{x}\right)$$

- 由于函数 P_i 是将函数 α_i 对 ε_{it} 中的连续变量积分得到的，P_i 是比 α_i 维数更低的对象。

- 在 $\varepsilon_{it}(a_{it})$ 以可加形式进入利润函数的离散选择博弈中，最优反应策略函数 $\alpha_i(\mathbf{x}_t, \varepsilon_{it})$ 与其 CCP 函数 $P_i(.|\mathbf{x}_t)$ 之间存在**一一对应关系**。

- 显然，给定 $\alpha_i(\mathbf{x}_t, \varepsilon_{it})$，存在唯一的 $P_i(.|\mathbf{x}_t)$。

- 反过来——给定 $P_i(.|\mathbf{x}_t)$，存在唯一的最优反应函数 $\alpha_i(\mathbf{x}_t, \varepsilon_{it})$——是**Hotz-Miller 反演定理**的推论。

作为 CCP 映射不动点的 MPE

- 给定由 CCP 函数 $\mathbf{P}$ 描述的策略函数，可以把**期望利润** $\pi_i^{\mathbf{P}}$ 与**期望转移** $f_i^{\mathbf{P}}$ 定义为：

$$\pi_i^{\mathbf{P}}(a_{it}, \mathbf{x}_t) = \sum_{a_{-it}} \left[\prod_{j \neq i} P_j\left(a_{jt} \mid \mathbf{x}_t\right) \right] \pi_i\left(a_{it}, \boldsymbol{a}_{-it}, \mathbf{x}_t\right)$$

$$f_i^{\mathbf{P}}(\mathbf{x}_{t+1} | a_{it}, \mathbf{x}_t) = \sum_{a_{-it}} \left[\prod_{j \neq i} P_j\left(a_{jt} \mid \mathbf{x}_t\right) \right] f_x(\mathbf{x}_{t+1} | a_{it}, \boldsymbol{a}_{-it}, \mathbf{x}_t)$$

- 我们还定义**期望条件选择价值**：

$$v_i^{\mathbf{P}}(a_{it}, \mathbf{x}_t) \equiv \pi_i^{\mathbf{P}}(a_{it}, \mathbf{x}_t) + \delta \int V_i^{\mathbf{P}}(\mathbf{x}_{t+1}) \, f_i^{\mathbf{P}}(\mathbf{x}_{t+1} | a_{it}, \mathbf{x}_t) \, d\mathbf{x}_{t+1}$$

- 其中：

$$V_i^{\mathbf{P}}(\mathbf{x}_t) = \int \max_{a_{it}} \left\{ v_i^{\mathbf{P}}(a_{it}, \mathbf{x}_t) + \varepsilon_{it}(a_{it}) \right\} dG_i(\varepsilon_{it})$$

作为 CCP 映射不动点的 MPE [2]

- MPE 是一个 CCP 向量 $\mathbf{P} \equiv \{P_i(a_i|\mathbf{x}) : \text{对任意}(i, a_i, \mathbf{x})\}$，使得对任意 $(i, a, \mathbf{x})$：

$$P_i(a_i|\mathbf{x}) = \Pr\left(a_i = \arg\max_{a'} \left\{v_i^{\mathbf{P}}(a', \mathbf{x}) + \varepsilon_i(a')\right\} \mid \mathbf{x}\right)$$

- 这个方程组定义了一个从 CCP 空间 $\mathbf{P}$ 到其自身的不动点映射：

$$\mathbf{P} = \Psi(\mathbf{P})$$

- 映射 $\Psi(.)$ 是连续的。因此，**根据 Brouwer 不动点定理，均衡存在**。

- 一般而言，该模型存在多重均衡。

用 CCP 表示的 MPE：　　一个例子

- 假设向量 ε_{it} 独立同分布，服从第一类极值分布。
- 那么，MPE 是一个向量 $\mathbf{P} \equiv \{P_i(a|\mathbf{x}) : \text{对任意}(i, a, \mathbf{x})\}$，使得：

$$P_i(a|\mathbf{x}) = \frac{\exp\left\{v_i^{\mathbf{P}}(a, \mathbf{x})\right\}}{\sum_{a'} \exp\left\{v_i^{\mathbf{P}}(a', \mathbf{x})\right\}}$$

- 其中

$$v_i^{\mathbf{P}}(a_{it}, \mathbf{x}_t) \equiv \pi_i^{\mathbf{P}}(a_{it}, \mathbf{x}_t) + \delta \sum_{\mathbf{x}_{t+1}} V_i^{\mathbf{P}}(\mathbf{x}_{t+1})\ f_i^{\mathbf{P}}(\mathbf{x}_{t+1}|a_{it}, \mathbf{x}_t)$$

- 且 $V_i^{\mathbf{P}}$ 是如下 Bellman 方程的唯一解：

$$V_i^{\mathbf{P}}(\mathbf{x}_t) = \ln\left(\sum_{a_i} \exp\left\{\pi_i^{\mathbf{P}}(a_{it}, \mathbf{x}_t) + \delta \sum_{\mathbf{x}_{t+1}} V_i^{\mathbf{P}}(\mathbf{x}_{t+1})\ f_i^{\mathbf{P}}(\mathbf{x}_{t+1}|a_{it}, \mathbf{x}_t)\right\}\right)$$

4. 序贯估计

估计——预备知识

- 模型的原始要素 $\{\pi_i, \beta_i, f_x, G_\varepsilon\}$ 可以用研究者未知的参数向量 θ 来描述。

- 不妨把 θ 分成四个子向量：$(\theta_\pi, \theta_f, \beta, \theta_\varepsilon)$。

- 在大多数实证应用中，主要挑战在于**估计 θ_π 中的“动态参数”**：

  - θ_f 可以在动态决策模型“之外”估计。
  - 消费者需求与企业的可变成本（属于 θ_π 的一部分）可以在动态决策模型“之外”估计。
  - 大多数应用假设 θ_ε（ε 的分布）与 β 已知。
  - 动态博弈估计的重点，通常是刻画动态的参数，即投资成本、进入/退出成本、固定成本。

估计方法提纲

1. **均衡唯一**的模型的极大似然估计（MLE）
    - Rust 的**嵌套不动点（NFXP）**算法。
2. **存在多重均衡**的模型的极大似然估计（MLE）
3. 序贯**CCP 方法**

4.1 均衡唯一时的 MLE

MLE：均衡唯一的模型

- 存在一些充分条件，使得对参数 θ 的每个可能取值，动态博弈都有唯一的均衡。
- 均衡唯一性的充分条件举例如下：
  i. 有限期 T。
  ii. 在每一期 t 内，企业依次作出决策：企业 1 先行，企业 2 其次，……，企业 N 最后。这些决策成为顺序中靠后企业的共同知识。
- 令 $P_{it}(a_{it}|\mathbf{x}_t, \theta)$ 为参数向量为 θ 时，企业 i 在 t 期的均衡 CCP 函数。
- **完整的对数似然函数**为 $\ell(\theta) = \sum_{m=1}^{M} \ell_m(\theta)$，其中 $\ell_m(\theta)$ 是市场 m 的贡献：

$$\ell_m(\boldsymbol{\theta}) = \sum_{i=1}^{N}\sum_{t=1}^{T} \log P_{it}(a_{imt}|\mathbf{x}_{mt}, \boldsymbol{\theta}) + \log f_x(\mathbf{x}_{m,t+1}|\boldsymbol{a}_{mt}, \mathbf{x}_{mt}, \boldsymbol{\theta}_f)$$

嵌套不动点（NFXP）算法

- MLE 为：$$\widehat{\theta} = argmax_{\theta}\ \ell(\theta).$$
- Rust 的 NFXP 算法是计算 MLE 的一种方法。对每个试验值 θ，它把 BHHH 迭代（**外层算法**）与均衡求解算法（**内层算法**）结合起来。

1. 从一个初始猜测值出发：$\widehat{\theta}_0$。
2. 在每次**外层迭代** k中，进行一次 BHHH 迭代：

$$\widehat{\theta}_{k+1} = \widehat{\theta}_k + \left(\sum_{m=1}^{M} \frac{\partial \ell_m(\widehat{\theta}_k)}{\partial \theta} \frac{\partial \ell_m(\widehat{\theta}_k)}{\partial \theta'} \right)^{-1} \left(\sum_{m=1}^{M} \frac{\partial \ell_m(\widehat{\theta}_k)}{\partial \theta} \right)$$

3. 得分向量 $\partial \ell_m(\widehat{\theta}_k)/\partial \theta$ 取决于 $\partial \log P_i(a_{imt}|\mathbf{x}_{mt}, \widehat{\theta}_k)/\partial \theta$。为得到这些导数，**内层算法**用不动点迭代求解给定 $\widehat{\theta}_k$ 时的均衡 CCP。
4. 外层 BHHH 迭代持续进行，直到 $||\widehat{\theta}_{k+1} - \widehat{\theta}_k|| <$ 某个小常数

4.2 存在多重均衡时的 MLE

(a) 多重均衡下的 NFXP

(b) MPEC

多重均衡下的 NFXP

- 令 $\mathcal{P}(\theta)$ 为与结构参数取值 θ 相对应的正则 MPE 集合。

- Doraszelski & Satterthwaite（2011）表明，对 θ 的每个取值，集合 $\mathcal{P}(\theta)$ 都是离散且有限的。

$$\mathcal{P}(\boldsymbol{\theta}) = \{\boldsymbol{P}^{\tau}(\boldsymbol{\theta}) : \ \tau = 1, 2, ..., \mathcal{T}\}$$

- 假设模型的结构使我们有算法能够对任意试验值 θ 计算均衡集合 $\mathcal{P}(\theta)$。

- 例如 Iskhakov, Rust, & Schjerning（2016）中的递归词典序搜索（RLS）算法。

- 那么，MLE 定义为：

$$(\widehat{\boldsymbol{\theta}}_{MLE}, \hat{\tau}_{MLE}) = argmax_{\boldsymbol{\theta}, \tau \in \mathcal{P}(\boldsymbol{\theta})} \sum_{i=1}^{N} \sum_{t=1}^{T} \log P_{it}^{\tau}(a_{imt} | \mathbf{x}_{mt}, \boldsymbol{\theta})$$

多重均衡下的 NFXP (2)

- NFXP 算法的步骤如下。

1. 从初始猜测值 θ^0 出发。
2. **内层迭代 S——求解**：在第 $n+1$ 次迭代，给定 θ^n，用 RLS 算法找出均衡集合 $\mathcal{P}(\theta^n)$。
3. **内层迭代 M——对 τ 最大化**：选择给定 θ^n 时似然值最大的均衡类型 $\tau^*(\theta^n)$。
4. **外层迭代——BHHH**：给定特定均衡下的对数似然函数 $\ell^{\tau^*(\theta^n)}(\theta)$，用 BHHH 算法得到新的 θ^{n+1}。
5. 迭代直到 $||\theta^{n+1} - \theta^n|| < \text{cconv}$。

多重均衡下的 MPEC

- 存在多重均衡时，$\ell(\theta)$ 不是函数而是对应。MLE 不能定义为 $\ell(\theta)$ 的 argmax。
- 为了在多重均衡模型中定义 MLE，不妨定义一个扩展的或**伪似然函数**。
- 对任意的 θ 值与企业 CCP $\mathbf{P}$，定义：

$$Q(\boldsymbol{\theta}, \mathbf{P}) = \sum_{m=1}^{M} \sum_{i=1}^{N} \sum_{t=1}^{T} \log \Psi_i(a_{imt} \mid \mathbf{x}_{mt}, \boldsymbol{\theta}, \mathbf{P})$$

其中 Ψ_i 是最优反应概率函数。

多重均衡下的 MPEC [2]

- MLE 是一对 $(\widehat{\theta}_{MLE}, \widehat{\mathbf{P}}_{MLE})$，它**在 CCP 为均衡策略的约束下最大化** Q:

$$(\widehat{\theta}_{MLE}, \widehat{\mathbf{P}}_{MLE}) = \begin{cases} \arg\max\limits_{(\theta,\mathbf{P})} & Q(\theta, \mathbf{P}) \\ \\ \text{subject to:} & \mathbf{P} = \Psi(\theta, \mathbf{P}) \end{cases}$$

- 或者使用拉格朗日函数:

$$(\widehat{\theta}_{MLE}, \widehat{\mathbf{P}}_{MLE}, \widehat{\lambda}_{MLE}) = \arg\max_{(\theta,\mathbf{P},\lambda)} \; Q(\theta, \mathbf{P}) + \lambda' \left[\mathbf{P} - \Psi(\theta, \mathbf{P})\right]$$

- 一阶条件即拉格朗日方程组:

$$\begin{cases} \widehat{\mathbf{P}}_{MLE} - \Psi(\widehat{\theta}_{MLE}, \widehat{\mathbf{P}}_{MLE}) = \mathbf{0} \\ \nabla_{\theta} Q(\widehat{\theta}_{MLE}, \widehat{\mathbf{P}}_{MLE}) - \widehat{\lambda}'_{MLE} \nabla_{\theta} \Psi(\widehat{\theta}_{MLE}, \widehat{\mathbf{P}}_{MLE}) = \mathbf{0} \\ \nabla_{\mathbf{P}} Q(\widehat{\theta}_{MLE}, \widehat{\mathbf{P}}_{MLE}) - \widehat{\lambda}'_{MLE} \nabla_{\mathbf{P}} \Psi(\widehat{\theta}_{MLE}, \widehat{\mathbf{P}}_{MLE}) = \mathbf{0} \end{cases}$$

多重均衡下的 MPEC [3]

- 可以用牛顿法求这个拉格朗日方程组的根。
- 一个关键的计算问题是**该方程组的维数非常高**。
- 该算法中最耗时的部分是**计算雅可比矩阵** $\nabla_{\mathbf{P}}\Psi(\widehat{\theta},\widehat{\mathbf{P}})$。在动态博弈中，它一般不是稀疏矩阵，可能包含数十亿乃至数万亿个元素。
- 对新的 $\mathbf{P}$ 值计算最优反应映射 $\Psi(\theta,\mathbf{P})$，需要求解一个估值算子，并求解一个与 $\mathbf{P}$ 维数相同的方程组。

4.3 序贯 CCP 方法

两步 CCP 方法

- 这类方法完全不需要求解企业的最优反应或均衡，哪怕一次也不需要。

- **Hotz & Miller（REStud，1993）** 是这类方法的开创性贡献。他们证明了条件选择价值可以写成 CCP、转移概率与 θ 的已知函数。

- 假设单期利润关于参数是线性的：

$$\pi_i(a_{it}, \boldsymbol{a}_{-it}, \mathbf{x}_t) \;=\; h(a_{it}, \boldsymbol{a}_{-it}, \mathbf{x}_t)' \; \boldsymbol{\theta}_{\pi,i}$$

其中 $h(a_{it}, a_{-it}, \mathbf{x}_t)$ 是研究者已知的函数向量。

- 条件选择价值函数 $v_i^{\mathbf{P}}(a_{it}, \mathbf{x}_t)$ 为：

$$v_i^{\mathbf{P}}(a_{it}, \mathbf{x}_t) = \mathbb{E}\left(\sum_{j=0}^{\infty} \beta^j \; h(\boldsymbol{a}_{t+j}, \mathbf{x}_{t+j})' \; \boldsymbol{\theta}_{\pi,i} + \varepsilon_{i,t+j}(a_{i,t+j}) \mid a_{it}, \mathbf{x}_t \right)$$

其中未来行动 a_{t+j} 按照均衡 CCP 选择。

两步 CCP 方法 [2]

- 我们可以写成：

$$v_i^{\mathbf{P}}(a_{it}, \mathbf{x}_t) = \widetilde{h}_i^{\mathbf{P}}(a_{it}, \mathbf{x}_t)\ \boldsymbol{\theta}_{\pi,i} + \widetilde{e}_i^{\mathbf{P}}(a_{it}, \mathbf{x}_t)$$

其中：

$$\widetilde{h}_i^{\mathbf{P}}(a_{it}, \mathbf{x}_t) = \mathbb{E}\left(\sum_{j=0}^{\infty}\beta^j\ h(\boldsymbol{a}_{t+j}, \mathbf{x}_{t+j}) \mid a_{it}, \mathbf{x}_t\right)$$

$$\widetilde{e}_i^{\mathbf{P}}(a_{it}, \mathbf{x}_t) = \mathbb{E}\left(\sum_{j=0}^{\infty}\beta^j\ [\gamma - \ln P_i(a_{i,t+j}|\mathbf{x}_{t+j})] \mid a_{it}, \mathbf{x}_t\right)$$

- 给定企业的均衡 CCP、$\mathbf{P}$、β 以及 $\mathbf{x}$ 的转移概率，可以用（例如）前向蒙特卡洛模拟来计算这些现值。

两步 CCP 方法 [3]

- 有了条件选择价值的这种表示，伪似然函数 $Q(\theta, \mathbf{P})$ 的结构几乎与静态或简约形式的离散选择模型相同。

- 进入 $Q(\theta, \mathbf{P})$ 的最优反应概率，可以看作标准随机效用模型中的选择概率：

$$\Psi_i(a_{imt} = j | \mathbf{x}_{mt}, \boldsymbol{\theta}, \mathbf{P}) = \frac{\exp\{\widetilde{h}_i^{\mathbf{P}}(j, \mathbf{x}_{mt})\ \boldsymbol{\theta}_i + \widetilde{e}_i^{\mathbf{P}}(j, \mathbf{x}_{mt})\}}{\sum_{k=0}^{J} \exp\{\widetilde{h}_i^{\mathbf{P}}(k, \mathbf{x}_{mt})\ \boldsymbol{\theta}_i + \widetilde{e}_i^{\mathbf{P}}(k, \mathbf{x}_{mt})\}}$$

- 给定 $\widetilde{h}_i^{\mathbf{P}}(., \mathbf{x}_{mt})$、$\widetilde{e}_i^{\mathbf{P}}(., \mathbf{x}_{mt})$ 以及 ε 分布的参数化设定（例如 logit、probit），参数向量 θ_i 可以像标准 logit 或 probit 模型那样估计。

两步 CCP 方法 [3]

- 该方法分两步进行。
- 令 $\widehat{\mathbf{P}}^0$ 为真实 $\mathbf{P}^0$ 的一致非参数估计量。θ 的两步估计量定义为：

$$\widehat{\boldsymbol{\theta}}_{2S} = \arg\max_{\boldsymbol{\theta}} Q(\boldsymbol{\theta}, \widehat{\mathbf{P}}^0)$$

- 在标准正则条件下，该两步估计量是 $\sqrt{M}$ 一致且渐近正态的。
- 它可以推广到包含市场层面的不可观测异质性（例如 Aguirregabiria & Mira (2007)；Arcidiacono & Miller (2011)）。
- 可以用蒙特卡洛模拟计算现值：Bajari, Benkard, & Levin (2007)。
- 局限：第一步中 CCP 估计不精确会导致有限样本偏误。

嵌套伪似然（NPL）

- 施加均衡约束，但不需要：
  - 对每个试验值 θ 反复求解 MPE（如 NFXP）
  - 计算 $\nabla_{\mathbf{P}}\Psi(\widehat{\theta},\widehat{\mathbf{P}})$（如 NFXP 与 MPEC）

- NPL $(\widehat{\theta}_{NPL},\widehat{\mathbf{P}}_{NPL})$ 满足两个条件：

  (1) 给定 $\widehat{\mathbf{P}}_{NPL}$，有 $\widehat{\theta}_{NPL} = \arg\max_{\theta} Q(\theta,\widehat{\mathbf{P}}_{NPL})$

  (2) 给定 $\widehat{\theta}_{NPL}$，有 $\widehat{\mathbf{P}}_{NPL} = \Psi(\widehat{\theta}_{NPL},\widehat{\mathbf{P}}_{NPL})$

- 在与 MLE 相同的正则条件下，NPL 估计量一致且渐近正态。对动态博弈而言，NPL 估计量的渐近方差大于 MLE。

嵌套伪似然（NPL） [2]

- 计算 NPL 的一种算法是**NPL 不动点算法**。
- 从初始值 $\widehat{\mathbf{P}}_0$ 出发，在第 $k \geq 1$ 次迭代：

  （第 1 步） 给定 $\widehat{\mathbf{P}}_{k-1}$，$\widehat{\theta}_k = \arg\max_{\theta} Q(\theta, \widehat{\mathbf{P}}_{k-1})$；

  （第 2 步） 给定 $\widehat{\theta}_k$，$\widehat{\mathbf{P}}_k = \Psi(\widehat{\theta}_k, \widehat{\mathbf{P}}_{k-1})$。
- 初始值 $\widehat{\mathbf{P}}_0$ 的一个自然选择是用数据得到的 CCP 频率估计量。
- 在大多数应用中，第 1 步非常简单，其计算成本与求静态单个决策者离散选择模型的 MLE 相同。
- 第 2 步相当于求解一次维数与 $\mathbf{P}$ 相同的线性方程组。
- 这种不动点算法的一个局限是**不能保证收敛**。另一种已被用来计算 NPL 的算法是**谱残差算法**。

计算 NPL 估计量的算法

- NPL 估计量可以描述为 CCP 向量空间中的一个不动点：

$$\widehat{\mathbf{P}} = \phi(\widehat{\mathbf{P}})$$

其中 $\phi\left(\widehat{\mathbf{P}}\right)$ 是**NPL 映射**：

$$\phi(\widehat{\mathbf{P}}) \equiv \Psi\left(\widehat{\mathbf{P}}, \widehat{\theta}(\widehat{\mathbf{P}})\right)$$

$\Psi(\mathbf{P}, \boldsymbol{\theta})$ 是均衡映射，$\widehat{\theta}(\widehat{\mathbf{P}})$ 是伪 MLE 映射。

- 我们研究计算 NPL 估计量的 3 种算法。
  1. NPL 映射 ϕ 中的不动点迭代。
  2. 用牛顿法求解方程组 $\mathbf{P} - \phi(\mathbf{P}) = 0$
  3. 用谱残差法求解方程组 $\mathbf{P} - \phi(\mathbf{P}) = 0$

- (1) 不能保证收敛。(2) 能保证收敛，但在大多数应用中不可行。(3) 相对于 (1) 和 (2) 具有优势。

NPL 不动点迭代

- 令 $\mathbf{P}^0 \equiv \{\mathbf{P}_i^0 : \text{对任意} i\}$ 为任意的 CCP 向量。
- 在第 n 次迭代：

$$\mathbf{P}^n = \phi(\mathbf{P}^{n-1}) = \Psi\left(\mathbf{P}^{n-1}, \widehat{\theta}(\mathbf{P}^{n-1})\right)$$

- 检查是否收敛：

$$\begin{cases} \text{若 } \left\|\mathbf{P}^n - \mathbf{P}^{n-1}\right\| \leq \kappa, \text{ 则 } \mathbf{P}^n \text{ 与 } \theta^n = \widehat{\theta}(\mathbf{P}^{n-1}) \text{ 即为 NPL} \\ \text{若 } \left\|\mathbf{P}^n - \mathbf{P}^{n-1}\right\| > \kappa, \text{ 则进入第 } n+1 \text{ 次迭代} \end{cases}$$

其中 κ 是一个小的正常数，例如 $\kappa = 10^{-6}$。

- **不能保证收敛**。这是一个严重的局限。

牛顿法

- 定义函数 $f(\mathbf{P}) \equiv \mathbf{P} - \Psi\left(\mathbf{P}, \widehat{\theta}(\mathbf{P})\right)$。
- 求 NPL 估计量等价于求 f 的零点（根）。
- 我们可以用牛顿法求 f 的根。
- 在第 n 次迭代：　　（$\nabla f(\mathbf{P})$ 是雅可比矩阵）

$$\mathbf{P}^n = \mathbf{P}^{n-1} + \left[\nabla f\left(\mathbf{P}^{n-1}\right)\right]^{-1} f\left(\mathbf{P}^{n-1}\right)$$

- 检查是否收敛：$\left\|\mathbf{P}^n - \mathbf{P}^{n-1}\right\| \leq \kappa$
- **保证收敛**（收敛到多重均衡中的某一个）。

牛顿法 [2]

- 牛顿迭代的主要计算成本来自雅可比矩阵 $\nabla f(\mathbf{P})$ 的计算。
- 该矩阵中的导数没有闭式表达式。而且在这类模型中，这个矩阵不是稀疏的。
- 该矩阵的维数为 $N|\mathcal{A}||\mathcal{X}| \times N|\mathcal{A}||\mathcal{X}|$，计算其中任一个元素都需要求解许多单个决策者的动态规划问题，每个问题的复杂度为 $O(|\mathcal{X}|^3)$。
- 总之，在大多数 $|\mathcal{X}|$ 大于 10^5 的实证应用中，牛顿法并不可行。

谱残差法

- 这是求解高维非线性方程组 $f(\mathbf{P}) = 0$ 的通用方法。

- 它有两个非常吸引人的特点：

1. 它不需要求导，一次迭代的成本相当于计算一次 $f(\mathbf{P})$，与一次不动点迭代的成本相同。

2. 在温和的正则条件下它收敛到一个解，收敛性质与牛顿法同样良好。

谱残差法 [2]

- 谱方法提出如下更新规则/迭代：

$$\mathbf{P}_{n+1} = \mathbf{P}_n - \alpha_n \, f\left(\mathbf{P}_n\right)$$

其中 α_n 是谱步长，为标量。

- 文献中提出了不同的更新规则，常用的是 Barzilai and Borwein（1988）：

$$\alpha_n = \frac{[\mathbf{P}_n - \mathbf{P}_{n-1}]'[f(\mathbf{P}_n) - f(\mathbf{P}_{n-1})]}{[f(\mathbf{P}_n) - f(\mathbf{P}_{n-1})]'[f(\mathbf{P}_n) - f(\mathbf{P}_{n-1})]}$$

- 谱残差法收敛的直观原因在于：α_n 的更新可以保证朝着正确的方向收敛。