一种面向离线逆强化学习与动态离散选择模型的经验风险最小化方法

Enoch Hyunwook Kang[*1], Hema Yoganarasimhan[1] and Lalit Jain[1 2]

2025 年计量经济学会动态结构计量经济学暑期学校

1 华盛顿大学 Foster 商学院

2 Google DeepMind

我们将讨论……

动机：大规模问题

回顾：动态离散选择（DDC）模型

回顾：关于求解 DDC 模型我们已经知道什么

一次性的基于梯度的优化方法

估计的偏误修正与经验风险最小化框架

GLADIUS 算法及其全局最优性

模拟实验

提纲

动机：大规模问题

回顾：动态离散选择（DDC）模型

回顾：关于求解 DDC 模型我们已经知道什么

一次性的基于梯度的优化方法

估计的偏误修正与经验风险最小化框架

GLADIUS 算法及其全局最优性

模拟实验

Example: Walmart+'s optimal coupon timing

- Free delivery service if subscribed
- $12.95/month subscription, renewed monthly
- Each month, subscribers decide whether to continue/discontinue Walmart + membership
- Walmart wants to find the optimal coupon timing for subscribers
  - Give the subscriber a 50% discount this month
    - Walmart loses money now but may make more money in the future
  - Don't give subscriber a 50% discount this month.
    - Walmart doesn't lose money now, customer may churn

Example: Walmart's optimal coupon timing

state at month 0 (s_0)

action at month 0 (a_0) – Coupon

state at month 1 (s_1)

action at month 1 (a_1) – No coupon

state at month 2 (s_2)

action at month 2 (a_2) – No coupon

state at month 3 (s_3)

action at month 3 (a_3) – No coupon

Customer Churn

Page views
Session Duration
Cart addition
Abandonment Rate
Purchase Frequency
Average Order Value
Product Category Preference
Device Usage Proportion
Average Items per Cart
Search Usage Frequency
Time Between Purchases
Peak Activity time
Shipping Cost Tolerance
Average Scroll Depth
Loyalty Program Engagement
...

Example: Walmart+'s optimal coupon timing

state at month 0 (s_0)

action at month 0 (a_0) – Coupon

state at month 1 (s_1)

action at month 1 (a_1) – No coupon

state at month 2 (s_2)

action at month 2 (a_2) – No coupon

state at month 3 (s_3)

action at month 3 (a_3) – No coupon

Customer Churn

Walmart's utility?

$u(s_0, a_0)$

$u(s_1, a_1)$

$u(s_2, a_2)$

$u(s_3, a_3)$

(−) immediate subscription revenue
(+) Increased sales
(+) Enhanced customer loyalty
(+) Increased lifetime value
….

Unknown utilities

Example: Walmart+'s optimal coupon timing

Given: Dataset of $(s_0, a_0, s_1, a_1, \dots,)$

Unknown: $(u(s_0, a_0), u(s_1, a_1), \dots,)$

Goal: Infer the unknown utility function $u(s_t, a_t)$

Canonical Dynamic Discrete Choice Model problem

Question: Can we apply existing DDC methods?

提纲

动机：大规模问题

回顾：动态离散选择（DDC）模型

回顾：关于求解 DDC 模型我们已经知道什么

一次性的基于梯度的优化方法

估计的偏误修正与经验风险最小化框架

GLADIUS 算法及其全局最优性

模拟实验

单个决策者 [2] 马尔可夫决策过程（MDP）

给定离线数据集 $\mathcal{D} = (s_0, a_0, s_1, a_1, \ldots)$，其中 $s_t = t$ 期的状态，$a_t = t$ 期的行动

$\mathcal{D}$ 是个体与马尔可夫决策过程 $(\mathcal{S}, \mathcal{A}, P, \nu_0, r, G, \beta)$交互时收集的：

- $\mathcal{S}$ 表示状态空间，$\mathcal{A}$ 表示有限的行动空间
- $P \in \Delta_{\mathcal{S}}^{\mathcal{S}\times\mathcal{A}}$ 是马尔可夫转移核，$\nu_0 \in \Delta_{\mathcal{S}}$ 是 $\mathcal{S}$ 上的初始状态分布
- $\beta \in (0, 1)$ 为贴现因子
- $r(s, a) + \epsilon_a$ 是个体私下观测到的奖励 [1]
  - $r \in \mathbb{R}^{\mathcal{S}\times\mathcal{A}}$ 是奖励的确定性部分。
  - $\epsilon_a \overset{i.i.d.}{\sim} G(\delta, 1)$ 是奖励的随机部分，其中 G 为第一类极值（T1EV）分布（即 Gumbel 分布）

[1] 这种奖励形式通常被称为满足线性可加性与条件独立性

[2] 我们最后将讨论如何扩展到不可观测异质性的情形

记号

给定初始状态 $s_0 \sim \nu_0$，对策略 π，在样本空间

$(\mathcal{S} \times \mathcal{A})^\infty = \{(s_0, a_0, s_1, a_1, \ldots) : s_h \in \mathcal{S}, a_h \in \mathcal{A}, h \in \mathbb{N}\}$ 上定义状态—行动序列的分布 $\mathbb{P}_{\nu_0,\pi}$

并用 $\mathbb{E}_{\nu_0,\pi}$ 表示关于 $\mathbb{P}_{\nu_0,\pi}$ 的期望

进一步定义：

- 最优策略 $\pi^* := \operatorname{argmax}_{\pi \in \Delta_{\mathcal{A}}^{\mathcal{S}}} \mathbb{E}_{\nu_0,\pi,G}\left[\sum_{h=0}^{\infty} \beta^h (r(s_h, a_h) + \epsilon_{a_h})\right]$
- 价值函数 $V^*(s) := \max_{\pi \in \Delta_{\mathcal{A}}^{\mathcal{S}}} \mathbb{E}_{\nu_0,\pi,G}\left[\sum_{h=0}^{\infty} \beta^h (r(s_h, a_h) + \epsilon_{a_h}) \mid s_0 = s\right]$
- Q 函数 $Q^*(s, a) := r(s, a) + \beta \cdot \mathbb{E}_{s' \sim P(s,a)}\left[V^*(s') \mid s, a\right]$

动态离散选择（DDC）模型的估计问题

假设 1（理性）

数据 $\mathcal{D}$ 是个体按最优策略 π^* 与 MDP $(\mathcal{S}, \mathcal{A}, P, \nu_0, r, G, \beta)$

交互时收集的。

定义 1（动态离散选择（DDC）模型的估计问题）

给定离线数据 $\mathcal{D}$，在假设 1 下，我们希望找到一个函数 $\hat{r} \in \mathcal{R} \subseteq \mathbb{R}^{\mathcal{S}\times\mathcal{A}}$：

$$\underset{\hat{r}\in\mathcal{R}\subseteq\mathbb{R}^{\bar{\mathcal{S}}\times\mathcal{A}}}{\operatorname{argmin}} \quad \mathbb{E}_{(s,a)\sim\nu_0,\pi^*}\left[\left(\hat{r}(s,a) - r(s,a)\right)^2\right]$$

其中 $\bar{\mathcal{S}} := \{s \in \mathcal{S} \mid \mathbb{P}_{\nu_0,\pi^*}(\{s_h = s\}) > 0$，对某个 $h \geq 0\}$ 定义了最优策略的

覆盖范围，即在专家最优策略 π^* 下能以非零概率到达的状态

所构成的集合。[3]

[3] 即使数据无限，推断 $\bar{\mathcal{S}}$ 之外的奖励也是不适定的。类似地，用 π^* 的状态—行动分布计算 MSE 是很自然的，因为目标是恢复能够解释专家行为的奖励函数。

DDC 模型的基本结论

事实 1（最优性方程）

在假设 1 下，有

$$\pi^*(a \mid s) = \frac{\exp\left(Q^*(s,a)\right)}{\sum_{a' \in \mathcal{A}} \exp\left(Q^*(s,a')\right)} \text{ 对 } a \in \mathcal{A} \tag{1}$$

$$\begin{aligned} Q^*(s,a) &= r(s,a) + \beta \cdot \mathbb{E}_{s' \sim P(s,a)}\left[V(s') \mid s, a\right] \\ &= r(s,a) + \beta \cdot \mathbb{E}_{s' \sim P(s,a)}\left[\log \sum_{a' \in \mathcal{A}} \exp(Q^*(s',a')) \mid s, a\right] + \delta + \gamma \end{aligned} \tag{2}$$

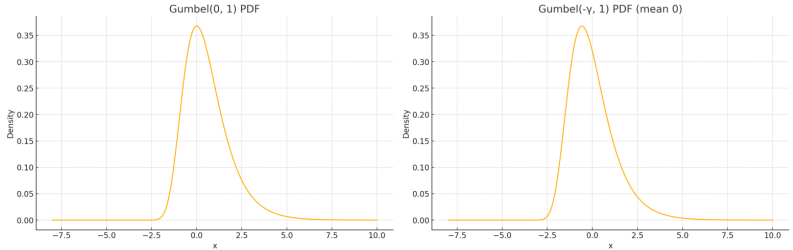
最优性方程 (1)：π^* 与 Q^* 的关系

最优性方程 (2)：关于 Q^* 的 Bellman 方程

注）T1EV（Gumbel）分布的设定

回顾：奖励的随机部分为 $\epsilon_a \overset{i.i.d.}{\sim} G(\delta, 1)$，其中 G 为第一类极值（T1EV）分布（即 Gumbel 分布）

- $G(0,1)$ 不是均值为 0 的分布　　（均值 $\delta + \gamma = 0 + \gamma = \gamma$）
- $G(-\gamma, 1)$ 是均值为 0 的分布　　（均值 $\delta + \gamma = -\gamma + \gamma = 0$）



为简单起见，下文始终使用 $\epsilon_a \overset{i.i.d.}{\sim} G(-\gamma, 1)$

注）DDC 与 IRL 的等价性

DDC 与 IRL 的区别在于如何解释行动选择中的**随机性**：

- 动态离散选择模型（DDC）的解释：

  “存在一个不可观测的随机状态成分，造成了这种不确定性”

- 逆强化学习（IRL）的解释：

  “行动选择本身就是随机的，因为个体天生偏好随机的行动选择”

事实 2

事实 1 中完全相同的最优性方程对 DDC 和 IRL 都成立。[4]

事实上，IRL 学界一直在重新发现 DDC 已经发展出的成果。[5] [6]

[4] 详见 Kang et al.（2025）的附录 C

[5] “Identifiability in inverse reinforcement learning”，Cao et al.，NeurIPS 2021

[6] “A maximum likelihood framework for offline inverse reinforcement learning”，Zeng et al.，NeurIPS 2023

提纲

动机：大规模问题

回顾：动态离散选择（DDC）模型

回顾：关于求解 DDC 模型我们已经知道什么

一次性的基于梯度的优化方法

估计的偏误修正与经验风险最小化框架

GLADIUS 算法及其全局最优性

模拟实验

回顾：最优性方程

$$\pi^*(a \mid s) = \frac{\exp\left(Q^*(s,a)\right)}{\sum_{a' \in \mathcal{A}} \exp\left(Q^*(s,a')\right)} \text{ 对 } a \in \mathcal{A} \tag{1}$$

$$Q^*(s,a) = r(s,a) + \beta \cdot \mathbb{E}_{s' \sim P(s,a)}\left[\log \sum_{a' \in \mathcal{A}} \exp(Q^*(s',a')) \mid s, a\right] \tag{2}$$

我们希望用它们求出 r 与 Q^*。

为此，我们改写这些方程。

改写最优性方程 (1)

定义 $\frac{\exp(Q(s,a))}{\sum_{a' \in \mathcal{A}} \exp(Q(s,a'))}$，记为 $\hat{p}_Q(a \mid s)$.

那么，Q 要满足最优性方程 (1)，就必须满足 $\pi^*(a|s) = \hat{p}_Q(a|s)$。

引理 1

$$\left\{ Q \in \mathcal{Q} \mid \pi^*(\cdot \mid s) = \hat{p}_Q(\cdot \mid s) \quad \forall s \in \bar{\mathcal{S}} \quad a.e. \right\}$$

$$= \arg\min_{Q \in \mathcal{Q}} \ \mathbb{E}_{(s,a) \sim \pi^*, \nu_0} \left[-\log \left(\hat{p}_Q(a \mid s) \right) \right]$$

定义 $\mathcal{L}_{NLL}(Q)(s,a) := -\log(\hat{p}_Q(a|s))$，称之为负对数似然（NLL）损失。

改写后的最优性方程 (1)：

$$Q^* \in \arg\min_{Q \in \mathcal{Q}} \ \mathbb{E}_{(s,a) \sim \pi^*, \nu_0} \left[\mathcal{L}_{NLL}(Q)(s,a) \right]$$

求解 DDC 模型的已知结论

假设 2

对所有 $s \in \mathcal{S}$，存在一个行动 $a_s \in \mathcal{A}$，令 $r(s, a_s) = 0$。

在假设 2 下，我们知道两种求解 DDC 模型的方法：

r, Q^* 的估计

⇕ (Rust 1994)

1. Q^* 最小化 $\mathbb{E}_{(s,a)\sim\pi^*}[\mathcal{L}_{NLL}(Q)(s,a)]$
2. Q^* 满足 Bellman 方程，$\forall s \in \bar{\mathcal{S}}, a \in \mathcal{A}$

r, Q^* 的估计

⇕ (Hotz and Miller 1993)

1. Q^* 最小化 $\mathbb{E}_{(s,a)\sim\pi^*}[\mathcal{L}_{NLL}(Q)(s,a)]$
2. $Q^*(s,a) := \mathbb{E}_{\pi^*,\nu_0}\left[\sum_{t=0}^{\infty} \beta^t r(s_t, a_t) + \epsilon_{a_t} \mid s, a\right]$

我们注意到两种方法共有的两个挑战

1. 优化是嵌套的（无法一次性优化）
2. 维数灾难

挑战 1：优化需要嵌套

r, Q^* 的估计

$\Updownarrow$ (Rust 1994)

(1) Q^* 最小化 $\mathbb{E}_{(s,a)\sim\pi^*}[\mathcal{L}_{NLL}(Q)(s,a)]$

(2) Q^* 满足 Bellman 方程，$\forall s \in \mathcal{S}, a \in \mathcal{A}$

r, Q^* 的估计

$\Updownarrow$ (Hotz and Miller 1993)

(1) Q^* 最小化 $\mathbb{E}_{(s,a)\sim\pi^*}[\mathcal{L}_{NLL}(Q)(s,a)]$

(2) $Q^*(s_t, a_t) := \mathbb{E}_{\pi^*,\nu_0}\left[\sum_{t=0}^{\infty} \beta^t r(s_t, a_t)\right]$

在两种情形下，我们都需要对 r 进行参数化（以满足方程 (2) 的部分）。

但这样一来，我们需要求解一个嵌套的优化问题：

- 方程 (1) 的部分是外层循环，是在 Q 空间内进行优化
- 方程 (2) 的部分是内层循环，是由 r 推出 Q

挑战 2：维数灾难

挑战 2：对两种方法而言，为大规模问题求解方程 (2) 都很困难

- 按 Rust（1994）的做法：需要求解 Bellman 方程

  $$Q(s,a) = r(s,a) + \beta E_{s' \sim P(s,a)} \left[\ln \left(\sum_{a \in \mathcal{A}} \exp \left(Q\left(s', a\right) \right) \right) \mid s, a \right]$$

  - 计算复杂度随维数增加呈指数增长

- 按 Hotz and Miller（1993）的做法：需要估计转移函数，

  来计算 $Q(s_t, a_t) := \mathbb{E}_{\pi^*, \nu_0} \left[\sum_{t=0}^{\infty} \beta^t r(s_t, a_t) \right]$

  - 统计复杂度随维数增加呈指数增长

Walmart+ 's optimal coupon timing problem

state at month 0 (s_0)

action at month 0 (a_0) – Coupon

state at month 1 (s_1)

action at month 1 (a_1) – No coupon

state at month 2 (s_2)

action at month 2 (a_2) – No coupon

state at month 3 (s_3)

action at month 3 (a_3) – No coupon

Customer Churn

Page views
Session Duration
Cart addition
Abandonment Rate
Purchase Frequency
Average Order Value
Product Category Preference
Device Usage Proportion
Average Items per Cart
Search Usage Frequency
Time Between Purchases
Peak Activity time
Shipping Cost Tolerance
...

State space size > 10^{20}

Curse of dimensionality happens!

用非参数函数近似应对维数灾难

在不了解转移函数的情况下，求解 Bellman 方程有两种方法 [7]：

- 拟合不动点迭代（例如拟合价值迭代、拟合 Q 迭代）
  - John 之前已经介绍过
  - Adusumilli and Eckardt（2022）[8] 作过研究
  - 与神经网络结合时会不稳定（见下页）
- 基于梯度的平方 Bellman 误差（BE）最小化
  - 之前没有相关研究（稍后解释）
  - 本文

[7] 见 "Offline reinforcement learning in large state spaces: algorithms and guarantees"，Jiang and Xie，Statistical Science（即将发表）。注意，重要性抽样方法不在此列，因为它们不能保证 Bellman 方程成立。

[8] Adusumilli and Eckardt，"Temporal-Difference estimation of dynamic discrete choice models"，RES（即将发表）

拟合不动点迭代方法的发散问题

定理 2（Tsitsiklis and Roy 1996，Jiang and Xie 2025）

即使以下条件全部成立，拟合不动点方法也可能发散：

1. $|\mathcal{D}| = \infty$ 且拟合是精确的（即用无限计算实现完美优化）。
2. $\mathcal{F}$ 是能精确刻画 Q^* 的一维线性函数类，即 $Q^* \in \mathcal{Q}$（又称可实现性）。

这不只是理论上的现象 [9]，不稳定性在实践中是个大问题。 [10]

与神经网络结合时，这个问题会更严重。 [11]

直观地说："求解 Bellman 方程涉及对尚未实现的函数进行自举" [12]

[9] Tsitsiklis and Roy，"Feature-based methods for large scale dynamic programming"，Machine Learning（1996）

[10] Van Hasselt et al.，"Deep reinforcement learning and the deadly triad"，arXiv:1812.02648（2018）。

[11] Wang et al.，"Instabilities of offline rl with pre-trained neural representation"，ICML（2021）

[12] Jiang and Xie，"Offline reinforcement learning in large state spaces: algorithms and guarantees"，Statistical Science（2025）

本文回答的问题

能否有一种可扩展的基于梯度的方法，在不对奖励结构/转移函数知识作任何假设的情况下，推断奖励（或 Q^* 函数），同时可证明地保证全局最优性？

提纲

动机：大规模问题

回顾：动态离散选择（DDC）模型

回顾：关于求解 DDC 模型我们已经知道什么

一次性的基于梯度的优化方法

估计的偏误修正与经验风险最小化框架

GLADIUS 算法及其全局最优性

模拟实验

术语：Bellman 算子

将Bellman 算子 $\mathcal{T}$ 定义为：

$$\mathcal{T}Q(s,a) := r(s,a) + \beta \mathbb{E}_{s' \sim P(s,a)} \left[\ln \left(\sum_{a \in \mathcal{A}} \exp\left(Q\left(s', a'\right)\right) \right) \mid s, a \right]$$

将经验 Bellman 算子 $\widehat{\mathcal{T}}$ 定义为：

$$\widehat{\mathcal{T}}Q(s,a,s') := r(s,a) + \beta \left[\ln \left(\sum_{a \in \mathcal{A}} \exp\left(Q\left(s', a'\right)\right) \right) \mid s, a \right]$$

注意 $\mathbb{E}_{s' \sim P(s,a)} \left[\widehat{\mathcal{T}}Q(s,a,s') \right] = \mathcal{T}Q(s,a)$。

术语：Bellman 误差（BE）损失与时间差分（TD）损失

Bellman 方程：

$$Q^*(s_t, a_t) = \underbrace{r(s_t, a_t) + \beta E_{s_{t+1} \sim P(s_t, a_t)} \left[\ln \left(\sum_{a \in \mathcal{A}} \exp\left(Q^*(s_{t+1}, a)\right) \right) \mid s_t, a_t \right]}_{\mathcal{T} Q^*(s_t, a_t)}$$

定义 $\mathcal{L}_{BE}(Q)(s, a) := (Q(s, a) - \mathcal{T} Q(s, a))^2$，称之为平方 Bellman 误差（BE）损失。

定义 $\mathcal{L}_{TD}(Q)(s, a) := (Q(s, a) - \widehat{\mathcal{T}} Q(s, a, s'))^2$，称之为平方时间差分（TD）损失。

回顾：Rust（1994）的做法

假设 2

对所有 $s \in \mathcal{S}$，存在一个行动 $a_s \in \mathcal{A}$，令 $r(s, a_s) = 0$。

在假设 2 下，有：

r, Q^* 的估计

$\Updownarrow$ (Rust 1994)

1. Q 最小化 $\mathbb{E}_{(s,a)\sim\pi^*,\nu_0}[\mathcal{L}_{NLL}(Q)(s,a)]$
2. Q 满足 Bellman 方程，$\forall s \in \mathcal{S}, a \in \mathcal{A}$

Magnac and Thesmar（2009）

假设 2

对所有 $s \in \mathcal{S}$，存在一个行动 $a_s \in \mathcal{A}$，令 $r(s, a_s) = 0$。

在假设 2 下，有：

r, Q^* 的估计

$\Updownarrow$ Magnac and Thesmar（2009）

1. Q 最小化 $\mathbb{E}_{(s,a)\sim\pi^*,\nu_0}[\mathcal{L}_{NLL}(Q)(s,a)]$
2. 对所有 $s \in \mathcal{S}$ 的 (s, a_s)，Q 满足 Bellman 方程

改写最优性方程 (2)

注意我们有

$$\begin{aligned}
&\{Q \in \mathcal{Q} \mid \text{对所有 } s \in \mathcal{S} \text{ 的 } (s, a_s),\ Q \text{ 满足 Bellman 方程 } \} \\
&= \left\{Q \in \mathcal{Q} \mid \mathcal{L}_{BE}(Q)(s, a_s) = 0 \quad \forall s \in \overline{\mathcal{S}}\right\} \\
&= \arg\min_{Q \in \mathcal{Q}} \mathbb{E}_{(s,a) \sim \pi^*, \nu_0} \left[\mathbf{1}_{a=a_s} \mathcal{L}_{BE}(Q)(s, a)\right]
\end{aligned}$$

假设 2

对所有 $s \in \mathcal{S}$，存在一个行动 $a_s \in \mathcal{A}$，令 $r(s, a_s) = 0$。

在假设 2 下，有：

$$Q = Q^*, r = r^*$$

$$\Updownarrow \text{ Magnac and Thesmar（2009）}$$

1. Q 最小化 $\mathbb{E}_{(s,a)\sim\pi^*,\nu_0}[\mathcal{L}_{NLL}(Q)(s,a)]$

   不含与 r 相关的项

2. Q 最小化 $\mathbb{E}_{(s,a)\sim\pi^*,\nu_0}[1_{a=a_s}\mathcal{L}_{BE}(Q)(s,a)]$

   由于假设 2，不含未知的 r

不再需要对 r 参数化。通过对 Q 参数化，可以避免嵌套优化！

通过期望风险最小化实现一次性最小化

定义 2（期望风险最小化问题）

期望风险最小化问题定义为寻找 Q，

使期望风险 $\mathcal{R}_{exp}(Q)$ 最小，期望风险定义为

$$\mathcal{R}_{exp}(Q) := \mathbb{E}_{(s,a)\sim\pi^*,\nu_0}\left[\mathcal{L}_{NLL}(Q)(s,a) + \mathbb{1}_{a=a_s}\mathcal{L}_{BE}(Q)(s,a)\right]$$

定理 3（通过期望风险最小化实现识别）

期望风险最小化问题的解 $\widehat{Q}$ 在 $s \in \bar{\mathcal{S}}$、$a \in \mathcal{A}$ 的范围内

唯一地识别 Q^*。此外，在 $s \in \bar{\mathcal{S}}$、$a \in \mathcal{A}$ 的范围内，可以通过下式唯一地识别 r

$$r(s,a) = \widehat{Q}(s,a) - \beta \cdot E_{s_{t+1}\sim P(s_t,a_t)}\left[\ln\left(\sum_{a\in\mathcal{A}}\exp\left(\widehat{Q}\left(s_{t+1},a\right)\right)\right) \mid s_t, a_t\right]$$

提纲

动机：大规模问题

回顾：动态离散选择（DDC）模型

回顾：关于求解 DDC 模型我们已经知道什么

一次性的基于梯度的优化方法

估计的偏误修正与经验风险最小化框架

GLADIUS 算法及其全局最优性

模拟实验

估计的挑战与 TD 方法

估计并最小化

$$\mathcal{R}_{exp}(Q) := \mathbb{E}_{(s,a)\sim\pi^*,\nu_0}\left[\mathcal{L}_{NLL}(Q)(s,a) + \mathbb{1}_{a=a_s}\mathcal{L}_{BE}(Q)(s,a)\right]$$

看起来很直接，但由于 $\mathcal{L}_{BE}(Q)(s,a) = (\mathcal{T}Q(s,a) - Q(s,a))^2$ 这一项，它很有挑战性

- $\mathcal{T}Q(s,a) := r(s,a) + \beta\mathbb{E}_{s'\sim P(s,a)}\left[\ln\left(\sum_{a\in\mathcal{A}}\exp(Q(s',a))\right) \mid s,a\right]$ 在经验上无法得到，除非我们知道转移函数
- 而 $\widehat{\mathcal{T}}Q(s,a,s') := r(s,a) + \beta\left[\ln\left(\sum_{a\in\mathcal{A}}\exp(Q(s',a))\right) \mid s,a\right]$ 是可以得到的。

因此，$\mathcal{L}_{BE}(Q)(s,a) = (\mathcal{T}Q(s,a) - Q(s,a))^2$ 这一项的自然替代是

$$\mathbb{E}_{s'\sim P(s,a)}\left[\mathcal{L}_{TD}(Q)(s,a,s')\right] = \mathbb{E}_{s'\sim P(s,a)}[(\widehat{\mathcal{T}}Q(s,a,s') - Q(s,a))^2]$$

这常被称为时间差分（TD）方法。它可行吗？

TD 方法并不最小化 Bellman 误差

问题：TD 方法由于偏误，不能保证 Bellman 方程成立。[13]

引理 4（TD 是有偏的）

$$\mathbb{E}_{s'\sim P(s,a)}\left[\mathcal{L}_{TD}(Q)(s,a,s')\right] = \mathcal{L}_{BE}(Q)(s,a) + \underbrace{\mathbb{E}_{s'\sim P(s,a)}\left[(\mathcal{T}Q(s,a) - \hat{\mathcal{T}}Q(s,a,s'))^2\right]}_{\text{除非 } P \text{ 是确定性的，否则永远不为 0}}$$

定义 $\delta_Q(s,a,s') := \widehat{\mathcal{T}}Q(s,a,s') - Q(s,a)$。直观地说，上述偏误的产生是因为

$$\mathbb{E}_{s'\sim P(s,a)}\left[\delta_Q\left(s,a,s'\right)^2 \mid s,a\right] \neq \mathbb{E}_{s'\sim P(s,a)}\left[\delta_Q\left(s,a,s'\right) \mid s,a\right]^2$$

[13] 出于同样的原因，Adusumilli and Eckardt（2022）提出的半梯度 TD 方法也不能保证 Bellman 方程成立。

双共轭技巧

我们采用一种常被称为“双共轭技巧”的方法，用称为双共轭的线性函数

代替有问题的平方函数：

$$\begin{aligned}\mathcal{L}_{BE}(s,a)(Q) &:= \mathbb{E}_{s'\sim P(s,a)}\left[\delta_Q\left(s,a,s'\right) \mid s,a\right]^2 \\ &= \max_{h\in\mathbb{R}} 2\cdot \mathbb{E}_{s'\sim P(s,a)}\left[\delta_Q\left(s,a,s'\right) \mid s,a\right]\cdot h - h^2\end{aligned}$$

进一步用 $\zeta = h - r(s,a) + Q(s,a)$ 对 h 重新参数化，经过一些代数运算，得到

引理 5（见下页）

用双共轭技巧去偏

引理 5

(a) 平方 Bellman 误差可以表示为

$$\begin{aligned}\mathcal{L}_{BE}(Q)(s,a) &:= (\mathcal{T}Q(s,a) - Q(s,a))^2 \\ &= \mathbb{E}_{s'\sim P(s,a)}\left[\mathcal{L}_{TD}(s,a,s')(Q)\right] - \beta^2 D(Q)(s,a)\end{aligned}$$

其中 $V_Q(s) := \ln\left(\sum_{a\in\mathcal{A}} \exp(Q(s,a))\right)$，

$$D(Q)(s,a) := \underbrace{\min_{\zeta\in\mathbb{R}} \mathbb{E}_{s'\sim P(s,a)}\left[\left(V_Q(s') - \zeta\right)^2 \mid s,a\right]}_{\text{由 } P \text{ 导致的 } V_Q(s') \text{ 的方差}}$$

(b) 将 $D(Q)(s,a)$（在所有状态与行动上）的最小值点定义为

$$\zeta^* : (s,a) \mapsto \underbrace{\arg\min_{\zeta\in\mathbb{R}} \mathbb{E}_{s'\sim P(s,a)}\left[\left(V^*(s') - \zeta\right)^2 \mid s,a\right]}_{\mathbb{E}_{s'\sim P(s,a)}[V^*(s')]}$$

则 $r(s,a) = Q^*(s,a) - \beta\zeta^*(s,a)$。

修改后的一次性最小化框架

定理 6

Q^* 由下式唯一识别

$$\begin{aligned}
&\min_{Q\in\mathcal{Q}} \mathcal{R}_{exp}(Q) \\
&= \min_{Q\in\mathcal{Q}} \mathbb{E}_{(s,a)\sim\pi^*,\nu_0}\left[\mathcal{L}_{NLL}(Q)(s,a) + \mathbb{1}_{a=a_s}\left\{\mathbb{E}_{s'\sim P(s,a)}\left[\mathcal{L}_{TD}(Q)(s,a,s')\right] - \beta^2 D(Q)(s,a)\right\}\right] \\
&= \min_{Q\in\mathcal{Q}} \max_{\zeta\in\mathbb{R}^{S\times A}} \mathbb{E}_{(s,a)\sim\pi^*,\nu_0,s'\sim P(s,a)}\Big[\underbrace{-\log\left(\hat{p}_Q(a\mid s)\right)}_{1)} + \mathbb{1}_{a=a_s}\Big\{\underbrace{\left(\hat{\mathcal{T}}Q(s,a,s') - Q(s,a)\right)^2}_{2)} \\
&\quad - \beta^2 \underbrace{\left(\left(V_Q(s') - \zeta(s,a)\right)^2\right)}_{3)}\Big\}\Big] \qquad (3)
\end{aligned}$$

此外，$r(s,a) = Q^*(s,a) - \beta\zeta^*(s,a)$，其中 ζ^* 在引理 5 中定义。

也就是说，估计出 Q^* 之后，r 的估计无需额外成本。

定义 3（经验风险最小化）

给定 $N := |\mathcal{D}|$，其中 $\mathcal{D}$ 是有限数据集。经验风险最小化问题定义为

寻找使经验风险 $\mathcal{R}_{emp}(Q;\mathcal{D})$ 最小的 Q 的问题，经验风险定义为

$$\mathcal{R}_{emp}(Q;\mathcal{D}) := \max_{\zeta\in\mathbb{R}^{S\times A}} \frac{1}{N} \sum_{(s,a,s')\in\mathcal{D}}$$

$$\Big[-\log\left(\hat{p}_Q(a\mid s)\right) + \mathbb{1}_{a=a_s}\Big\{\left(\hat{\mathcal{T}}Q\left(s,a,s'\right) - Q(s,a)\right)^2 - \beta^2\left(V_Q\left(s'\right) - \zeta(s,a)\right)^2\Big\}\Big]$$

$$= \frac{1}{N}\Big[\sum_{(s,a,s')\in\mathcal{D}} \left(-\log\left(\hat{p}_Q(a\mid s)\right)\right) + \mathbb{1}_{a=a_s}$$

$$\Big(\sum_{(s,a,s')\in\mathcal{D}} \left(\hat{\mathcal{T}}Q\left(s,a,s'\right) - Q(s,a)\right)^2 - \beta^2 \min_{\zeta\in\mathbb{R}^{S\times A}} \sum_{(s,a,s')\in\mathcal{D}} \left(V_Q\left(s'\right) - \zeta(s,a)\right)^2\Big)\Big] \qquad (4)$$

提纲

动机：大规模问题

回顾：动态离散选择（DDC）模型

回顾：关于求解 DDC 模型我们已经知道什么

一次性的基于梯度的优化方法

估计的偏误修正与经验风险最小化框架

GLADIUS 算法及其全局最优性

模拟实验

参数化与可实现性

给定 $\dim(\mathcal{S}) < \infty$ 的紧状态空间 $\mathcal{S}$，以及 $|\mathcal{A}| < \infty$ 的有限行动空间 $\mathcal{A}$，考虑一组参数化函数

$$\mathcal{Q} = \left\{ Q_{\boldsymbol{\theta}} : \mathbb{R}^{\dim(\mathcal{S})+\dim(\mathcal{A})} \to \mathbb{R} \mid \boldsymbol{\theta} \in \Theta \subseteq \mathbb{R}^{d_{\boldsymbol{\theta}}}, Q_{\boldsymbol{\theta}} \in \mathcal{F} \right\}$$

其中 $\mathcal{F}$ 表示一类函数，例如线性、多项式或深度神经网络函数类，由 θ 参数化。我们作如下假设，常称为可实现性假设。

假设 3（可实现性）

$\mathcal{Q}$ 包含最优函数 Q^*，即存在 $\theta^* \in \Theta$ 使 $Q_{\theta^*} = Q^*$。

用梯度上升—下降求解极小极大优化

我们希望求解极小极大优化问题

$$\min_{Q\in\mathcal{Q}} \frac{1}{N}\Big[\sum_{(s,a,s')\in\mathcal{D}} \big(-\log\left(\hat{p}_Q(a\mid s)\right)\big) + \mathbb{1}_{a=a_s}$$
$$\Big(\sum_{(s,a,s')\in\mathcal{D}} \left(\hat{\mathcal{T}}Q\left(s,a,s'\right) - Q(s,a)\right)^2 - \beta^2 \min_{\zeta\in\mathbb{R}^{S\times A}} \sum_{(s,a,s')\in\mathcal{D}} \left(V_Q\left(s'\right) - \zeta(s,a)\right)^2\Big)\Big]$$

求解极小极大优化的经典方法是梯度上升—下降 [14]

- 以任意的 ζ_{θ_1} 与 Q_{θ_2} 初始化
- 交替进行：对 ζ_{θ_1} 最大化，对 Q_{θ_2} 最小化

[14] Yang et al., "Global convergence and variance-reduced optimization for a class of nonconvex-nonconcave minimax problems"

Algorithm 1 **G**radient-based **L**earning with **A**scent-**D**escent for **I**nverse **U**tility learning from **S**amples (GLADIUS)

Require: Offline dataset $\mathcal{D} = \{(s, a, s')\}$, time horizon T
Ensure: $\widehat{r}$, $\widehat{Q}$

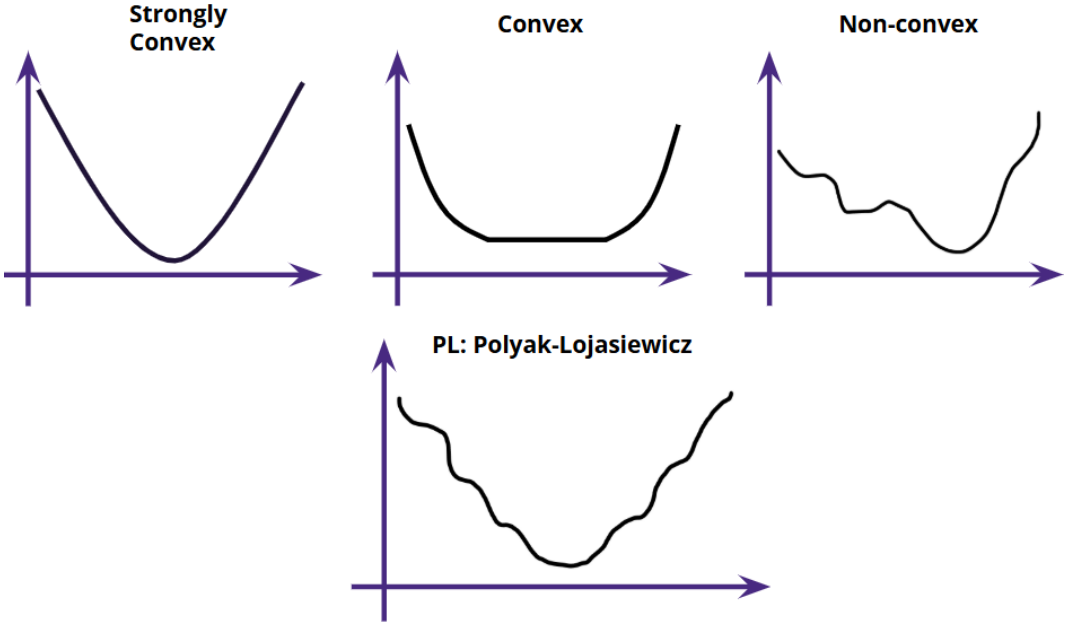
Initialize $Q_{\boldsymbol{\theta_2}}$, $\zeta_{\boldsymbol{\theta_1}}$, iteration $\leftarrow 1$
while $t \leq T$ **do**
  Draw batches B_1, B_2 from $\mathcal{D}$
  [Ascent Step: Update $\zeta_{\boldsymbol{\theta_1}}$, fixing $Q_{\boldsymbol{\theta_2}}$ and $V_{\boldsymbol{\theta_2}}$]
  $D_{\boldsymbol{\theta_1}} \leftarrow \sum_{(s,a,s') \in B_2} \left(V_{\boldsymbol{\theta_2}}(s') - \zeta_{\boldsymbol{\theta_1}}(s, a)\right)^2$
  where $V_{\boldsymbol{\theta}}(s') := \log \sum_{\tilde{a} \in \mathcal{A}} \exp(Q_{\boldsymbol{\theta}}(s', \tilde{a}))$
  $\boldsymbol{\theta_1} \leftarrow \boldsymbol{\theta_1} - \tau_1 \nabla_{\boldsymbol{\theta_1}} D_{\boldsymbol{\theta_1}}$
  [Descent Step: Update $Q_{\boldsymbol{\theta_2}}$ and $V_{\boldsymbol{\theta_2}}$, fixing $\zeta_{\boldsymbol{\theta_1}}$]
  $\overline{\mathcal{L}_{NLL}} \leftarrow \sum_{(s,a,s') \in B_2} -\log\left(\hat{p}_{\boldsymbol{\theta_2}}(a \mid s)\right)$
  $\overline{\mathcal{L}_{\text{BE}}} \leftarrow \sum_{(s,a,s') \in B_1} \mathbb{1}_{a=a_s^*} \left[\mathcal{L}_{TD}(Q)\,(s, a, s') - \beta^2 (V_{\boldsymbol{\theta_2}}(s') - \zeta_{\boldsymbol{\theta_1}}(s, a))^2\right]$
  where $\mathcal{L}_{TD}(Q)\,(s, a, s') := \left(\hat{\mathcal{T}} Q\,(s, a, s') - Q(s, a)\right)^2$
  $\mathcal{L}_{\boldsymbol{\theta_2}} \leftarrow \overline{\mathcal{L}_{\text{NLL}}} + \overline{\mathcal{L}_{\text{BE}}}$
  $\boldsymbol{\theta_2} \leftarrow \boldsymbol{\theta_2} - \tau_1 \nabla_{\boldsymbol{\theta_2}} \mathcal{L}_{\boldsymbol{\theta_2}}$
  iteration $\leftarrow$ iteration $+ 1$
end while
$\widehat{\zeta} \leftarrow \zeta_{\boldsymbol{\theta_1}}$
$\widehat{Q} \leftarrow Q_{\boldsymbol{\theta_2}}$
$\widehat{r}(s, a) \leftarrow \widehat{Q}(s, a) - \beta \cdot \widehat{\zeta}(s, a)$

定义 4（关于 ℓ_2 范数的 Polyak-Łojasiewicz（PL）条件）

给定 $\Theta \in \mathbb{R}^{d_\theta}$，若函数 $g : \Theta \to \mathbb{R}$ 满足下列条件，则称其满足关于 ℓ_2 范数的

Polyak-Łojasiewicz（PL）条件：g 的解集非空，对 $\theta^* \in \Theta \subseteq \mathbb{R}^d$ 有有限的最小值 $g(\theta^*)$，

并且存在某个 $c > 0$，使得 $\frac{1}{2}\|\nabla g(\theta)\|_2^2 \geq c(g(\theta) - g(\theta^*))$，$\forall \theta \in \Theta$。


Strongly Convex
Convex
Non-convex
PL: Polyak-Lojasiewicz

GLADIUS 何时全局最优？

引理 7（Yang et al.，2020）

对函数 $f(\theta_1, \theta_2)$ 的极小极大优化（对 θ_1 最小化、对 θ_2 最大化），

若函数关于 θ_1 与 θ_2 都满足PL 条件，则梯度上升—下降

保证收敛到全局最小值。

推论 8

若下式

$$\frac{1}{N}\Big[\sum_{(s,a,s')\in\mathcal{D}}\left(-\log\left(\hat{p}_{Q_{\theta_2}}(a\mid s)\right)\right)+\mathbb{1}_{a=a_s}$$

$$\Big(\sum_{(s,a,s')\in\mathcal{D}}\left(\hat{\mathcal{T}}Q_{\theta_2}(s,a,s')-Q_{\theta_2}(s,a)\right)^2-\beta^2\sum_{(s,a,s')\in\mathcal{D}}\left(V_{Q_{\theta_2}}(s')-\zeta_{\theta_1}(s,a)\right)^2\Big)\Big]$$

关于 θ_1 与 θ_2 都满足 PL 条件，则 GLADIUS 达到全局最优。

GLADIUS 是全局最优的吗？

引理 9

对于 Q 的线性函数与神经网络参数化 Q_θ，$\mathcal{L}_{NLL}(Q_\theta)(s,a)$ 与

$\mathcal{L}_{BE}(Q_\theta)(s,a)$ 关于 θ 满足 PL 条件。

引理 10

对于 Q 与 ζ 的线性函数与神经网络参数化，期望风险与

经验风险都关于 θ_1 与 θ_2 满足 PL 条件。

定理 11（GLADIUS 的全局最优性）

对于 Q 与 ζ 的线性函数与神经网络参数化，上式

关于 θ_1 与 θ_2 都满足 PL 条件。也就是说，GLADIUS 达到全局最优。

引理 12（Charles and Papailiopoulos（2018），Lei（2023））

将 N 个样本的数据集记为 $\mathcal{D}_N$，并把经验风险 $\mathcal{R}_{emp}(\theta)$ 的最小值点记为 $\theta^*_{\mathcal{D}_N}$。若 $\mathcal{R}_{emp}(\theta)$ 关于 θ 满足 PL 条件，则

$$\mathbb{E}_{\mathcal{D}_N}\left[\left(\boldsymbol{\theta}^*_{\mathcal{D}_N}-\boldsymbol{\theta}^*\right)^2\right]\leq\frac{2\sigma}{N}$$

其中 σ 在论文中给出。

GLADIUS 的理论结果——总结

定理 13（全局收敛）

在假设 3 下，对 Q 与 ζ 的线性和神经网络参数化，

$$\mathbb{E}_{\mathcal{D}_N}\left[\left(\theta^* - \hat{\theta}_T\right)^2\right] \leq \frac{2\nu}{\gamma + T} + \frac{2\sigma}{N}$$

其中 T 为梯度步数，N 为样本量，常数 γ、

ν 与 σ 的取值在论文中给出。

这是 $O(1/\sqrt{T})$ 以及 $O(1/\sqrt{N})$ 速率的收敛（与现有参数方法相当）

提纲

动机：大规模问题

回顾：动态离散选择（DDC）模型

回顾：关于求解 DDC 模型我们已经知道什么

一次性的基于梯度的优化方法

估计的偏误修正与经验风险最小化框架

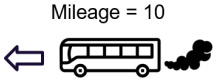
GLADIUS 算法及其全局最优性

模拟实验

A standard econometrics benchmark: Rust (1987) bus engine replacement simulation







A standard econometrics benchmark: Rust (1987) bus engine replacement simulation





Engine replacement

v.s.

Engine maintenance

Replacement cost = $\text{mileage} * c_1$

Maintenance cost = c_2

A standard econometrics benchmark: Rust (1987) bus engine replacement simulation





Engine replacement

Mileage = 0 (reset)



Engine maintenance

Mileage = 10 (continued)



(when bus returns, mileage randomly increases)

性能测试

No. of Trajectories (H=100)	Oracle Baselines		Nonparametric, No Knowledge of Transition Probabilities			
	Rust	ML-IRL	**Ours**	SAmQ	IQ-learn	BC

性能测试

No. of Trajectories (H=100)	Oracle Baselines		Nonparametric, No Knowledge of Transition Probabilities			
	Rust	ML-IRL	**Ours**	SAmQ	IQ-learn	BC

“Oracle” baselines use

1. Linear reward model: Replacement cost = $\text{mileage} * c_1$
   Maintenance cost = c_2

2. Exact transition probabilities

性能测试

No. of Trajectories (H=100)	Oracle Baselines		Nonparametric, No Knowledge of Transition Probabilities			
	Rust	ML-IRL	**Ours**	SAmQ	IQ-learn	BC

Developed by Amazon;
Q parametrization + TD

性能测试

No. of Trajectories (H=100)	Oracle Baselines		Nonparametric, No Knowledge of Transition Probabilities			
	Rust	ML-IRL	**Ours**	SAmQ	IQ-learn	BC

Popular IRL algorithms

性能测试

Mean Absolute Percentage Error (MAPE) $\frac{1}{N}\sum_{i=1}^{N}\left|\frac{\hat{r_i}-r_i}{r_i}\right| \times 100$

No. of Trajectories (H=100)	Oracle Baselines		Nonparametric, No Knowledge of Transition Probabilities			
	Rust	ML-IRL	**Ours**	SAmQ	IQ-learn	BC
	MAPE (SE)	MAPE (SE)	MAPE (SE)	MAPE (SE)	MAPE (SE)	MAPE (SE)

性能测试

Mean Absolute Percentage Error (MAPE) $\frac{1}{N}\sum_{i=1}^{N}\left|\frac{\hat{r_i}-r_i}{r_i}\right| \times 100$

No. of Trajectories (H=100)	Oracle Baselines		Nonparametric, No Knowledge of Transition Probabilities			
	Rust	ML-IRL	**Ours**	SAmQ	IQ-learn	BC
	MAPE (SE)	MAPE (SE)	MAPE (SE)	MAPE (SE)	MAPE (SE)	MAPE (SE)
50						
250						
500						
1000						
2500						
5000						

Based on 20 repetitions. Oracle baselines (Rust, MLIRL) were based on bootstrap repetition of 100.

性能测试

Mean Absolute Percentage Error (MAPE) $\frac{1}{N}\sum_{i=1}^{N}\left|\frac{\hat{r}_i - r_i}{r_i}\right| \times 100$

No. of Trajectories (H=100)	Oracle Baselines		Nonparametric, No Knowledge of Transition Probabilities			
	Rust	ML-IRL	**Ours**	SAmQ	IQ-learn	BC
	MAPE (SE)	MAPE (SE)	MAPE (SE)	MAPE (SE)	MAPE (SE)	MAPE (SE)
50	3.62 (1.70)	3.62 (1.74)	**3.44** (1.28)	4.92 (1.20)	114.13 (26.60)	80.55 (12.82)
250	1.37 (0.77)	1.10 (0.78)	**0.84** (0.51)	3.65 (1.00)	112.86 (27.31)	72.04 (13.21)
500	0.90 (0.56)	0.84 (0.59)	**0.55** (0.20)	3.13 (0.86)	113.27 (25.54)	71.92 (12.44)
1000	0.71 (0.49)	0.64 (0.48)	**0.52** (0.22)	1.55 (0.46)	112.98 (24.12)	72.17 (12.11)
2500	0.68 (0.22)	0.62 (0.35)	**0.13** (0.06)	N/A	111.77 (23.99)	62.61 (10.75)
5000	0.40 (0.06)	0.43 (0.26)	**0.12** (0.06)	N/A	119.18 (22.55)	46.45 (8.22)

Based on 20 repetitions. Oracle baselines (Rust, MLIRL) were based on bootstrap repetition of 100.

为什么会这样？

原因 1：GLADIUS 只在频繁出现的区域表现良好

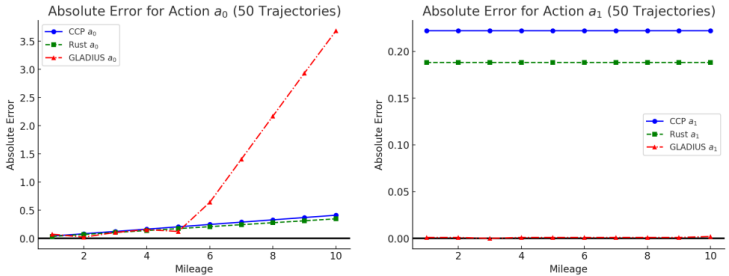


Figure 2: Reward estimation error comparison for 50 trajectories. Closer to 0 (black line) is better.

Mileage	Frequency		Ground Truth r		ML-IRL		Rust		GLADIUS	
	a_0	a_1	a_0	a_1	a_0	a_1	a_0	a_1	a_0	a_1
1	412	37	-1.000	-5.000	-0.959	-4.777	-0.965	-4.812	-1.074	-4.999
2	65	18	-2.000	-5.000	-1.918	-4.777	-1.931	-4.812	-1.978	-5.001
3	43	80	-3.000	-5.000	-2.877	-4.777	-2.896	-4.812	-3.105	-5.000
4	24	101	-4.000	-5.000	-3.836	-4.777	-3.861	-4.812	-3.844	-5.001
5	8	134	-5.000	-5.000	-4.795	-4.777	-4.827	-4.812	-4.878	-5.001
6	4	37	-6.000	-5.000	-5.753	-4.777	-5.792	-4.812	-6.642	-5.001
7	1	26	-7.000	-5.000	-6.712	-4.777	-6.757	-4.812	-8.406	-5.001
8	0	7	-8.000	-5.000	-7.671	-4.777	-7.722	-4.812	-10.170	-5.001
9	0	2	-9.000	-5.000	-8.630	-4.777	-8.688	-4.812	-11.934	-5.001
10	0	1	-10.000	-5.000	-9.589	-4.777	-9.653	-4.812	-13.684	-5.002

Table 5: Reward estimation for 50 trajectories. Color indicates appearance frequencies.

原因 2：数据不平衡下的估计困难

这是 RL 中众所周知的问题 [15]：“若行为策略诱导的分布不能充分覆盖状态空间，
那么，相对于该分布向函数近似器空间作投影，
可能导致较差的表现。”

- 即外推到数据稀少的区域 =
- 所有轨迹都从里程 1 开始，并且更换行动（行动 0）会把里程重置为 1。
  因此，专家数据中观测到的大多数状态都在里程 1—5 之间。

[15] Tsitsiklis and Van Roy, “Analysis of temporal-difference learning with function approximation”, NeurIPS 1996

A standard econometrics benchmark: Rust (1987) bus engine replacement simulation



What if we don't know mileage only matters?



Bus mileage at $t = 1$

Bus age at $t = 1$

Downtime cost

Customer complaints

Engine temperature

⋮

More dummy variables

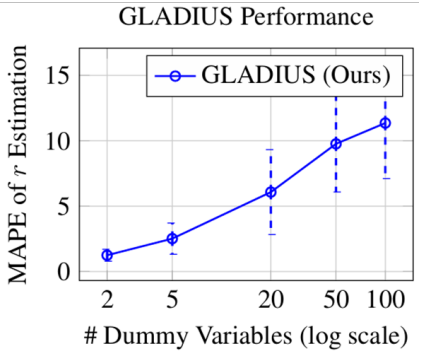
⋮

可扩展性测试结果

Mean Absolute Percentage Error (MAPE) $\frac{1}{N}\sum_{i=1}^{N}\left|\frac{\hat{r}_i - r_i}{r_i}\right| \times 100$

Dummy Variables	**Ours**	SAmQ	IQ-learn	BC
	MAPE (SE)	MAPE (SE)	MAPE (SE)	MAPE (SE)
2	**1.24** (0.45)	1.79 (0.37)	112.0 (14.8)	150.9 (29.1)
5	**2.51** (1.19)	2.77 (0.58)	192.2 (19.2)	171.1 (37.3)
20	**6.07** (3.25)	N/A	180.1 (15.6)	180.0 (33.7)
50	**9.76** (3.68)	N/A	282.2 (25.2)	205.1 (35.3)
100	**11.35** (4.24)	N/A	321.1 (23.1)	288.8 (42.9)

Based on 10 repetitions. For SAmQ, N/A means that the algorithm did not scale.



总结

- 我们需要一种可扩展的 DDC 方法。能否与非参数（例如机器学习）方法结合？
- 拟合不动点迭代方法被证明是不稳定的。
- 尚不存在全局最优收敛的基于梯度的方法。
- 在本研究中，我们提出了一种！
  - 经验风险最小化（ERM）框架
  - 全局最优收敛，例如即使采用神经网络参数化
  - 在标准基准上有不错的实证表现
  - 可很好地扩展到 10^{100} 个状态（$\gg$ 宇宙中的原子数），精度只损失 10%

进一步讨论

- 问：如果数据量远小于 10^{100} 个状态，怎么可能识别奖励？

  答：可以把它想象成用一张光滑的薄片去拟合地形上少数几个测量点：一旦知道薄片如何弯曲，不必测量每个位置，也能读出任何地方的高度。这张薄片只由几千个可调节的“旋钮”控制（神经网络的权重）。所需的样本量取决于旋钮结构的复杂程度。

- 问：给定 $\hat{r}$，进行反事实分析时难道不仍然需要显式估计 P 吗？

  - 答：不需要。给定数据集 $\{s_0, a_0, s_1, a_1, \ldots\}$，我们现在有 $\{s_0, a_0, \hat{r}(s_0, a_0), s_1, a_1, \hat{r}(s_1, a_1), \ldots\}$。给定一个反事实情景（例如对奖励的干预），就可以直接应用离线 RL 算法来恢复相应的反事实最优策略。

未来的扩展

– 所提出的方法可以扩展到处理不可观测异质性。

- 适应不可观测异质性在机器学习中常被称为“上下文学习（ICL）”
- 有了基于梯度的估计方法，就可以实现 ICL[16,17]
- 本文提出了这样一种方法，因此可以实现 ICL！（工作论文即将发布！）

– PL 条件的证明可以推广到离线强化学习（offline RL）

- 尚未有基于梯度的离线 RL 方法被证明全局收敛
- 本文的结果可以很容易地推广（工作论文即将发布！）

[16] Ahn et al.，“Transformers learn to implement preconditioned gradient descent for in-context learning.”，NeurIPS23

[17] Wang et al.，“Transformers learn temporal difference methods for in-context reinforcement learning.”，arXiv:2405.13861。

感谢聆听！

特别感谢 John Rust 邀请我作这次报告，并对论文提出了详细而富有洞见的意见。也非常感谢 DSE 组织者出色的协调工作。