在结构模型中
引入不可观测异质性

Stéphane Bonhomme

芝加哥大学

计量经济学会暑期学校
动态结构计量经济学

伦敦大学学院，2025 年 7 月 5 日

提纲

1. 混合表示

2. 识别策略

3. 随机效应估计

4. 分组固定效应估计

5. 应用

1．混合表示

一个动态选择模型

- 有限期。选择 c_t，状态 s_t。
- 效用 $u(c_t, s_t)$，贴现因子 β。
- 状态转移 $s_{t+1}|s_t, c_t$。
- 个体最大化期望效用。

$$\max_{c_1,\cdots,c_T} \mathbb{E}\left[\sum_{t=1}^{T} \beta^{t-1} u(c_t, s_t)\right]$$

- Bellman 原理意味着价值函数满足

$$V_t(s_t) = \max_{c_t} u(c_t) + \beta \mathbb{E}\left[V_{t+1}(s_{t+1}) \,|\, s_t, c_t\right].$$

不可观测异质性

- 偏好 u（以及技术、能力等）与贴现 β 的异质性。

- 信念也可能是异质的。

- 状态转移同样可能是异质的。

- 我们主要关注永久性的不可观测异质性（更简单!）。

- 不可观测异质性在数量上很重要。一个经典例子是 Keane and Wolpin（1997）对职业选择的分析。

离散类型还是连续类型

- 结构研究中的一种常见做法，是假设潜在类型只取少数几个值：

$$a \in \mathcal{A} = \{a_1, \ldots, a_K\}，\text{其中 K 是“小”的。}$$

- 这是一种允许多维异质性、又易于处理的方法。

- 例如，效用 $u(c_t, s_t, a)$ 可以因类型而异。等价地，每种类型的个体有自己的效用函数 $u_a(c_t, s_t)$。

- 连续类型建模的优点是更现实，因为它既允许组内异质性也允许组间异质性。但它也更具挑战性。

混合表示

- 令 Y 为包含模型中所有内生变量的向量，包括选择 c_t、（内生）状态变量 s_t，以及其他收益变量。

- 令 X 为包含所有外生变量的向量，包括初始条件与不随时间变化的特征。

- 令 A 为包含潜在类型的向量。

- 最后，令 θ 包含所有结构参数。我们假设 Y, X, A 都是离散的。

- 利用全概率公式，可以写出

$$\Pr(Y = y \mid X = x) = \sum_{a \in \mathcal{A}} \Pr(Y = y \mid X = x, A = a; \theta) \Pr(A = a \mid X = x).$$

线性方程组

- 写成紧凑形式，可以等价地写为（对每个 x）：

$$D_x = M_x(\theta)\pi_x.$$

- 这里 D_x 是“数据”向量，元素个数与 Y 的支撑点数相同，维数为 $n \times 1$。

- $M_x(\theta)$ 是“模型”矩阵，行对应 y，列对应 a，维数为 $n \times K$。

- 最后，π_x 是“异质性”向量，维数为 $K \times 1$。

2. 识别策略

差分（I）：恢复 θ

- 本页及后两页沿用函数差分方法（B.，2012）。

- 从 $D_x = M_x(\theta)\pi_x$ 出发，作“残差”（或“组内”）投影得到

$$\left(I_n - M_x(\theta)M_x(\theta)^\dagger\right) D_x = 0.$$

- 这给出了关于 θ 的矩约束。任意 $n \times 1$ 向量 h_x 都给出一个矩函数

$$\varphi_x(y;\theta) = e_y' \left(I_n - M_x(\theta)M_x(\theta)^\dagger\right) h_x,$$

其中 e_y 是在位置 y 取 1 的标准基向量，满足

$$\mathbb{E}\left[\varphi_X(Y;\theta)\right] = 0.$$

- 识别通常要求 Y 的支撑比 A 的更大（“过度识别”）。

背景：SVD 与 Moore-Penrose 伪逆

- 令 M 为 $n \times K$ 矩阵。总可以写出其奇异值分解（SVD）

$$M = USV',$$

其中 U 为 $n \times n$ 正交矩阵，V 为 $K \times K$ 正交矩阵，S 的左上块为对角阵，其余元素均为零。

- M 的 Moore-Penrose 伪逆为

$$M^{\dagger} = V\tilde{S}U',$$

其中 $S^{\dagger}$ 的左上块为对角阵，其元素是 S 相应元素的倒数，其余元素均为零。

- $MM^{\dagger}$ 与 $I_n - MM^{\dagger}$ 分别是到 M 的像及其正交补上的正交投影。

差分（II）：恢复 π_x

- 假设 $M_x(\theta)$ 的秩为 K。
- 则 $M_x(\theta)^\dagger M_x(\theta) = I_K$。
- 这意味着（给定 θ）π_x 可识别，因为

$$\pi_x = M_x(\theta)^\dagger D_x.$$

- 对任意 $K \times 1$ 向量 g_x，可以构造函数

$$g_x(a) = e_a' g_x,$$

以及

$$\psi_x(a;\theta) = e_a' \left(M_x(\theta)^\dagger\right)' g_x,$$

它们满足

$$\mathbb{E}[\psi_X(A;\theta)] = \mathbb{E}\left[g(A,X)\right].$$

独立性约束

- 前面的论证需要对 $Y|X, A$ 施加参数约束，而结构模型
往往蕴含条件独立性约束，
这类约束有很强的识别力。

- Hu（2008）提出了一种针对离散数据的一般方法，
后来又得到推广（专著见 Hu，2015）。

- 假设给定 A, X 时 $Y = (Y_1, Y_2, Y_3)$ 相互独立，则

$$\begin{aligned}
&\Pr(Y_1 = y_1, Y_2 = y_2, Y_3 = y_3 \,|\, X = x) \\
&= \sum_{a \in \mathcal{A}} \Pr(Y_1 = y_1 \,|\, X = x, A = a) \Pr(Y_2 = y_2 \,|\, X = x, A = a) \\
&\qquad\qquad \times \Pr(Y_3 = y_3 \,|\, X = x, A = a) \Pr(A = a \,|\, X = x).
\end{aligned}$$

- 写成矩阵形式，对给定的 x 与 y_2，

$$D_x^{13}(y_2) = M_x^1 \Delta_x^2(y_2) \left(M_x^3\right)'.$$

特征值分解

- 由上一页，模型蕴含方程组

$$D_x^{13}(y_2) = M_x^1 \Delta_x^2(y_2) \left(M_x^3\right)',$$

其中假设 M_x^1 与 M_x^3 的秩为 K，$\Delta_x^2(y_2)$ 是对角阵。

- 为简单起见，设 $y_2 \in \{0, 1\}$。令 $D_x^{13}(0) = USV'$ 为 $D_x^{13}(0)$ 的奇异值分解。

- 令 $\Omega_x = S^{-\frac{1}{2}} U' M_x^1 \Delta_x^2(0)^{\frac{1}{2}}$. 由于

$$S^{-\frac{1}{2}} U' D_x^{13}(0) V S^{-\frac{1}{2}} = I_K,$$

有

$$\Delta_x^2(0)^{\frac{1}{2}} \left(M_x^3\right)' V S^{-\frac{1}{2}} = \Omega_x^{-1}.$$

特征值分解（续）

- 此外，有

$$S^{-\frac{1}{2}}U'D_x^{13}(1)VS^{-\frac{1}{2}} = \Omega_x\left(\Delta_x^2(0)^{-1}\Delta_x^2(1)\right)\Omega_x^{-1}.$$

- 这是一个特征值分解。

- 因此，若 $\Delta_x^2(0)^{-1}\Delta_x^2(1)$ 的对角元素各不相同，则 Ω_x 的各列作为相应的特征向量被唯一确定。由此 M_x^1 与 M_x^3 可识别。

- 识别只到标签为止，即 M_x^1 与 M_x^3 各列的置换。注意这种标签是因 x 而异的。要在不同 x 之间恢复共同的标签，需要更多地利用模型结构（Aguirregabiria and Mira，2019）。

协变量的识别作用

- 在离散选择中，结果的变异有限。但状态变量和其他协变量往往有更多变异，在附加假设下可以加以利用。

- 例如，假设 X 与 A 独立，则

$$\Pr(Y = y \,|\, X = x) = \sum_{a \in \mathcal{A}} \Pr(Y = y \,|\, X = x, A = a; \theta) \Pr(A = a).$$

- 把各个 x 值的约束堆叠起来，得到

$$D = M(\theta)\pi,$$

其中 D 为 $(n \dim x) \times 1$，π 为 $K \times 1$。

- 类似地，假设动态状态变量的运动规律不依赖于异质性也具有识别作用，如 Kasahara and Shimotsu（2009）所示。

扩展（I）：随时间变化的异质性

- 随时间变化的不可观测变量在结构模型中很重要（例如人力资本、企业生产率、工人努力……）。

- 现有的识别策略依赖马尔可夫假设：

$$A_t \mid A_{t-1}, ..., A_1, Y_{t-1}, ..., Y_1, X_{t-1}, ..., X_1 \overset{d}{=} A_t \mid A_{t-1}, Y_{t-1}, X_{t-1}.$$

- Hu and Shum（2012）给出了识别结果，并应用于结构模型。另见 Arcidiacono and Miller (2011)。

- 关于隐马尔可夫模型（HMM）的统计文献非常多，例如见 Rabiner（1989）的教程。

扩展（II）：连续异质性

- 允许连续异质性会使识别变得复杂。

- 恒等式

$$D_x = M_x(\theta)\pi_x$$

仍然成立，但此时 π_x 是（a 的）函数，$M_x(\theta)$ 是
线性算子（即函数之间的线性映射）。

- 当 Y 是离散的（如结构动态离散选择模型）时，
识别不太可能成立（尽管也有一些例外，
如 Aguirregabiria, Gu and Luo，2021）。

- 当结果是连续的时，Hu and Schennach（2008）给出了
推广 Hu（2008）分析的识别条件。

- 对 M_x^1 与 M_x^3 的满秩假设变成了非参数的
“完备性”条件。

3. 随机效应估计

极大似然

- **将 $\pi_x(a)$ 参数化为 $\pi(a, x; \gamma)$，其中 γ 是低维参数。**

- **似然函数的形式为**

$$L(\theta, \gamma) = \sum_{i=1}^{N} \ln \left(\sum_{a \in \mathcal{A}} \Pr(Y = Y_i \,|\, X = X_i, A = a; \theta) \Pr(A = a \,|\, X = X_i; \gamma) \right).$$

- **一种做法是用嵌套不动点方法（Rust，1987）或 MPEC（Su and Judd，2012）等其他方法最大化这一似然。**

- **在混合模型中，局部最优普遍存在，因此对参数抽取多组初始值很重要。**

EM 算法

- 存在不可观测异质性时，最大化似然的一种常用方法
是期望最大化（EM）算法
（Dempster, Laird, and Rubin，1977）。

- EM 算法在两步之间迭代：

1. E 步：计算后验概率

$$\begin{aligned} p_i(a;\theta,\gamma) &:= \mathsf{Pr}(A=a \,|\, X=X_i, Y=Y_i;\theta,\gamma) \\ &\propto \mathsf{Pr}(Y=Y_i \,|\, X=X_i, A=a;\theta)\,\mathsf{Pr}(A=a \,|\, X=X_i;\gamma). \end{aligned}$$

2. M 步：对 θ', γ' 最大化

$$\sum_{i=1}^{N} \sum_{a\in\mathcal{A}} p_i(a;\theta,\gamma)\,\mathsf{ln}\left(\mathsf{Pr}(Y=Y_i \,|\, X=X_i, A=a;\theta')\,\mathsf{Pr}(A=a \,|\, X=X_i;\gamma')\right).$$

- Arcidiacono and Miller（2011）基于条件选择概率，
为动态离散选择模型发展了一种 EM 方法。

联合对角化

- 在独立性约束下，可以对分布进行非参数估计。

- 考虑给定 A, X 时 $Y = (Y_1, Y_2, Y_3)$ 相互独立的情形。则对所有 y_2，有

$$S^{-\frac{1}{2}} U' D_x^{13}(y_2) V S^{-\frac{1}{2}} = \Omega_x \left(\Delta_x^2(0)^{-1} \Delta_x^2(y_2) \right) \Omega_x^{-1}.$$

- 这启发我们把 Ω_x 估计为一组矩阵的共同特征向量。

- B.、Jochmans and Robin（2015，2016）提出并研究了这类非参数估计量。

- 实现依赖于基于初等旋转（例如 Givens 旋转）的矩阵近似联合对角化算法。

连续异质性

- 在连续情形中，若愿意对异质性的分布进行参数化，就可以最大化积分似然的对数，

$$L(\theta,\gamma)=\sum_{i=1}^{N}\ln\left(\int_{\mathcal{A}}\Pr(Y=Y_i\,|\,X=X_i,A=a;\theta)\pi(a\,|\,X=X_i;\gamma)da\right).$$

- 实现 EM 算法需要近似这些积分。另一种做法是在每个 E 步中，从后验分布抽取 $A_i^{(s)}$，$s=1,\ldots,S$（“随机 EM”）。

- 允许 π_x 为非参数形式（结果分布也可能是非参数的）更具挑战性。对前者，非参数极大似然（Kiefer and Wolfowitz，1957）提供了一种选择。筛极大似然（例如 Chen，2007）提供了一种通用方法。

4. 分组固定效应估计

GFE 模型

- 分组固定效应（GFE）方法（B. and Manresa，2015）提供了看待类型的另一种视角。

- 在这种方法中，所有类型 A_i（$i = 1, \ldots, n$）都被视为待估计的离散参数。

- 不需要异质性的概率模型。

- 此外，类型 A_i 对协变量 X_i 的依赖完全不受限制。

- 例如，可以事后分析估计出的类型 $\widehat{A}_i$ 如何依赖于协变量 X_i。

T 的作用

- 要了解类型 A_i，需要 Y_i 的维数（通常是时间维度 T）相对较大。

- 为了直观理解，假设我们要根据模型 $Y_i = A_i + \overline{U_i}$ 估计类型，其中 $U_i|A_i \sim \mathcal{N}\left(0, \frac{\sigma^2}{T}\right)$。

- 对类型满足 $A_i > A_j$ 的两个个体 i 与 j，分类错误的概率为

$$\Pr\left(\overline{Y}_i < \overline{Y}_j\right) = \Phi\left(-\frac{A_i - A_j}{\sqrt{\frac{2\sigma^2}{T}}}\right).$$

- 只有当 T 趋于无穷时它才趋于零……

- ……但随着 T 增大，它以指数速度趋于零。

联合 GFE 估计

- 似然模型 $f(Y_i|X_i, A_i, \theta)$（给定类型时的结构模型）。

- 联合 GFE 估计量最大化

$$\sum_{i=1}^{n} \ln f(Y_i \mid X_i, A_{k_i}, \theta),$$

关于 θ、$A_1, \ldots, A_K$（“中心”）以及 $k_1, \ldots, k_N$（组别指示变量）。

- 在回归情形中，计算机科学中有大量关于 k 均值聚类与分簇回归算法的文献。近期的分组方法包括 Chetverikov and Manresa（2021）、Mugnier（2023）以及 Gu et al.（2024）。

- 然而，在结构模型中，联合分类与估计的计算代价很高。

两步分组固定效应估计

- B.、Lamadon and Manresa（2022）**提出两步** GFE：

1. **第一步：对个体特定的矩** $h_i = h(Y_i, X_i)$ **应用** k **均值，估计个体单位的划分** $\{\widehat{k}_i\}$；**即：**

$$\left(\widehat{h}, \widehat{k}_1, ..., \widehat{k}_n\right) = \underset{(\tilde{h}, k_1, ..., k_n)}{\text{argmin}} \sum_{i=1}^{n} \left\| h_i - \tilde{h}(k_i) \right\|^2,$$

其中 $(k_1, \ldots, k_n) \in \{1, \ldots, K\}^n$。

2. **第二步：对共同参数与组特定的个体效应最大化对数似然函数，其中分组由第一步估计的** $\widehat{k}_i$ **给出；即：**

$$\left(\widehat{\theta}, \widehat{A}_1, ..., \widehat{A}_K\right) = \underset{(\theta, A_1, ..., A_K)}{\text{argmax}} \sum_{i=1}^{n} \ln f\left(Y_i \,|\, X_i, A_{\widehat{k}_i}, \theta\right).$$

在分组世界中进行分组的理论依据

- **在分组的数据生成过程中，当 n 和 T 趋于无穷时，分组是一致的**（B. and Manresa，2015；Hahn and Moon，2010；Lin and Ng，2012；Su et al.，2016）。

- **参数估计的渐近分布不受分组估计的影响**。

- **分组一致性的条件允许 n 以比 T 快的多项式速度增长。这不需要长面板**。

- **分组一致性取决于各组之间充分分离**。

- **组数 K 可以用** BIC **等信息准则一致估计，也可以用检验方法估计（例如** Lu and Su，2017）。

在连续世界中进行分组的理论依据

- 当异质性 A_i 是连续的时，对固定的 T，随着 n 趋于无穷，类型估计收敛到某些“伪真值”（Pollard，
1981，1982）.

- 此外，只要 K, n, T 都趋于无穷，参数估计对真实参数值仍是一致的（B.、Lamadon and Manresa，2022）。

- 此时，分组是一种正则化手段，K 可以看作调节参数。

- 两步 GFE 估计量的收敛速度在很大程度上取决于异质性的维数。

5. 应用

A．地点选择的动态离散模型

- 选择 j_{it}，收益 W_{it}，状态 (X_{it}, A_i)。

- 似然函数为（在标准假设下）：

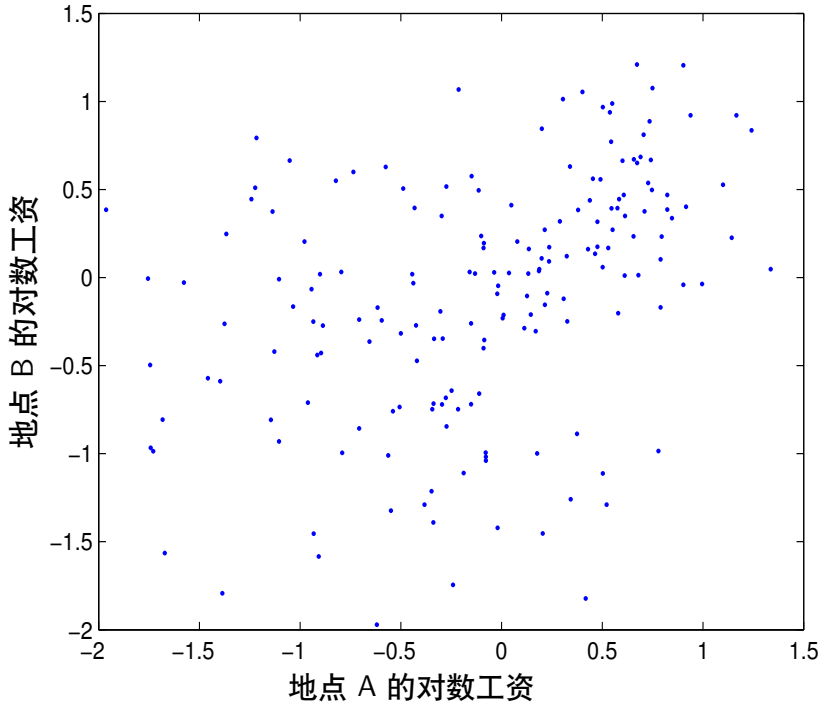
$$\prod_t \underbrace{f\left(j_{it} \mid X_{it}, A_i, \theta\right)}_{\text{choices}} \underbrace{f\left(X_{it} \mid j_{i,t-1}, X_{i,t-1}, A_i, \theta\right)}_{\text{states}} \underbrace{f\left(W_{it} \mid j_{it}, X_{it}, A_i, \theta\right)}_{\text{payoffs}}.$$

- 向量 h_i 可以包含收益变量或可观测状态变量的矩，也可以包含个体选择概率。

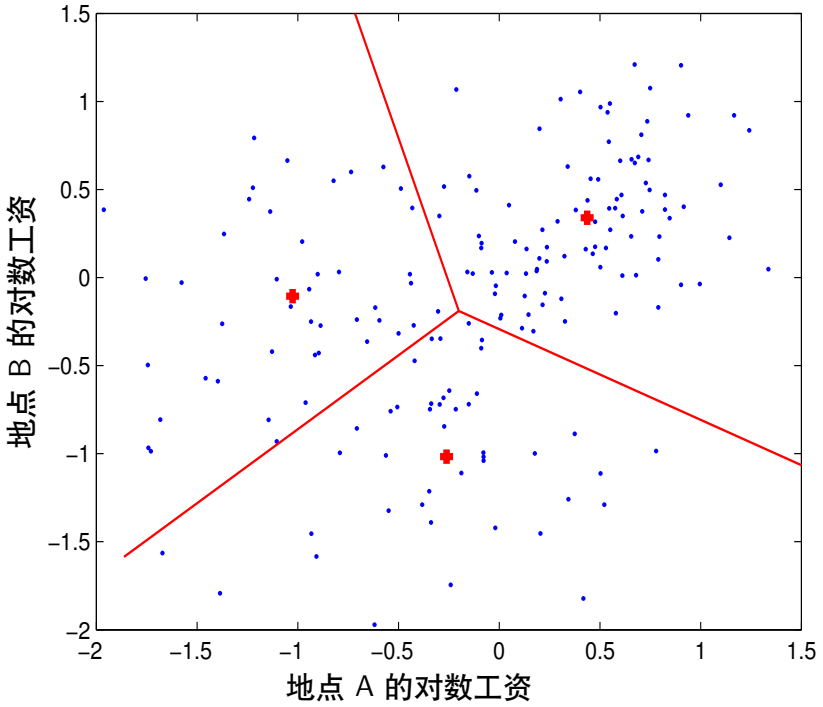
- B.、Lamadon and Manresa（2022）按照 Kennan and Walker（2011）的思路估计了一个地点选择的结构模型。

$K = 3$ 组的 k 均值聚类

(a) 数据



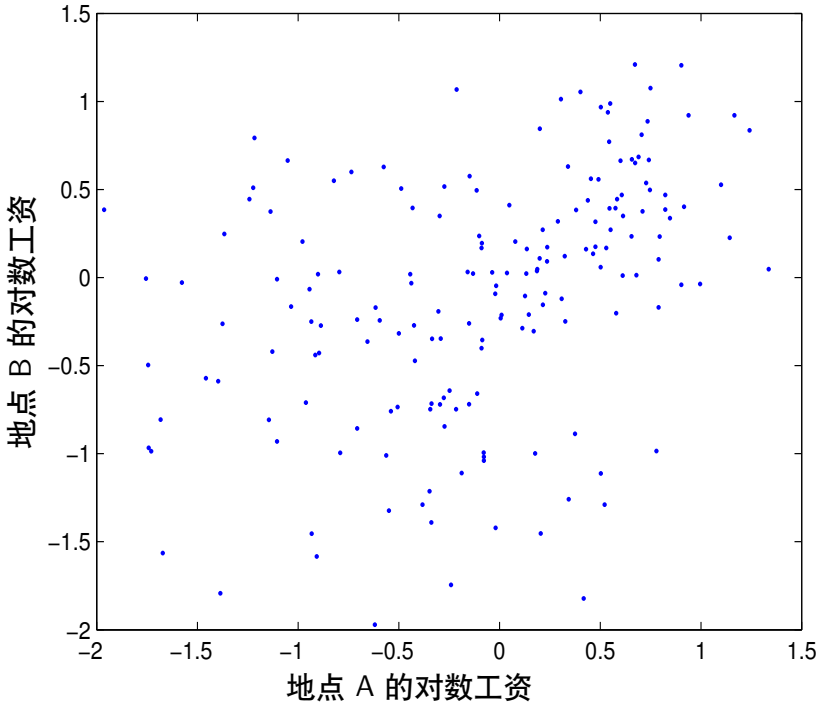
(b) 划分



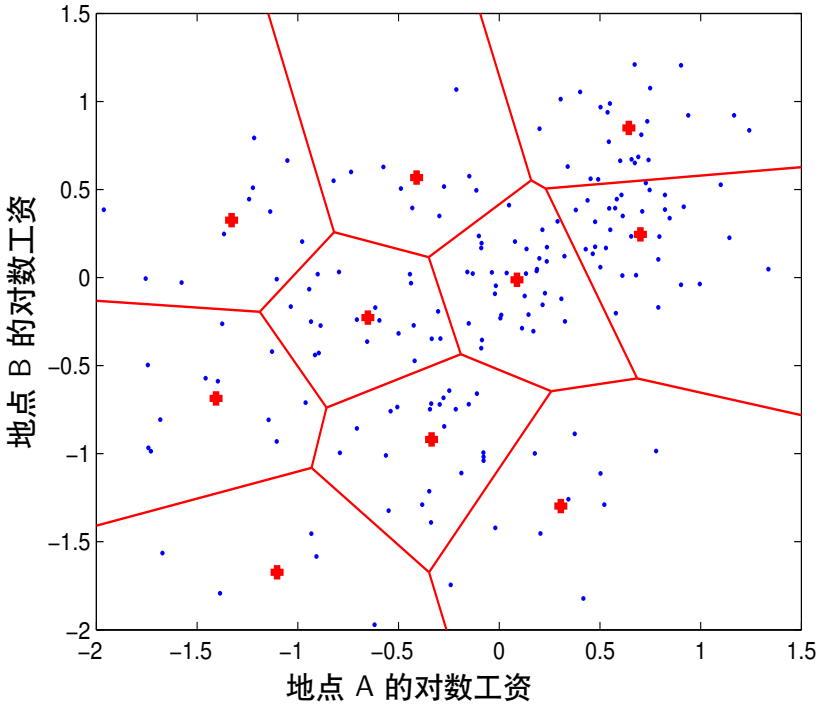
注：NLSY79 中男性迁移者在地点 A（东部）与 B（西部）的平均对数工资。

$K = 10$ 组的 k 均值聚类

(a) 数据



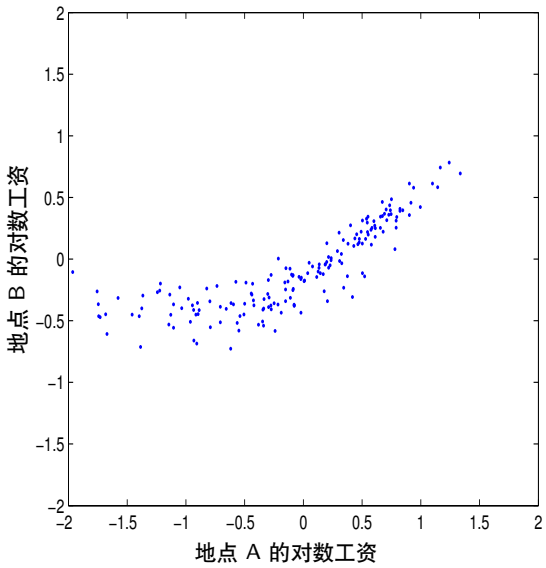
(b) 划分



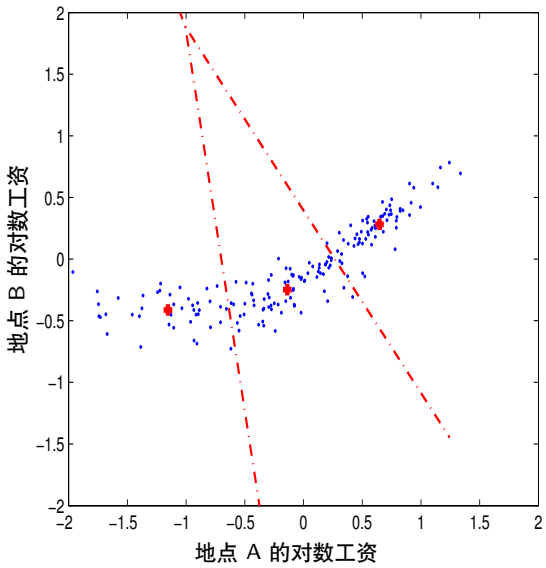
注：NLSY79 中男性迁移者在地点 A（东部）与 B（西部）的平均对数工资。

底层维数较低时的 k 均值

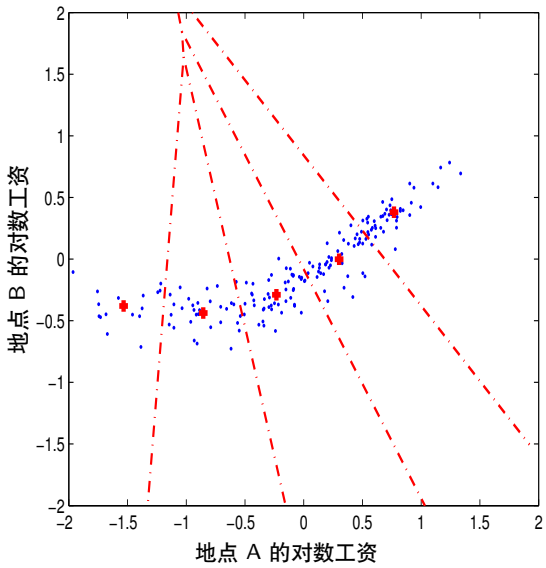
(a) 数据



(b) $K = 3$ 组



(c) $K = 5$ 组



注：样本的条件均值与 NLSY79 相同，条件标准差为其三分之一。

模型（按 Kennan and Walker，2011 的思路）

- **地点**：$j_{it} \in \{1, \ldots, J\}$。**在 j 的对数工资**：$\ln W_{it} = A_i(j) + \varepsilon_{it}(j)$。

- **效用**：$U_{it}(j) = \rho W_{it}(j) + \xi_{it}(j)$。**迁移成本**：$c_{j,j'}$。

- **个体对自己在未来地点的类型 $A_i(\cdot)$ 存在不确定性。他们具有理性预期，求解一个带连续异质性的无限期最优化问题。**

- **离散估计**：**第一步，将地点特定的对数工资均值离散化，估计 $\widehat{A}(j_{it}, \widehat{k}_i)$；第二步，通过求解动态问题估计效用与成本参数。**

- **给定任一地点历史，共有 K 个状态变量。**

校准与模拟

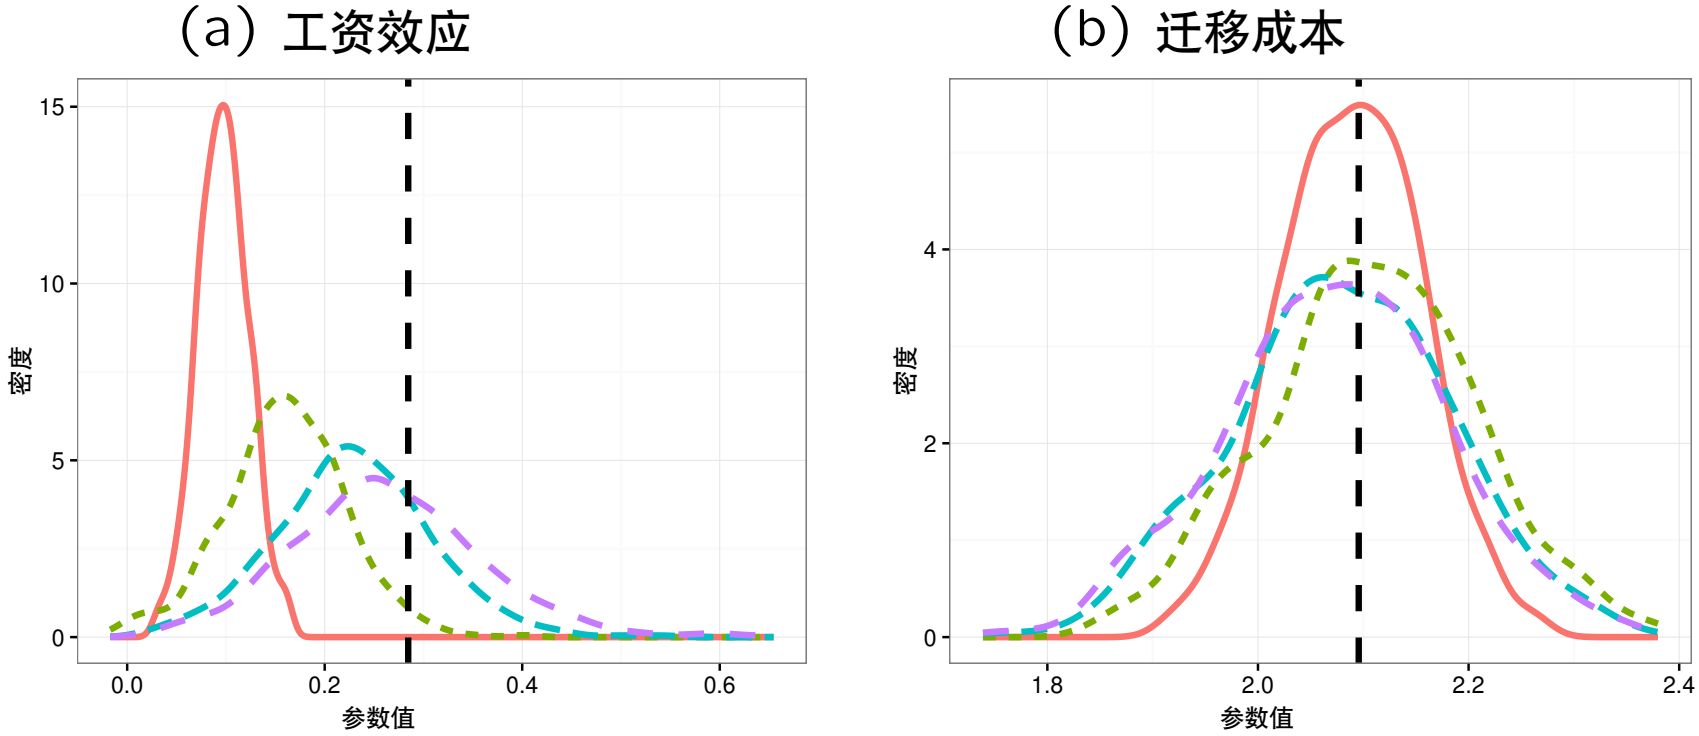
- 用 NLSY79 数据校准参数值。22 岁以上男性，追踪到 1994 年。对数工资残差扣除了年龄、种族和教育虚拟变量。两个地区：A（东北部和南部）与 B（中北部和西部）。A 的工资高 9%。迁移率很低（每年 1.5%）。

- $K = 10$，并仿照 Kennan and Walker（2011），存在成为“留守类型”的概率。估计显示工资效应为正，$\widehat{\rho} = .28$，成本很大，$\widehat{c} = 2.1$（假设对称）。

- 给定参数值，模拟带连续异质性的模型。假设 $(A_i(1), A_i(2))$ 服从二元正态分布。

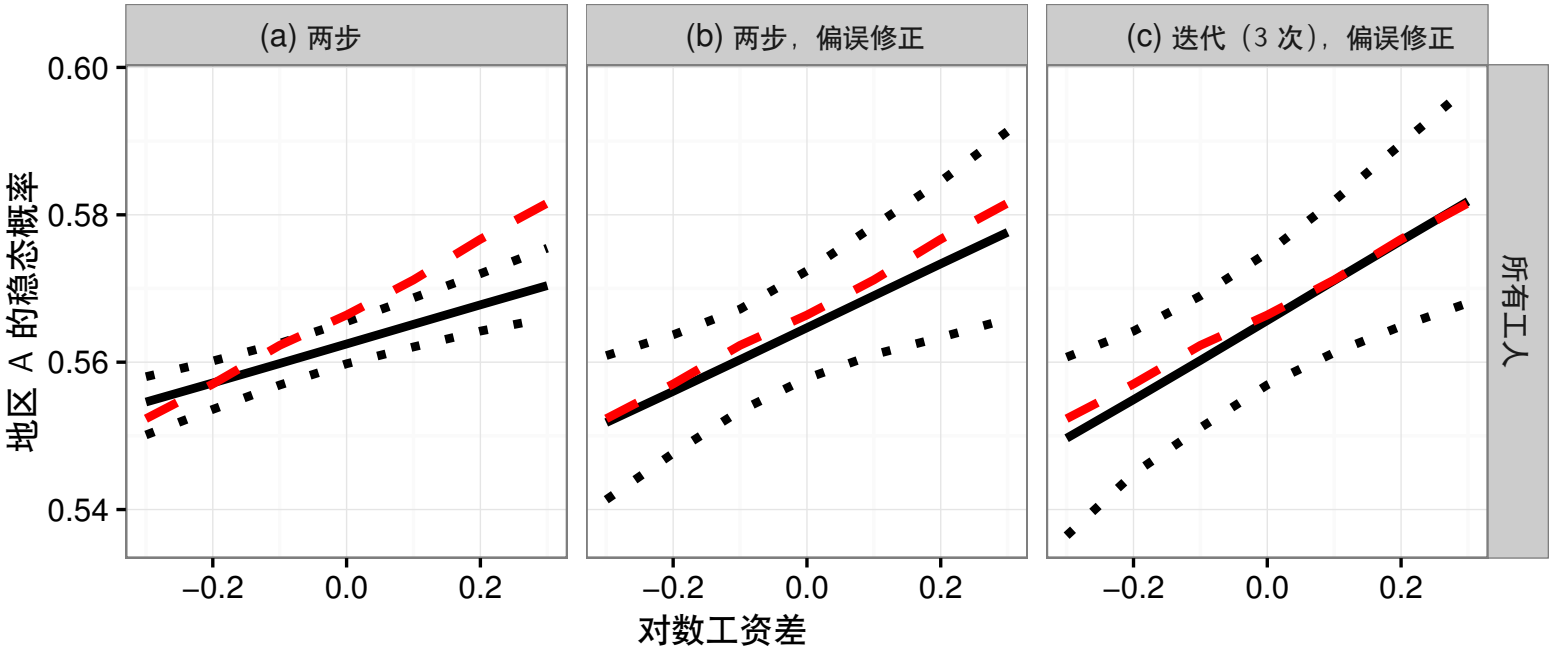
- 用两步 GFE 估计模型。

参数估计（$\widehat{K}$ 的平均值为 7）



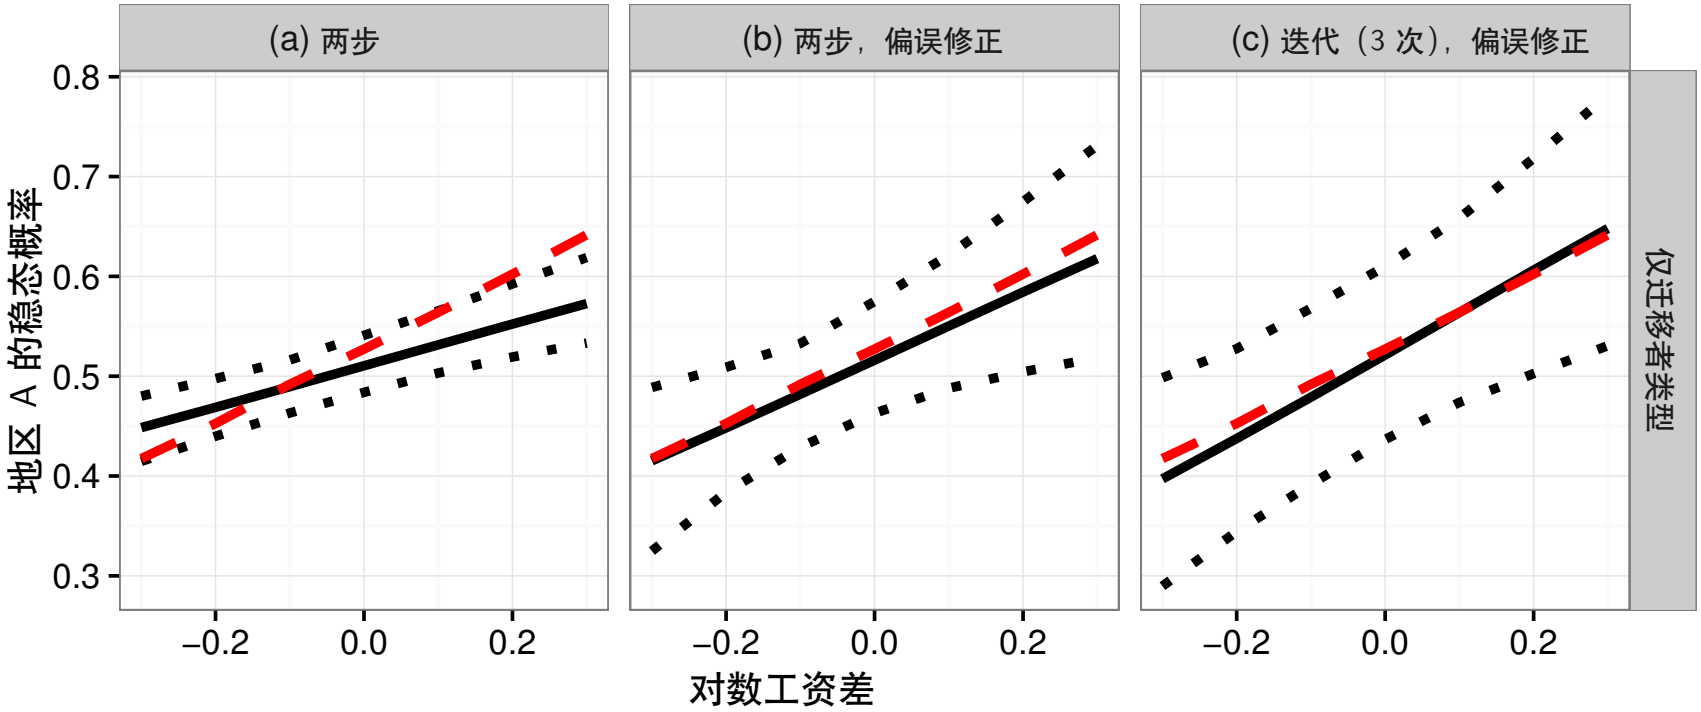
注：实线为两步分组固定效应，点线为偏误修正后的结果，虚线为迭代一次并修正偏误，点划线为迭代三次并修正偏误。竖线表示真实参数值。$N = 1889, T = 16$，500 次重复。

工资对地点的长期影响



注：(*a*) 为两步分组固定效应，(*b*) 为偏误修正后的结果，(*c*) 为迭代三次并修正偏误。虚曲线表示真实值。实曲线为均值，点曲线为各次模拟的 97.5% 与 2.5% 分位数。500 次重复。

工资对地点的长期影响（仅迁移者类型）



注：(*a*) 为两步分组固定效应，(*b*) 为偏误修正后的结果，(*c*) 为迭代三次并修正偏误。虚曲线表示真实值。实曲线为均值，点曲线为各次模拟的 97.5% 与 2.5% 分位数。500 次重复。

B．工人与企业的异质性

- 重要问题：企业与工人的匹配分选及最优配置、收入不平等的来源……

- 两类文献利用雇主—雇员匹配数据，从不同角度研究这些问题：

-双向固定效应回归，始于 Abowd, Kramarz and Margolis（1999，AKM）。

-工人与企业分选的结构模型，受 Becker 启发
(1974).

- B.、Lamadon and Manresa（2019）构建了一个框架，旨在架起这两种方法之间的桥梁。

固定效应回归

- AKM 回归：

$$log\,earnings\ =\ worker\,FE\ +\ firm\,FE\ +\ covariates\ +\ error\,term.$$

- 由此可以记录关联 *cov*(工人 FE, 企业 FE)，更一般地，记录工人和企业对收入离散程度的贡献。

- 利用匹配数据，以易于处理的方式允许双边异质性。

- 被广泛应用于劳动经济学及其他领域（学校、医院、城市……）。

固定效应模型的两个特点

1．可加模型（取对数）。因此工人与企业不可观测因素之间的互补性形式非常特殊。

-这是分选模型的理论与结构文献所强调的特点（Becker 1974，Shimer and Smith 2000，Eeckhout and Kircher 2011，Hagedorn, Law and Manovskii 2017 等）。

2. 静态模型。特别是，给定当前雇主，换工作后的收入不取决于前一个雇主。

-这可能与工资公告模型或议价模型等不一致。

异质性

- N 个工人，J 家企业，T 期。

- 企业由所属的类别刻画，$k_{it} \in \{1, \ldots, K\}$ 表示企业 j_{it} 的类别。

- $k_{it} = k(j_{it})$ 可以是企业本身（当 $K = J$ 时），也可以是行业等企业特征。B.、Lamadon and Manresa（2019）假设企业异质性是离散的，并使用两步 GFE。

- 不可观测的工人类型 A_i 可以是离散的，也可以是连续的。

静态模型，两期

- 第 1 期：

– 处于类别 k 企业中的类型 a 工人，从 $F_{ka}(y_1)$ 中抽取对数收入 Y_{i1}。

- 第 2 期：

-工人以取决于 a 和 k（以及 k'）、但不取决于 Y_{i1} 的概率，转到类别 k' 的企业。

-若转移，工人从取决于 a 和 k'、但不取决于 (k, Y_{i1}) 的分布 $F^m_{k'a}(y_2)$ 中抽取对数收入 Y_{i2}。

- 两个假设：1）流动由类型/类别驱动；2）换工作后序列独立。

动态模型，四期

- 第 1、2 期：处于类别 k 企业中的类型 a 工人，从取决于 (a, k) 的二元分布中抽取对数收入 (Y_{i1}, Y_{i2})。

- 第 3 期：

-工人以取决于 a, k 和 Y_{i2}（以及 k'）、但不取决于 Y_{i1} 的概率，转到类别 k' 的企业。

-若转移，工人从取决于 a, k', k, Y_{i2}、但不取决于 Y_{i1} 的分布中抽取对数收入 Y_{i3}。

- 第 4 期：工人随后从取决于 a, k', Y_{i3}、但不取决于 (k, Y_{i2}, Y_{i1}) 的分布中抽取对数收入 Y_{i4}。

与理论模型的联系

- 静态模型：

-例：Shimer and Smith（2000），不含或含在职搜寻（工人的威胁点是失业的价值）。-匹配特定的抽取不起作用，除非它们在时间上独立或是测量误差。不含序贯拍卖。

- 动态模型：

-状态变量 (a, k_t, Y_t) 为一阶马尔可夫的模型。-例：工资公告、序贯拍卖（Lamadon, Lise, Meghir and Robin 2015），含总量冲击（Lise and Robin 2014）。-不含潜在人力资本积累 (a_t)，不含岗位内永久 + 暂时的收入动态（例如随机游走 + 独立同分布冲击）。

主要方程（静态模型）

- 令 m_{it} 表示 t 与 $t+1$ 之间的流动。在两期静态模型中，有：

$$\begin{aligned}\Pr\left[Y_{i1} \leq y_1\,,\, Y_{i2} \leq y_2 \,|\, m_{i1}=1, k_{i1}=k, k_{i2}=k'\right] \qquad (1)\\ = \int p_{kk'}(a)\, F_{ka}(y_1) F^m_{k'a}(y_2) da, \qquad \text{(MOV)}\end{aligned}$$

$$\Pr\left[Y_{i1} \leq y_1 \,|\, k_{i1}=k\right] = \int F_{ka}(y_1) q_k(a)\, da. \qquad \text{(CROSS)}$$

- 企业类别 $k_{it} = k(j_{it})$ 可以用 (MOV) 和/或 (CROSS) 恢复。

- BLM 说明了如何利用换工作者由 (MOV) 恢复 $F_{ka}, F^m_{k'a}$ 与 $p_{kk'}(a)$，并利用第一个横截面由 (CROSS) 恢复 $q_k(a)$。

离散工人类型下的识别（概要）

- 令 $k \neq k'$/为企业类别，并把 (k, k') 转移的 (MOV) 写成矩阵形式：

$$A(k, k') = F(k)D(k, k')F(k')',$$

其中为简单起见，假设 $F_{ka} = F_{ka}^m$，并且矩阵 $F(k) = [F_{ka}(y_1)]_{(y_1,a)}$ 是方阵。

- 若所有类型都有进行 $k \to k'$ 与 $k' \to k$ 转移的换工作者，并在适当的秩条件下：

$$A(k, k')A(k', k)^{-1} = F(k)D(k, k')D(k', k)^{-1}F(k)^{-1}$$

可以识别 F_{ka}，只差尺度（作为 cdf 已被确定）与类型的标签。

- 在连续类型下，这些变成算子约束，识别需要完备性（如 Hu and Schennach，2008）。

恢复企业类别

- 识别结果在类别层面 k_{it} 上成立，原则上类别可以与企业 j_{it} 一致。

- 然而，在典型的匹配数据集中，允许企业特定参数会增加计算成本，并带来统计上的挑战（例如附带参数的“低流动性”偏误）。

- BLM 提出了一种降维方法，可以在初始估计步骤中进行。我们给出了离散企业异质性下企业分类一致性的条件。

- 分类基于收入，不过 BLM 也使用了基于其他数据（工人流动、增加值）的多种方法。

用 k 均值分类

- 在模型中，不可观测的企业异质性作用于企业类别层面，而非单个企业层面。

- 例如，对类别 $k = k(j)$ 中的所有企业 j，对数收入的 cdf F_j 应当相同。

- 这启发了如下 k 均值估计量：

$$\min_{k(1),\ldots,k(J),H_1,\ldots,H_K} \sum_{j=1}^{J} n_j \sum_{d=1}^{D} \left(\widehat{F}_j(y_d) - H_{k(j)}(y_d) \right)^2,$$

其中 $\widehat{F}_j$ 表示企业 j 中对数收入的经验 cdf，n_j 为企业 j 的工人数，$y_1, \ldots, y_D$ 为工资分位数。

两步 GFE 估计

1. 用聚类估计类别 $\widehat{k}_{it} = \widehat{k}(j_{it})$。

2. 在给定 $\widehat{k}_{it}$ 的条件下估计模型参数。

- 工资 cdf F_{ka} 与 F^m_{ka} 为正态分布，均值与方差因 (k, a) 而异。BLM 使用 EM 算法进行计算。

- 一个关键特点是：给定企业类别，似然在工人之间可以分解。

- 因此，在第一步中估计企业类别，就把问题变回了单个决策者问题！

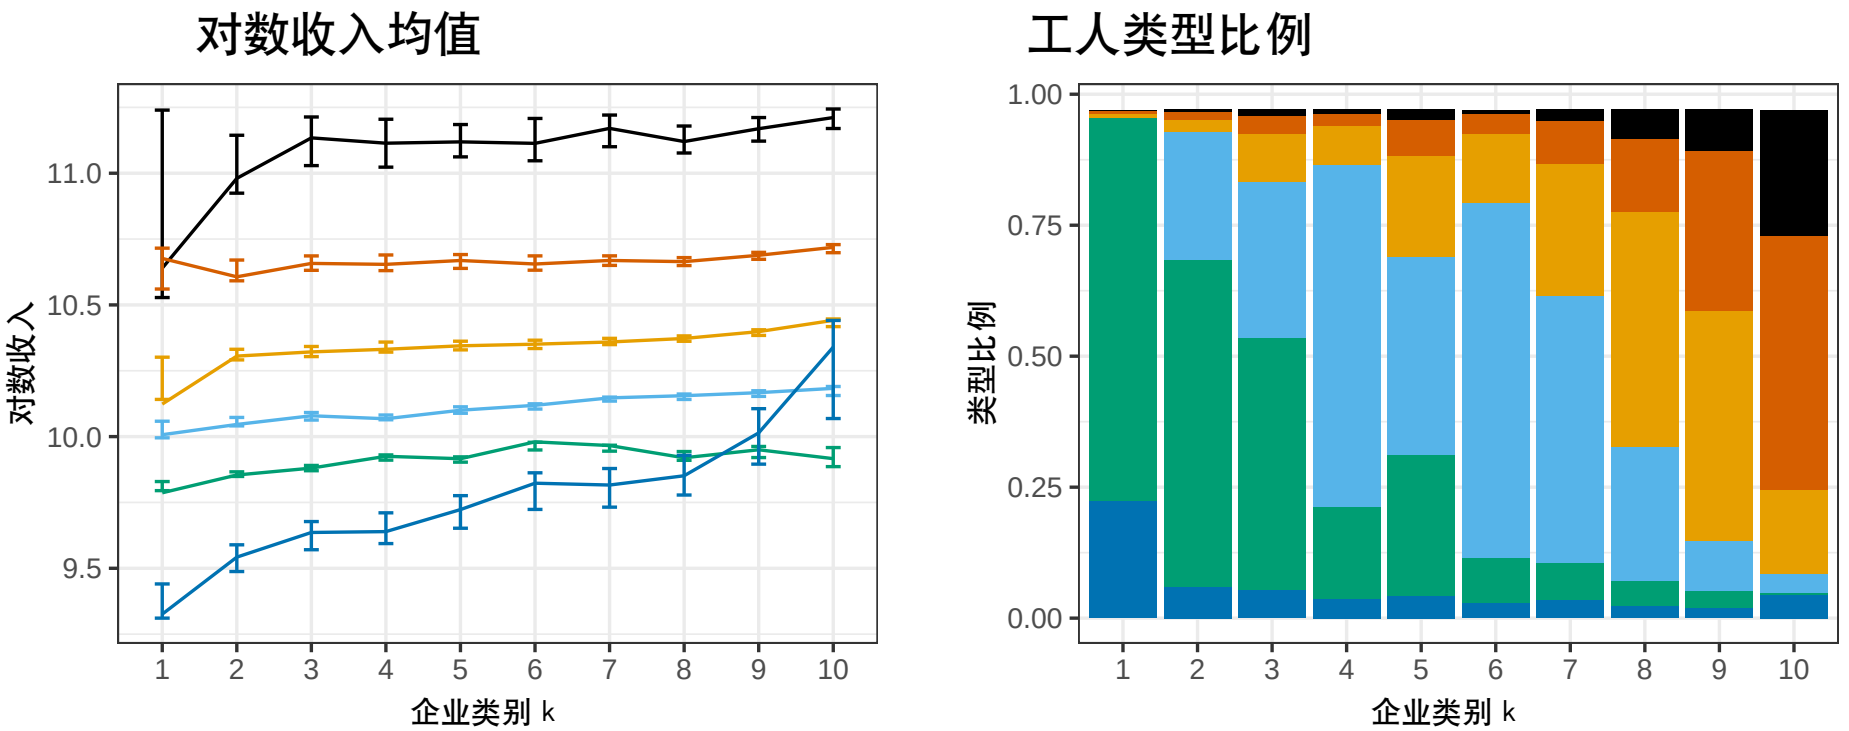
估计出的企业类别的描述统计

类别:	1	2	3	4	5	6	7	8	9	10	全部
工人数	16,868	50,906	74,073	76,616	80,562	66,120	105,485	61,272	47,164	20,709	599,775
企业数	5,808	6,832	4,983	5,835	3,507	4,149	3,672	3,467	2,886	2,687	43,826
企业报告规模的均值	12.43	20.92	42.68	28.47	65.06	32.30	60.08	51.24	54.16	50.86	37.59
企业数 ≥ 10（实际规模）	160	1,034	1,519	1,357	1,192	930	999	855	632	415	9,093
企业数 ≥ 50（实际规模）	7	87	260	225	270	162	245	183	147	52	1,638
% 高中辍学	28.5%	27.8%	25.9%	26.8%	22.2%	23.8%	18.9%	12.9%	6.1%	3.2%	20.6%
% 高中毕业	61.3%	63.4%	62.3%	63.3%	59.1%	62.7%	58.4%	49.3%	34.9%	25.6%	56.7%
% 上过大学	10.2%	8.8%	11.8%	9.9%	18.7%	13.5%	22.8%	37.8%	59.0%	71.2%	22.7%
% 30 岁以下工人	24.3%	19.5%	19.8%	17.5%	18.6%	15.4%	13.8%	14.3%	15.0%	14.3%	16.8%
% 31 至 50 岁工人	54.1%	54.6%	55.0%	56.2%	56.0%	57.6%	58.5%	58.9%	60.0%	64.2%	57.2%
% 51 岁以上工人	21.7%	25.9%	25.1%	26.3%	25.5%	27.0%	27.6%	26.8%	25.0%	21.5%	26.0%
% 制造业工人	24.3%	39.3%	46.8%	53.0%	51.5%	52.0%	53.0%	40.3%	31.5%	7.6%	45.4%
% 服务业工人	39.3%	32.1%	23.3%	19.7%	14.4%	15.0%	16.0%	29.7%	52.1%	72.6%	25.3%
% 零售与贸易业工人	26.4%	19.0%	24.9%	10.6%	29.3%	7.9%	8.4%	17.7%	14.8%	18.7%	16.7%
% 建筑业工人	9.9%	9.6%	5.1%	16.8%	4.9%	25.1%	22.5%	12.3%	1.5%	1.1%	12.6%
对数收入均值	9.69	9.92	10.01	10.06	10.15	10.16	10.24	10.36	10.50	10.77	10.18
对数收入方差	0.101	0.054	0.085	0.051	0.102	0.051	0.077	0.096	0.109	0.173	0.124
对数收入偏度	-1.392	-0.709	0.345	0.019	0.576	0.433	0.474	0.703	0.385	1.001	0.582
对数收入峰度	7.780	14.093	9.017	15.565	7.788	14.763	10.033	8.141	6.651	6.984	7.400
between-firm variance of log-earnings	0.0462	0.0044	0.0036	0.0018	0.0032	0.0016	0.0016	0.0045	0.0057	0.0435	0.0475
mean log-value-added per worker	12.40	12.58	12.69	12.69	12.84	12.75	12.87	12.94	13.03	13.18	12.74

注：男性，2002 年和 2004 年在同一企业全职工作，企业持续存在。

数据为 2002 年。

估计的对数收入均值与工人类型比例



注：静态模型，2002—2004 年。左图为按工人类型和企业类别划分的对数收入分布均值的估计。右图为各企业类别中工人类型比例的估计。左图中括号表示参数自助法的 2.5% 与 97.5% 分位数（200 次重复）。

C．量化团队中的个人投入

- 个人对团队产出的贡献有多大？这是研究与创新、劳动经济学、体育等领域的核心问题。

- B.（即将发表）提出了一个计量框架，用于在只观测到团队产出时量化个人贡献。

- 识别策略依赖于追踪那些随时间在不同团队工作的个人。

- 两个应用：估计经济学家对研究质量的影响，以及发明者对其专利质量的贡献。

框架：工人与团队

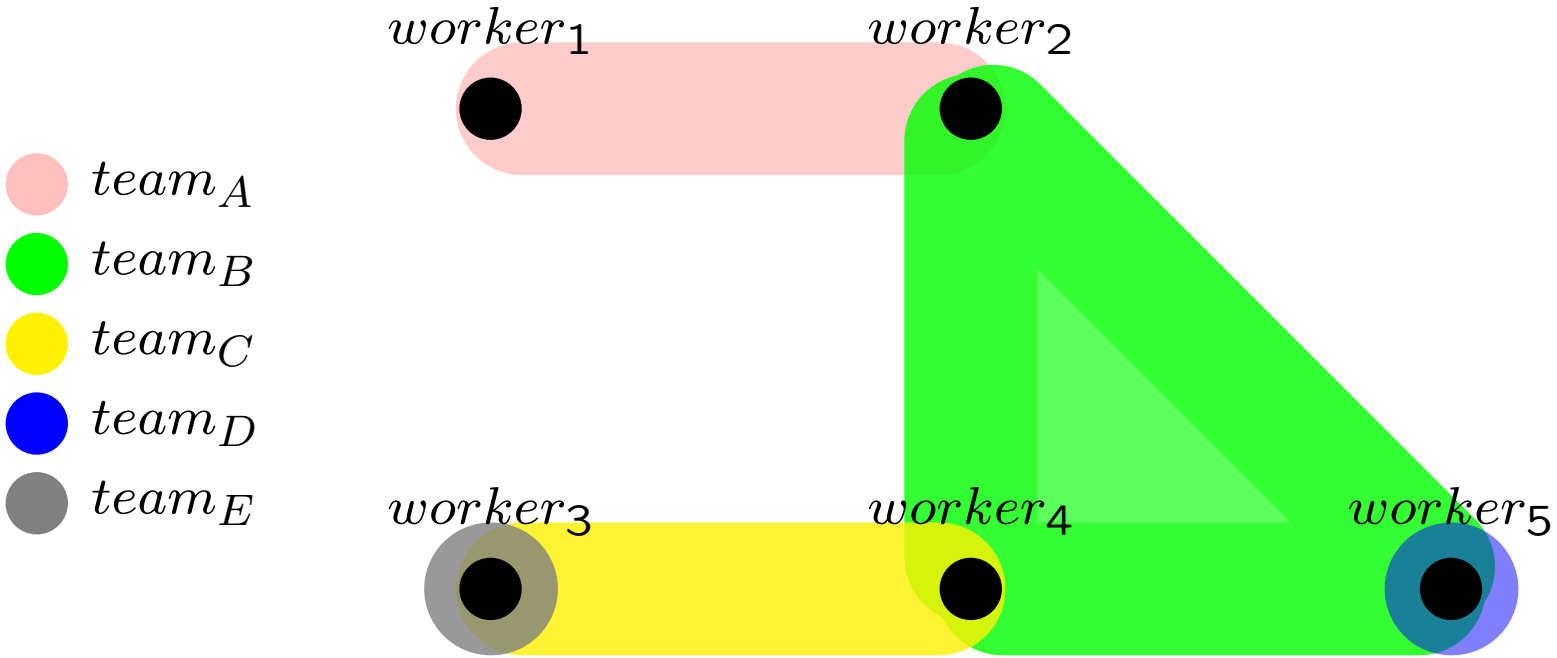
- 工人 $i = 1, \ldots, N$ 是超图中的节点。工人合作并以团队形式生产产出。

- 工人之间通过超边相连。

- 超边称为团队，规模为 n 的团队 j 中的工人集合记为 $\{i_1(j), \ldots, i_n(j)\}$。

- 工人 i 为团队贡献数量 A_i。类型 A_i 在各次合作中保持不变。

合作超图：一个例子


$team_A$
$team_B$
$team_C$
$team_D$
$team_E$
$worker_1$
$worker_2$
$worker_3$
$worker_4$
$worker_5$

框架：生产

- 有 n 名工人的团队 j 的产出 Y_{nj} 为

$$Y_{nj} = \phi_n(A_{i_1(j)}, ..., A_{i_n(j)}, \varepsilon_{nj}),$$

其中 ϕ_n 是 n 人团队的生产函数，对其前 n 个自变量对称。

- ε_{nj} 代表工人投入 A_i 之外影响团队产出的其他因素或冲击。

- 模型中没有“团队效应”。这里的团队只是一组工人，外加一个冲击 ε。

框架：主要假设

- 假设 1（网络外生性）：

给定各 A_i，各 ε_{nj} 与各 $(i_1(j), \ldots, i_n(j))$ 独立。

– 假设 1 限制了团队的形成。如果工人在加入团队之前就提前掌握了 ε_{nj} 的信息，它就不成立。

- 假设 2（独立冲击）：

各 ε_{nj} 相互独立，且与各 $(i_1(j), \ldots, i_n(j))$ 及各 A_i 独立。

– 假设 2 特别意味着，反复合作的工人所受的冲击在时间上是独立的。

非线性生产

- A_i 最多取 K 个值。

- 随机效应方法：$A_1, \ldots, A_N$ 取自联合分布 $\prod_i \pi(A_i)$，其中 $\pi(A_i)$ 为类型概率。

- 一个重要问题是类型 A_i 如何与合作关系 $(i_1(j), \ldots, i_n(j))$ 相关。B.（即将发表）报告了基于三种方法的结果：

  - 独立随机效应（RE）。

  - 相关 RE（以度数作为工人特征）。

  - 联合 RE，同时对生产与团队形成建模（使用团队形成的随机块模型）。

非线性生产：识别

- **假设各 A_i 与各 $(i_1(j), \ldots, i_n(j))$ 独立，并且团队规模为** $n \in \{1, 2\}$.

- **着眼于至少独自生产三次的工人，得到：**

$$\Pr\left[Y_{1j_1} \leq y_1, Y_{1j_2} \leq y_2, Y_{1j_3} \leq y_3 \,|\, i_1(j_1) = i_1(j_2) = i_1(j_3)\right]$$
$$= \sum_a \underbrace{\pi(a)}_{\text{Type prop.}} \prod_{r=1}^{3} \underbrace{\Pr\left[Y_{1j_r} \leq y_r \,|\, A_{i_1(j_r)} = a\right]}_{\text{独自生产}}.$$

- **在适当的秩条件下，这识别了** $\Pr\left(Y_{1j} \leq y \,|\, A_{i_1(j)} = a\right)$ **与** $\pi(a)$ (Allman et al., 2009; Hu, 2008)。

非线性生产：识别（续）

- 然后，着眼于独自生产一次、合作生产一次的工人对，识别两人合作的生产：

$$\begin{aligned}
&\Pr\left[Y_{1j_1} \le y_1, Y_{1j_2} \le y_2, Y_{2j_3} \le y_3 \,|\, \{i_1(j_1), i_1(j_2)\} = \{i_1(j_3), i_2(j_3)\}\right] \\
&= \sum_{a,a'} \pi(a)\pi(a') \Pr\left[Y_{1j_1} \le y_1 \,|\, A_{i_1(j_1)} = a\right] \Pr\left[Y_{1j_2} \le y_2 \,|\, A_{i_1(j_2)} = a'\right] \\
&\qquad \times \underbrace{\Pr\left[Y_{2j_3} \le y_3 \,|\, A_{i_1(j_3)} = a, A_{i_2(j_3)} = a'\right]}_{\text{两人合作生产}}.
\end{aligned}$$

- 这一论证依赖于独自生产的工人（不过另见 Allman et al.，2011）。

非线性生产：随机效应（RE）似然

- 假设产出密度取决于有限维参数 θ。

- 在应用中：经济学家样本采用对数正态设定，发明者样本采用负二项设定。

- 然而，RE 似然

$$\mathcal{L}(\theta, \pi) = \sum_{a_1} ... \sum_{a_N} \prod_i \pi(a_i) \prod_n \prod_j f^n_{a_{i_1(j)},...,a_{in(j)}} \left(Y_{nj}; \theta \right)$$

涉及对所有可能的工人类型实现求一个难以处理的 N 维和。

- 似然不能以简单的方式分解，除非所有团队都只有一名工人这一特例。

非线性生产：变分近似

- 为降低计算复杂度，B.（即将发表）采用平均场变分方法（Bishop，2006）。

- 其思想是引入辅助分布 $\prod_{i=1}^{N} q_i(a_i)$，并让它尽可能接近 $a_1, \ldots, a_N$ 的后验密度 $p(a_1, \ldots, a_N; \theta, \pi)$

  $a_1, ..., a_N$.

- 与后验密度 p 不同，其变分近似 q 在 i 之间可以分解。这使得即使在大型数据集中估计也是可行的。

- 这一思想在随机块模型（Daudin et al.，2008）等网络模型中被广泛使用，更一般地也用于复杂数据的情形（例如 Blei et al.，2003）。

变分近似（续）

- **变分目标函数为**

$$\mathsf{ELBO}(\theta,\pi) = \max_{q_1,\dots,q_N} \ln\left(\mathcal{L}(\theta,\pi)\right) - \underbrace{\mathbb{E}_{q_1\dots q_N} \ln \frac{\prod_i q_i(a_i)}{p(a_1,\dots,a_N;\theta,\pi)}}_{\substack{\mathsf{KL}\quad \mathsf{divergence} \\ \text{散度}}}.$$

- **等价地，有**

$$\mathsf{ELBO}(\theta,\pi) = \max_{q_1,\dots,q_N} \sum_n \sum_j \sum_{a_1} \dots \sum_{a_n} q_{i_1(j)}(a_1)\dots q_{i_n(j)}(a_n) \ln f_{a_1,\dots,a_n}(Y_{nj};\theta) + \sum_i \sum_a q_i(a) \ln \pi(a) - \sum_i \sum_a q_i(a) \ln q_i(a).$$

- **只要团队规模 n 足够小，这一表达式就可以计算。用 EM 算法最大化“证据下界”** ELBO（Bishop，2006；Mariadassou et al.，2010）。

变分近似：统计性质

- 对于随机块模型，Bickel et al.（2013）给出了平均场变分估计量一致且渐近正态的条件。

- 其条件依赖于网络以特定方式增长。

- 在其渐近框架下，变分估计量与（难以处理的）极大似然估计量是一阶等价的。

- B.（即将发表）进行了蒙特卡洛模拟，以检验变分估计量的准确性。

蒙特卡洛模拟

	True	较小样本 Mean	较小样本 p2.5%	较小样本 p97.5%	较大样本 Mean	较大样本 p2.5%	较大样本 p97.5%
类型 1 均值	0.00	0.00	-0.05	0.06	0.00	-0.03	0.02
类型 2 均值	2.00	2.00	1.92	2.07	2.00	1.97	2.03
类型 1 方差	0.50	0.50	0.43	0.56	0.50	0.47	0.53
类型 2 方差	0.50	0.50	0.42	0.57	0.50	0.47	0.53
类型 (1,1) 均值	0.00	0.05	-0.49	0.74	0.01	-0.10	0.12
类型 (1,2) 均值	1.00	1.01	0.59	1.42	1.01	0.92	1.10
类型 (2,2) 均值	4.00	3.71	0.78	4.72	4.00	3.85	4.16
类型 (1,1) 方差	0.50	0.46	0.11	0.93	0.50	0.40	0.62
类型 (1,2) 方差	0.50	0.46	0.16	0.84	0.50	0.42	0.59
类型 (2,2) 方差	0.50	0.38	0.00	1.24	0.49	0.35	0.69
类型 1 比例	0.60	0.60	0.53	0.67	0.60	0.57	0.63

注：在由 $K_0 = 2$ 组的随机效应模型生成的数据中，估计 $K = 2$ 组的该模型。500 次模拟。较小样本有 156 名工人和 896 个团队，较大样本有 921 名工人和 5447 个团队。

应用于经济学家与研究质量

- 数据来自 Ductor et al.（2014），取自 EconLit 数据库。

- 1995—1999 年发表的、合作者不超过三人的文章。

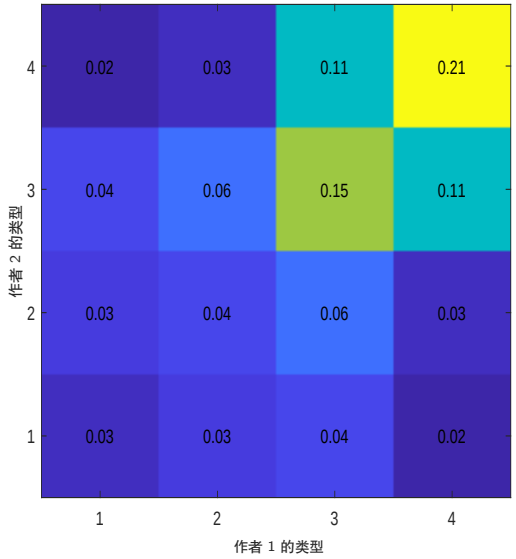
- 只包括这一时期至少发表 5 篇文章的作者。

- 共有 41150 篇文章和 6509 位作者。50% 的作者最多发表 8 篇，而 1% 的作者至少发表 39 篇。

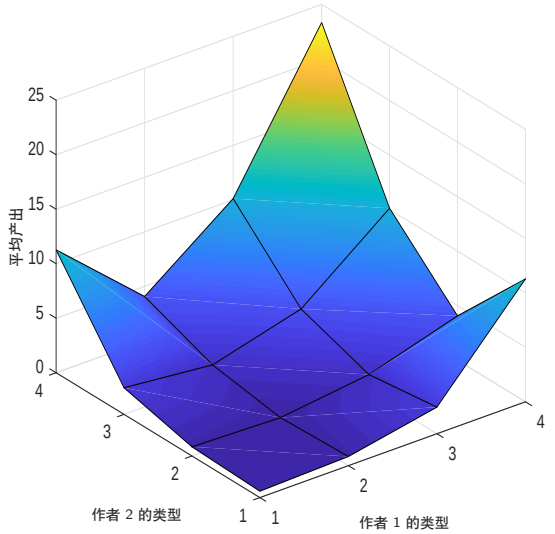
- 产出用期刊质量衡量（Kodrzycki and Yu，2006），是 0 到 100 之间的排名，并扣除了乘法形式的时间效应。

非线性模型估计，经济学研究者（$K = 4$）

（a）分选



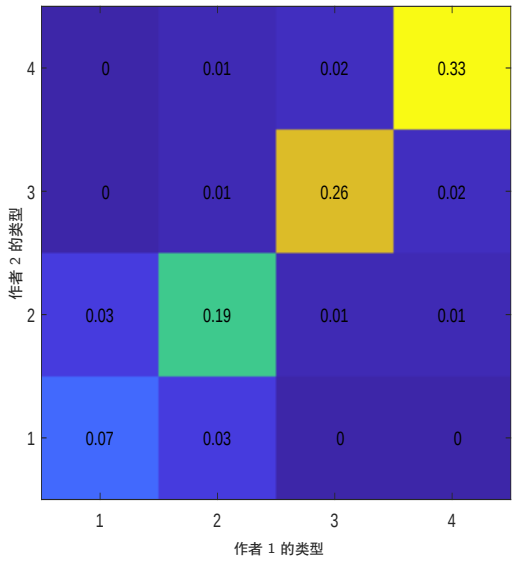
（b）异质性与互补性



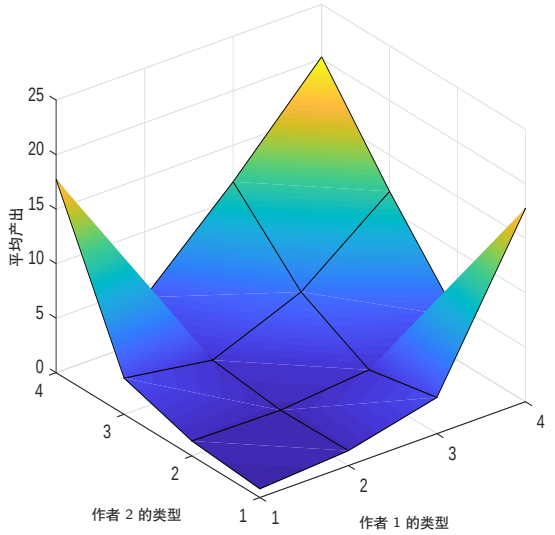
注：$K = 4$ 种类型的有限混合模型的随机效应估计。图 (a) 为两人合作作者的类型比例。图 (b) 为不同类型组合的平均产出。总体类型比例：15%（类型 I），20%（II），36%（III），29%（IV）。

非线性模型估计，经济学研究者：联合 RE

（a）分选



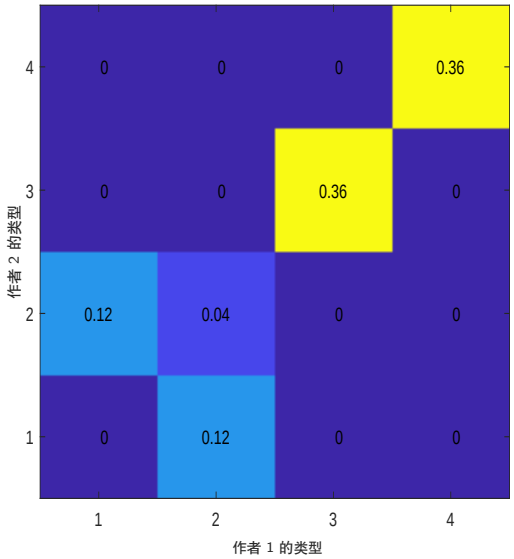
（b）异质性与互补性



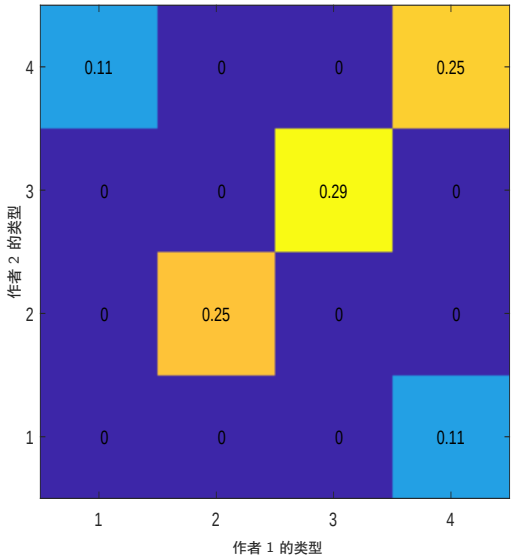
注：$K = 4$ 种类型的有限混合模型的随机效应估计，采用联合 RE 设定（使用团队形成的泊松块模型）。图 (a) 为两人合作作者的类型比例。图 (b) 为不同类型组合的平均产出。

最优配置，经济学研究者（$K = 4$）

(a) 独立 RE



(b) 联合 RE



注：在使总产出最大化的配置中，两人合作作者的类型比例。图 (a) 与 (b) 的估计分别使用独立随机效应与联合随机效应。

应用于发明者与专利质量

- 数据来自 Akcigit et al.（2016）。其主要来源是 Li et al.（2014）消歧后的发明者数据，该数据可以在 USPTO 数据中识别出唯一的发明者。

  - 1995—1999 年间在美国授权、属于“计算机与通信”类别的专利。

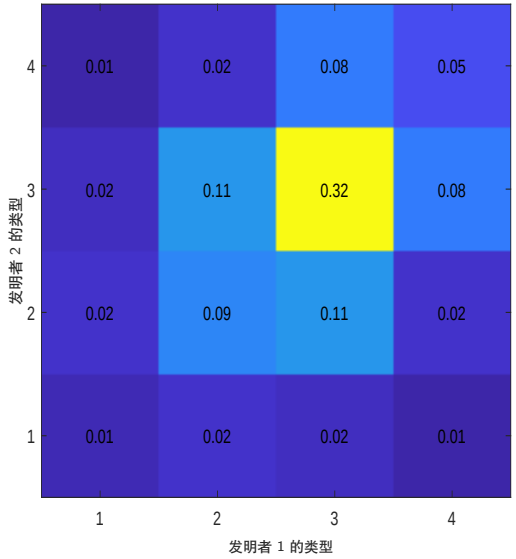
  - 只包括至少产出 5 项专利的发明者。

  - 共有 30068 项专利和 5896 位发明者。

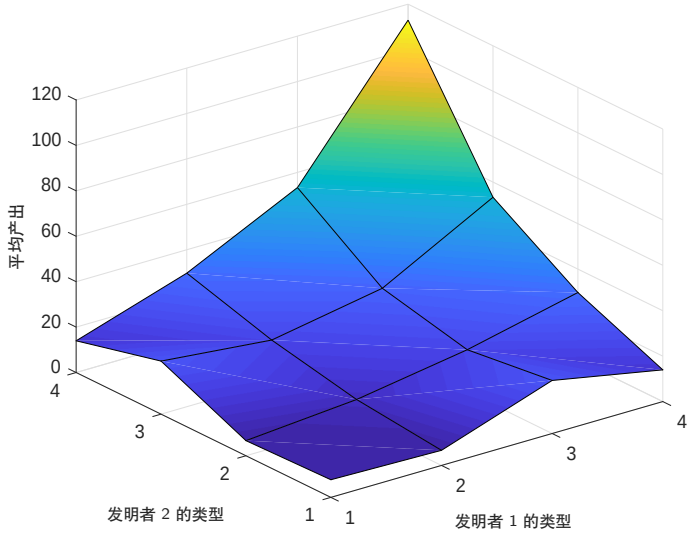
- 产出采用 Hall et al.（2001）经截断调整的前向引用数，并扣除了乘法形式的时间效应。

非线性模型估计，专利与发明者（$K = 4$）

（a）分选



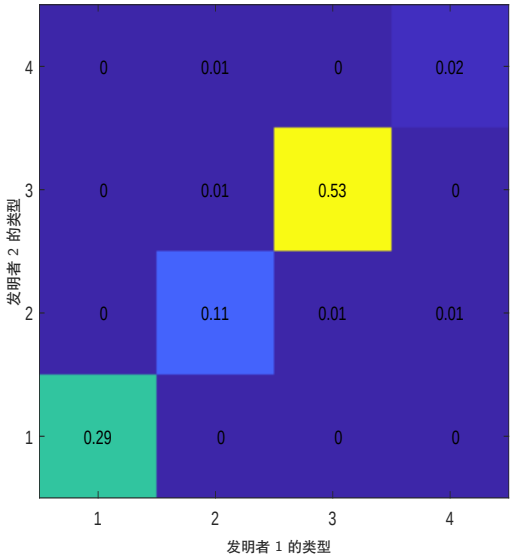
（b）异质性与互补性



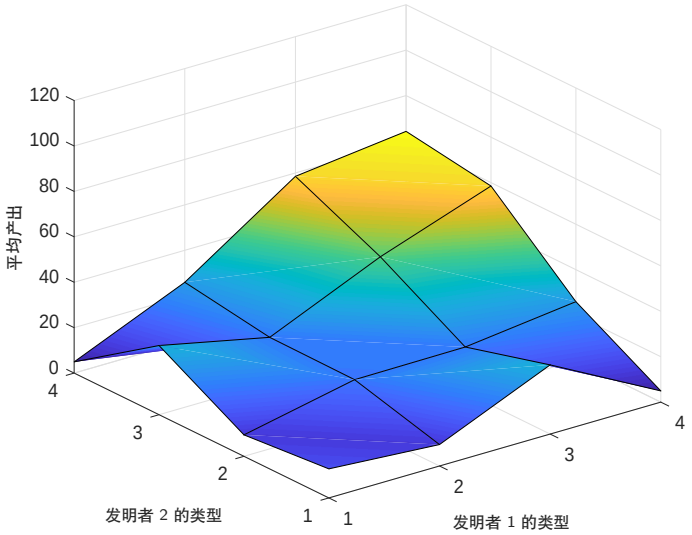
注：图 (a) 为两人团队中发明者的类型比例。图 (b) (b) 为不同类型组合的平均产出。总体类型比例：6%（类型 I），25%（II），52%（III），17%（IV）。

非线性模型估计，专利与发明者：联合 RE

（a）分选



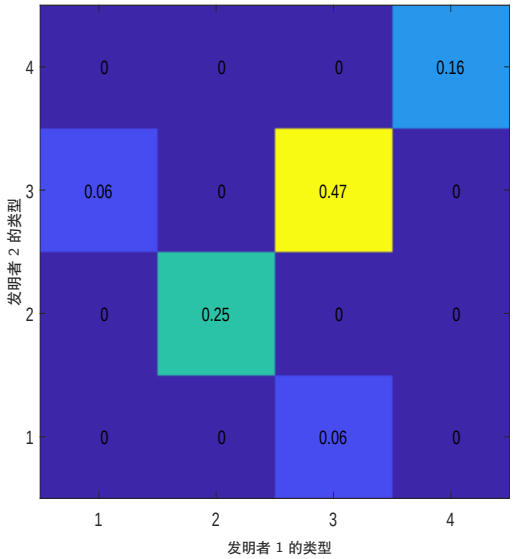
（b）异质性与互补性



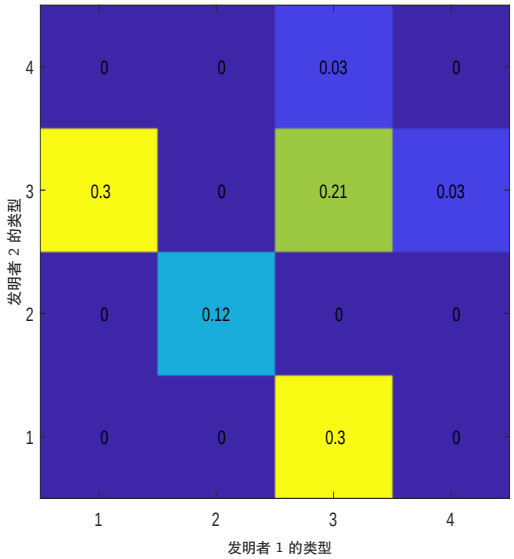
注：联合 RE 设定（使用团队形成的泊松模型）。图 (*a*) *(a)* 为两人团队中发明者的类型比例。图 (*b*) 为不同类型组合的平均产出。

最优配置，专利与发明者（$K = 4$）

(a) 独立 RE



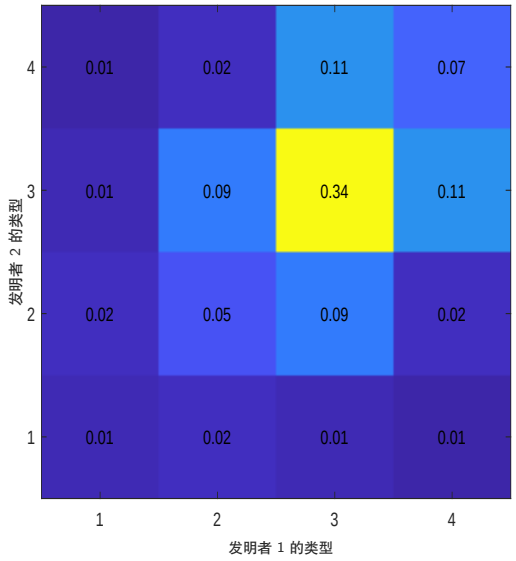
(b) 联合 RE



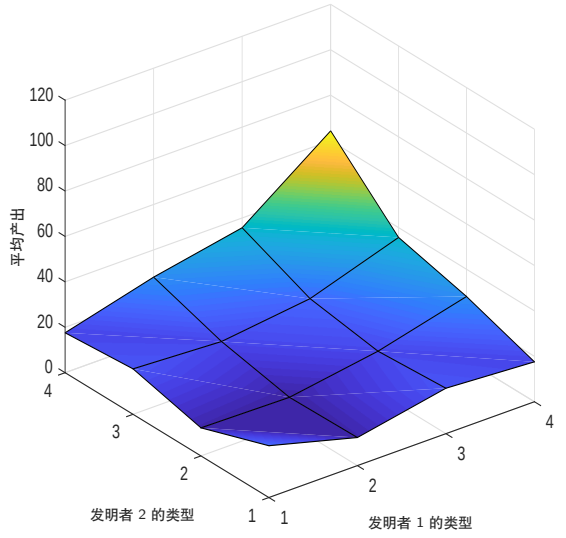
注：在使总产出最大化的配置中，两人团队中发明者的类型比例。图 (a) 与 (b) 的估计分别使用独立随机效应与联合随机效应。

应用于发明者与专利质量：样本外的异质性、分选与互补性

（a）分选



（b）异质性与互补性



注：样本来自 Akcigit et al.（2016）。模型用 1995—1999 年的数据估计，$K = 4$ 种类型。图中为 2000—2005 年间两人团队中的发明者。

我本人工作中的一些参考文献

Bonhomme (forthcoming): "Teams: Heterogeneity, Sorting, and Complementarity", Proceedings of the 2020 World Congress of the Econometric Society.

Bonhomme (2012): "Functional Differencing", Econometrica.

Bonhomme and Manresa (2015): "Grouped Patterns of Heterogeneity in Panel Data", Econometrica.

Bonhomme, Lamadon and Manresa (2022): "Discretizing Unobserved Heterogeneity", Econometrica. + Working paper version

Bonhomme, Lamadon and Manresa (2019): "A Distributional Framework for Matched Employer-Employee Data", Econometrica.

更多内容见：https://sites.google.com/site/stephanebonhommeresearch/

其他一些参考文献

Aguiregabiria and Mira (2010): "Dynamic discrete choice structural models: A survey", Journal of Econometrics.

Hu (2008): "Identification and estimation of nonlinear models with misclassification error using instrumental variables: A general solution", Journal of Econometrics.

Hu (2015): "Microeconomic models with latent variables: applications of measurement error models in empirical industrial organization and labor economics".

Kasahara and Shimotsu (2009): "Nonparametric identification of finite mixture models of dynamic discrete choices", Econometrica.