动态博弈：问题与前景

Ariel Pakes（哈佛大学）

DSE 暑期学校 2025，UCL，伦敦

2025 年 7 月 5 日

背景：产业组织中的实证研究

- 在发展实证分析产业组织静态问题所需的方法时，我们从理论界同行那里借用了分析框架，并用计量方法把各种市场制度的丰富细节纳入其中。

- 具体来说，我们借用了：
  - 来自理论：使用某种形式的纳什均衡，因为它使我们能够分析反事实；以及
  - 来自计量：纳入可观测与不可观测异质性的方法，以及计算工具。

- 这始于完全信息的“要么接受要么放弃”博弈（零售定价）的分析，后来扩展到纳什议价、允许信息不对称的模型，以及非价格配置（或匹配）机制。在更复杂环境中的定价方面，仍有很多工作要做。

动态分析也以类似方式开始。

- 即我们借用了理论界同行的框架。他们所作的假设保证了

  1. 状态变量服从马尔可夫过程演化，
  2. 并且均衡是某种形式的马尔可夫完美（在状态变量的任何取值上，任何个体都没有偏离的激励）。

- Starr and Ho（1969），更直接的是 Maskin and Tirole（1988），他们使用完全信息环境。

- 我们像静态分析那样起步，试图让动态框架适应现实中各种不同制度的丰富细节。

- Ericson and Pakes（1995）为此构建了一个框架。

基本的完全信息马尔可夫完美博弈

- **状态**。
  - $i \in \mathcal{Z}^+$（可以是多维的）
  - s_i 为效率水平为 i 的企业数目，
  - $s = [s_i; i \in \mathcal{Z}^+]$ 为“产业结构”（各效率水平上企业数目的计数测度）。
  - ζ 是外生演化的总量状态变量（可能服从马尔可夫过程），例如外部选择。

Bellman 方程：“资本积累”博弈

$$V(i,s) = \max\{\phi, \pi(i,s) + \sup_{(x \geq 0)} [-cx + \beta \sum V(i',s') pr(i',s'|x,i,s,\zeta) p(\zeta)]\},$$

$$\text{where,} \quad pr(i',s'|x,i,s,\zeta) = pr(i'|i,x,\zeta) q(s - e(i)|i,x,s,\zeta).$$

- $pr(i'|i,x,\zeta)$。在这一博弈中，我自己的投资只影响我自己的状态变量。ξ 是总量状态，外生演化，并以同样的方式影响所有参与人

- $q(s - e(i)|i,x,s,\zeta)$：我对竞争对手将处于何处的认知。
- $\mathcal{P} = \{p(i'|x,\zeta); x \in \mathcal{R}^+\}$，对每个 ζ 关于 x 随机递增。
- $q[\cdot|i,s,\zeta]$ 是均衡对象，体现了在位者对进入与退出的信念。

- 进入模型有多种可能。例如：
  - 必须支付 $x_e(> \beta\varphi)$ 才能进入，
  - 在一期之后以概率 $p^e(\cdot)$ 进入状态 $\omega_e \in \Omega^e \subset \mathcal{Z}^+$。
  - 只有当进入所带来的未来净现金流的期望贴现值大于进入成本时才会进入。)

- **动态均衡**。

1. 每个个体在给定其对未来可能产业结构的认知下选择最优策略，
2. 这些认知在所有地方都与该个体竞争对手的行为一致，即 $\forall$ 可能的 (i, s)。

- Doraszelski and Satterthwaite（2003）证明了存在性（为此需要随机的进入费与退出成本）。

- E-P 给出的条件意味着任何均衡
  1. 都是“可计算的”：活跃企业从不超过 n 家，且只在 $\Omega = \{1, \ldots, K\}$ 上观测到“i” $\Rightarrow$ 只需对 $(i, s) \in \Omega \times S$ 计算均衡

$$S \equiv \{s = [s_1, ..., s_k] : \sum s_j \leq \overline{n} < \infty\} \Rightarrow \#S \leq K^N$$

  2. 为产业结构生成一个齐次马尔可夫链［对 $\{s_t\}$］，即 $Q(s'|s)$

$$Pr[s_{t+1} = s'|s^t] = Pr[s_{t+1} = s'|s_t] \equiv Q[s'|s_t].$$

  3. 并给出原始要素上的条件，保证任何均衡 $Q[\cdot|\cdot]$ 都是遍历的。［见图］
     - $\#R$ 通常远小于 $\#S$
     - 极限概率收敛到 R 中各点上的不变测度（常被称为系统的“稳态”，不过“稳”字似乎用词不当，因为状态并非恒定）。

为什么我们在把这些模型用于动态问题的实证分析时不太成功？

复杂性问题。在实证情形中，模型假定个体

1. 能够获取大量信息，并且
2. 能够计算或学会数量多得不现实的策略（每个信息集一个）。

- 马尔可夫完美的复杂性既
  - 限制了我们对市场结果进行动态分析的能力，
  - 也引出一个问题：是否有其他均衡概念能更好地近似个体的行为。

个体（或研究者）要计算一个均衡，需要做什么？

- 可以把它看作类似单个决策者问题的迭代算法：只是在计算延续价值时，要用上一轮迭代中竞争对手的最优策略，对算法预期它们下一期所处的位置积分。然后最大化当期收益加贴现的延续价值，并迭代直到收敛。

- 如果使用标准的迭代计算工具（例如 Pakes and McGuire，1994），计算负担取决于三个因素：
  - 每次迭代需要计算的点数；
  - 每个点的计算负担；
  - 迭代次数（价值函数和/或策略函数迭代）。

点数。

- 由于 n 家活跃企业中的每一家只能处于 K 个不同状态之一，每次迭代需要计算的点数为

$$\#S \leq K^{\overline{n}}.$$

竞争对手状态变量的函数具有可交换性：我们无需区分互为置换的两个竞争对手向量（详见 Pakes（1993））

每个点的负担。取决于：

- 计算未来状态（企业自身的以及竞争对手的）期望值的成本。若给定企业的 $m-1$ 个活跃竞争对手每个都在 κ 个点上有正概率，则需要对 κ^m 个可能的未来状态求和。

- 在给定延续价值的情况下求最优策略的成本。

结论

- 模型的计算负担随两个方面迅速增长：同时活跃企业的最大数目（在这一维度上按几何级数增长），以及每家企业的状态变量个数（在这一维度上按指数增长）。这就是“维数灾难”。

- 因此，尽管逐点算法既被用作研究无法求得解析解的理论问题的工具，也被用作在静态问题中控制动态选择的框架，但它在实证研究中的应用很有限。

- 计算文献和理论文献对此有不同的回应，二者都清楚地认识到了这个问题。
  - 我们先看计算文献，它转向了近似方法。
  - 再回到理论文献：寻找更弱的均衡概念。

近似方法。

- 已有若干种方法。各有问题，但它们计算均衡的负担远小于标准算法。这里其他人比我更熟悉这一领域。早期贡献有：
  - 确定性近似方法。在经济学中始于 Judd（2004）的著作，现已扩展到使用各种与 AI 相关的工具。
  - 随机算法（Pakes and McGuire，2001）
  - 连续时间算法。Doraszelski and Judd（2004）。
  - 无知均衡（平均场理论）。Benkard, Van Roy, Weintraub，2010。用分布的矩进行近似。
- 近似方法带来的一个问题是：分析反事实时，你要分析的环境中，用于近似的数据并不直接相关。

理论：首先要问，如果保留完美性，假设信息不对称是否有帮助？

- 它通过假设个体只能获取部分状态变量，减少了状态变量的个数。
  - 由于个体大概知道自己的特征，而这些特征往往具有持续性，“完美性”概念就会引向“贝叶斯”马尔可夫完美解。

- **假设“贝叶斯 MP”更现实吗**？它降低了对信息获取和保留的要求，但大大增加了计算策略的负担。额外的负担来自需要计算后验分布和最优策略，并要求两者相互一致。

- 还有一个问题是个体能否学会最优策略。我在下文再回到这一点。

理论问题。

- 最初的动态框架假设 [1]
  1. 状态变量服从马尔可夫过程（易于处理且常可验证，因此我们保留它），
  2. 并且均衡是某种形式的马尔可夫完美（在状态变量的任何取值上，任何个体都没有偏离的激励）。
- 完美性假设的复杂性导致：(i) 对其模拟行为能力的怀疑，以及 (ii) 研究者的实现问题。
- 人们设想的规避这些问题的方法（如信息不对称）只会导致更复杂的框架。

[1] Maskin and Tirole (1988)，产业组织理论；Ericson and Pakes (1995)，应用研究。

- 理论与实证研究都在探索前进的方向。理论方面：
  - 认知要求更低的较弱均衡概念，以及
  - 模拟企业如何应对变化的学习过程。
- 例子
  - Fudenberg and Levine（1993）：自我确认均衡。
  - Osborne and Rubinstein（1998）：程序理性的参与人。
  - Esponda and Pouzo（2016）：Berk-Nash 均衡（不恰当先验）
  - Jehiel（2020）：基于类比的预期均衡（ESWC 卷）
- 这些研究是在重复博弈的背景下进行的，重点是学习竞争对手如何博弈。相关的实证研究：Hortaçsu and Puller，2008；Doraszelski, Lewis, & Pakes，2018，关于电力市场。
- 我们感兴趣的大多是“与收益相关”状态上的投资的决定因素及其影响。要用这些思想分析这些问题，需要修改理论框架。

应用研究者面临的问题。

- 前提：马尔可夫完美的复杂性既
  - 限制了我们对市场结果进行动态分析的能力，也
  - 引出一个问题：是否有其他均衡概念能更好地近似个体的行为。

- 我们可以放松 MP 的哪些假设？最初的框架所作的假设保证了

1. 状态变量服从马尔可夫过程演化，
2. 并且均衡是某种形式的马尔可夫完美（在状态变量的任何取值上，任何个体都没有偏离的激励）。

关于马尔可夫假设。

- 除了需要主动试验来学习的情形（此时策略是暂时性的）之外，我们很可能会保留“状态服从有限阶马尔可夫过程”这一假设。理由是：
  - 方便，而且与数据拟合良好。
  - 从现实性看，信息获取与保留的条件限制了所用的记忆。
  - 我们可以为单方面偏离设定界限（Ifrach and Weintraub，2014），并且有条件保证：只要让保留的历史长度增加，这些偏离就可以任意小（White and Scherer，1994）。
- 有些情形下我们可能不希望过程是时间齐次的（这常取决于需求中关于“外部选择”的假设）。我在下文再回到这一点。

完美性。

- 面对现实制度的复杂性，马尔可夫完美框架变得难以驾驭，这就引出一个问题：是否有其他均衡概念能更好地近似个体的行为。

- 复杂性问题意味着个体
  - 能够获取并保留大量信息（全部状态变量），并且
  - 能够计算或学会数量多得不现实的策略（每个信息集一个）。

这一要求有多高？耐用品的例子。

在动态博弈中放弃完美性。

- 我从作为某个动态系统“静止点”的策略出发。这使定义静止点容易得多，因为
  - 静止点上的策略很可能满足某种纳什条件，否则就会有人有偏离的激励。
  - 然而，这仍留下一个问题：纳什条件采取什么形式？
- 企业如何学会均衡策略，仍是一个问题。
  - 我们不认为企业会瞬间跳到均衡，并且可能希望分析过渡路径。
  - 现实的动态博弈中存在多重均衡，过渡路径会选出其中相关的那一个。
- 我在下文再回到这一点。

对于被反复访问的状态，可以对静止点假设什么条件？

我们预期（并且我认为应该纳入建模）：

1. 个体认为自己在这些点上都做到了最好，并且

2. 这些认知至少与他们观察到的情况一致。注意，若某一状态被反复访问，企业就能看到与之相关的利润分布。

注。假设得更多一些可能也是合理的：个体 (i) 知道和/或 (ii) 探索未被反复访问状态的结果性质。我在下文再回到这一点。

假设的形式化。

- 记企业 i 在 t 期的信息集为 $J_{i,t}$。$J_{i,t}$ 同时包含公共信息 (ξ_t) 与私人信息 $(\omega_{i,t})$，因此 $J_{i,t} = \{\xi_t, \omega_{i,t}\}$。
- 假设 $(J_{1,t}, \ldots, J_{n_t,t})$ 在 $\mathcal{J}$ 上服从有限状态马尔可夫过程（或可以用它充分近似）。

- 策略（记为 $m_{i,t} \in \mathcal{M}$）是 $J_{i,t}$ 的函数。为简单起见，假设 $\#\mathcal{M}$ 有限，并且这是一个简单的资本积累博弈（并非必要，也不总是合适），即 $\forall (m_i, m_{-i}) \in \mathcal{M}^n$，$\forall \omega \in \Omega$

$$P_\omega(\cdot|m_i, m_{-i}, \omega) = P_\omega(\cdot|m_i, \omega),$$

- 公共信息 ξ 用于预测竞争对手的行为以及共同的需求与成本条件（这些条件服从外生马尔可夫过程演化）。

- 系统的一个“状态”为

$$s_t = \{J_{1,t}, \ldots, J_{n_t,t}\} \in \mathcal{S},$$

$\#\mathcal{S}$ 有限。$\Rightarrow$ 任何策略集合都会使 s_t 在有限时间内进入 $\mathcal{S}$ 的一个常返子集，记为 $\mathcal{R} \subset \mathcal{S}$，此后以概率 1 永远有 $s_{t+\tau} \in \mathcal{R}$。

- 注意，个体无需跟踪全部 s_t，只需跟踪 $J_{i,t}$；即 $J_{i,t}$ 就是管理层在形成动态策略时所依据的信息。
- 记个体在状态 J_i 选择 m 时，对当前及未来净现金流期望贴现值的认知为

$$W(m|J_i), \quad \forall m \in \mathcal{M} \ \ \& \ \ \forall J_i \in \mathcal{J},$$

- 对期望利润的认知为 $\pi^E(m|J_i)$。

我们的假设意味着：

- 每个个体选择使其对期望贴现值的认知最大的行动，并且
- 对于被反复访问的状态（即属于常返类 $\mathcal{R}$ 的状态），这些认知与观察到的结果一致。

形式上

$$\textbf{A}.\quad W(m^*|J_i) \geq W(m|J_i),\ \ \forall m \in \mathcal{M}\ \ \&\ \ \forall J_i \in \mathcal{J},$$

B. **且对作为某个** $s \in \mathcal{R}$ **之组成部分的所有** J_i

$$W(m(J_i)|J_i) = \pi^E(m|J_i) + \beta \sum_{J_i'} W(m^*(J_i')|J_i')p^e(J_i'|J_i),$$

其中，若 $p^e(\cdot)$ **给出经验概率（事件发生的时期占比）**

$$\pi^E(m|J_i) \equiv \sum_{J_{-i}} E[\pi(\cdot)|J_i, J_{-i}]p^e(J_{-i}|J_i),$$

以及

$$\left\{ p^e(J_{-i}|J_i) \equiv \frac{p^e(J_{-i}, J_i)}{p^e(J_i)} \right\}_{J_{-i}, J_i},$$

而

$$\left\{ p^e(J_i'|J_i) \equiv \frac{p^e(J_i', J_i)}{p^e(J_i)} \right\}_{J_i', J_i}. \ \spadesuit$$

“基于经验的均衡”

- 这些是（受限）EBE 的条件（Fershtman and Pakes，2012）。概念上与上面引用的一些理论论文类似，但我们允许状态变量随时间演化，这会带来新的问题。

- 贝叶斯完美均衡满足这些条件，更弱的概念也满足。特别地，EBE 并不要求对不被反复访问的点有一致的认知。这为多重性开辟了另一条途径，因为对未访问点的认知会影响已访问点上的决策；我们在下文再回到这一点。

- 考虑两种计算算法。
  - 第一种算法企业也可以用来学习均衡行为。它可能更适用于小的扰动，因为在剧烈变化之后学习需要很长时间。
  - 第二种不具备学习规则的优点，但会直接计算出一个均衡（纳什意义上的静止点）。

计算算法。

- 异步强化学习算法（Pakes and McGuire，2001 首次用于动态博弈），早期针对单个决策者问题的机器学习文献称之为“Q 学习”。

- 由于它基于从实现的数据中学习，它既可以用来分析环境的扰动（只要扰动没有大到引发试验），也可以用来计算动态博弈的均衡。

- 若存在多个均衡，学习算法会选出其中一个。若从相同的初始条件多次运行该算法，它会选出一个均衡分布。

- 形式上，它规避了计算均衡时维数灾难的两个来源。

迭代

- 现在，管理层与研究者面对的计算问题不同：管理层只以 $J_{i,t}$ 为条件，而研究者必须对 $s_t = (J_{1,t}, \ldots, J_{n_t})$ 计算均衡。这里我们处理研究者的计算问题，下文再回到企业的问题。

- **迭代由以下要素定义**：
  - 位置，记为 $L^k = (J_1^k, \ldots, J_{n(k)}^k) \in \mathcal{S}$：活跃个体的信息集。
  - 记忆中的对象（即 M^k）：
    (i) 认知的评估值 W^k，
    (ii) 每个点的访问次数 h^k。

必须更新 (L^k, W^k, h^k)。计算负担由记忆约束和计算时间决定。我对记忆采用一种简单（不一定最优）的结构。

更新位置。

- 为每个个体计算“贪婪”策略（现在策略记为“m”）

$$m^*_{i,k} = \arg \max_{m \in \mathcal{M}} W^k(m|J_{i,k})$$

- 在给定 $m^*_{i,k}$ 的条件下随机抽取结果：
- 例如：若我们投资于“与收益相关”的 $\omega_{i,k} \in J_{i,k}$，则抽取 $\omega_{i,k+1}$，条件为 $(\omega_{i,k}, m^*_{i,k})$.
- 用结果更新 $L^k \to L^{k+1}$。

更新 W^k。

- “学习”的解释：简单情形：假设个体观察到竞争对手的静态控制变量 m_{-i}（通常是价格或出价），并且起初假设个体（也许通过估计）知道原始要素 $\pi_i(\cdot)$、$p(\omega_{i,t+1}|\omega_{i,t}, m_{i,t})$。这些对象可以“离线”估计。

- 它对“若当初选择了 m，其价值会是多少”的事后认知为

$$V^{k+1}(J_{i,k}, m) =$$

$$\pi(\omega_{i,k}, m, m_{-i,k}, d_k) + \max_{\tilde{m}\in M} \beta W^k(\tilde{m}|J_{i,k+1}(m)),$$

其中 $J_i^{k+1}(m)$ 是在给定 m 与竞争对手实际行为时，第 $k+1$ 期的信息。

把 $V^{k+1}(J_{i,k})$ 视为 $W(m|J_{i,k})$ 可能实现值中的一次随机抽取，并像随机积分（Robbins and Monro，1956）那样更新 W^k

$$W^{k+1}(m|J_{i,k}) =$$

$$\frac{1}{h^k(J_{i,k})}V^{k+1}(J_{i,k},m) + \frac{(h^k(J_{i,k})-1)}{h^k(J_{i,k})}W^k(m|J_{i,k}),$$

或

$$W^{k+1}(m|J_{i,k}) - W^k(m|J_{i,k}) =$$

$$\frac{1}{h^k(J_{i,k})}[V^{k+1}(J_{i,k},m) - W^k(m|J_{i,k})].$$

（其他权重更有效，因为 $V^{k+1}(J_{i,k},m)$ 的早期估计比后期估计噪声更大；而且如果知道如何利用相邻状态的信息来更新给定状态，会很有帮助……）

注。

- 一旦得到均衡估值，我们就倾向于停留在那里，即若用 * 表示均衡，

$$E[V^*(J_i, m^*)|W^*] = W^*(m^*|J_i).$$

因此一旦到达均衡，就倾向于停留在均衡。

- 与所有动态博弈的计算算法一样，它不保证收敛，但学习的解释为无论如何都使用它提供了理由。

- 事实上，抽样中隐含的平滑往往能缓解逐点算法的收敛问题，但可能需要很多次迭代（这就引出企业能否做得更好的问题）。

- 个体（不仅是分析者）也可以用该算法寻找均衡策略，或针对环境的扰动进行调整。

- 形式上，该算法没有维数灾难。
  1. 计算延续价值：积分被两个数的平均所取代。
  2. 算法最终会进入 $\mathcal{R}$ 并停留在那里，且 $\#\mathcal{R} \leq \#\mathcal{J}$。
- Fershtman and Pakes（2012）还给出了一个没有维数灾难的均衡检验。
- 不过，状态数仍可能变得很大（通常随状态变量个数线性增长）。
- 一种解决办法是在其中嵌入函数形式近似。运筹学中有相关文献研究单个决策者问题的计算，常称为“TD 学习”（见 Sutton and Barto，1998）。

REBE 的多重性。

- 回顾：$\mathcal{R}$ 是常返类（被反复访问的点）。

- $\mathcal{R}$ 同时包含“内部”点和“边界”点。存在可行策略能导向 $\mathcal{R}$ 之外的点为边界点；无论选择何种（可行）策略都只能转移到 $\mathcal{R}$ 中其他点的点为内部点。

- 我们的条件只保证在内部点上，对结果的认知与实际博弈的结果一致。在边界点上，对某些可行（但非最优）策略结果的认知并不受实际结果约束。

- “MPBE”是（受限）EBE 的特例，它们存在多重性。这里，边界点上不同的认知可以支撑（可能大得多的）均衡范围。

缩小均衡集合。

- 如果企业处于某个均衡，数据往往会揭示它们处于哪个可能的均衡。所以这个问题实际上只在计算反事实时才是问题。限制均衡数目的方法有不少，但据我所知，没有一种能保证唯一性。

  - 把初始条件约束为数据中的状态（历史会限制能生成的均衡）。

  - Asker, Fershtman, Jihye, and Pakes（2020，RAND）计算了企业在边界点上以 $m_i \neq m_i^*$ 进行试验的均衡。由此得到更强的均衡概念及其检验（边界一致性）。

- 边界一致性保证：若按记忆中的策略行事，边界点上每个**可行**行动的认知都与**实际博弈**的结果一致（因而在 $\mathcal{R}$ 上也一致）。

边界一致性

- 令 $B(J_i|\mathcal{W})$ 为在 $J_i \in s \in \mathcal{R}$ 处可能产生不在常返类中的结果的行动集合（若非空，则 J_i 是边界点），并令 $B(\mathcal{W}) = \cup_{J_i \in \mathcal{R}} B(J_i|\mathcal{W})$。那么保证“边界一致性”所需的额外条件为：

- **额外条件**。令 τ 标记未来各期，则 $\forall (m, J_i) \in B(\mathcal{W})$

$$W(m^*|J_i) \geq$$

$$E\left[\sum_{\tau=0}^{\infty} \delta^\tau \pi\Big(m(J_{i,\tau}), m(J_{-i,\tau})\Big)\Big|J_i = J_{i,0}, \mathcal{W}\right],$$

其中 $E[\cdot|J_i, \mathcal{W}]$ 用 $\mathcal{W}$ 生成的策略，对从 J_i 出发的未来状态取期望。♠

关于转向实证研究的说明（摘自 Dubois and Pakes，2025?）。

- 建议：
  - 从一个实证模型出发：企业在给定其认知时进行最大化，但这些认知不必是“正确的”或“均衡的”认知。
  - 应当用数据来确定企业策略似乎对数据中的哪些变量作出反应。通常包括利润的某个函数、制度特征，以及竞争企业的控制变量或状态。
  - 然后加入一个序列相关的不可观测状态，以反映企业知道但不在你数据中的变量（几乎总是需要）。

转向数据（Dubois and Pakes，2025?）

- 理论对个体的信息集不置可否，但实证研究必须设定它。

- 我们使用两个模型：
  - 实证模型：假设最大化行为，但不假设对未来的认知是正确的。
  - 均衡模型：施加 EBE 的约束。

实证模型的作用是什么？

- 确定状态变量，包括：
  - 数据中广告所响应的变量，以及
  - 不可观测变量的性质（企业作出反应、但不在我们数据中的广告决定因素）。

实证模型的作用（续）。

- 阐明模型需要复制哪些方面，才能提供可信的行为模型
- 估计实证模型时，要注意处理由不可观测的序列相关状态引起的问题，尤其是：
  - 存在退出或企业暂停投资一段时间时的选择问题；
  - 不可观测变量的序列相关所导致的右侧变量内生性问题。

• 实证模型与以往使用的模型（Benkard et al. 2007；Pakes et al. 2007）的区别只在于：

- 我们不假设均衡认知；
- 我们允许存在序列相关的不可观测状态变量。

反事实。

- 在进行反事实分析之前，应当先检查实证模型是否足够丰富，能充分近似数据。

- 反事实会重新参数化问题的原始要素。它们必然是“样本外”的，因此只用实证模型是不合适的。

- 分析反事实有两种选择：
  - 使用学习算法，可以是我们刚才讲过的那一种。
  - 使用我接下来要讲的直接算法。

注

- 没有人相信市场会瞬间切换到新的均衡，因此很可能存在某种学习过程。问题在于研究者可用的学习模型是否是好的近似。

- 若企业从不在我们数据中的信息中学习，我们能用的学习模型可能并不合适。

- 对较长期的预测而言，直接求均衡似乎更合适。当然，如果环境持续变化，这可能不是正确的分析方式。

算法：概览（摘自 Dubois-Pakes）。

- 计算动态市场均衡不动点时的问题：

1. 状态空间的维数（需要为多少个点计算策略）。
   - 不为所有可能状态计算策略，只为每个时期的每个产品分别计算策略（点数很少）。这是“逐点”的：即不做离散化或近似。

2. 计算延续价值（积分的维数）。
   - 用模拟代替积分：对模拟出的延续价值序列取平均。随机变量在各次迭代中必须保持不变。可以用最后一期的投资来衡量样本之后的激励（因此样本之后反映的是企业的认知）。

- 算法从数据中的初始点开始，并假设此后访问的每个点都属于某个边界一致均衡的常返类。

算法细节。

- 算法是迭代的。迭代以 l 标记，并与策略函数相对应。初始估计是实证模型的策略函数。

- 假设策略函数为

$$a_t = \theta_0 + \theta_1 \log\left(\frac{\partial \pi^l(\xi', J')}{\partial \xi'}\right) + w_t \beta_w$$

其中

$$\omega_t = \rho \omega_{t-1} + \nu_t$$

且 ν_t 与历史无关。

- 从实证模型得到的策略函数估计出发，并保持生成 ω_t 的过程等于实证模型的估计。

- 每次迭代时，用记忆中的策略函数为每家企业模拟 K 条利润 $\{\pi^{k,l}(\cdot)_{j,t}\}$ 与序列相关的
不可观测变量 $\{\omega^{k,l}_{h,j,t}\}$ 的样本路径，并在各次迭代中保持底层随机抽样不变（否则不会收敛）。

- 计算 $\{\pi^{k,l}(\cdot)_{j,t}\}$ 与 $\{\omega^{k,l}_{h,j,t}\}$ 在各样本路径上的平均值，
记为 $\{\pi^{l}(\cdot)\}_{j,t}$ 与 $\{\omega^{l}_{h,j,t}\}_{h,j,t}$。

- 计算平均贴现值 $W^{l}_{j,t} \equiv \sum_{\tau=1}^{\infty} \beta^{\tau} \pi^{l}(\cdot)_{j,t+\tau}$。

- a_t 的边际收益（我们设其等于 1）为

$$\mathcal{E}\Big[\sum_{\tau=0}^{\infty} \beta^{\tau} \frac{\partial \pi(\cdot)_{t+\tau}}{\partial a_t} | J_{j,t}\Big] \approx \sum \beta^{\tau} \frac{\partial \pi^{k}(\cdot)_{t+\tau}}{\partial a_t}$$

- 末期的贡献：用最后观察到的广告（记为 T_j）来近似 $\sum_{\tau=T_j}^{\infty}(\beta\rho)^{\tau}\frac{\partial\pi(\cdot)_{t+\tau}}{\partial\xi_{t+1}}\beta_{a,h}$（从而无需假设
企业对样本之后过程的认知与样本内相同）。

- 更新策略函数。将因变量

$$\sum \beta^{\tau}\frac{\partial\pi^{k}(\cdot)_{t+\tau}}{\partial a_t}-\omega_t$$

$$\approx \theta_0^{l+1}+\theta_1^{l+1}\log\left(\frac{\partial\pi^{l}(\xi',J')}{\partial\xi'}\right)+w_t\beta_w^{l+1}$$

- 最后计算

$$Y^{l}\equiv\frac{1}{\sum_{j,t}1}\sum_{j,t}\left(\frac{W_{j,t}^{l}-W_{j,t}^{l-1}}{W_{j,t}^{l-1}}\right)^{2}.$$

- 若 $Y^{l}<10^{-5}$ 则停止；若 $Y^{l}>10^{-5}$ 则进入第 $l+1$ 次迭代。

注。

- 若控制变量在某一点降为零（可能由于退出或其他原因），在拟合控制变量时也应当考虑退出决策。
- 你并没有估计任何东西，参数取自别处（包括 β）。

今天就讲到这里，希望对大家有用。