第 19 讲：
估计具有多重均衡的
方向性动态博弈：完全求解 MLE

计量经济学会动态结构计量经济学
暑期学校

Fedor Iskhakov，澳大利亚国立大学
Dennis Kristensen，伦敦大学学院
John Rust，乔治城大学
Bertel Schjerning，哥本哈根大学

UCL，伦敦
2025 年 7 月 6 日

路线图

1. 澳大利亚瓦楞纤维包装（CFP）生产商的合谋
2. 用模型做实验
3. 状态递归算法
   - 方向性动态博弈（DDG）理论
4. 递归词典序搜索（RLS）算法
5. 蛙跳博弈的完全求解
6. 用嵌套 RLS 方法对方向性动态博弈进行结构估计
   - NRLS 估计量的构造
   - 蒙特卡洛模拟

嵌套递归词典序搜索（NRLS）

- 来自 M 个独立市场、T 期的数据
  $Z = \left\{a^{jt}, x^{jt}\right\}_{j\in\{1,\ldots,N\},t\in\{1,\ldots,T\}}$
- 令所有 MPE 均衡的集合为 $\mathcal{E} = \{1, \ldots, K(\theta)\}$

1. 外层循环
   对结构参数 θ 最大化似然函数

$$\theta^{ML} = \arg\max_{\theta\in\Theta} \mathcal{L}(Z, \theta)$$

2. 内层循环
   对均衡选择最大化似然函数

$$\mathcal{L}(Z, \theta) = \arg\max_{k\in\{1,\ldots,K(\theta)\}} \mathcal{L}(Z, \theta, V_\theta^k)$$

在组织成 RLS 树的离散集合上求函数的最大值

状态空间上的似然

- 给定均衡 k 的选择概率 $P_i^k(a|x)$，似然为

$$\mathcal{L}(Z,\theta,V_\theta^k)=\sum_{j=1}^{N}\sum_{t=1}^{T}\sum_{i=1}^{J}\log P_i^k(a_i^{jt}|x^{jt};\theta)$$

- 令 ι 标记状态空间中的点
  $\iota=1$ 为初始点，$\iota=S$ 为终止状态
- 记 n_ι 为状态 x_ι 的观测数，$n_\iota^{a_i}$ 为参与人 i 在 x_ι 采取行动 a_i 的观测数

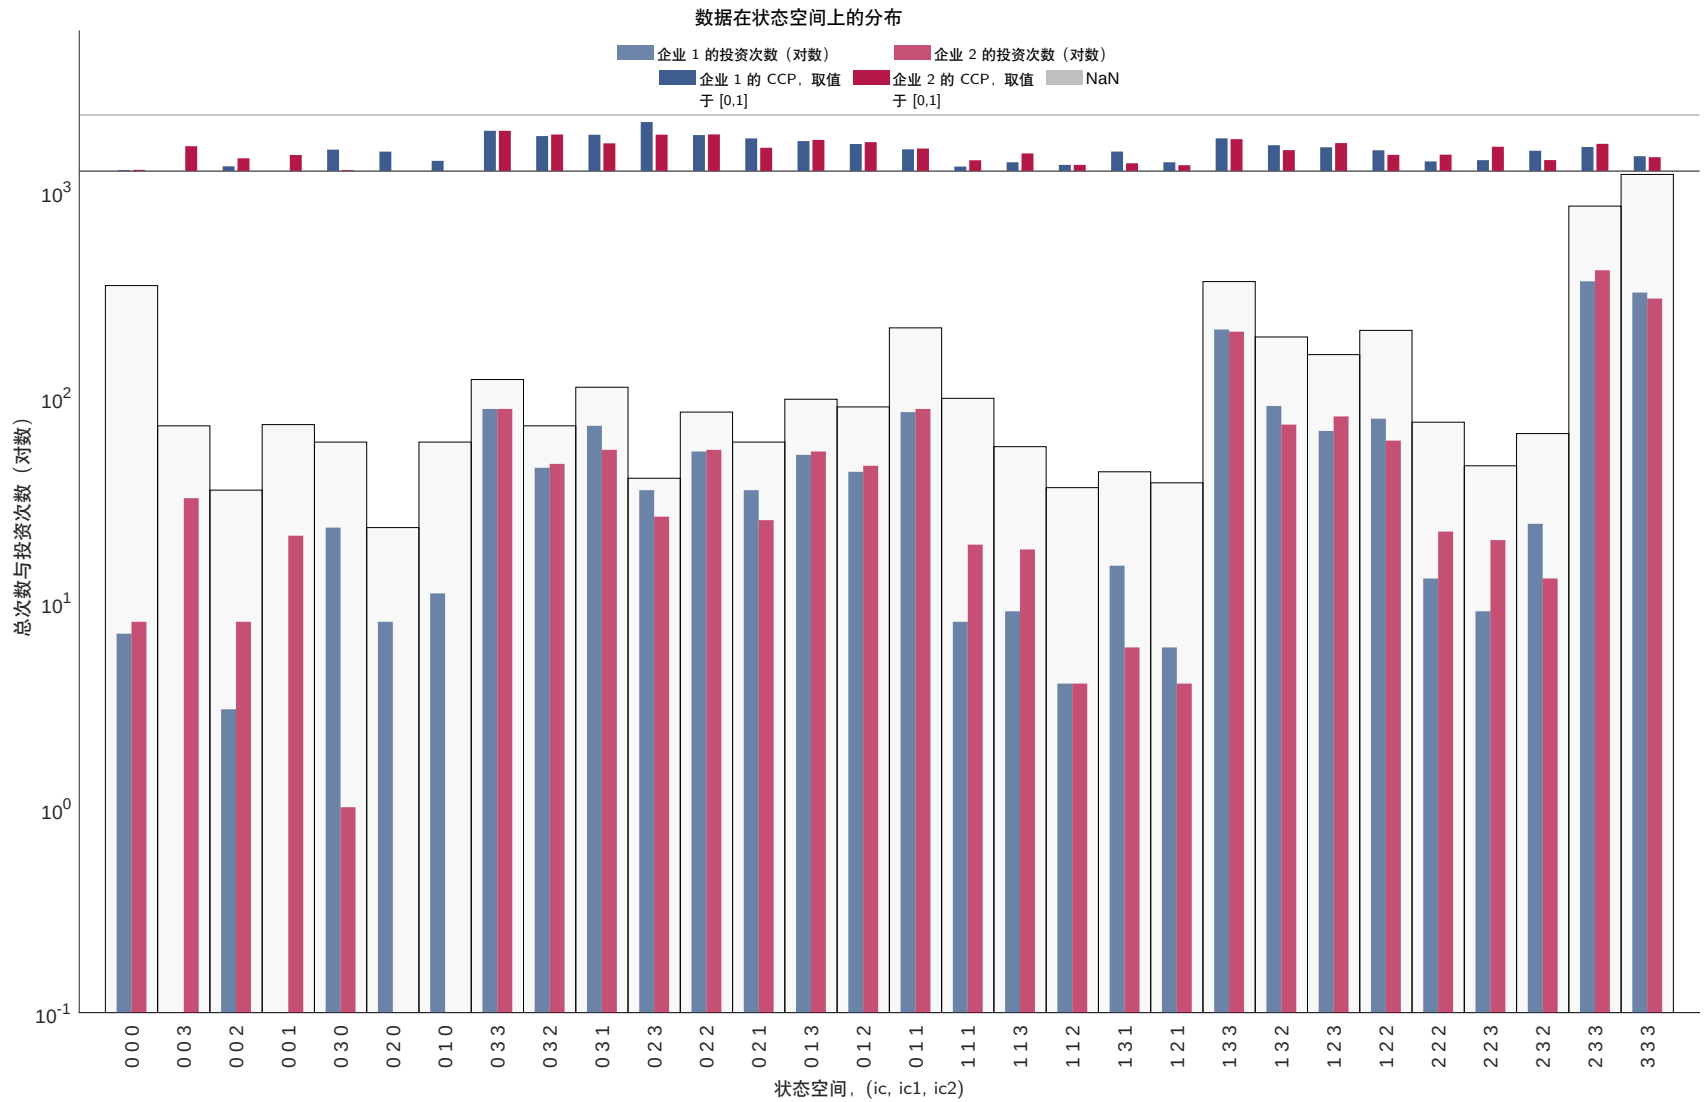
$$n_\iota=\sum_{j=1}^{N}\sum_{t=1}^{T}\mathbb{1}\{x^{jt}=x_\iota\}\qquad n_\iota^{a_i}=\sum_{j=1}^{N}\sum_{t=1}^{T}\mathbb{1}\{a_i^{jt}=a_i,x^{jt}=x_\iota\}$$

- 则特定均衡下的似然可以计算为

$$\mathcal{L}(Z,\theta,V_\theta^k)=\sum_{\iota=1}^{S}\sum_{i=1}^{J}\sum_{a}n_\iota^{a_i}\log P_i^k(a|x_\iota;\theta)$$

数据在状态空间上的分布

1000 个市场，5 期，从棱锥顶点开始



分支定界（BnB）法



Land and Doig，1960，Econometrica

- 求解离散规划问题的经典方法
- 在离散集合上最大化/最小化一个函数

1. 将可行方案集合的逐级细分组织成一棵树
2. 设定一个界函数，表示在给定子集上可达到的最优目标值
   - 单调性：界函数必须关于集合参数的基数弱递减（对 max 问题而言）
   - 在单点集上计算时，必须等于准则函数
3. 舍弃那些界低于当前已达到的最优目标值的方案子集

- BnB 方法有几种变体，
  区别在于具体实现
- BnB 方法有若干扩展

BnB 理论：分支

$$\max f(x) \text{ s.t. } x \in \Omega$$

$f(x) : R^n \to R$ 目标函数

Ω 可行 x 的集合

$\mathcal{P}_j(\Omega)$：把 Ω 划分为 $k_j + 1$ 个子集，$k_0 = 0$，$\mathcal{P}_0(\Omega) = \Omega$

$$\mathcal{P}_j(\Omega) = \{\Omega_{j1}, \ldots, \Omega_{jk_j} : \Omega_{ji} \cap \Omega_{ji'} = \varnothing, i \neq i', \cup_{i=1}^{k_j} \Omega_{ji} = \Omega\}$$

$\{\mathcal{P}_j(\Omega)\}_{j=1,\ldots,J}$ 是由 J 个逐步细化的划分构成的序列

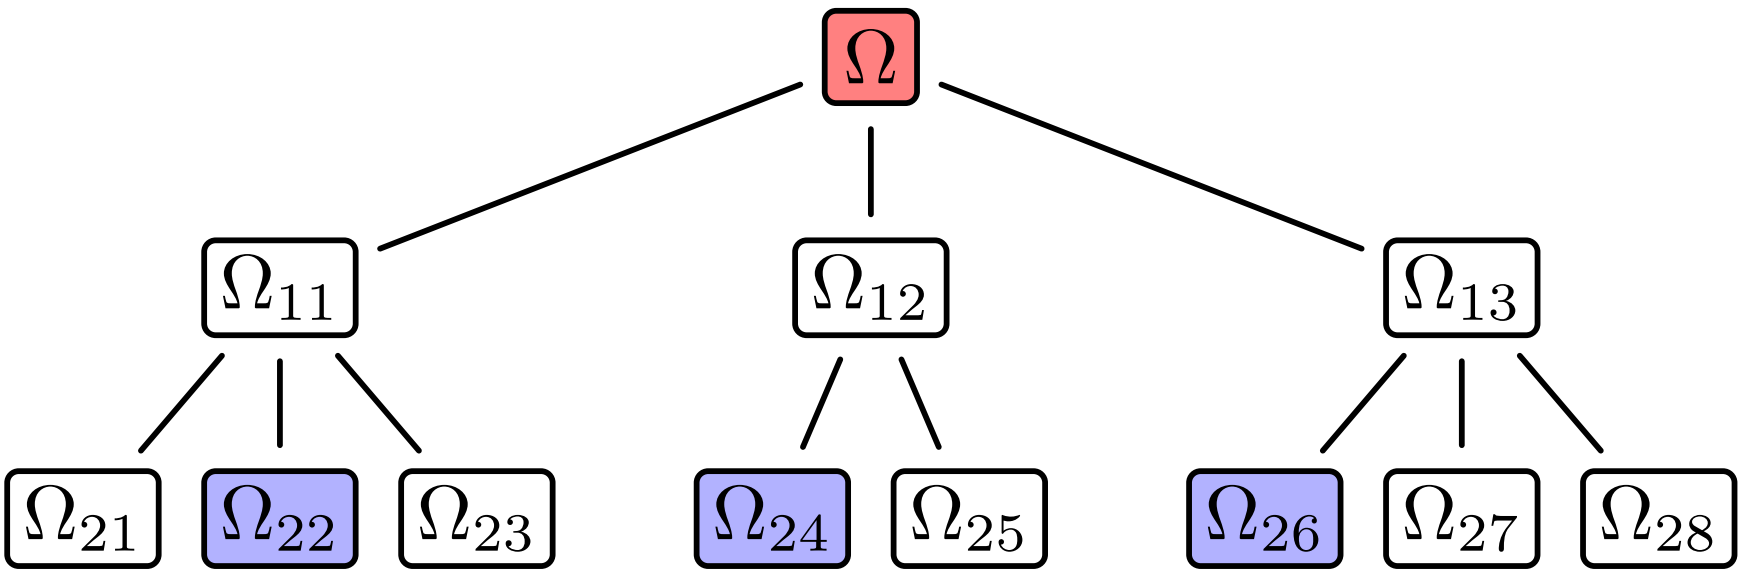
$$0 = k_0 \leq k_1 \leq \cdots \leq k_j \leq \cdots \leq k_J$$

$$|\Omega| \geq \max_i |\Omega_{k_1 i}| \geq \cdots \geq \max_i |\Omega_{k_j i}| \geq \cdots \geq \max_i |\Omega_{k_J i}|$$

$\forall j = 1, \ldots, J$，$\forall i = 1, \ldots, k_j$，$\forall j' < j$：$\exists i' \in \{1, \ldots, k_{j'}\}$，使得 $\Omega_{ji} \subset \Omega_{j'i'}$

BnB 理论：分支

$$\max f(x) \text{ s.t. } x \in \Omega$$



BnB 理论：定界

$$\max f(x) \text{ s.t. } x \in \Omega$$

$g(\Omega_{ij}) : 2^{\Omega} \to R$ 界函数：从 Ω 的子集映射到实数轴

对单点集有 $g(\{x\}) = f(x)$，即当 $\Omega_{ij} = \{x\}$ 时

界函数的单调性

$$\forall \Omega_{j_1,i_1} \supset \Omega_{j_2,i_2} \supset \cdots \supset \Omega_{j_k,i_k}$$

$$g(\Omega_{j_1,i_1}) \geq g(\Omega_{j_2,i_2}) \geq \cdots \geq g(\Omega_{j_k,i_k})$$

- 对最小化问题，不等号方向应反过来

结合 NRLS 的 BnB

- **分支**：RLS 树
- **定界**：界函数是在满足以下条件的状态子集上计算的部分似然

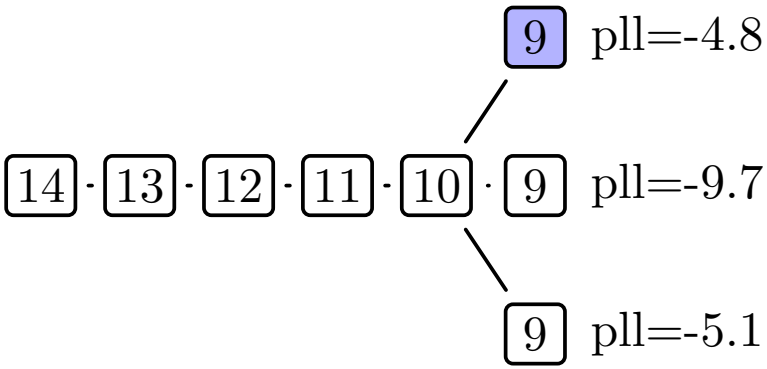
$$\mathcal{L}^{\text{Part}}(Z, \theta, \mathcal{S}) = \frac{1}{M} \sum_{i=1}^{N} \sum_{m=1}^{M} \sum_{t=1}^{T} \log P_i^{\ell}(a_i^{jt} | x^{jt}; \theta)$$
$$\text{s.t. } (x^{jt}, a_i^{jt}) \in \mathcal{S}$$

- 随着加入更多数据而单调下降
- 在 RLS 树的叶子处等于完整的对数似然

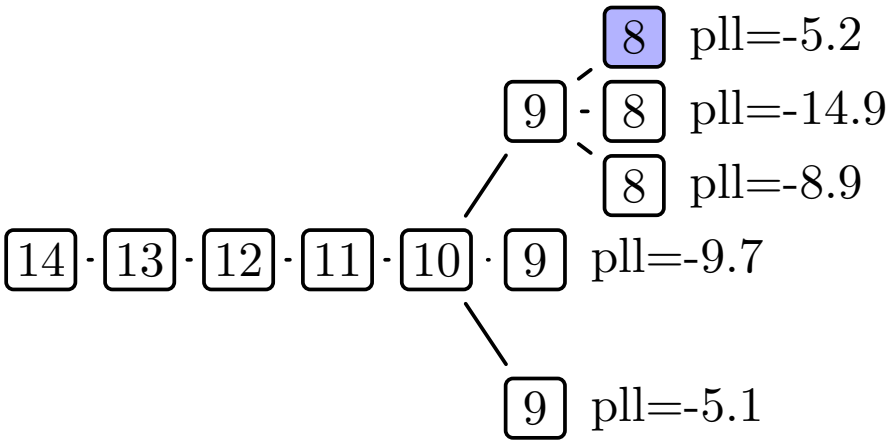
RLS 树上的 BnB，第 1 步

14 · 13 · 12 · 11 · 10 Partial loglikelihood = -3.2

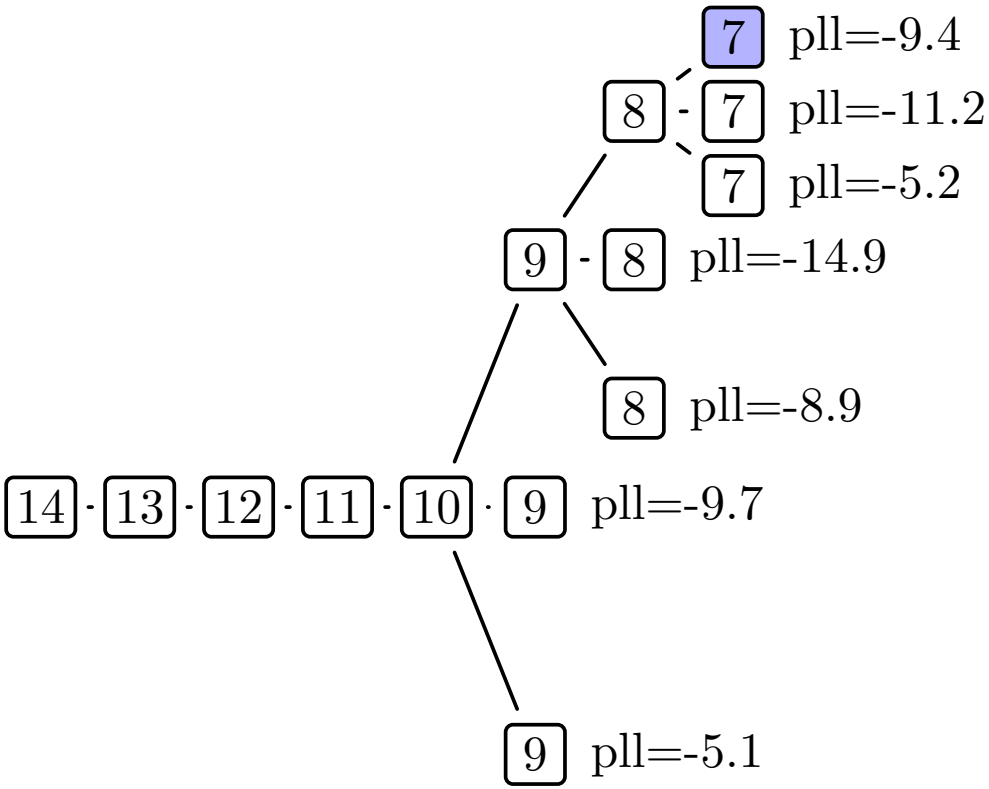
RLS 树上的 BnB，第 2 步



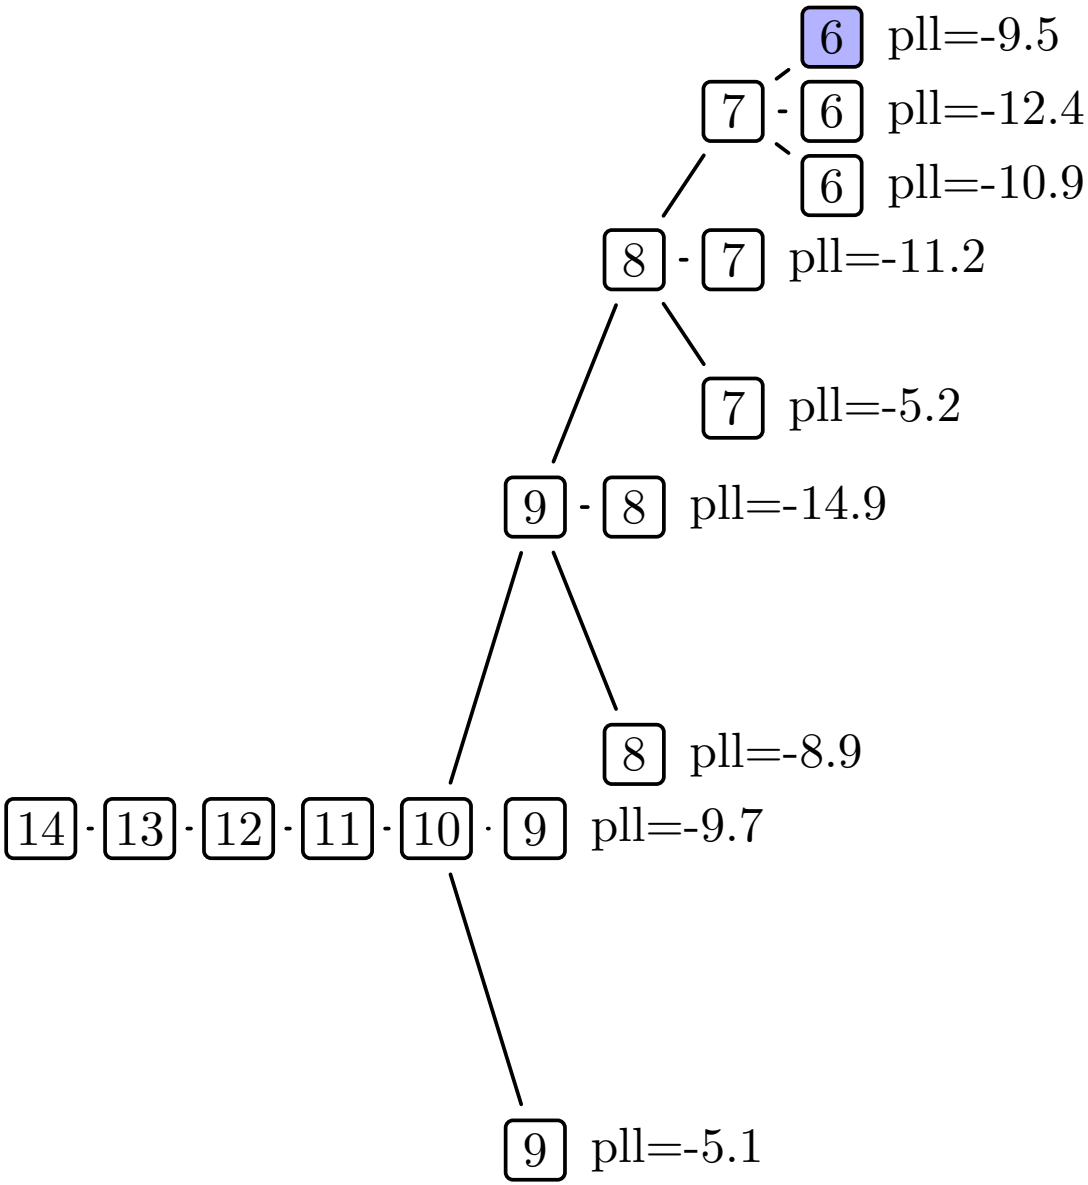
RLS 树上的 BnB，第 3 步



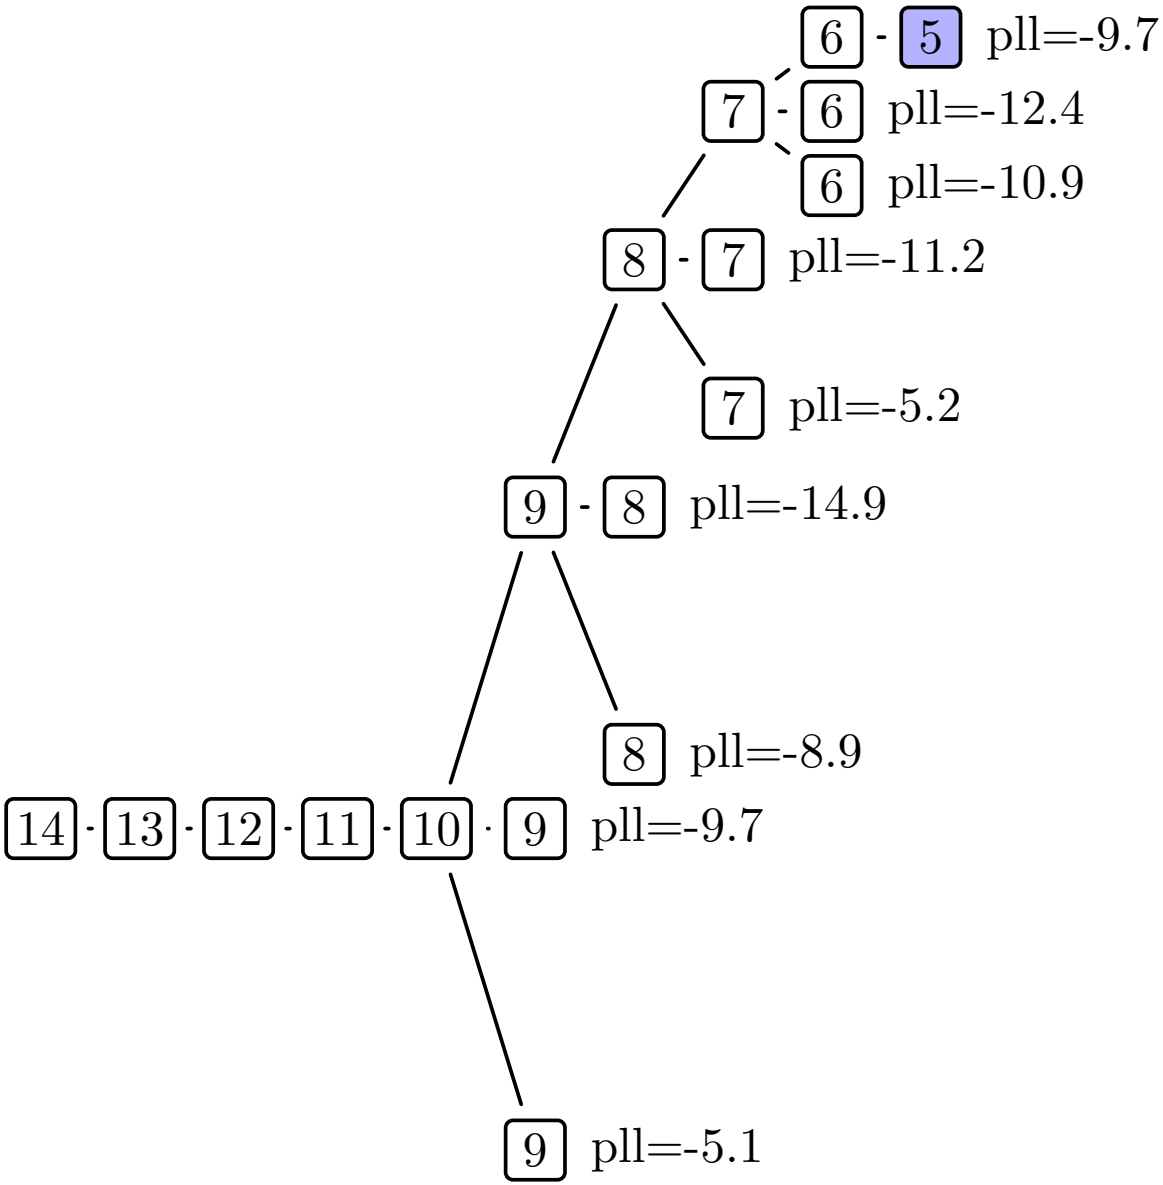
RLS 树上的 BnB，第 4 步



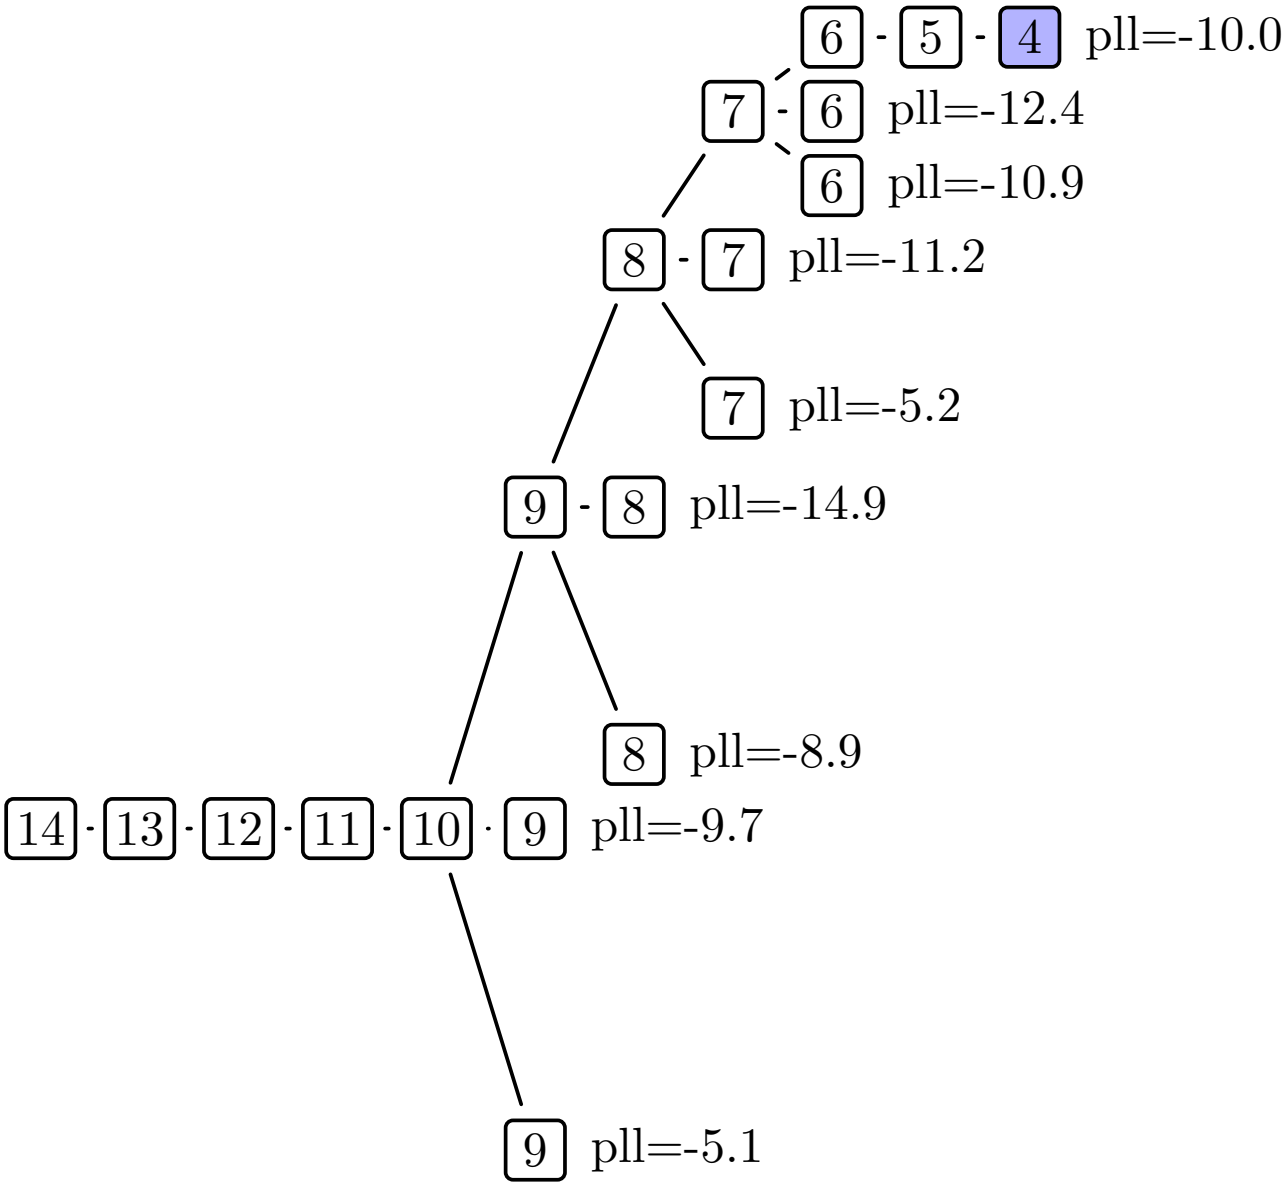
RLS 树上的 BnB，第 5 步



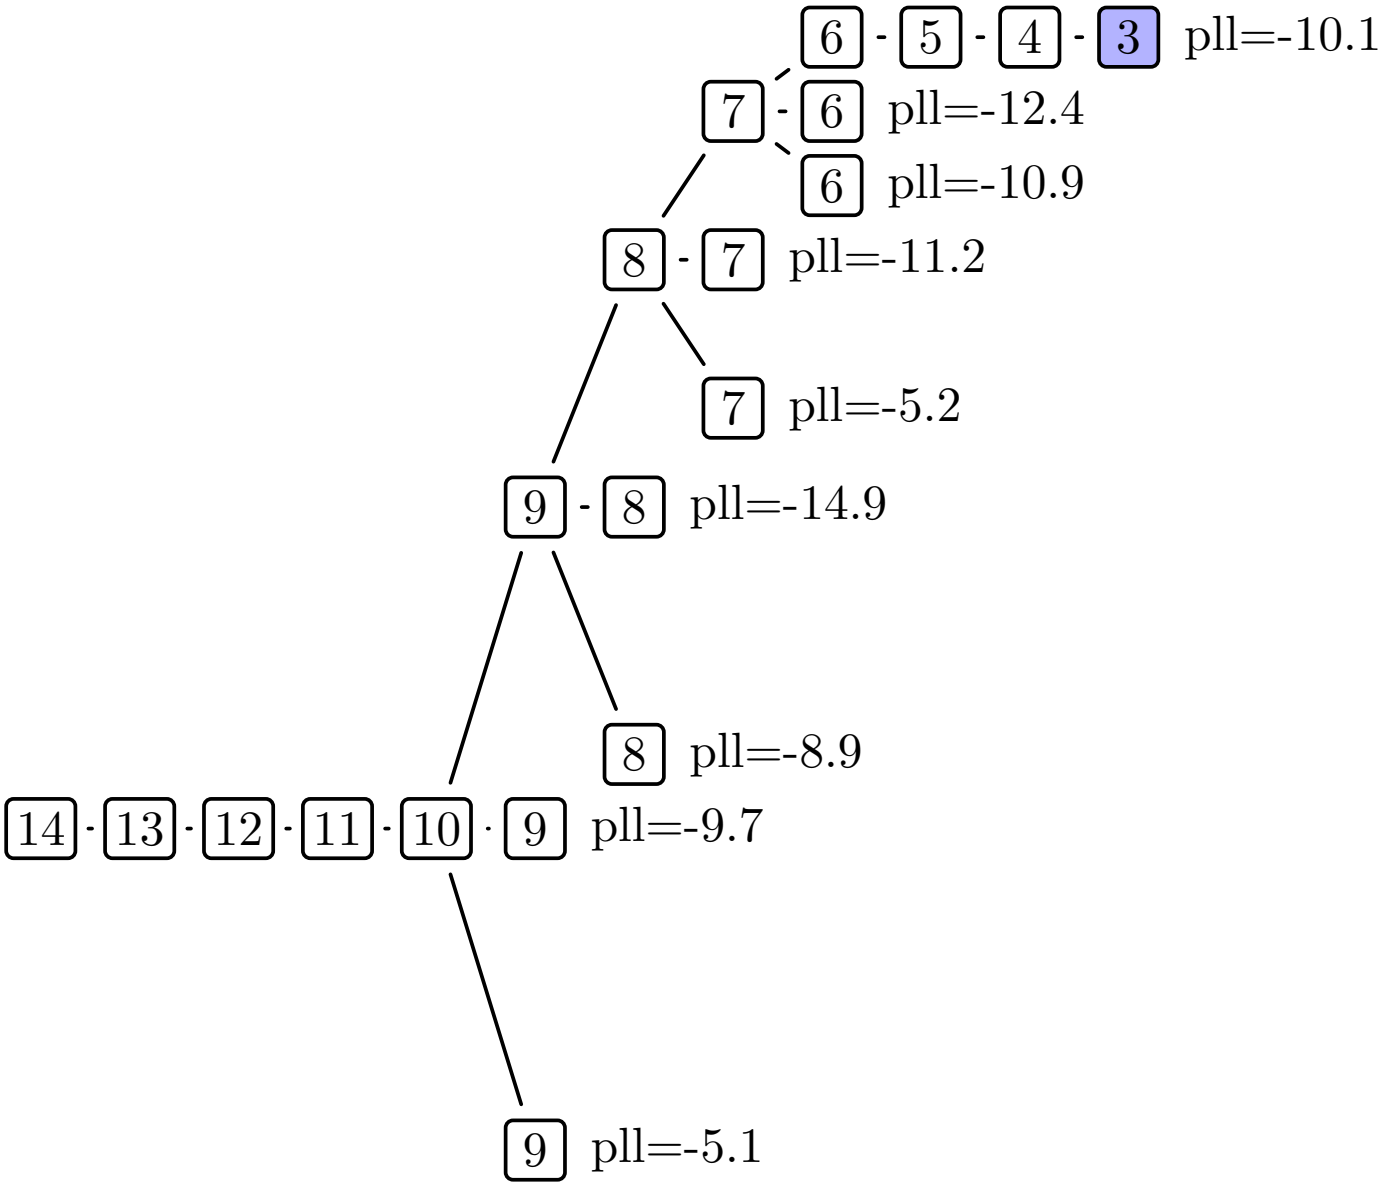
RLS 树上的 BnB，第 6 步



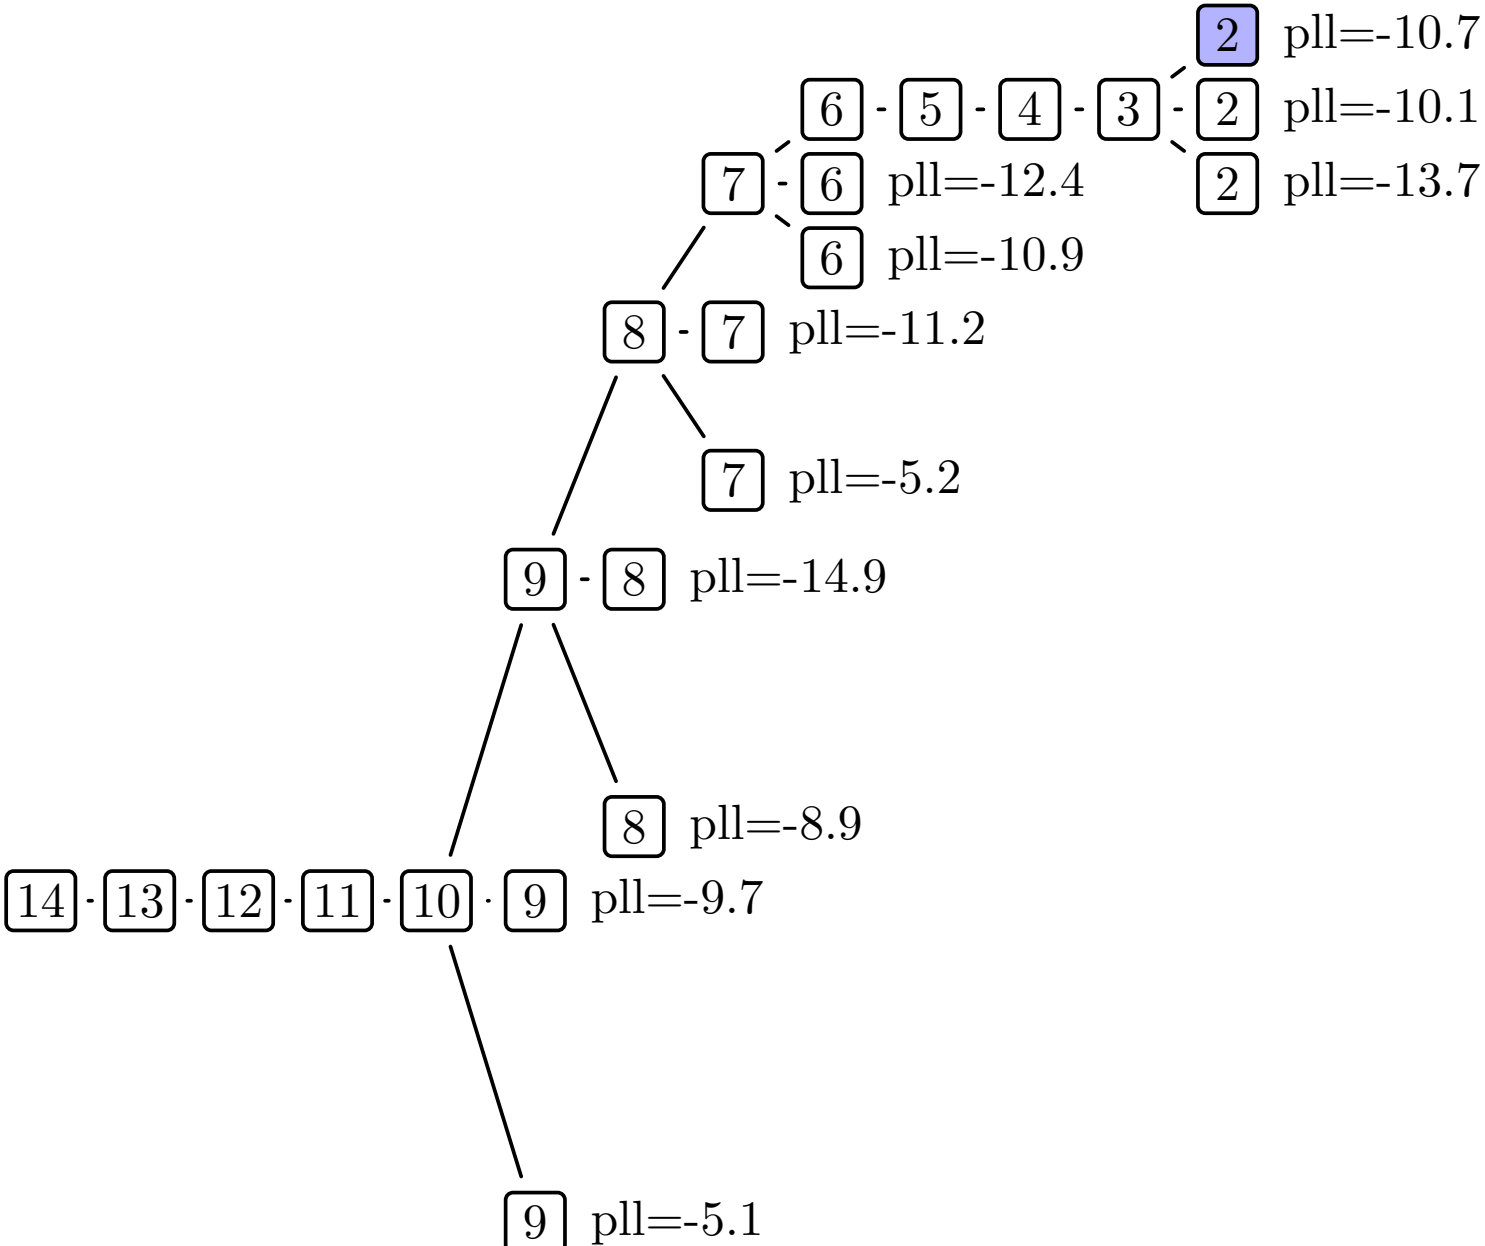
RLS 树上的 BnB，第 7 步



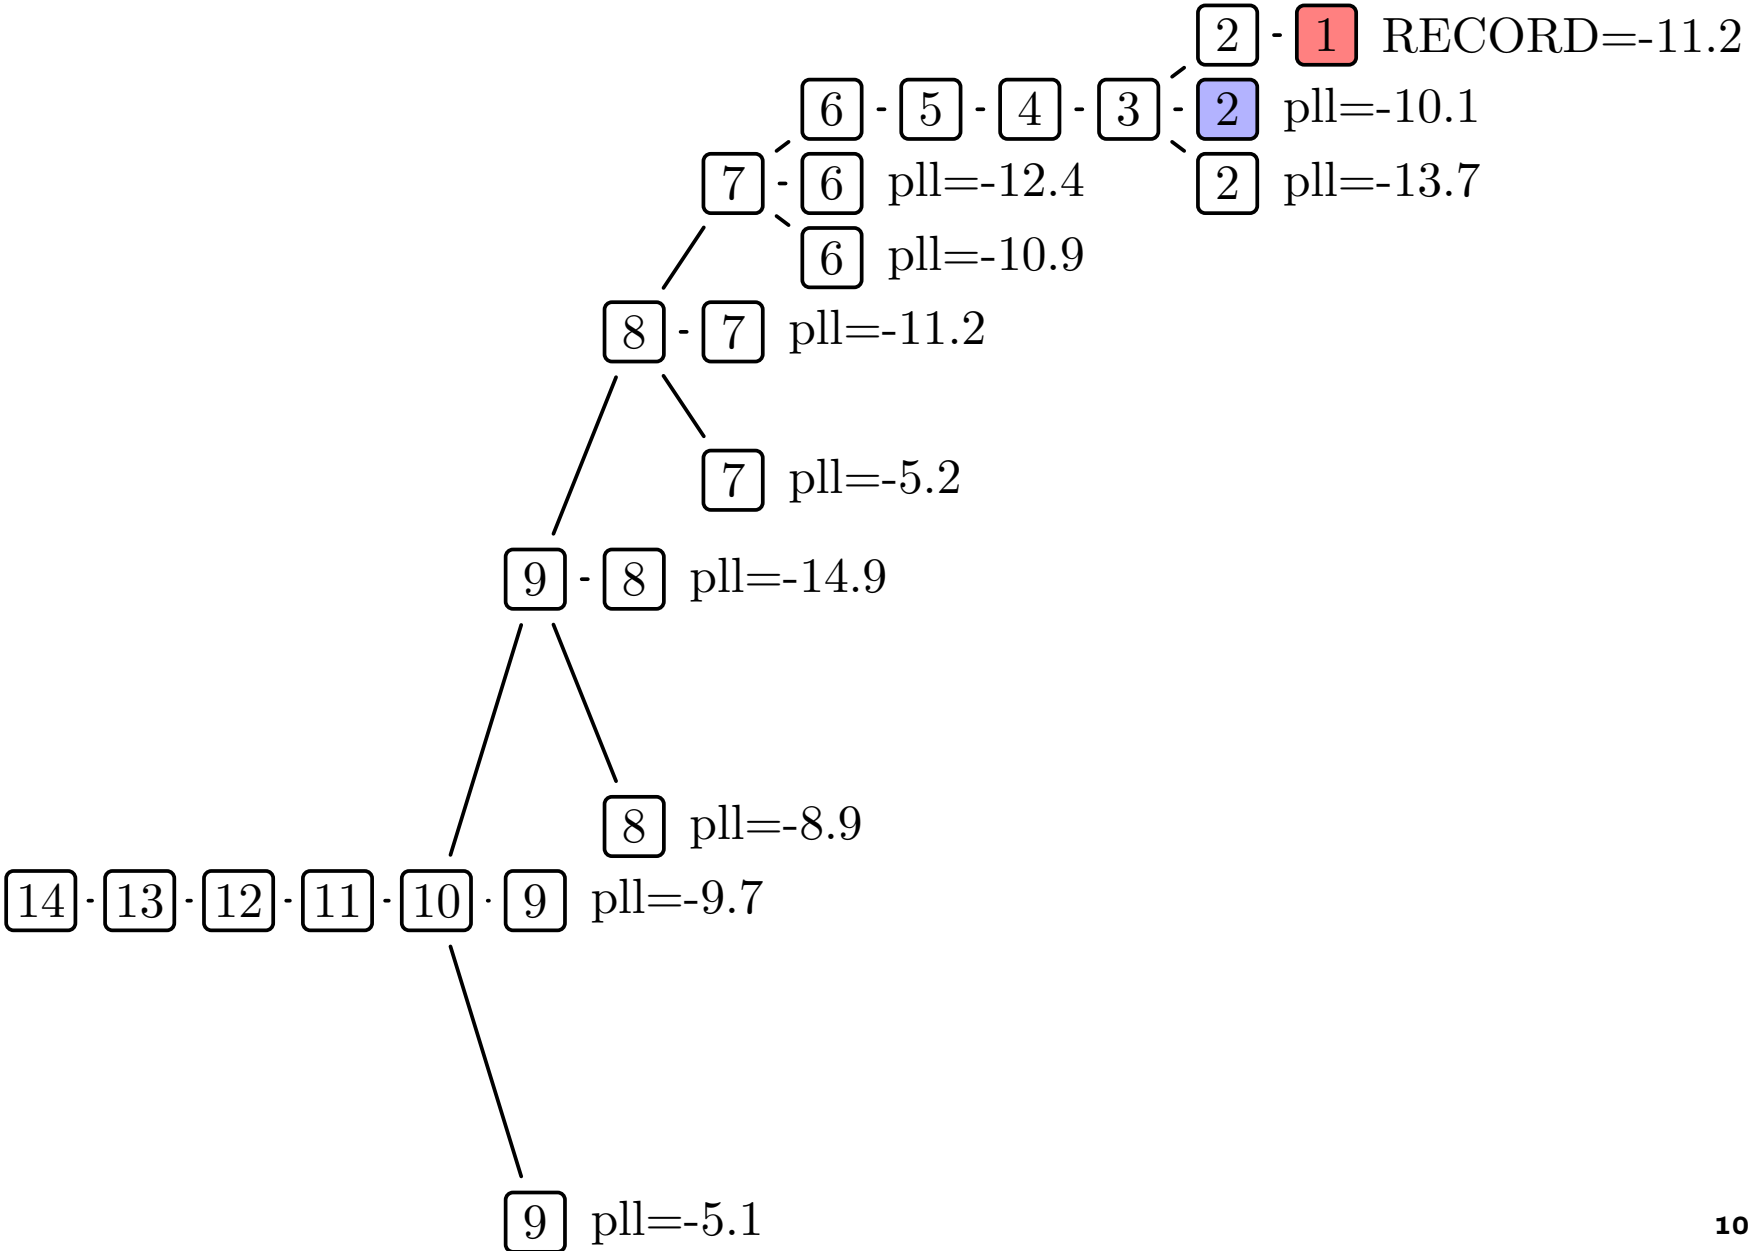
RLS 树上的 BnB，第 8 步



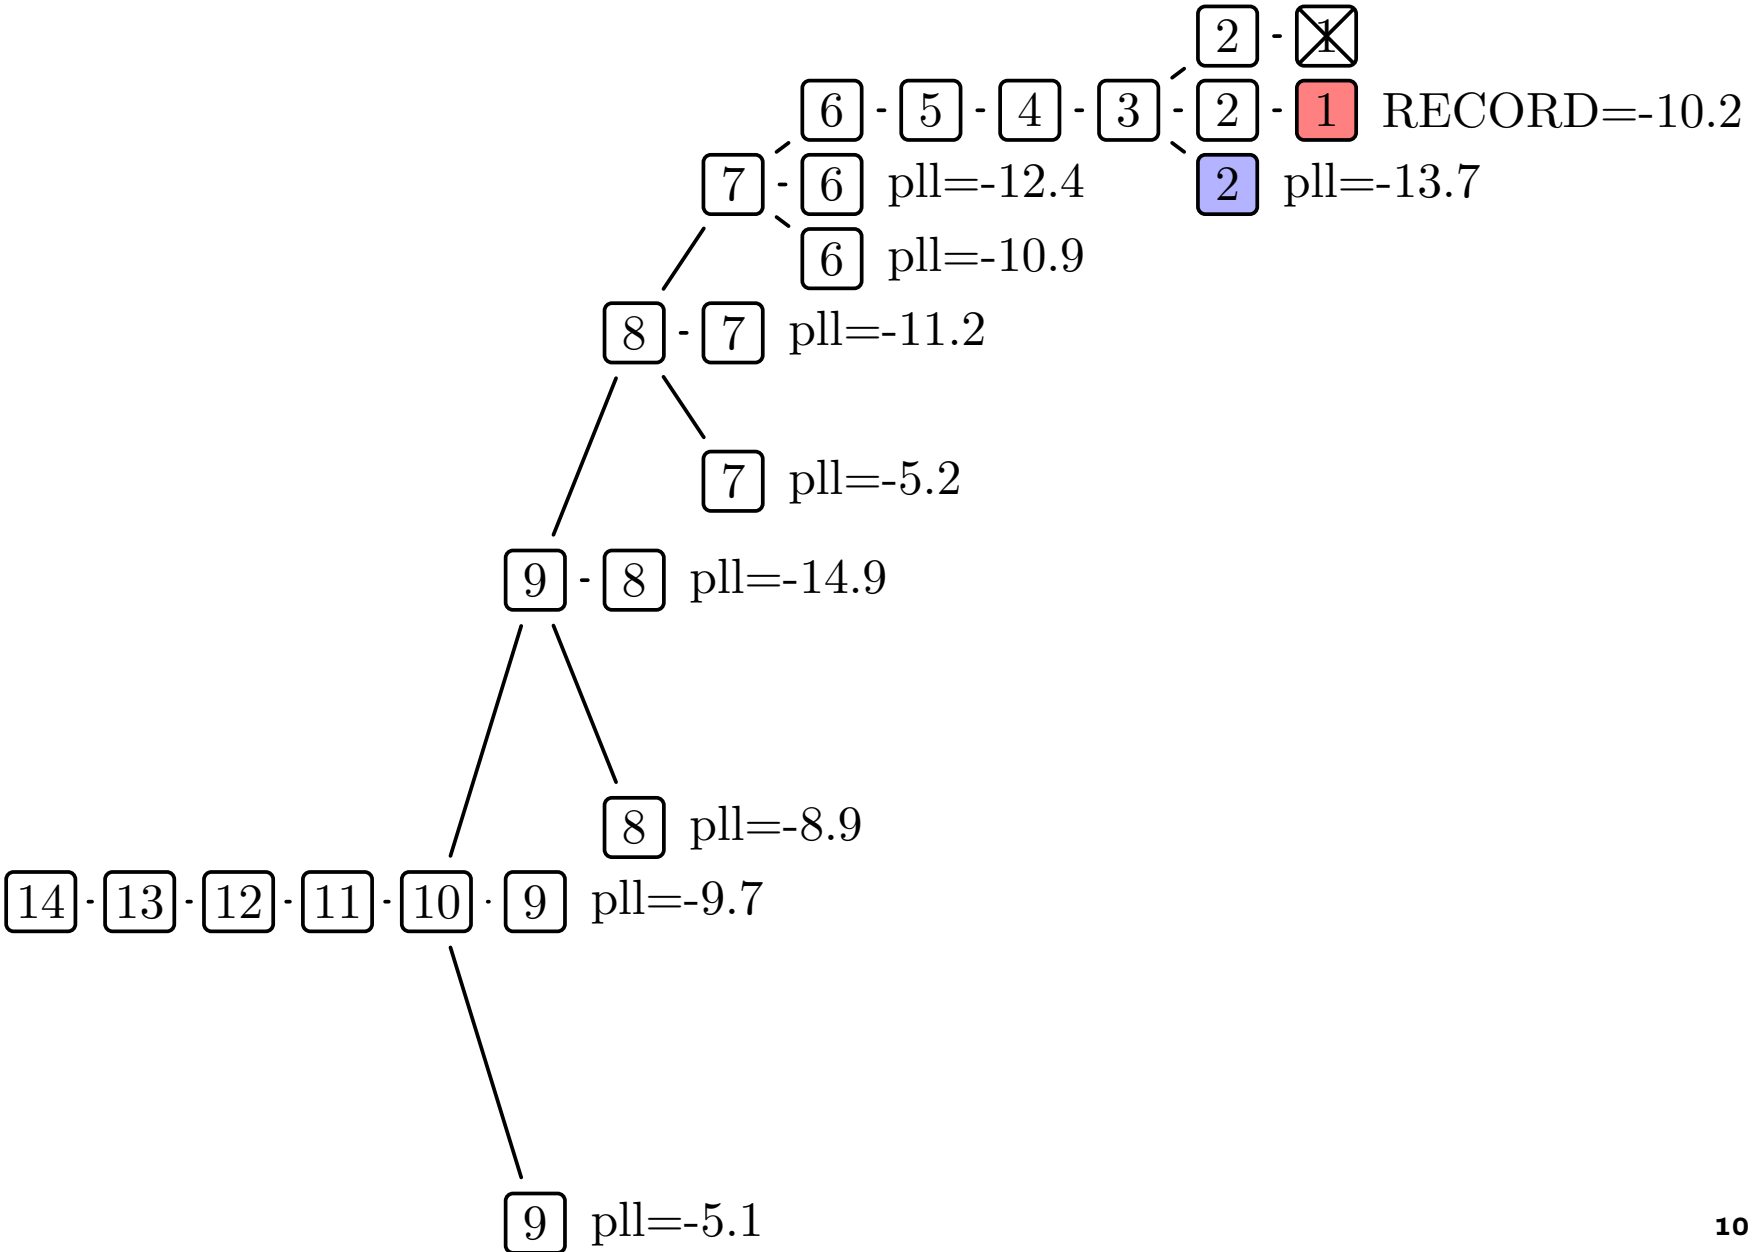
RLS 树上的 BnB，第 9 步



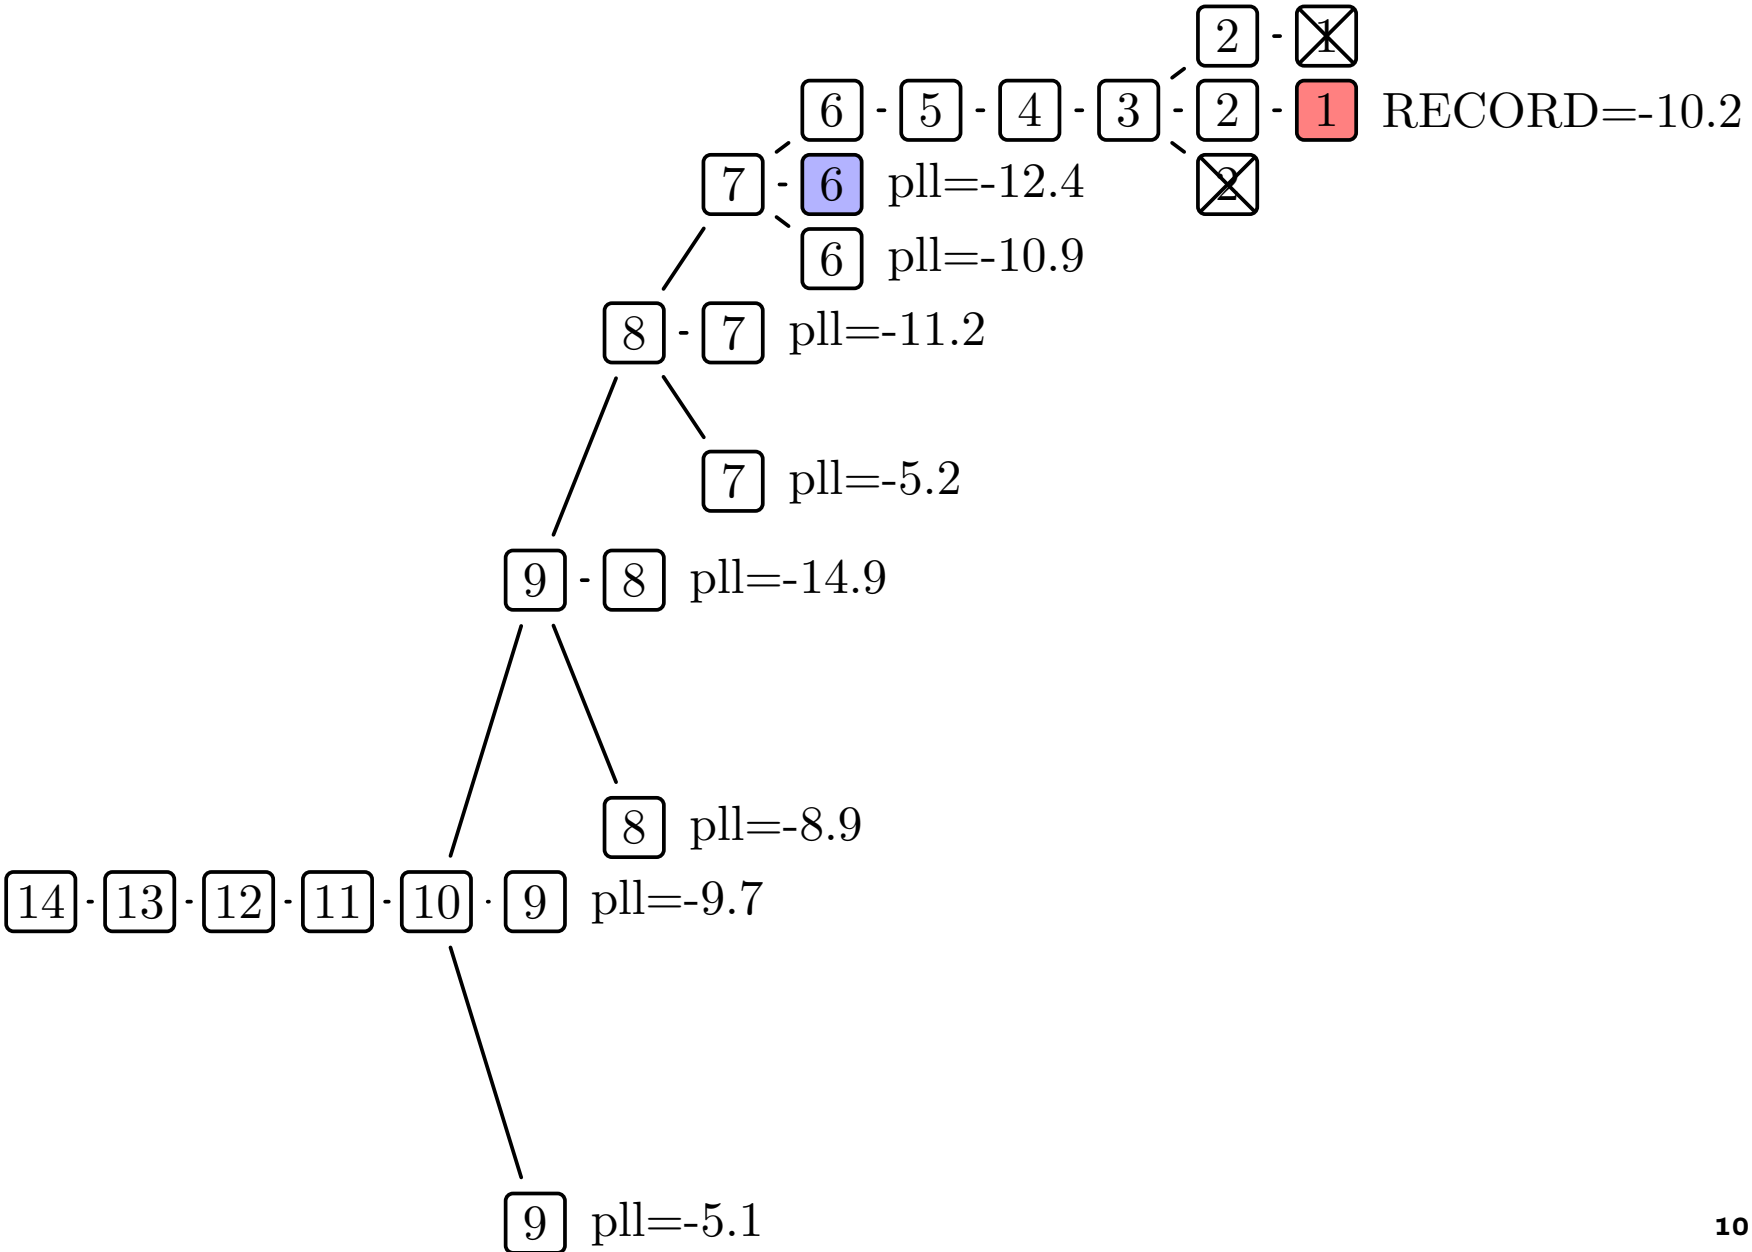
RLS 树上的 BnB，第 10 步



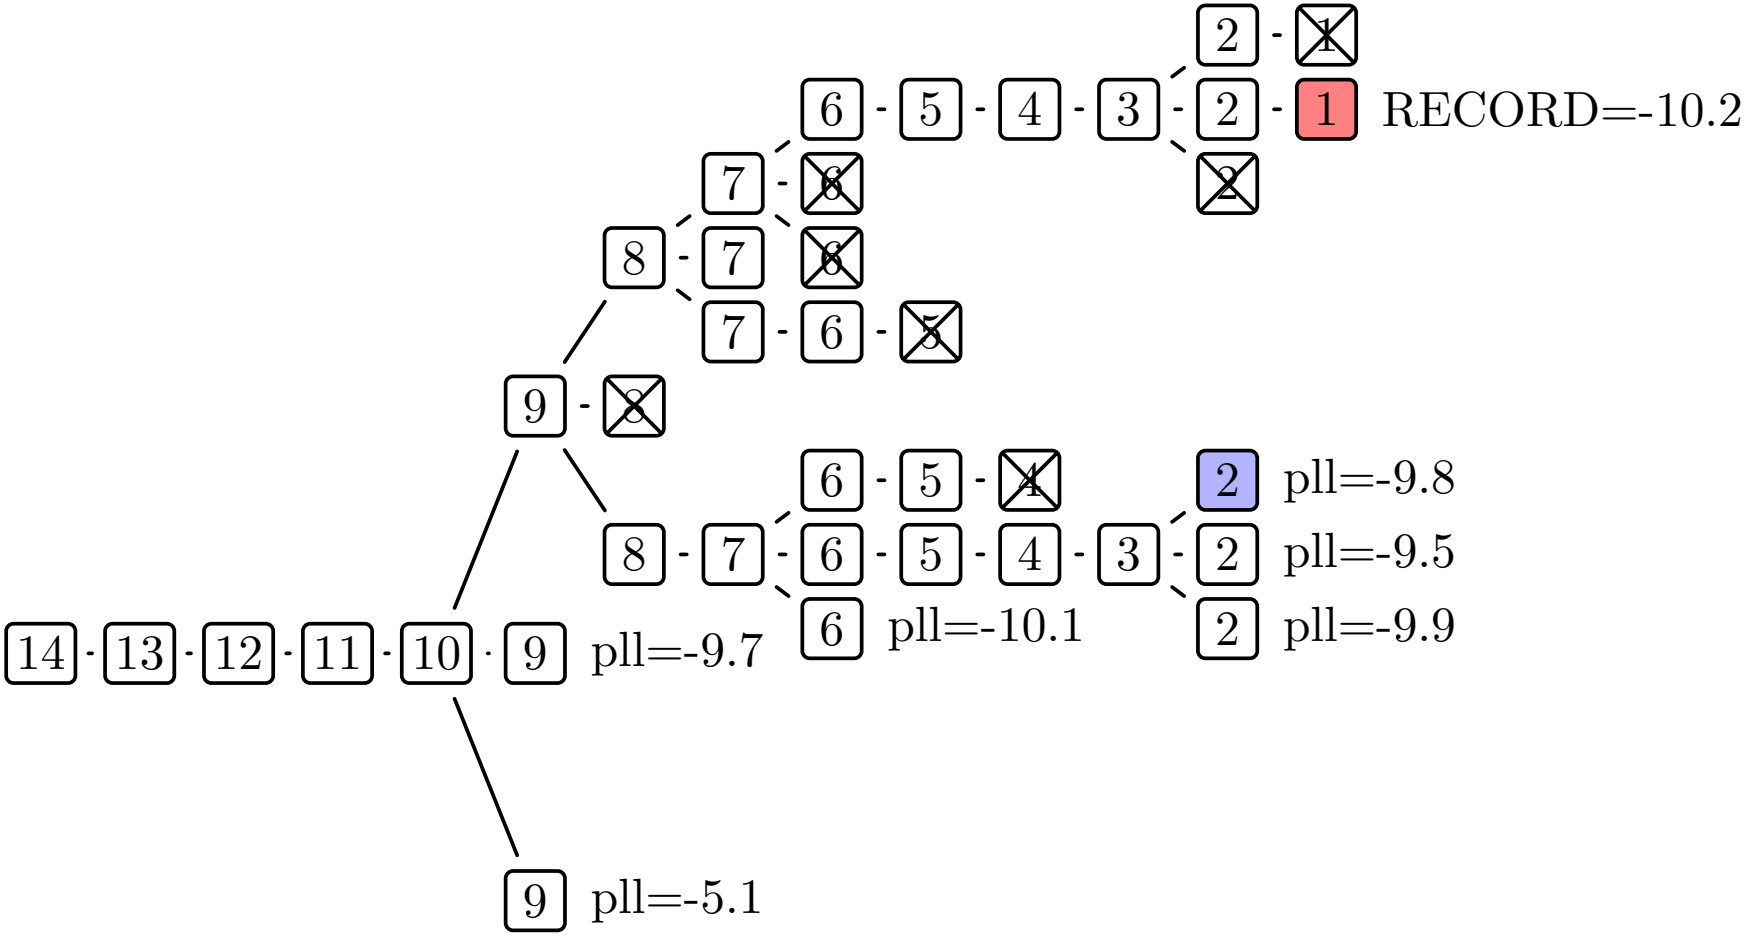
RLS 树上的 BnB，第 11 步



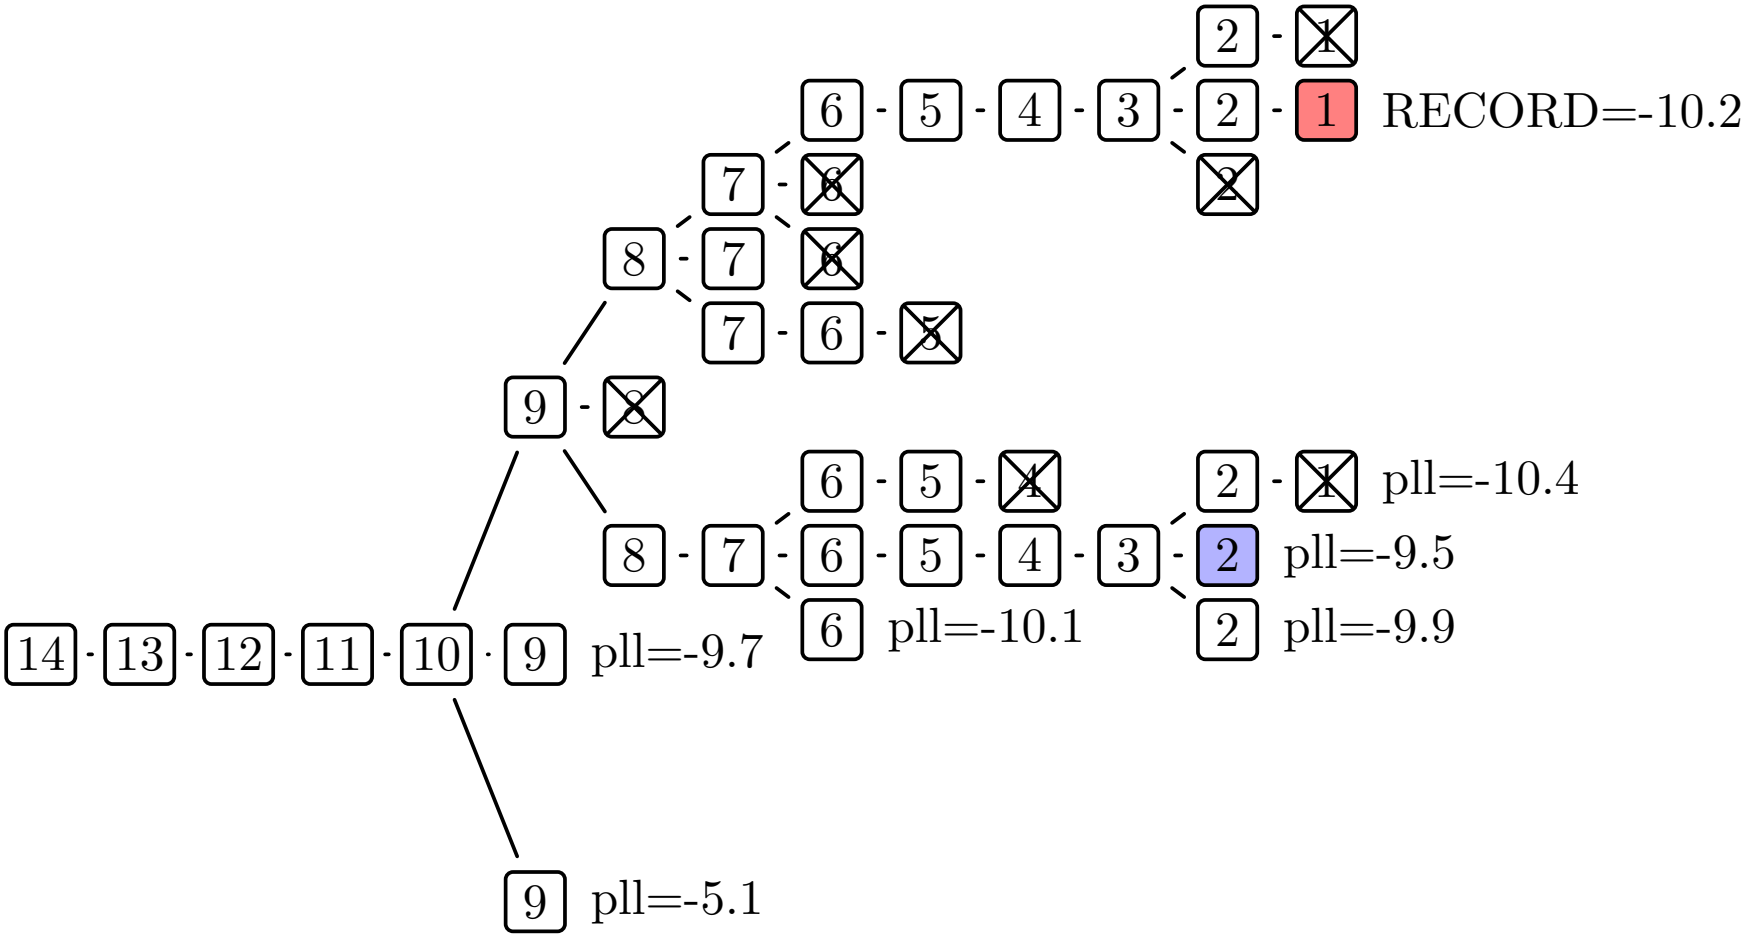
RLS 树上的 BnB，第 12 步



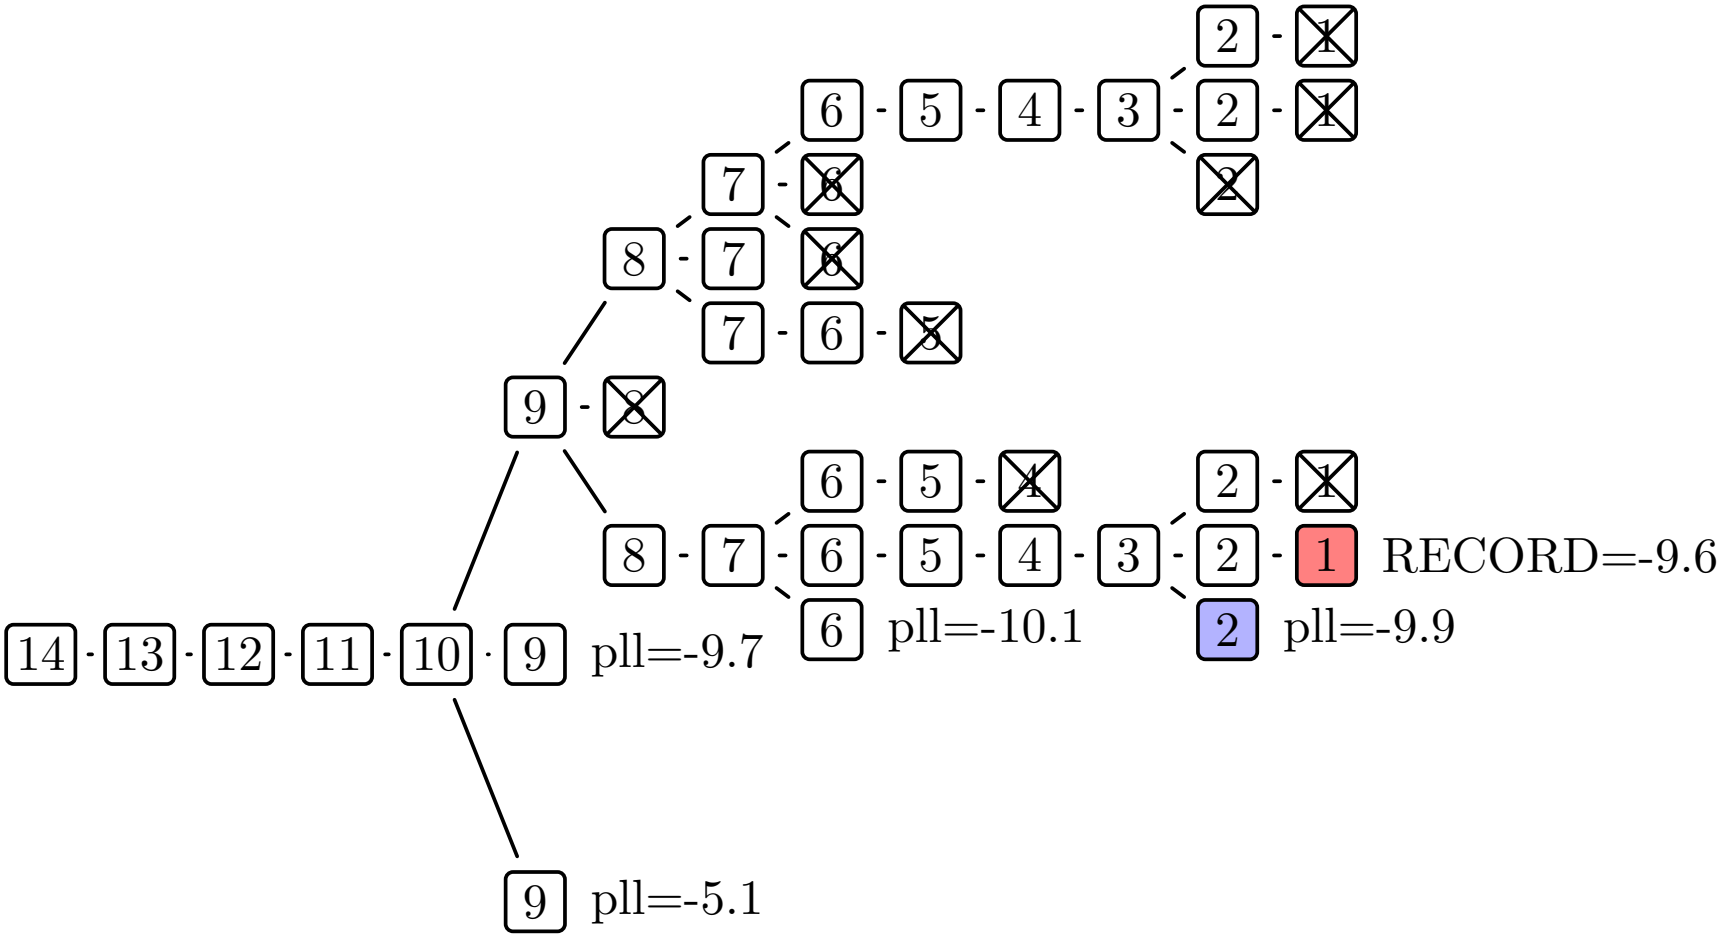
RLS 树上的 BnB，第 28 步



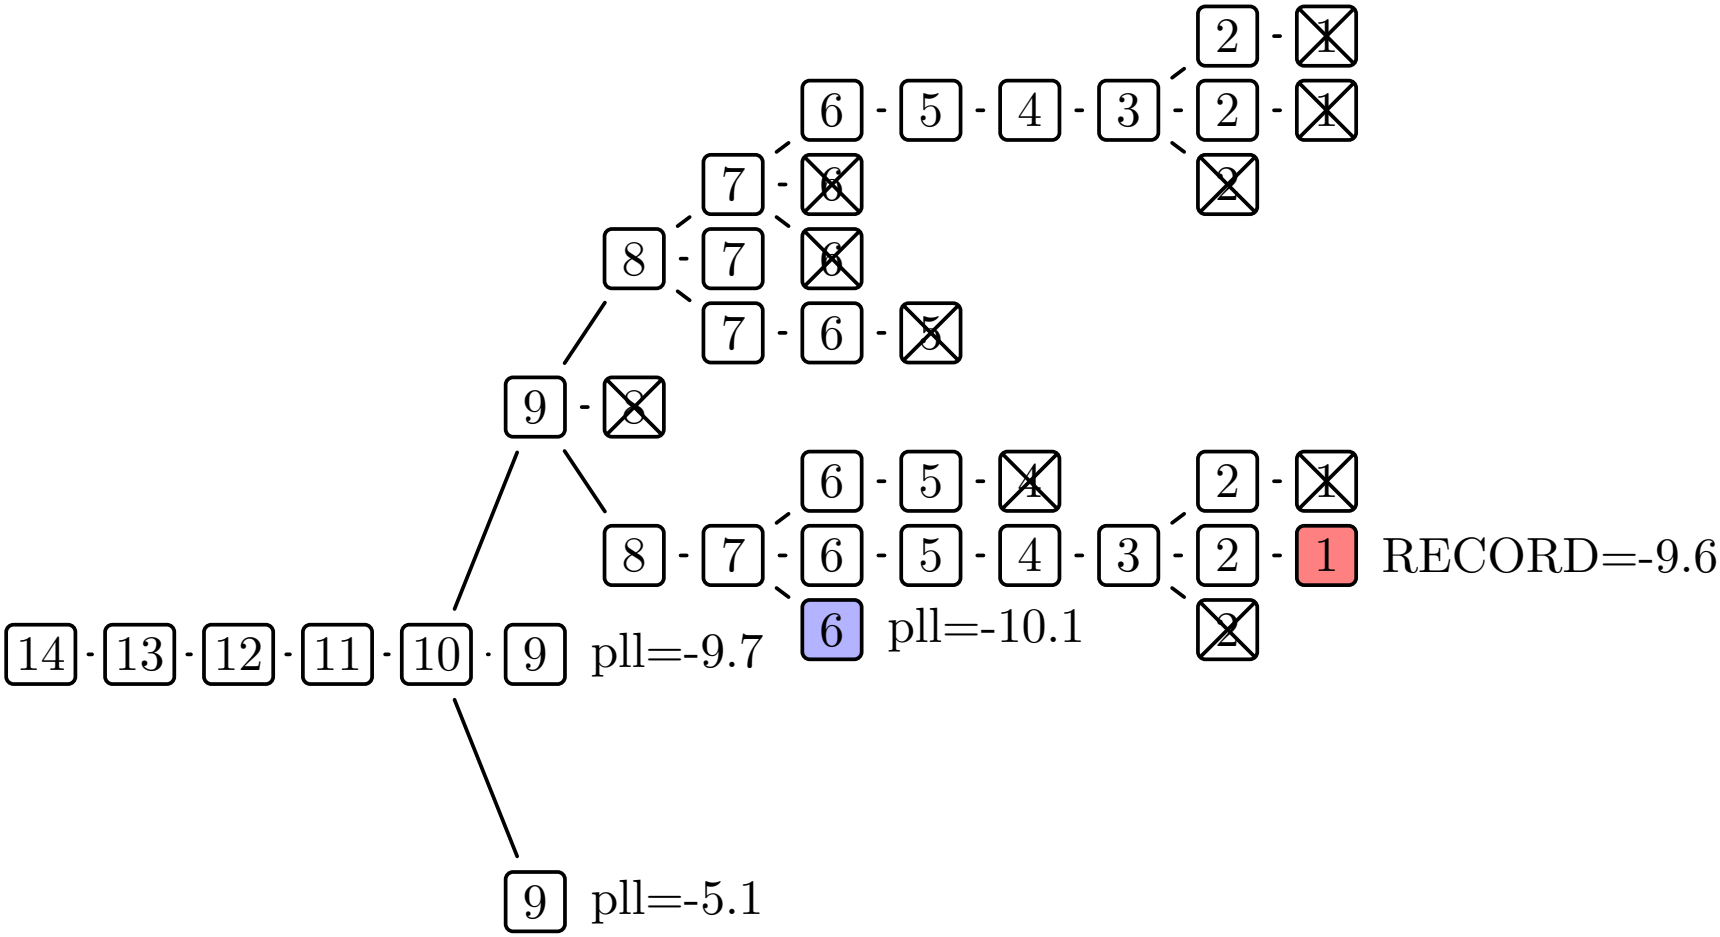
RLS 树上的 BnB，第 29 步



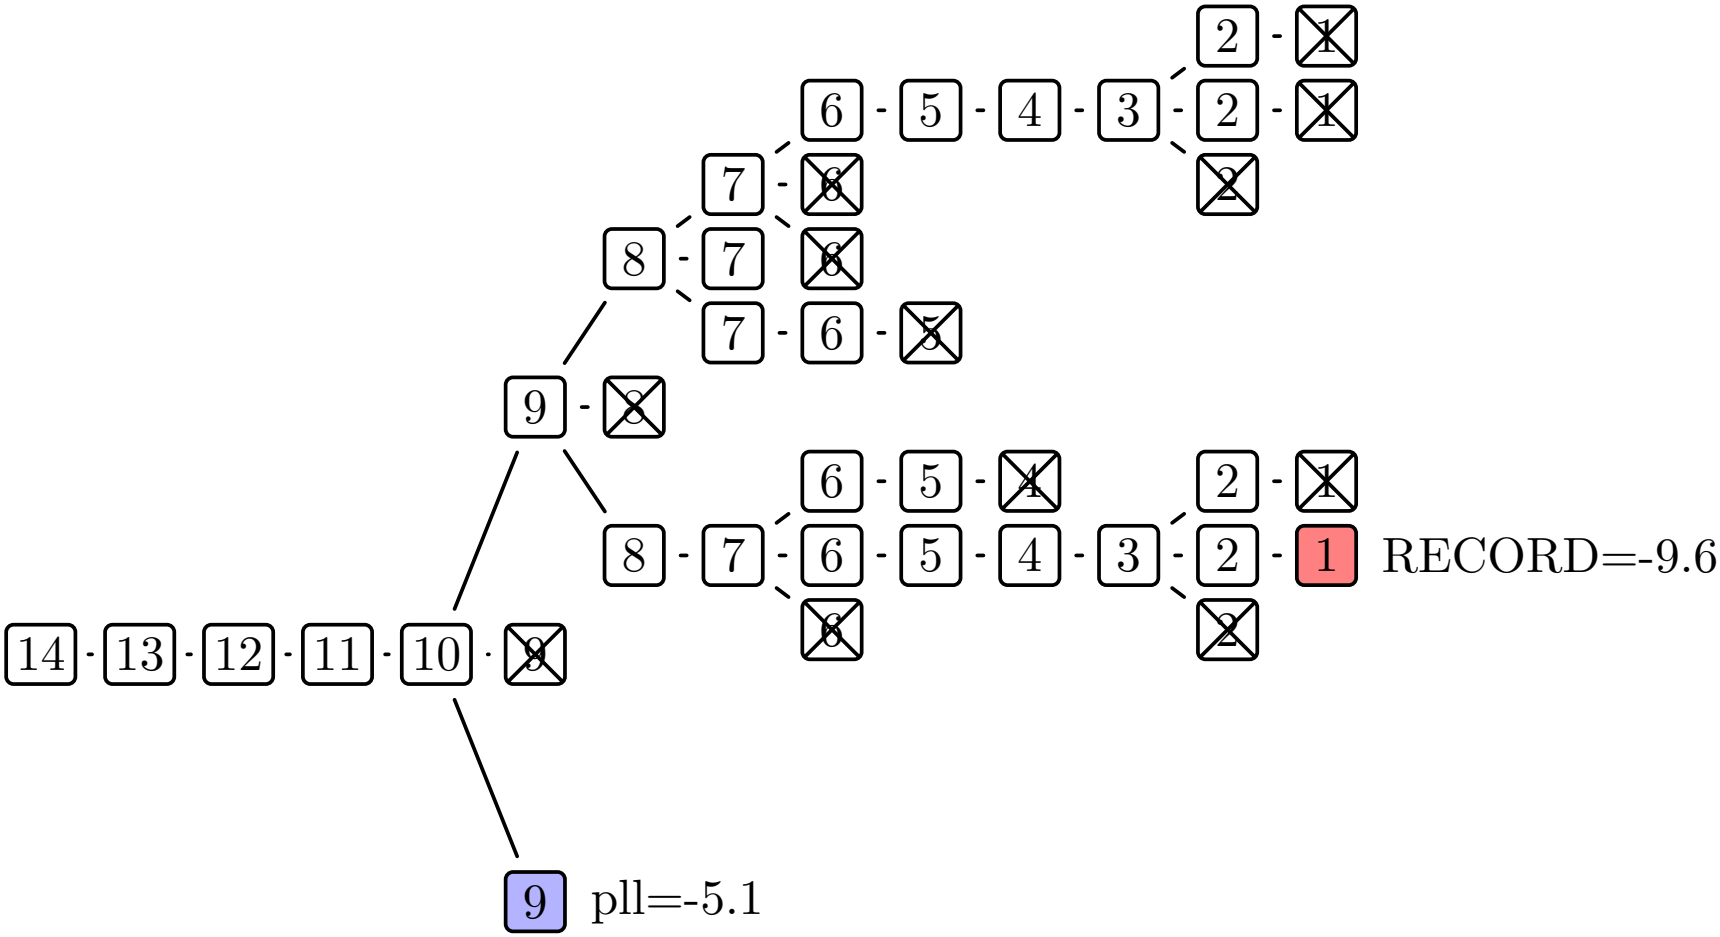
RLS 树上的 BnB，第 30 步



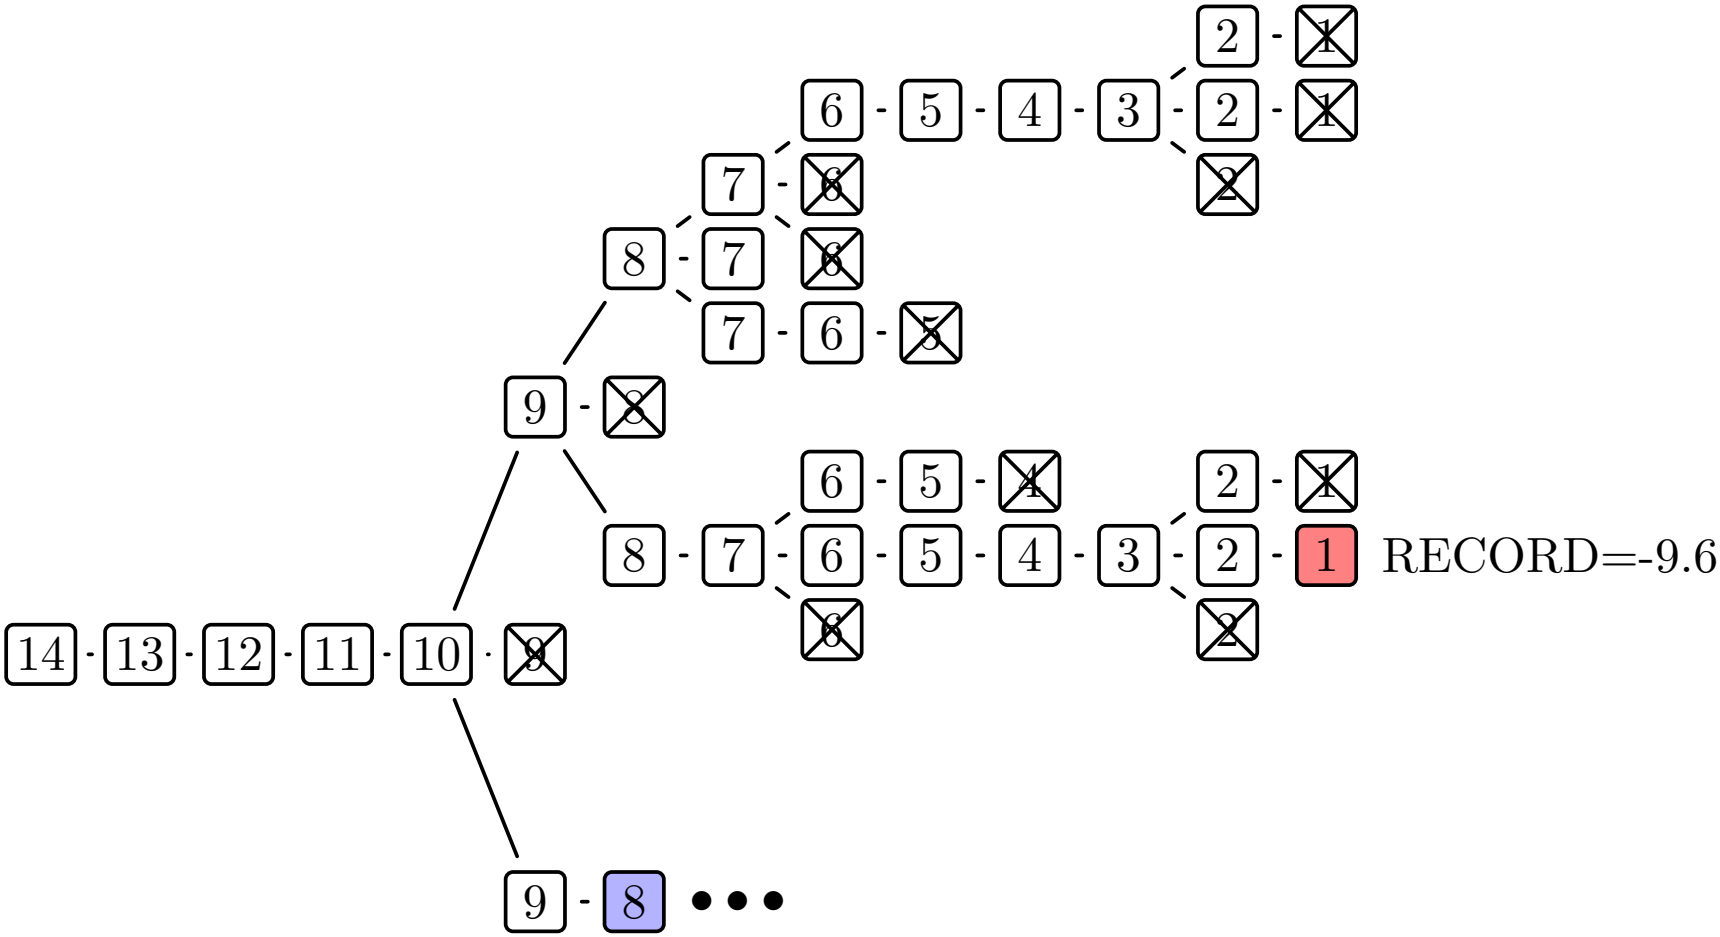
RLS 树上的 BnB，第 31 步



RLS 树上的 BnB，第 33 步



RLS 树上的 BnB，第 34 步



非参数的似然定界

- 用频率 n_ι^a/n_ι 替换选择概率 $P_i^k(a|x_\iota;\theta)$

$$\mathcal{L}^{\text{非参}}\quad(Z^{\mathcal{S}}) = \sum_{\iota\in\mathcal{S}}\sum_{i=1}^{J}\sum_{a} n_\iota^{a_i}\log(n_\iota^a/n_\iota)$$

- $\mathcal{L}^{\text{非参}}\quad(Z^{\mathcal{S}})$ 只取决于数据中的计数!
- 不难从代数上证明，对任意 $Z^{\mathcal{S}}$（$\approx$ Gibbs 不等式）

$$\mathcal{L}^{\text{非参}}\quad(Z^{\mathcal{S}}) > L^{\text{part}}(Z^{\mathcal{S}},\theta,V_\theta^k)$$

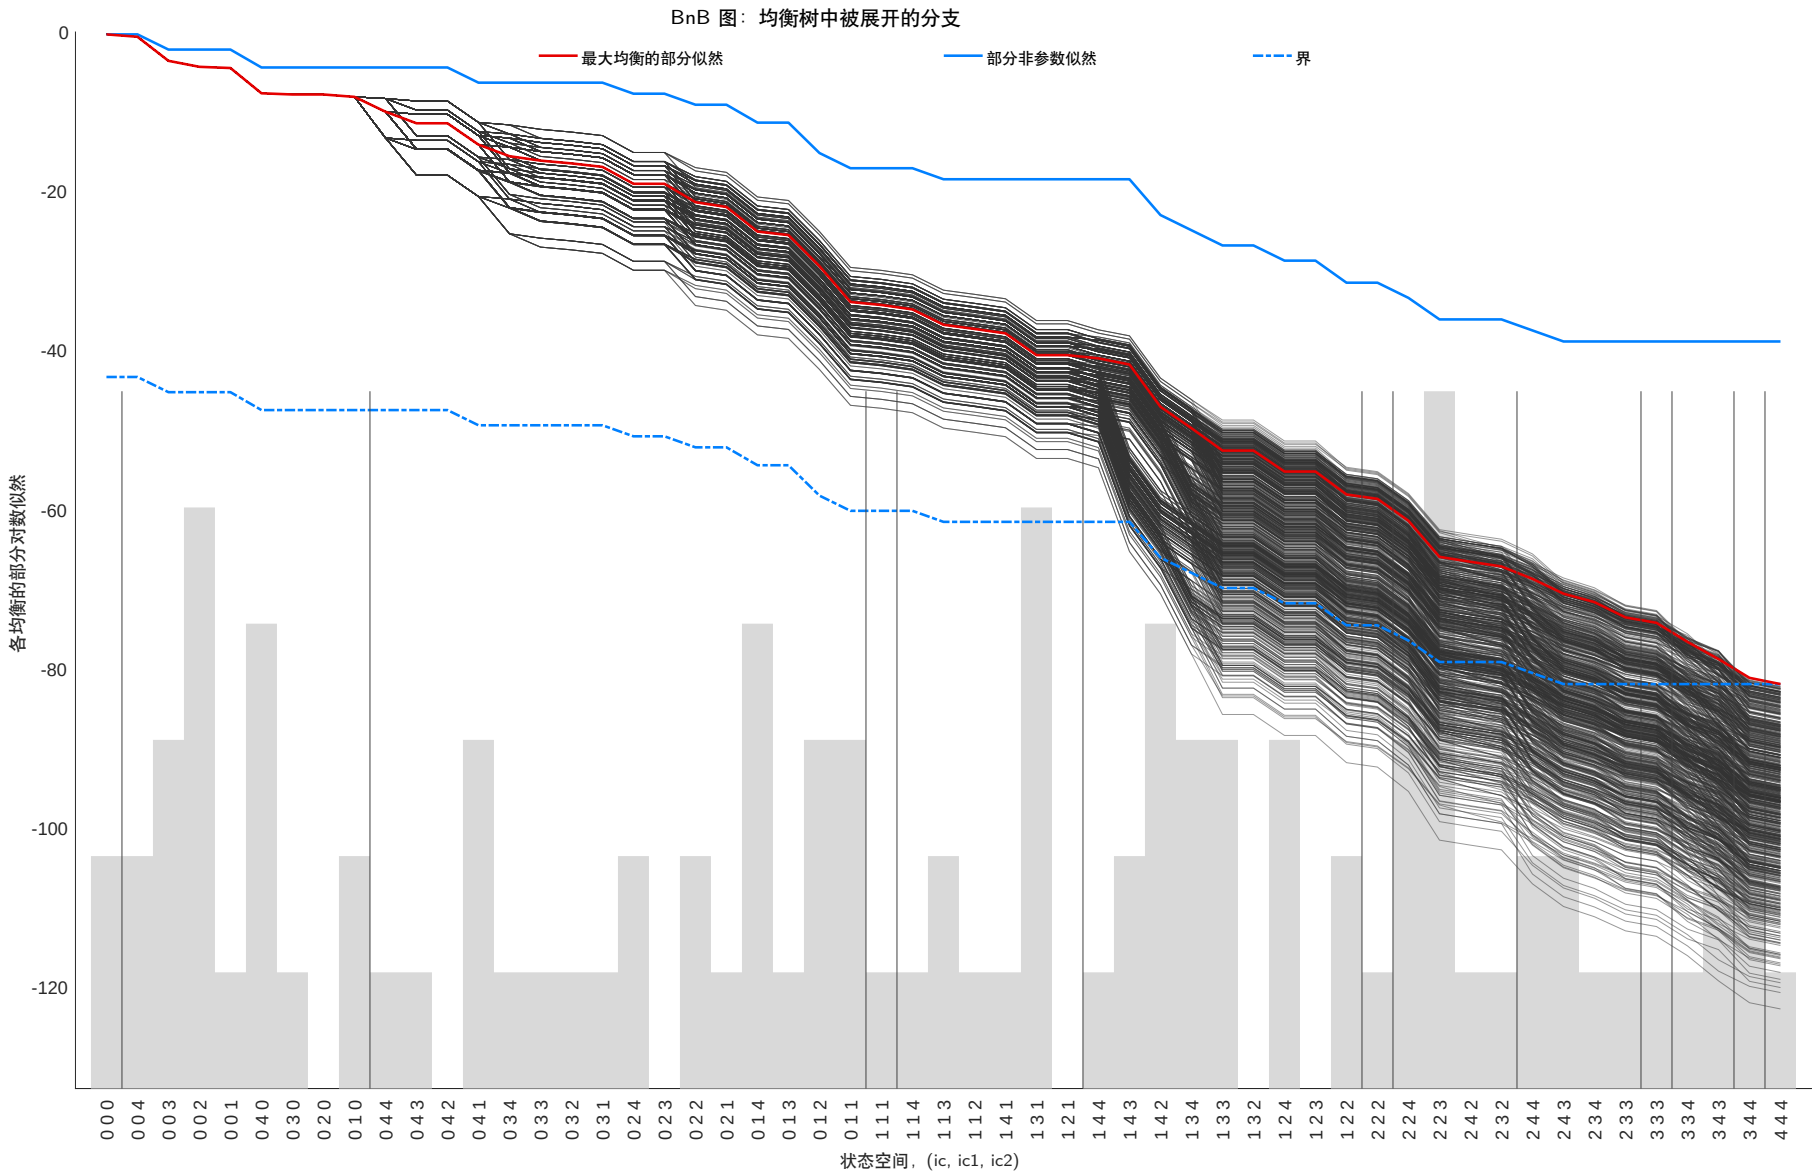
- 因此，在 RLS 树遍历的任一步 ι，都可以用经验似然对部分似然进行乐观的外推

$$\mathcal{L}^{\text{part}}(Z^{\{S,S-1,\ldots,\iota\}},\theta,V_\theta^k) + \mathcal{L}^{\text{非参}}\quad(Z^{\{\iota-1,\ldots,1\}})$$

- 增广的部分似然是 BnB 中强得多的界

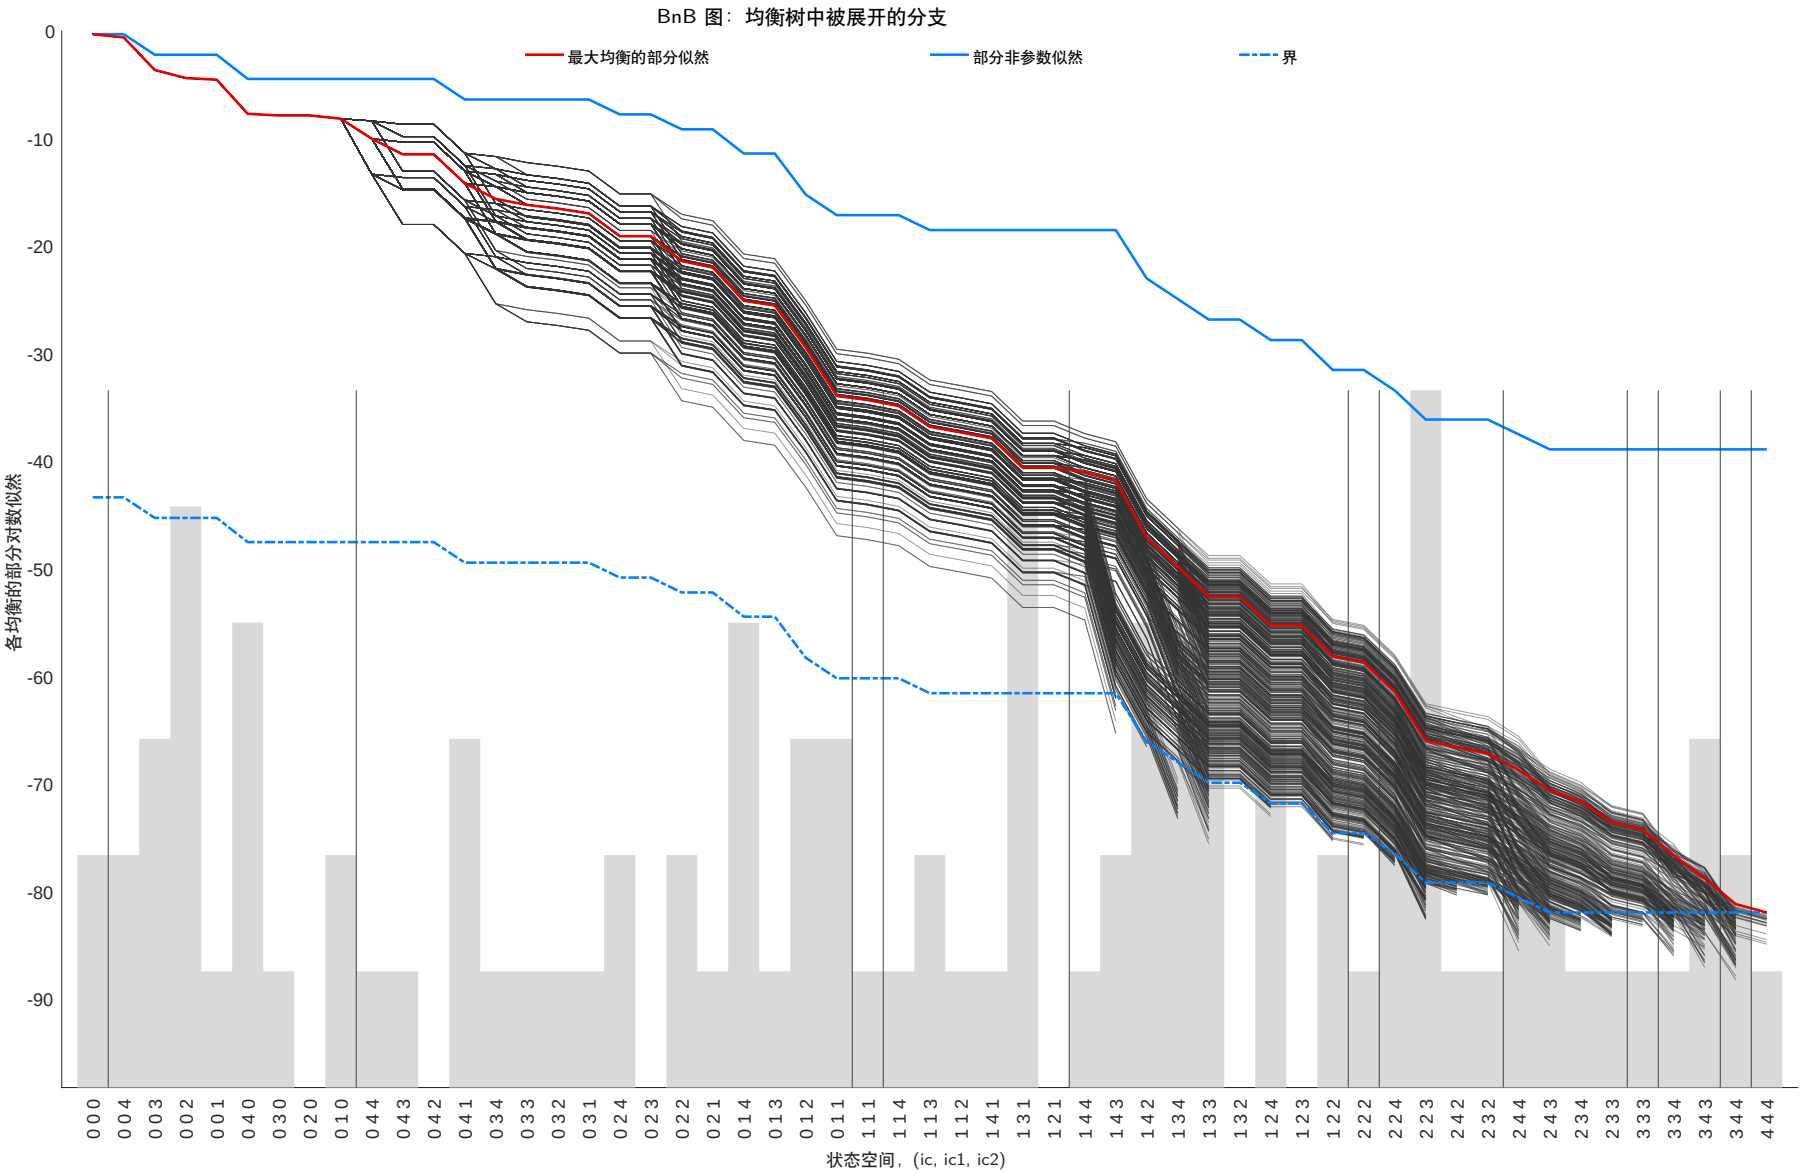
非参数的似然定界

左侧为 $\iota = S = 14$（终止状态），右侧为 $\iota = 1$（初始状态）



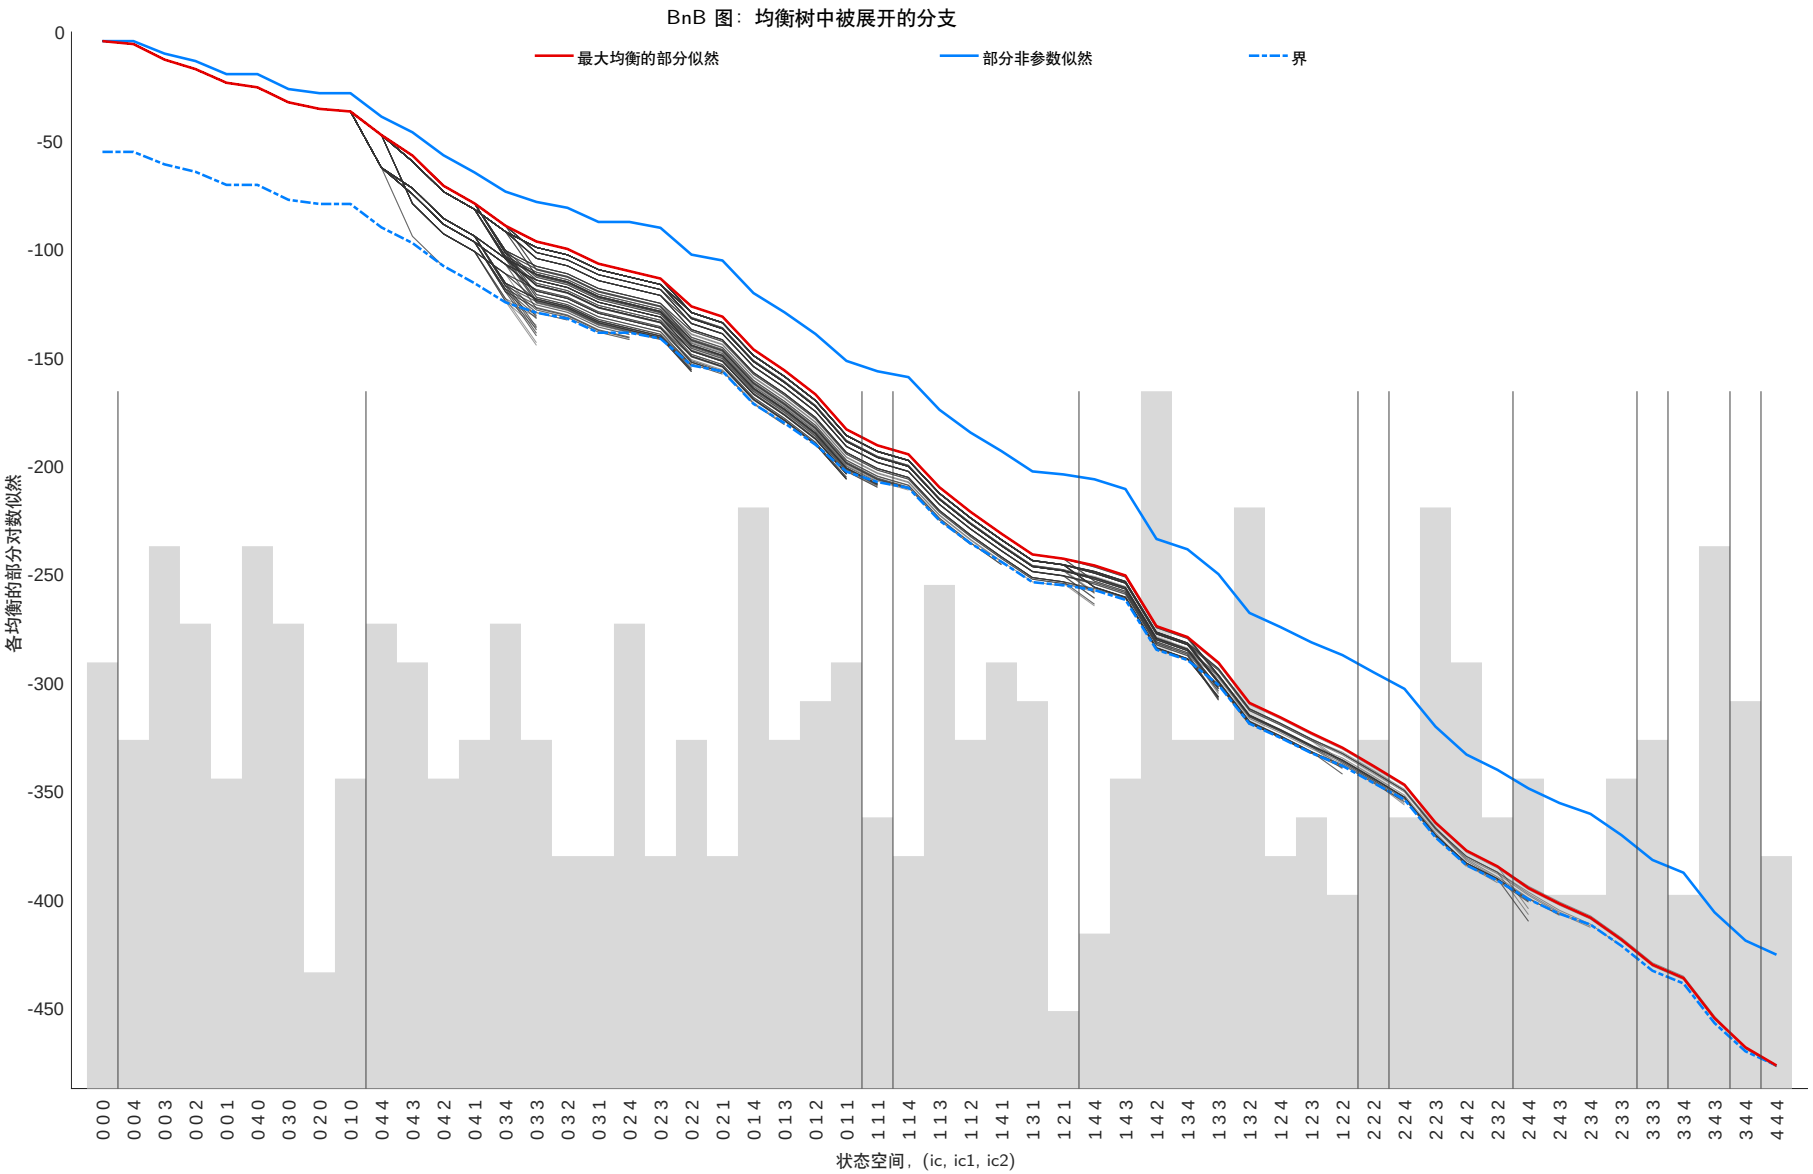
使用非参数似然界的 BnB

贪婪遍历 + 非参数似然界



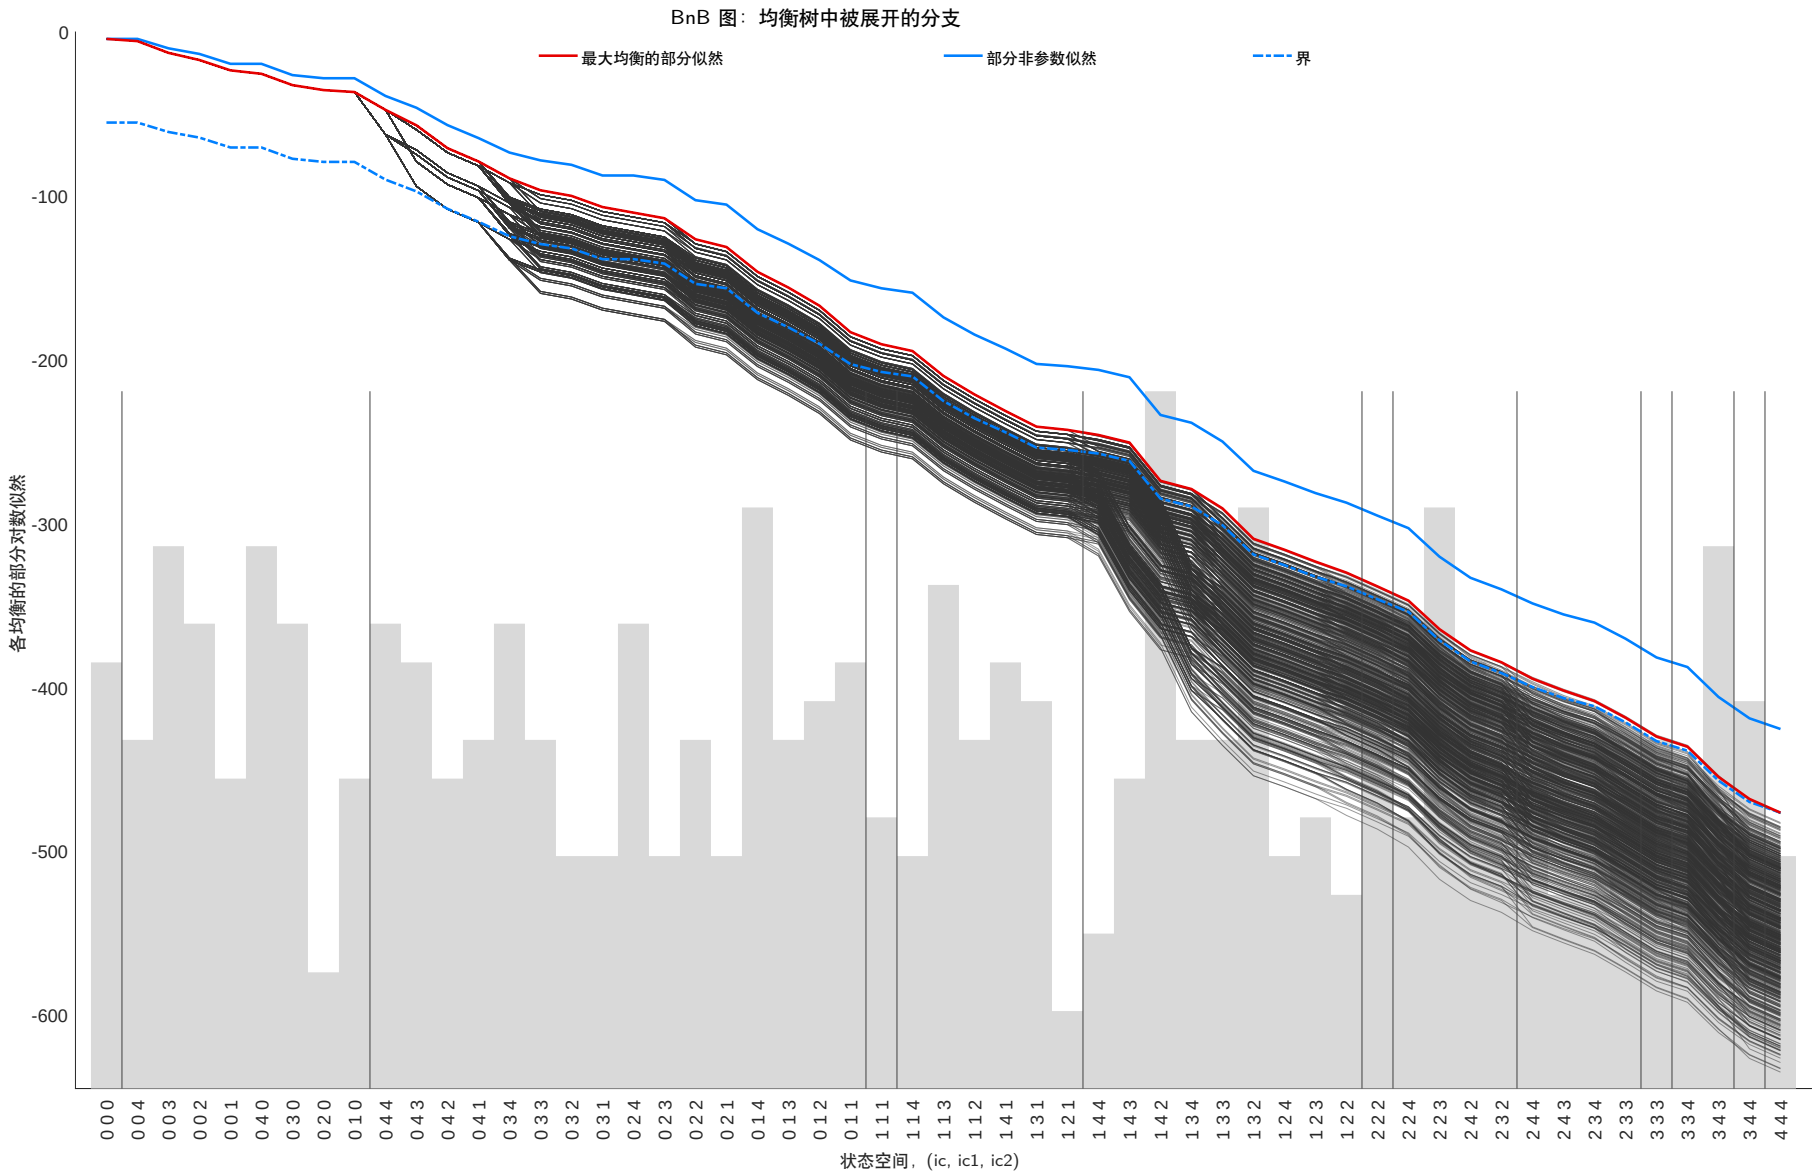
使用非参数似然界的 BnB，较大样本

在真实 θ 处，当 $N \to \infty$ 时非参数似然 $\to$ 参数似然 $\Rightarrow$ 计算量更少



较大样本中的完全枚举 RLS

与上一页相比，大部分计算都被省去了！



用非参数似然改进 BnB

- 对任意数据量，非参数似然在代数上都大于或等于参数似然
- 用非参数似然界增广的 BnB 给出更紧的定界规则 $\rightarrow$ 计算量更少
- 随着 $M \rightarrow \infty$，数据更多
- 非参数对数似然收敛到似然线
- 图中两条蓝线之间的带宽缩小

  $\rightarrow$ 定界规则更紧
  $\rightarrow$ 计算量更少

对任意样本量都是 MLE，而且数据越多越容易计算!

路线图

1. 澳大利亚瓦楞纤维包装（CFP）生产商的合谋
2. 用模型做实验
3. 状态递归算法
   - 方向性动态博弈（DDG）理论
4. 递归词典序搜索（RLS）算法
5. 蛙跳博弈的完全求解
6. 用嵌套 RLS 方法对方向性动态博弈进行结构估计
   - NRLS 估计量的构造
   - 蒙特卡洛模拟

马尔可夫完美均衡

- MPE 是一对策略组合与价值函数
- 简洁记法

$$\begin{aligned} \mathrm{V} &= \Psi^{\mathrm{V}}(\mathrm{V}, \mathrm{P}, \theta) \\ \mathrm{P} &= \Psi^{\mathrm{P}}(\mathrm{V}, \mathrm{P}, \theta) \end{aligned}$$

- 所有马尔可夫完美均衡的集合

$$SOL(\Psi, \theta) = \left\{ (\mathrm{P}, \mathrm{V}) \;\middle|\; \begin{array}{l} \mathrm{V} = \Psi^{\mathrm{V}}(\mathrm{V}, \mathrm{P}, \theta) \\ \mathrm{P} = \Psi^{\mathrm{P}}(\mathrm{V}, \mathrm{P}, \theta) \end{array} \right\}$$

- $\Psi^V : \mathbf{V}, \mathbf{P} \to \mathbf{V}$ Bellman 算子
- $\Psi^P : \mathbf{V}, \mathbf{P} \to \mathbf{P}$ 选择概率公式（logit）
- $\Gamma : \mathrm{P} \longrightarrow \mathrm{V}$ Hotz-Miller 反演

动态随机博弈的估计方法

- 两步（CCP）估计量
  - 速度快，但可能有较大的有限样本偏误



Hotz, Miller（1993）；Altug, Miller（1998）；Pakes, Ostrovsky, and Berry（2007）；Pesendorfer, Schmidt-Dengler（2008）

1. 估计 CCP $\rightarrow \hat{\mathbf{P}}$
2. 矩方法 ▪ 最小距离 ▪ 伪似然

$$\min_{\theta} \left[\hat{\mathsf{P}} - \Psi^{\mathsf{P}}(\Gamma(\theta, \hat{\mathsf{P}}), \hat{\mathsf{P}}, \theta)\right]' W \left[\hat{\mathsf{P}} - \Psi^{\mathsf{P}}(\Gamma(\theta, \hat{\mathsf{P}}), \hat{\mathsf{P}}, \theta)\right]$$

$$\max_{\theta} \mathcal{L}(\mathsf{Z}, \Psi^{\mathsf{P}}(\Gamma(\theta, \hat{\mathsf{P}}), \hat{\mathsf{P}}, \theta))$$

- 嵌套伪似然（NPL）
  - 递归的两步伪似然
  - 在效率与可处理性之间架起桥梁
  - 存在多重均衡时不稳定



Aguirregabiria, Mira（2007）；Pesendorfer, Schmidt-Dengler（2010）；Kasahara and Shimotsu（2012）；Aguirregabiria, Marcoux（2021）

动态随机博弈的估计方法

- 均衡不等式（BBL）
  - 最小化单侧偏差
  - 在大型模型中计算上可行



Bajari, Benkard, Levin（2007）

- 带均衡约束的数学规划（MPEC）
  - 将 MLE 写成约束最优化问题
  - 不依赖于问题的结构
  - 计算问题的规模大得多



Su（2013）；Egesdal, Lai and Su（2015）

$$\max_{(\theta,\mathrm{P},\mathrm{V})} \mathcal{L}(\mathbf{Z},\mathbf{P})\text{，约束条件为 } \mathbf{V}=\Psi^{V}(\mathbf{V},\mathbf{P},\theta)\text{，}\ \mathbf{P}=\Psi^{P}(\mathbf{V},\mathbf{P},\theta)$$

- 全部解的同伦 MLE



Borkovsky, Doraszelski and Kryukov（2010）

NRLS 概览

- 稳健且在计算上可行 $^{(?)}$ 的 MLE 估计量
  适用于方向性动态博弈（DDG）
- 依靠完全求解算法，可以证明在一定正则条件下能计算出全部 MPE
- 采用巧妙的离散规划方法，在有限的均衡集合上最大化似然函数
- 对 MPE 的多重性完全稳健
- 放松“数据中只有单一均衡”的假设
- 通向均衡选择规则的估计

蒙特卡洛模拟

A

模型中只有单一均衡
数据中只有一个均衡

B

模型中有多重均衡
数据中进行的是同一个均衡

C

模型中有多重均衡
数据中也有多重均衡：

- 长面板：每个市场进行各自的均衡
- 若干组市场各自进行相同的均衡

（今天不讲）

实现细节

- 两步估计量、NPL 与 EPL
  - Matlab 无约束优化器（使用数值导数）
  - 由频率估计量得到 CCP
  - 最多 120 次迭代（NPL 与 EPL）
- MPEC
  - Matlab 约束优化器（内点法），使用解析导数
  - MPEC-VP：对价值与选择概率同时施加约束（如 Egesdal, Lai and Su，2015）
  - MPEC-P：以选择概率表示约束 + Hotz-Miller 反演（变量数减半）
  - 以两步估计量为初始值
- 估计参数 k_1
- 样本量：1000 个市场，5 期
- 参数的选择保证了对状态空间的良好覆盖，以及所有状态下非退化的 CCP

蒙特卡洛 A，第 1 次运行：无多重性

真实参数下的均衡个数：1
数据中的均衡个数：1

	2step	NPL	EPL	MPEC-VP	MPEC-P	NRLS
真实 $k_1 = 3.5$	3.52786	3.49714	3.49488	3.49488	3.49486	3.49488
偏误	0.02786	-0.00286	-0.00512	-0.00512	-0.00514	-0.00512
MCSD	0.10037	0.06522	0.07042	0.07042	0.07078	0.07042
ave log-like	-1.16661	-1.16144	-1.16143	-1.16143	-1.16139	-1.16143
log-likelihood	-5833.07	-5807.21	-5807.16	-5807.16	-5806.95	-5807.16
log-like short	-	-0.050	-0.000	-0.000	-0.000	-0.000
KL divergence	0.03254	0.00021	0.00024	0.00024	0.00024	0.00024
$\|\|P - P0\|\|$	0.11270	0.00469	0.00495	0.00495	0.00500	0.00495
$\|\|\Psi(P) - P\|\|$	0.16185	0.0000	0.0000	0.0000	0.0000	0.0000
$\|\|\Gamma(v) - v\|\|$	0.87095	0.00000	0.00000	0.00000	0.00000	0.00000
100 次中收敛的次数	-	100	100	100	99	100

- 均衡条件得到满足（两步法除外）
- 几乎所有 MLE 估计量都一致到最后一位
- NPL 与 EPL 估计量接近 MLE

蒙特卡洛 B，第 1 次运行：少量多重性

真实参数下的均衡个数：3
数据中的均衡个数：1
数据生成均衡：稳定

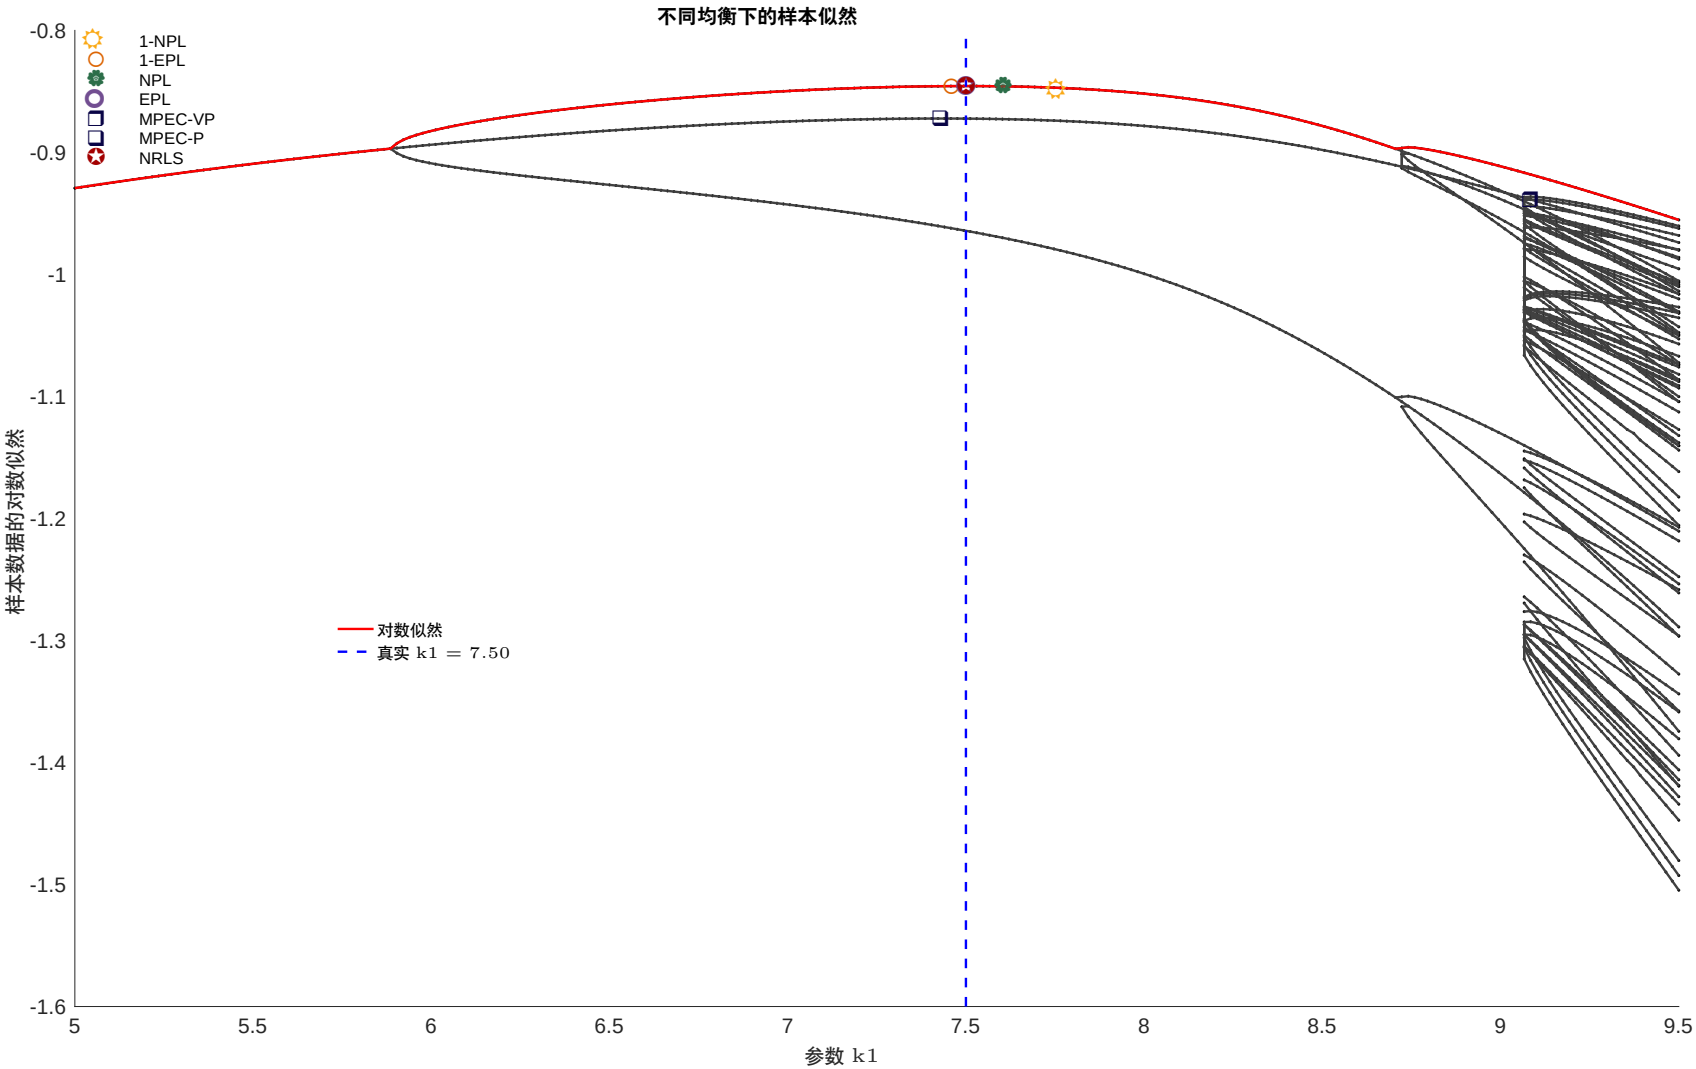
	2step	NPL	EPL	MPEC-VP	MPEC-P	NRLS
真实 $\mathrm{k1} = 7.5$	7.55163	7.49844	7.49918	7.65318	7.35124	7.49919
偏误	0.05163	-0.00156	-0.00082	0.15318	-0.14876	-0.00081
MCSD	0.17875	0.06062	0.03413	0.99742	0.47136	0.03413
ave log-like	-0.84779	-0.84425	-0.84421	-0.88682	-0.87541	-0.84421
log-likelihood	-21194.86	-21106.33	-21105.13	-22170.40	-21885.37	-21105.13
log-like short	-	-1.206	-0.000	-1062.740	-776.809	-0.000
KL divergence	0.02557	0.00040	0.00013	0.23536	0.16051	0.00013
$\|\|P - P_0\|\|$	0.11085	0.00490	0.00280	0.17466	0.20957	0.00280
$\|\|\Psi(P) - P\|\|$	0.170940	0.000000	0.000000	0.000000	0.000000	0.000000
$\|\|\Gamma(v) - v\|\|$	1.189853	0.000000	0.000000	0.000000	0.000000	0.000001
100 次中的运行次数	100	100	100	98	97	100

- MPEC 的收敛性变差
- 均衡条件得到满足，但估计量开始收敛到错误的均衡

（由相对于数据生成均衡的 KL 散度可见）

似然对应

线条用对称 KL 散度构造



蒙特卡洛 B，第 2 次运行：少量多重性，不稳定

真实参数下的均衡个数：3
数据中的均衡个数：1
数据生成均衡：不稳定

	2step	NPL	EPL	MPEC-VP	MPEC-P	NRLS
真实 $k1 = 7.5$	7.54238	7.39276	7.48044	7.73133	7.63100	7.50176
偏误	0.04238	-0.10724	-0.01956	0.23133	0.13100	0.00176
MCSD	0.17145	0.05608	0.15801	0.72988	0.89874	0.03820
ave log-like	-0.86834	-0.89374	-0.86550	-0.88512	-0.90196	-0.86504
log-likelihood	-21708.60	-22343.58	-21637.54	-22127.91	-22549.06	-21626.12
log-like short	-	-765.242	-11.413	-502.121	-920.643	-0.000
KL divergence	0.02271	0.15996	0.00257	0.11452	0.20182	0.00012
$\|\|P - P_0\|\|$	0.09757	0.20709	0.00619	0.03860	0.02504	0.00307
$\|\|\Psi(P) - P\|\|$	0.160102	0.000000	0.000000	0.000000	0.000000	0.000000
$\|\|\Gamma(v) - v\|\|$	1.126738	0.000000	0.000000	0.000000	0.000000	0.000001
100 次中的运行次数	100	18	100	99	98	100

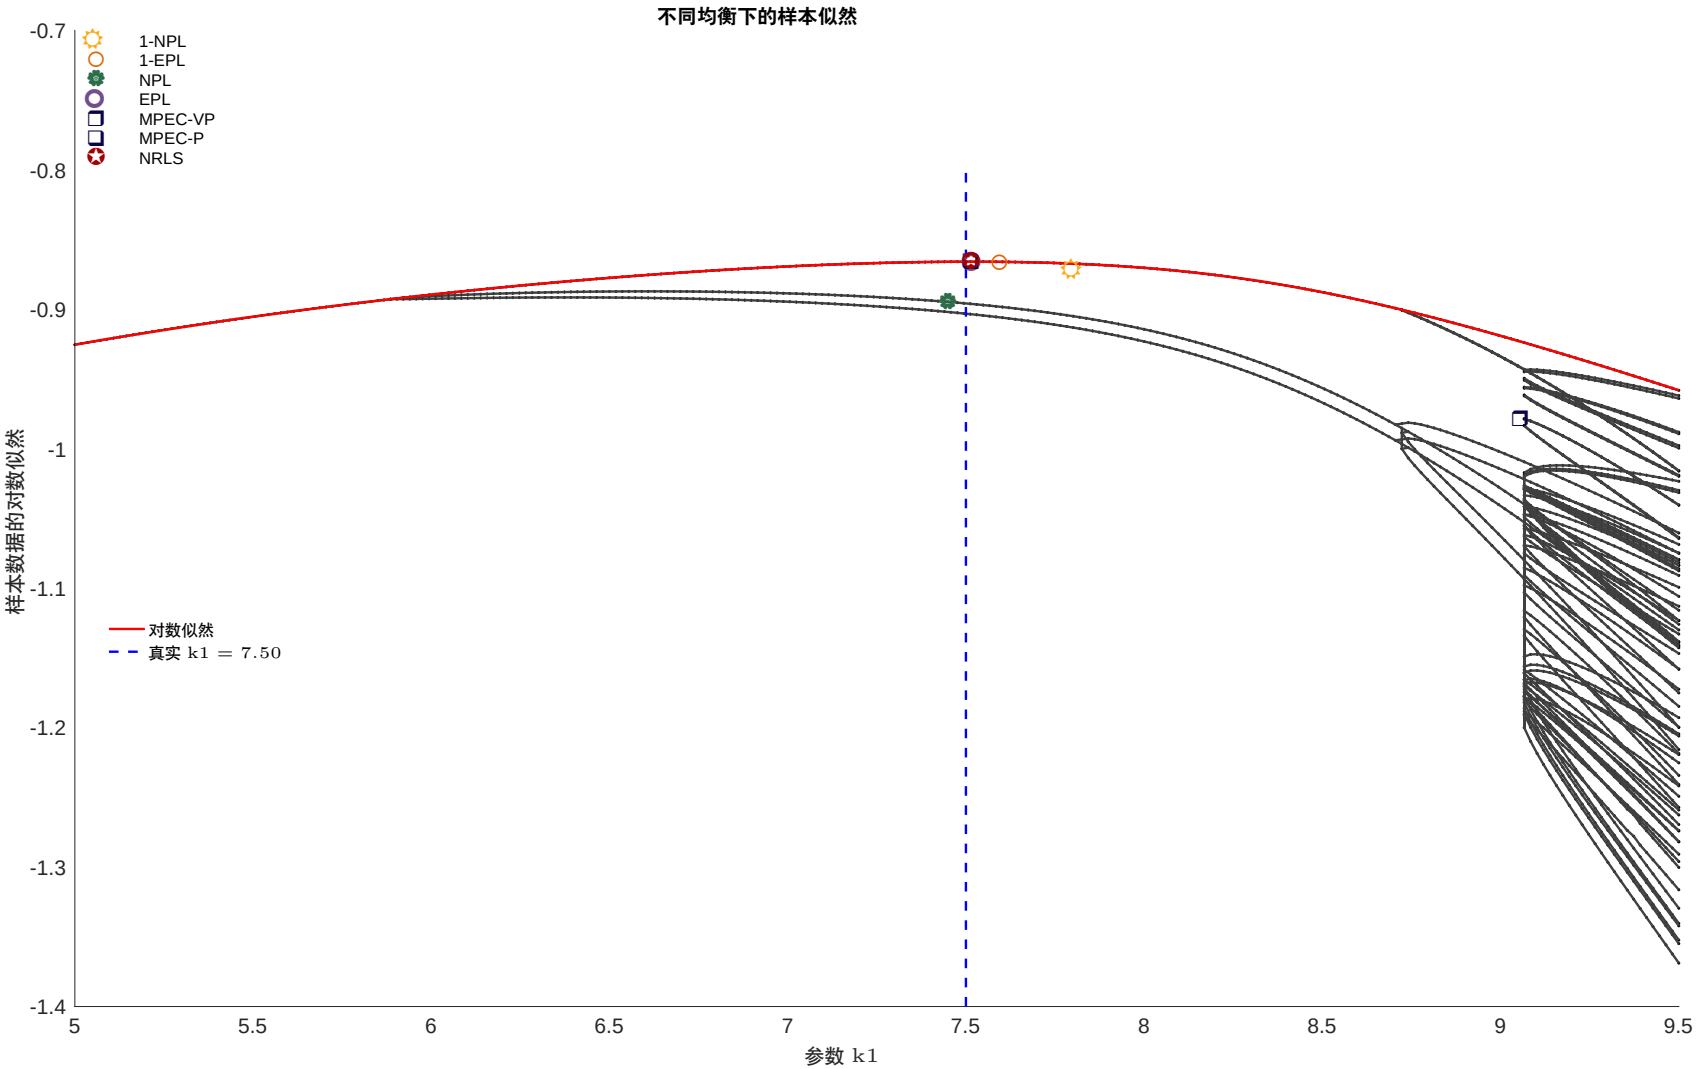
- NPL 估计量无法收敛
- MPEC 也有类似的收敛问题
- EPL 估计量表现良好



Aguirregabiria, Marcoux（2021）

似然对应

线条用对称 KL 散度构造



蒙特卡洛 B，第 3 次运行：不连续的似然

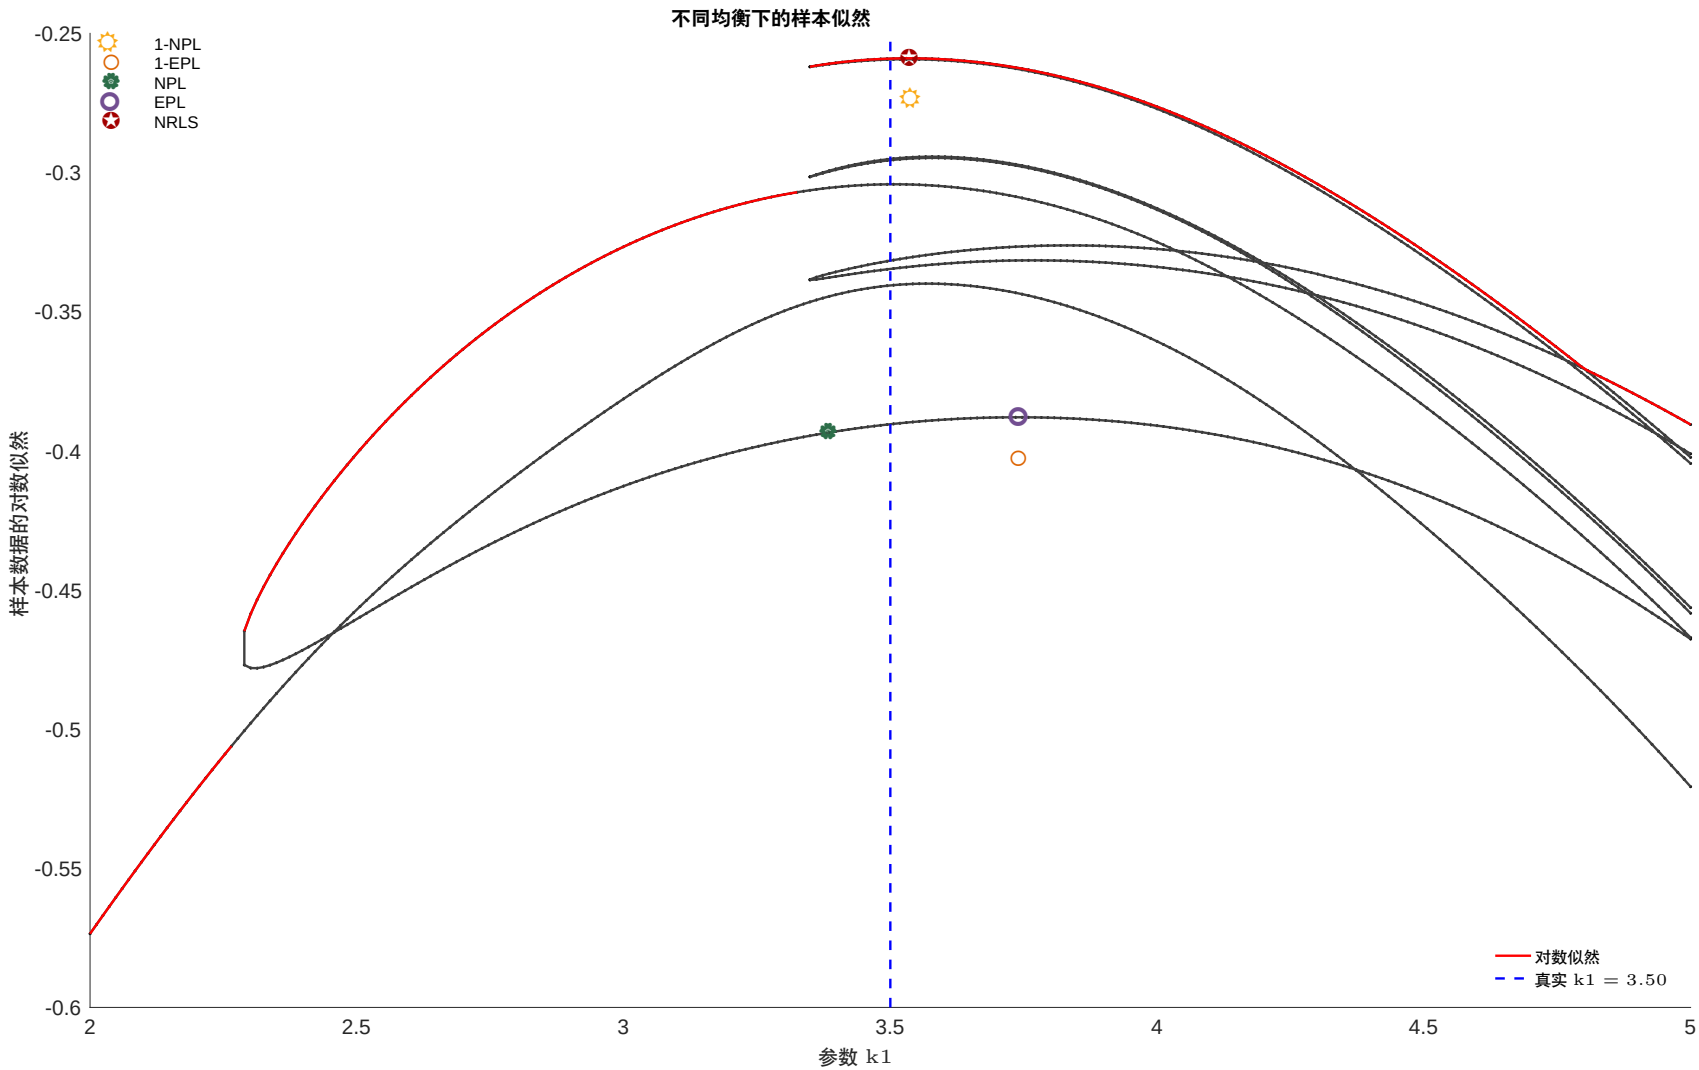
真实参数下的均衡个数：9
数据中的均衡个数：1
数据生成均衡：不稳定，接近“悬崖”

	2step	NPL	EPL	MPEC-VP	MPEC-P	NRLS
真实 $k_1 = 3.5$	3.49739	3.55144	3.64772	3.65943	3.67027	3.50212
偏误	-0.00261	0.05144	0.14772	0.15943	0.17027	0.00212
MCSD	0.13999	0.07133	0.12900	0.12693	0.11583	0.03255
ave log-like	-0.27494	-0.29474	-0.29528	-0.30330	-0.30257	-0.25086
log-likelihood	-1374.721	-1473.695	-1476.425	-1516.503	-1512.847	-1254.320
log-like short	-	-219.375	-222.104	-270.999	-267.523	-0.000
KL divergence	0.01512	0.04889	0.04495	0.04102	0.04078	0.00016
$\|\|P - P_0\|\|$	0.62850	0.86124	0.83062	0.66562	0.65879	0.01610
$\|\|\Psi(P) - P\|\|$	0.763764	0.000000	0.000000	0.000000	0.000000	0.000002
$\|\|\Gamma(v) - v\|\|$	0.852850	0.000000	0.000000	0.000000	0.000000	0.000005
100 次中的运行次数	100	100	100	28	27	100

- 类似的收敛问题
- EPL、NPL 与 MPEC 的估计较差
  （约束得到满足，但似然低、KL 散度高）

似然对应

线条用对称 KL 散度构造



蒙特卡洛 B，第 4 次运行：大量多重性

真实参数下的均衡个数：2455
数据中的均衡个数：1
枚举全部均衡（RLS）的用时：10 分 39 秒

	1-NPL	NPL	EPL	NRLS
真实 $k1 = 3.75$	3.70959	3.71272	3.78905	3.74241
偏误	-0.04041	-0.03728	0.03905	-0.00759
MCSD	0.11089	0.06814	0.40716	0.03032
ave log-likelihood	-0.38681557	-0.37348793	-0.45256293	-0.35998461
log-likelihood	-1934.078	-1867.440	-2262.815	-1799.923
log-like shortfall	-	-66.529	-467.607	-0.000
KL divergence	Inf	14.07523	12231.59186	0.32429
$\|\|P - P_0\|\|$	0.82204	0.65580	0.79241	0.07454
$\|\|\Psi(P) - P\|\|$	0.963574	0.000000	0.000000	0.000006
$\|\|\Gamma(v) - v\|\|$	7.020899	0.000000	0.000000	0.000008
100 次中的运行次数	100	18	68	100
CPU 时间	0.159s	11.262s	4.013s	4.731s

- NPL 与 EPL 存在严重的收敛问题
- 均衡识别较差（似然低、KL 散度高）
- NRLS 的 CPU 时间相当（比完全枚举快得多）

蒙特卡洛 C：数据中的多重均衡

下一步的方向：

- 假设每个市场在不同时期进行同一个均衡
- 分组固定效应，组由所进行的均衡定义

1. 联合分组固定效应估计
   - 将市场划分为进行不同均衡的组，与 θ 一起估计
   - 对每个市场在所有均衡上计算最大似然，并把它“分配”到相应的组（估计 + 分类）
   - 计算要求非常高：逐个市场做 BnB，非参数改进不起作用
2. 两步分组固定效应估计
   - 第 1 步：基于某些可观测特征对市场进行划分（K 均值聚类）
   - 第 2 步：估计 θ，允许不同组有不同的均衡
   - 额外的计算成本很小！



Bonhomme, Manresa（2015）；Bonhomme, Lamadon, Manresa（2022）

结论：Bertrand 投资模型

- 均衡中可能出现多种内生协调
  - 蛙跳（交替投资）
  - 先发制人（成本领先者投资）
  - 重复投资（同时投资）
- 完全的租金耗散与垄断结果都可以作为 MPE 得到支持。
- MPE 均衡数量众多，存在类似“无名氏定理”的结果
- 由于过度投资，均衡一般是无效率的
  - 重复或过于频繁的投资

结论：动态博弈的求解

- 当均衡不唯一时，计算算法会无意中充当均衡选择机制
- 当状态空间存在方向性时，状态递归算法优于时间迭代
- 大量的马尔可夫完美均衡带来新的挑战：
  - 企业如何在某个特定均衡上实现协调？
  - 实证应用的难度增加。
  - 从数据中识别均衡选择规则的前景令人生畏。
- 存在多重均衡的动态博弈的估计
  嵌套递归词典序搜索（NRLS）

结论：NRLS 估计量

- 针对一类特定动态博弈——方向性动态博弈（DDG）——的完全求解 MLE 估计量
- 嵌套循环：外层似然 $\max$ + 内层模型求解器
- 需要在所有均衡的集合上最大化 $\leftrightarrow$
  艰巨的计算任务
- 巧妙的 BnB 算法，不在不太可能的 MPE 上浪费时间
- NRLS 是针对一类特定动态博弈——方向性动态博弈（DDG）——的 MLE 估计量
  - 对均衡的多重性完全稳健
  - 能够识别数据中的多重均衡