人是理性的吗？

John Rust，乔治城大学

2025 年 7 月 6 日

我将讨论我最近的 3 篇论文

- 网球中的非均衡博弈（与 Axel Anderson、Jeremy Rosen 和 Kin-ping Wong 合作）
- 解释信息受限的升价拍卖中的提前出价（与 Sungjin Cho 和 Harry Paarsch 合作）
- 谁更像贝叶斯者？人类还是 ChatGPT？(与 Tianshi Mu、Pranjal Rawat、Qixuan Zhong 和 Chengjun Zhang 合作）

能否做结构行为经济学？

- 也就是说，能否放松理性假设？答案：可以，但由于识别问题，需要很强的假设
- 结构是三元组 $\{\beta, u, p\}$，其中 β 是贴现因子，u 是效用函数，转移概率 $p(s'|s,a)$ 是信念
- 在理性预期下，可以用 (s', s, a) 的数据估计 p，因此只剩 $\{\beta, u\}$ 未知

- 若施加最优性而放松理性，则 CCP 为 $P(a|s, \{\beta^*, u^*, p^*\})$。此时主观信念 p^* 可能不等于客观的（即理性的）信念 p

- 离散状态情形下的识别问题：由 $(|A|-1)|S|$ 个方程构成、含 $1+|A||S|+|S|^2|A|$ 个未知量 $\{\beta, u, p\}$ 的方程组是否有唯一解？

$$P(a|s, \{\beta^*, u^*, p^*\}) = P(a|s, \{\beta, u, p\})$$

- 答案一般是否定的：未知量多于方程，因此必须施加先验假设来识别主观信念，或者使用能诱导出信念的数据

信息时代的悖论

Justin Smith，《非理性：理性阴暗面的历史》（2019）

当今时代的一大悖论是：尽管人类知识的总和比历史上任何时候都更容易获取——事实上，地球上数十亿人如今用随身携带的一个特殊设备就能轻松获取——错误信念却一如既往地盛行。

- 当然，非理性/迷信早在信息时代之前就已存在，但现代信息技术可能反常地加剧错误/非理性的信念：用过多的信息淹没我们，即信息污染

- 人们越来越担心，人工智能和虚拟现实只会大大放大我们当前的错误信息问题，以及由此带来的群体性非理性蔓延的风险。例子：自动生成假新闻和深度伪造图像，甚至由 AI 生成的新闻主播。

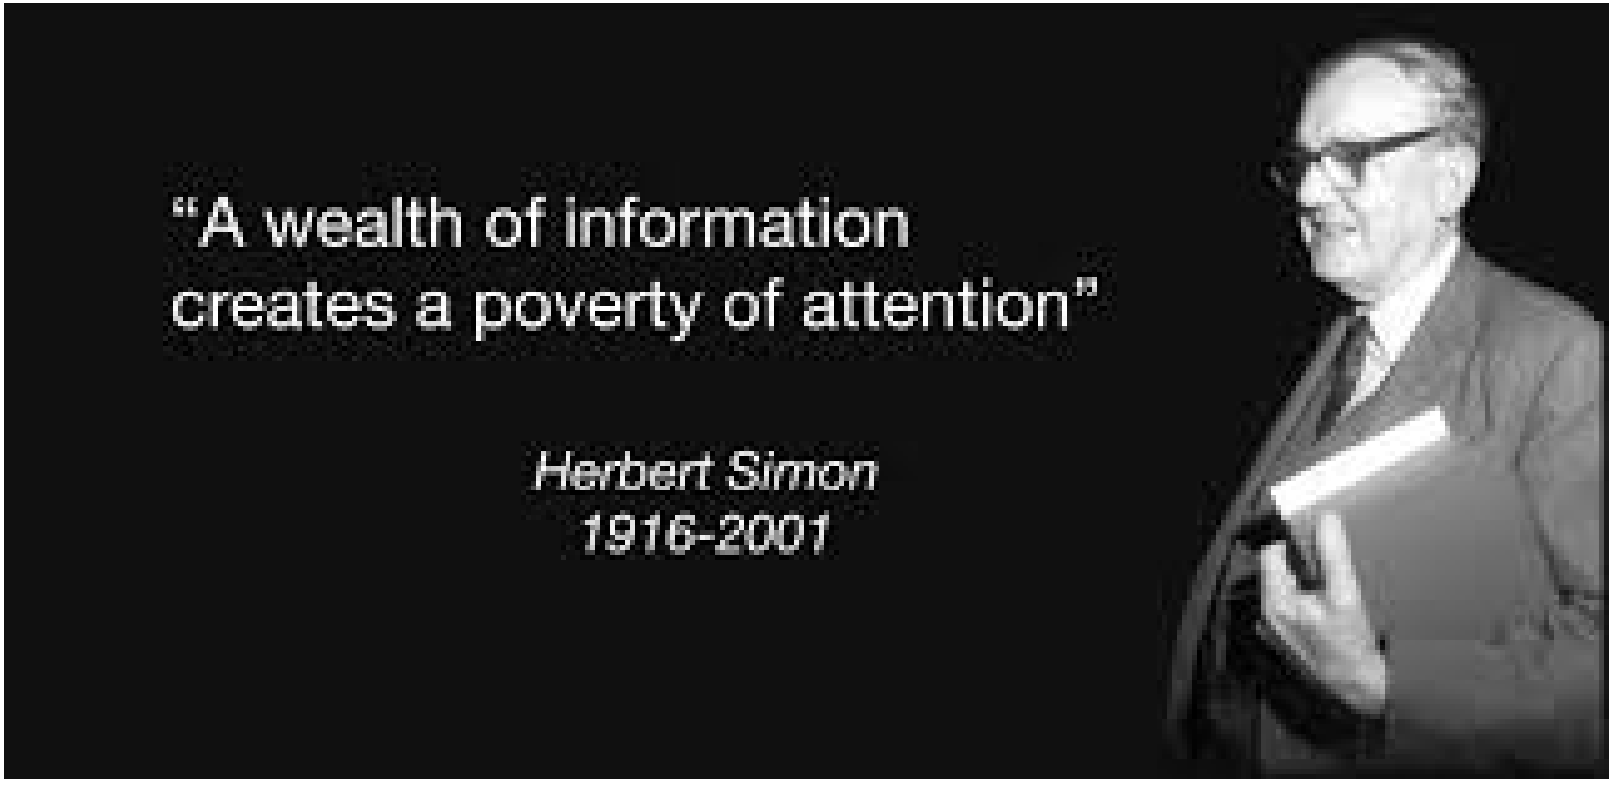
Herbert Simon：人是有限理性的

Herbert Simon 对“有限理性”的定义（维基百科）

有限理性是指：理性受到计算能力约束以及有限信息和知识的限制。在这种情况下，理性的个体会选择一个令人满意而非最优的决策。按照这一观点，决策者是“满意者”，借助启发式方法或聪明的经验法则寻找令人满意的解，而不是试图计算最优解。

- Simon 的这一概念旨在为“人是完全理性的”（也称“经济人”）这一被经济学家广泛采用的观点提供一个更现实的替代。
- 到 20 世纪 50 年代中期，有限理性理论已作为经典的全知理性的替代被提出，[而且] 已有相当数量的实证研究表明，实际的企业决策与有限理性的假设相当吻合，而与完全理性的假设不符。（引自 Simon 的诺贝尔奖演讲）

Herbert Simon



理性是需要耗费能量的

- 人脑的运转大约只需 20 瓦能量；它虽然只占体重的 2%，却消耗了我们总能量的 20%
- 而大语言模型需要巨量的能源。据 Google AI 估计，训练 GPT-3 这样的大语言模型最多可消耗 10 吉瓦时，每日的查询约耗费 1 吉瓦时
- 也许进化并没有把我们设计成在个体层面上完全理性的

Hutchinson 与 Meyer（1994）

不过，从更广的视角看，可以认为最优解只对相对少数相似且设定良好的问题是已知的，而人类是为了在充满大量多样且设定不良的问题的世界中生存而进化的。我们的“次优性”或许只是为直觉决策过程的灵活性和适应性付出的小小代价。

设定错误的模型与有偏学习

- 理性学习的标准模型是贝叶斯更新。
- 其假设是：你拥有正确的似然函数和一个（可能是主观的）先验，并通过贝叶斯法则进行更新。
- 贝叶斯 DP 加入了探索/利用的权衡：如果进一步学习代价高昂，那么有时保持不完全知情反而是最优的（例子：Easley 与 Kiefer（1988），Controlling a stochastic process with unknown parameters）

- Frick、Iijima 与 Ishii（2024），“Welfare Comparisons for Biased Learning”：如果你对问题的“心智模型”设定错误，那么相对于拥有正确设定模型的人，你的选择将是次优的。

- 洞见：1）设定错误的信念并不总会导致次优决策；2）似然设定错误的个体，可能优于似然设定正确但先验不确定性很高的个体

人类下的是完美的国际象棋吗？

- 职业棋手（例如 Magnus Carlsen）下棋是完全理性的吗（即采用动态最优的纳什均衡国际象棋策略）？

- 答案：显然不是！自 1997 年“深蓝”击败 Garry Kasparov 以来，世界上最强的棋手一直是计算机！
- 但计算机下的是“完美”的国际象棋吗？**答案**：还没有，但根据 Jeremy Rutman 的分析，它们将在以下年份达到完美：
  2059.
- **Zermelo 定理（1913）** 在没有随机行动的双人交替行动完全信息博弈中，如果双方都“完美地”下棋（即都使用动态纳什均衡策略），那么只有 3 种可能的结果：
  1. 博弈总是以平局结束
  2. 先行者总是获胜
  3. 后行者总是获胜
- 例子：完美地下井字棋，总是以平局结束

完美的国际象棋会是哪种结果？

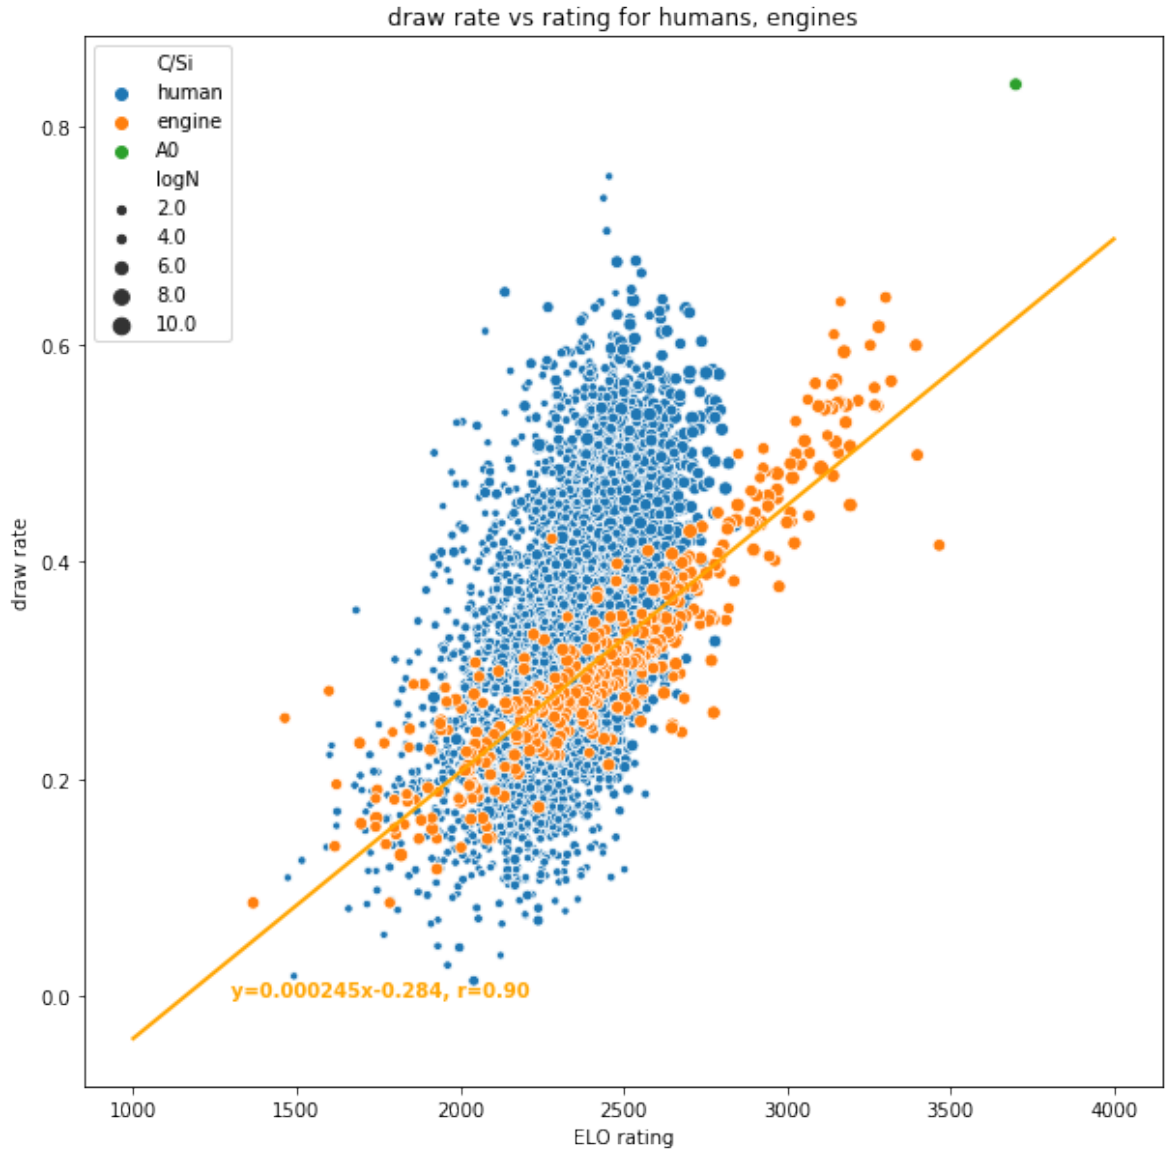
- 2007 年，Schaeffer 等人在 Science 上破解了西洋跳棋，并证明它总是以平局结束。
- 国际象棋的组合数仍然太大，我们无法求解（尽管剩余棋子数越来越多的残局已被求解）。

- 经验证据表明，完美的国际象棋也总是以平局结束。

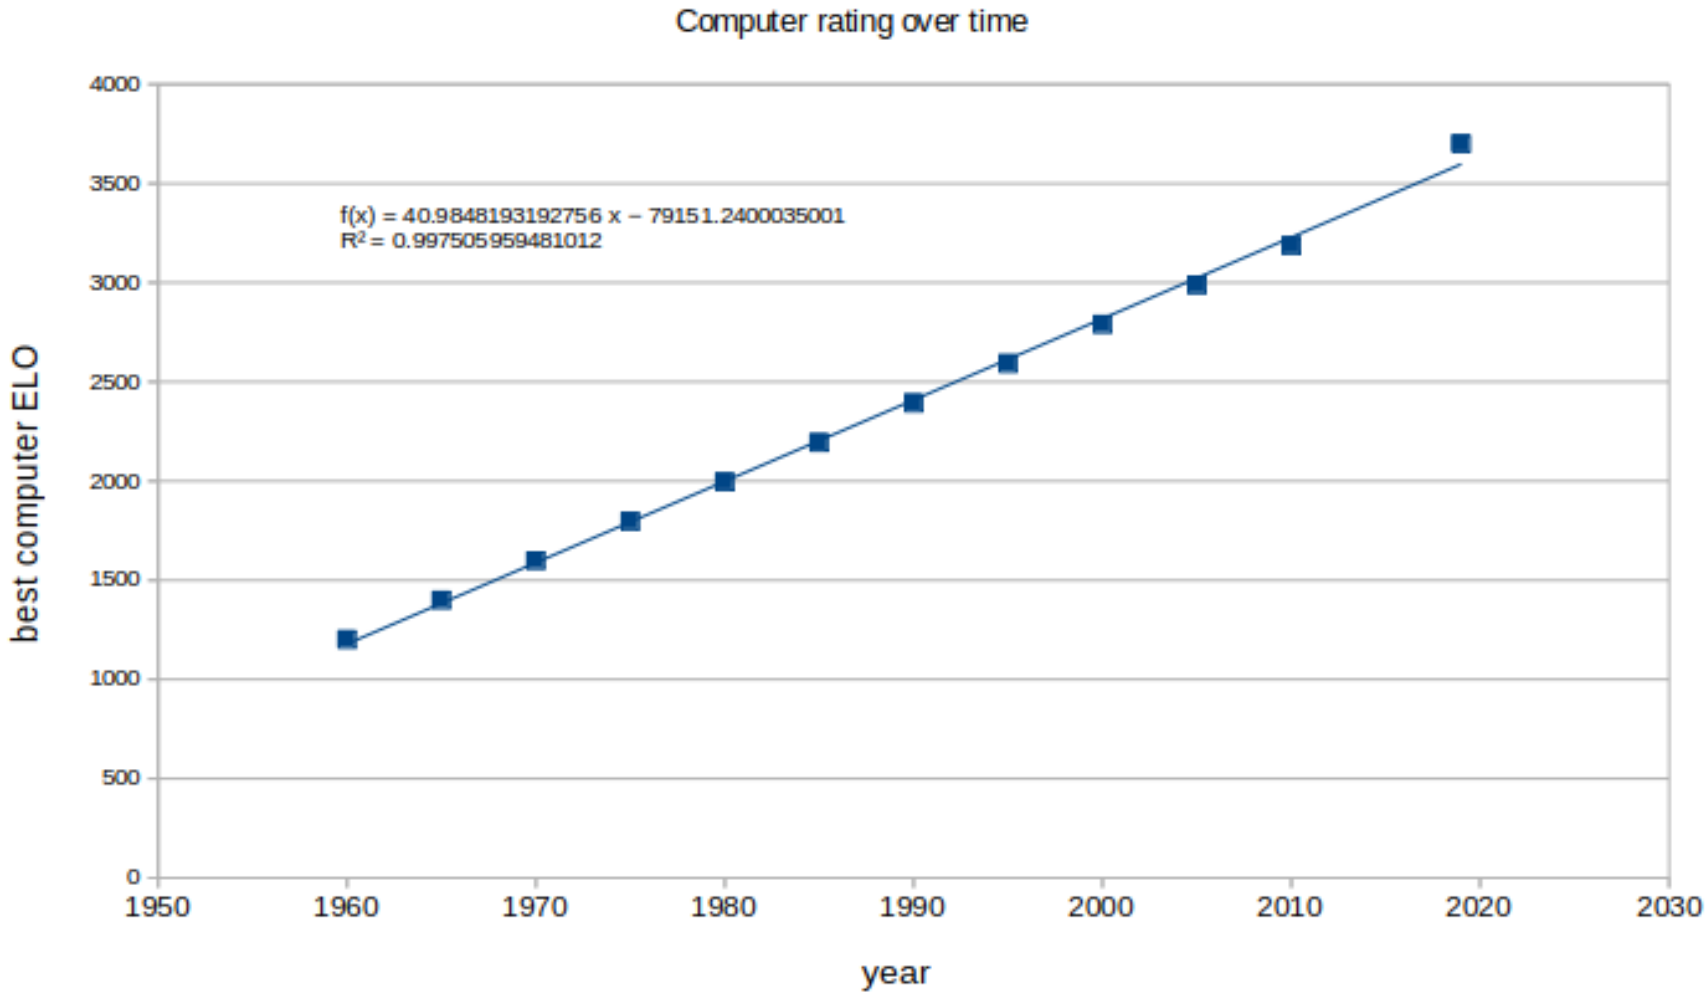
- Jeremy Rutman 汇编了国际象棋对局结果与 ELO 等级分（衡量棋力的标准指标）的数据，表明随着棋手 ELO 分的提高，和棋的概率随之上升。

- 根据当前 ELO 分的技术进步速度，他预测我们将在 2059 年左右实现完美的国际象棋，届时 ELO 分约为 5200（作为对比，Magnus Carlsen 的 ELO 分是 2840）。

国际象棋中的和棋率与 ELO 等级分



计算机的棋力提升速度快于人类



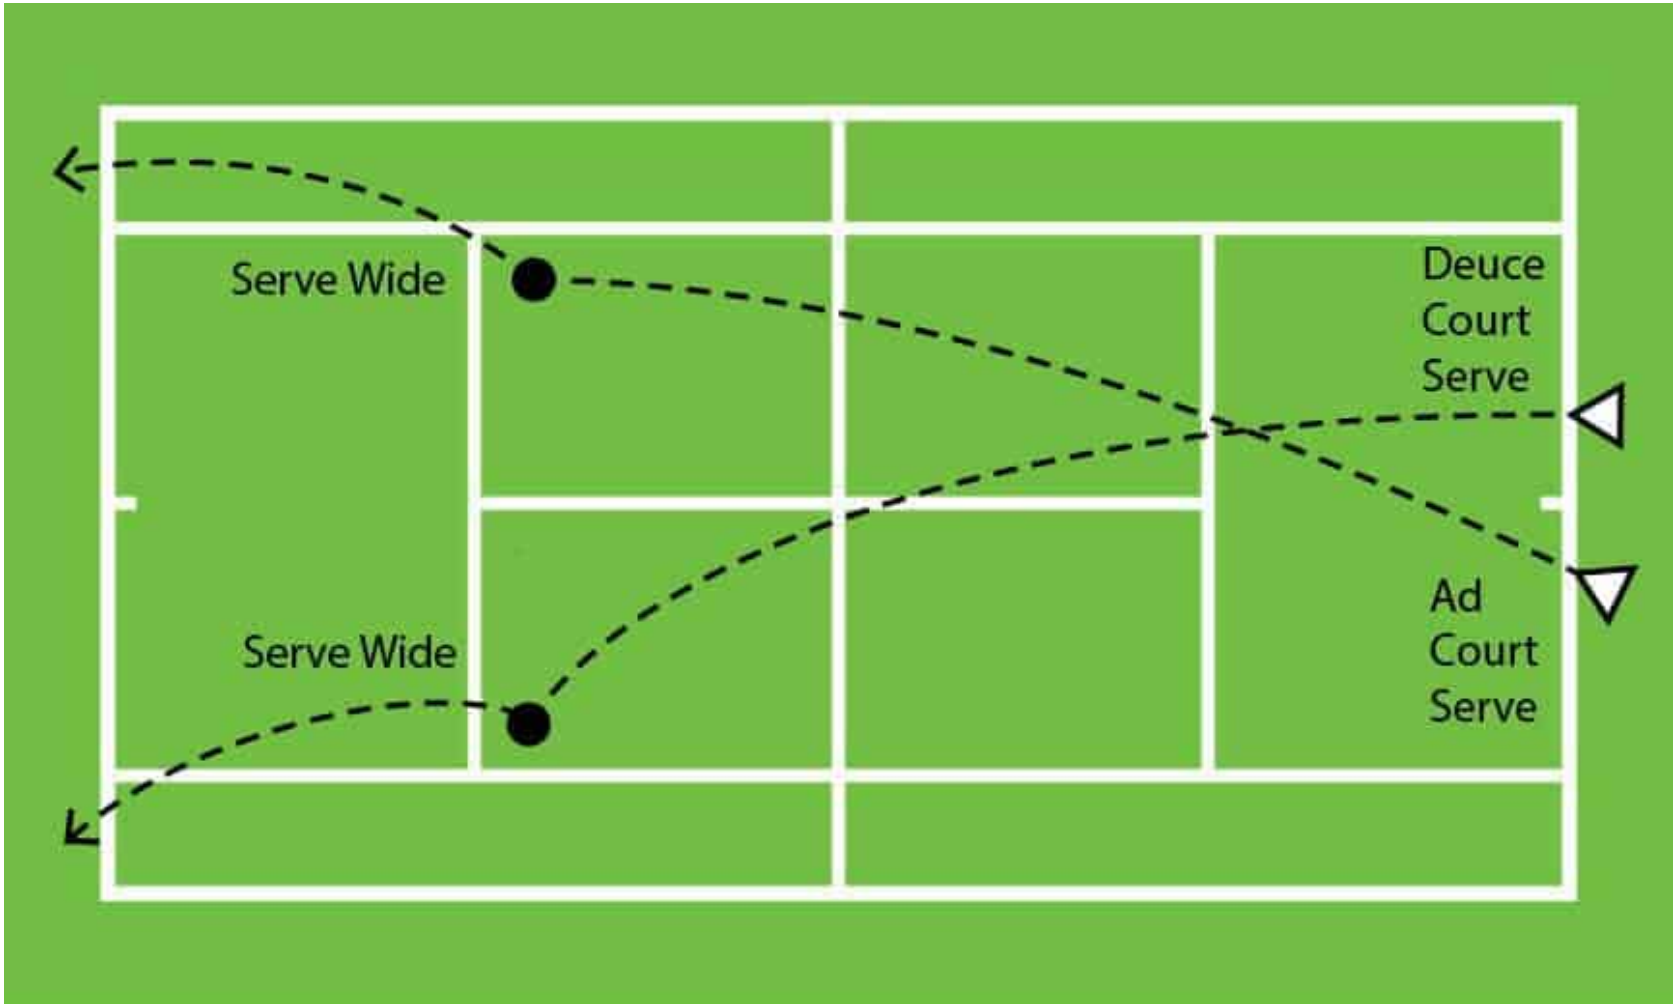
国际象棋与网球

- 二者都是双人交替行动的常和博弈。
- Zermelo 定理适用于网球吗？不适用：网球中随机因素起着重要作用，既体现在混合的发球策略上，也体现在不完美的肌肉控制上（例如一发失误）
- 此外，网球中不可能出现平局：网球规则使一局只有 2 种可能的结果：1）发球方赢，或 2）发球方输。
- 脑力与体力：国际象棋纯粹考验推理和预判的脑力，而网球中体能起着巨大的作用。
- 博弈论能否容纳体能上的差异？能否量化脑力与体力在网球胜负中的相对作用？

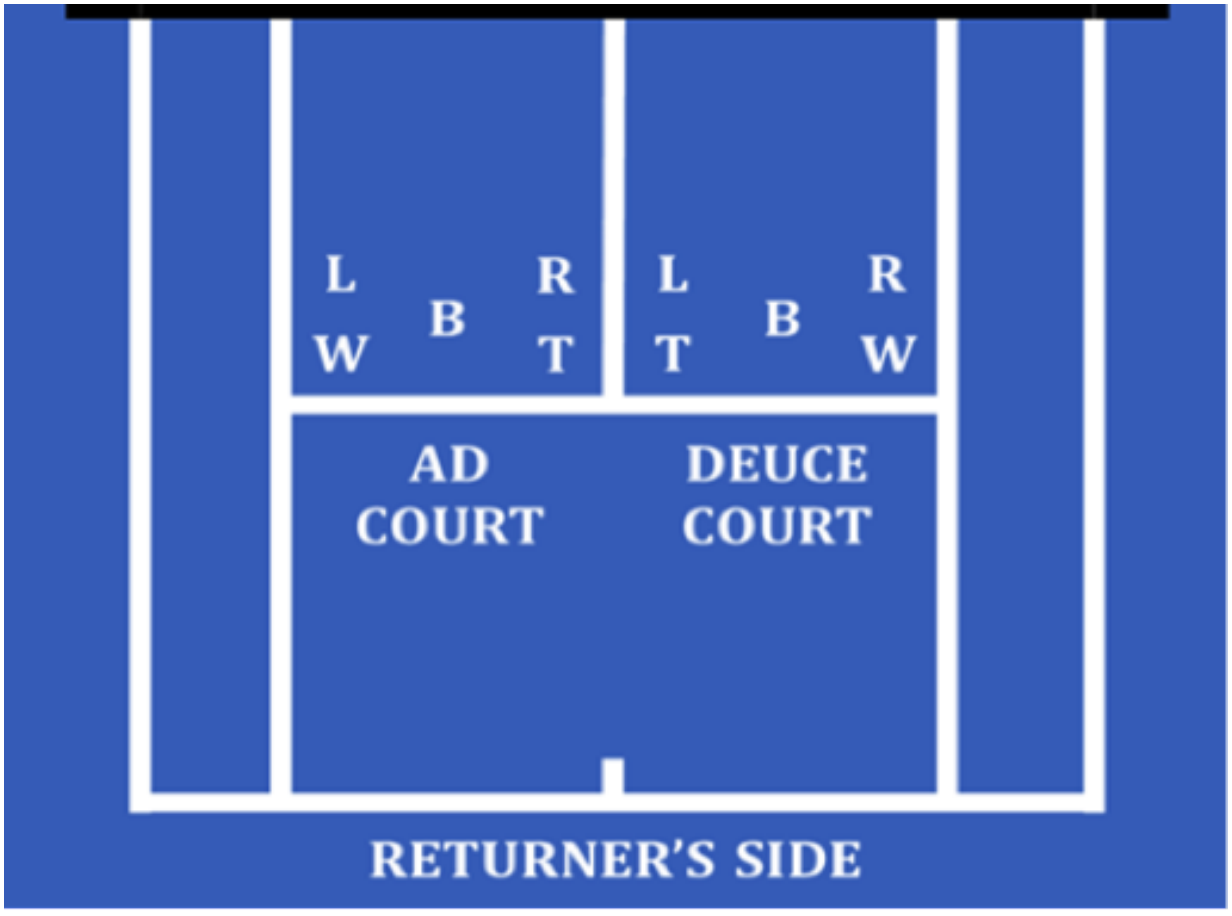
网球中的非均衡博弈

- 检验企业行为是否与 MPE 一致很困难，因为我们不知道企业的生产函数或目标函数（是最大化股票市值，还是股利的贴现现值？）
- 我关注的是更简单的问题：技术简单得多，目标也是已知的。
- 例子：网球或国际象棋：目标是采取最优反应策略以最大化获胜概率。
- 获胜的回报很高，而且比赛由职业选手进行，因此我们预期在这种情形下能观察到纳什/MPE 行为
- Walker 与 Wooders（2001），Minimax Play at Wimbledon；或 Palacios-Huerta（2003），Professionals Play Minimax

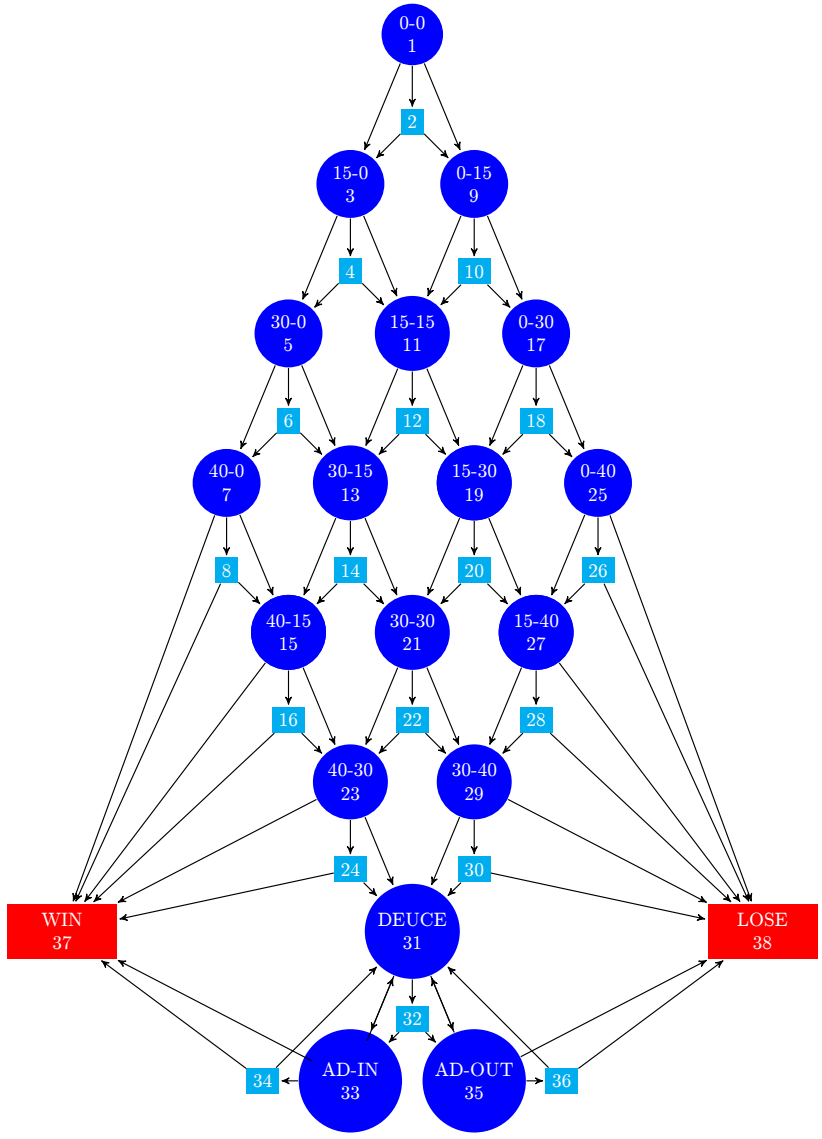
发球方向：外角、追身与中路（T 点）



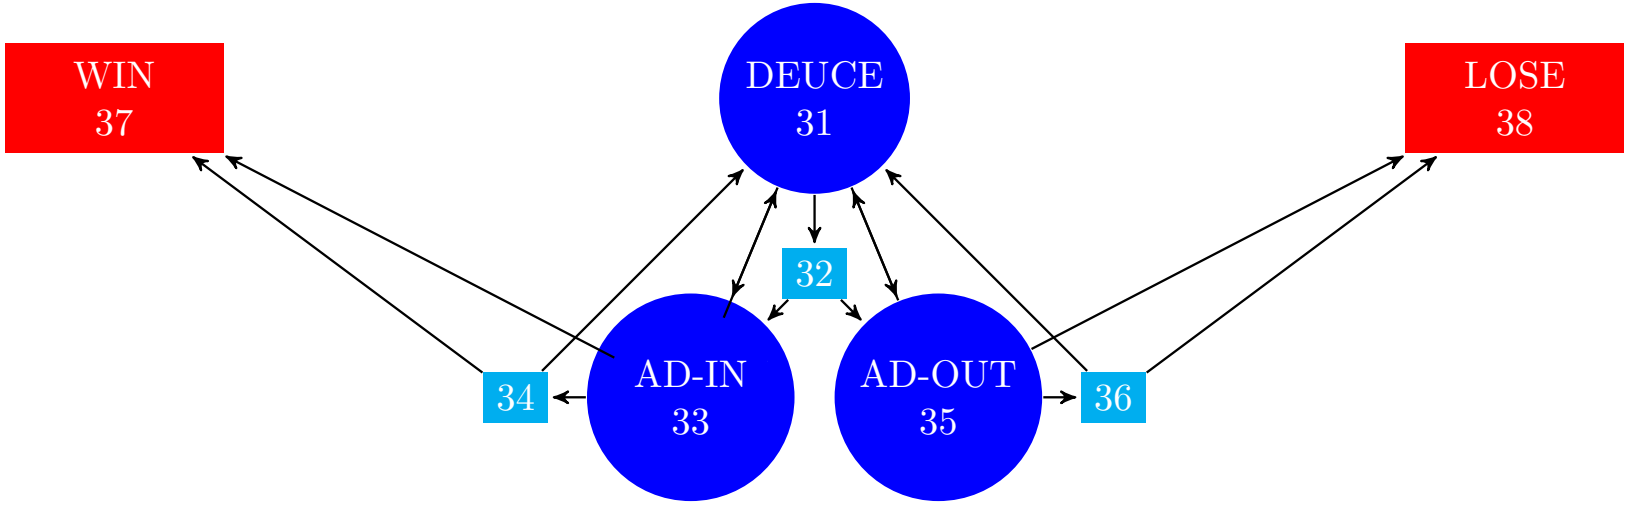
从接发球者视角看的发球方向



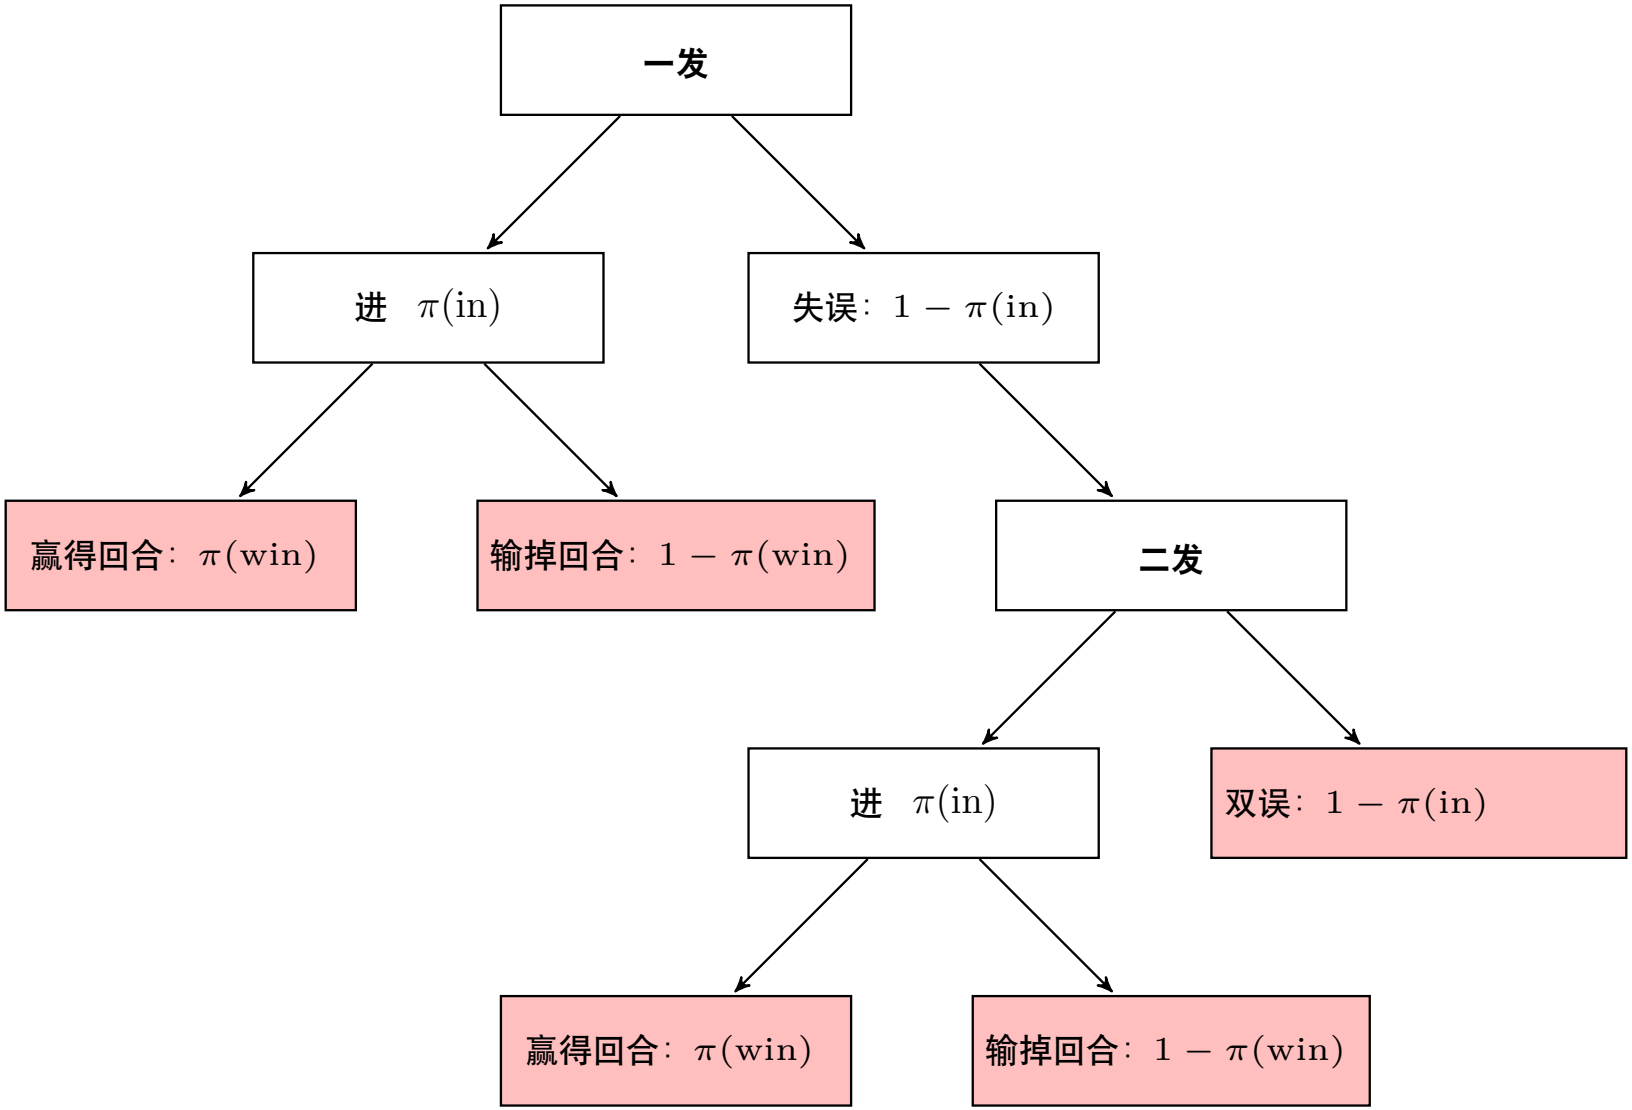
发球局中状态转移的图示



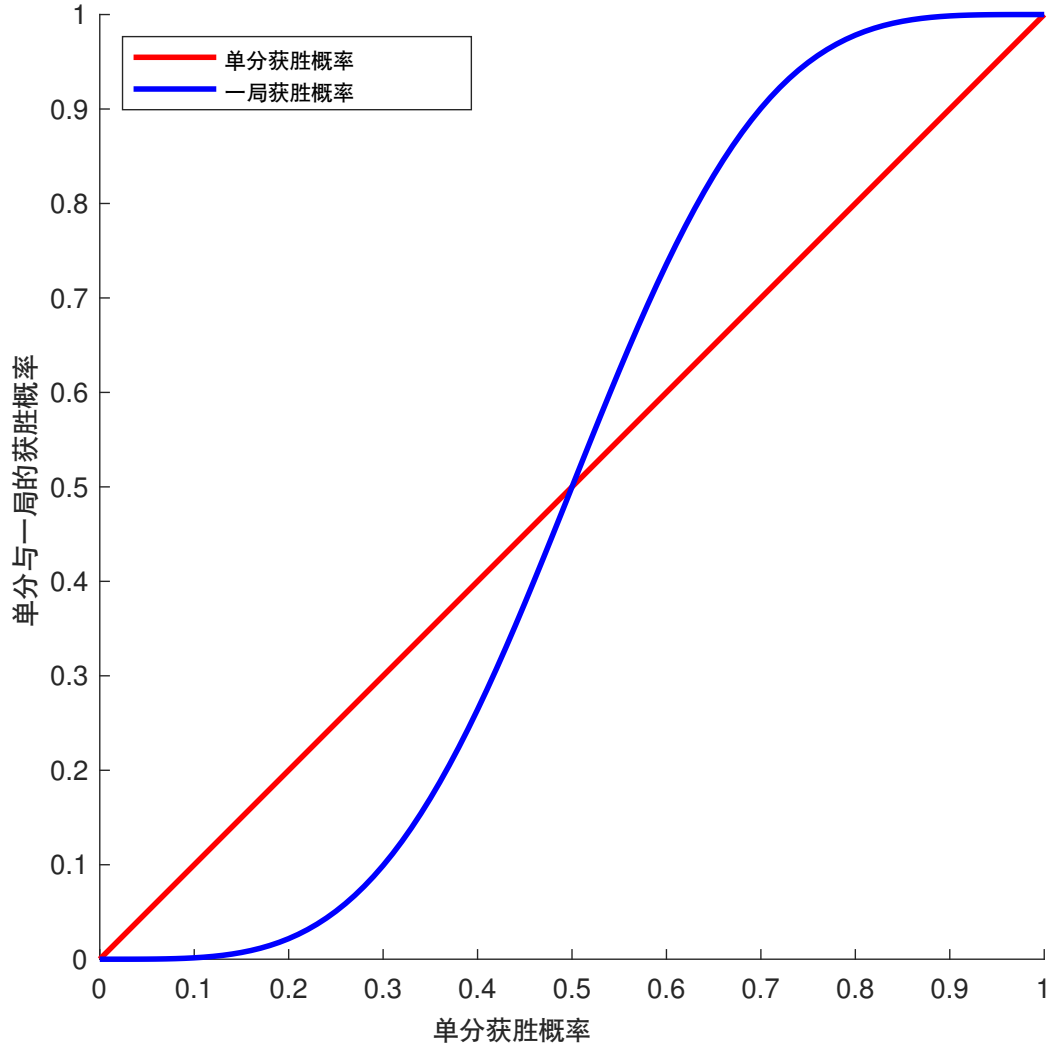
平分后残局的细节



单分阶段博弈的细节


一发
进　$\pi(\text{in})$
失误：$1-\pi(\text{in})$
赢得回合：$\pi(\text{win})$
输掉回合：$1-\pi(\text{win})$
二发
进　$\pi(\text{in})$
双误：$1-\pi(\text{in})$
赢得回合：$\pi(\text{win})$
输掉回合：$1-\pi(\text{win})$

单分获胜概率与一局获胜概率



网球中均衡博弈的两个关键含义

- **获胜概率相等**　在混合策略均衡中，无论发球方向哪个方向发球，其收益都应相同

- **单次偏离原则**　在网球比赛的任何时刻，发球方的策略都不应存在能提高其获胜概率的偏离

把网球建模为动态博弈

- 与以单分阶段博弈为分析单位的 Walker 和 Wooders 不同，我们关注整个发球局。
- 令 $x \in \{1, \ldots, 38\}$ 表示比分状态。按照我们在前一张图中对状态的编号，$x = 1$ 是一局的初始节点，对应比分 $0 - 0$。
- 如果发球方赢得一发，状态转移到 $x = 3$，对应比分 15-0。如果发球方一发失误，状态转移到 $x = 2$，对应比分 0-0 时的二发，依此类推。
- 有两个吸收状态：$x = 37$（发球方赢下这一局）与 $x = 38$（发球方输掉这一局）。

网球中发球者与接发球者的选择

- 在除两个吸收状态之外的每个状态 x，发球者选择发球类型 $t = (s, d)$，其中 $d \in \{l, r, b\}$ 是发球方向（左、右或追身），$s \in \mathcal{S} \subset R^2$ 表示球速与旋转。
- 接发球者预判发球者的方向选择，其中包括可观测的选择（例如站在哪里）和不可观测的选择（例如把注意力集中在哪里）。
- 我们用注意力向量 $(a_l, a_r, a_b) \geq 0$ 刻画预判，其中 a_d 是接发球者用于预判向方向 d 发球的注意力预算比例。把注意力预算标准化为 1，即 $1 = a_l + a_r + a_b$。
- 我们假设每次发球时，接发球者先选择 a 和站位，然后发球者行动，选择发球类型 t。

考虑肌肉记忆

- 我们通过肌肉记忆状态 m 来刻画网球中额外的动态性。
- 具体地，令 $m = (d_{-2}, d_{-1})$，即此前两次一发方向构成的向量。之所以有两期滞后，是因为发球在平分区和占先区之间交替，而我们假设相关的肌肉记忆是对同一侧场区上一次发球的记忆。
- 每局开始时肌肉记忆为空，$m = (\emptyset, \emptyset)$。向方向 d 一发之后，肌肉记忆按如下方式更新

$$m = (d_{-2}, d_{-1}) \longrightarrow m' = (d_{-1}, d) = m'(m, d)$$

- 二发之后不更新肌肉记忆。

得分结果概率（POPs）

定义

如果平稳性假设成立，且 (ρ, α) 由发球局的 MPE 所隐含，那么这些 MPE 策略所隐含的得分结果概率（POPs）为

$$\pi(in|x,m,d) \equiv \int l(x,m,d,s)\rho(ds|x,m)$$

$$\pi(win|x,m,d) \equiv \int\int \omega(x,m,d,s,a)\rho(ds|x,m)\alpha(da|x,m)$$

诱导出的动态规划

- 现在假设我们在网球中观察到的博弈与某个 MPE 一致，即我们观察到的是均衡博弈。
- 下面说明，发球方的条件获胜概率 $W_s(x, m)$ 是一个动态规划的解，该动态规划给出作为对接发球者策略之最优反应的最优发球方向。

- 如果博弈处于均衡，就可以把接发球者的混合策略以简约形式体现在 POPs 中，而发球者的策略与获胜概率将是对这些 POPs 的最优反应。

- 发球者的 Bellman 方程为

$$W_s(x, m) = \max_{d \in \{l, b, r\}} W_s(x, m, d)$$

其中 $W_s(x, m, d)$ 是发球者在状态 (x, m) 下向方向 d 发球时的条件获胜概率。

发球者的 Bellman 方程

- 令 $x^+(x)$ 和 $x^-(x)$ 分别表示发球者在单分状态 x 赢下与输掉该分之后的后继状态。利用它们，可以把 $W_s(x, m, d)$ 递归地写成

$$
\begin{aligned}
&W_s(x, m, d) = \\
&\pi(in|x, m, d)\pi(win|x, m, d)W_s(x^+(x), m'(d, m)) \\
&+\pi(in|x, m, d)[1 - \pi(win|x, m, d)W_s(x^-(x), m'(d, m)) \\
&+[1 - \pi(in|x, m, d)]W_s(x + 1, m'(d, m))
\end{aligned}
$$

对一发状态 x 成立，其中 $x+1$ 表示一发失误时的二发状态，$m'(d, m)$ 是向方向 d 发球后新的肌肉记忆状态，$m'(d, m) = (d_{-1}, d)$，其中 $m = (d_{-2}, d_{-1})$。

发球者的 Bellman 方程

- 如果 x 是二发状态（即在我们的比分状态编号中 x 为奇数），那么

$$
\begin{aligned}
&W_s(x, m, d) = \\
&\pi(in|x, m, d)\pi(win|x, m, d)W_s(x^+(x), m) \\
&+\pi(in|x, m, d)[1 - \pi(win|x, m, d)W_s(x^-(x), m) \\
&+[1 - \pi(in|x, m, d)]W_s(x^-(x), , m)
\end{aligned}
$$

  这里注意，二发之后肌肉记忆状态不更新，仍为 m。

- 最优发球策略 $\sigma_s(x, m)$ 是 Bellman 方程最大化元的集合

$$
\sigma_s(x, m) = \underset{d \in \{l, b, r\}}{argmax}\ W_s(x, m, d).
$$

求解发球者的 DP 问题

- 可以把发球者条件获胜概率的 Bellman 方程更紧凑地写成

$$W_s = \Gamma(W_s)$$

其中 Γ 是 Bellman 算子。尽管这个 DP 问题中没有贴现，POPs $(\pi(in|x, m, d), \pi(win|x, m, d))$（一般严格小于

1) 起到了与贴现因子相当的作用，借助压缩映射定理保证了 Bellman 方程存在唯一解。

- 实践中，我们用逆向归纳求解发球者的 DP 问题，但归纳不是沿时间进行，而是沿状态进行，所用算法被 Iskhakov、Schjerning 和 Rust（IRS，2016）称为状态递归。

纳什均衡的可检验含义

- 假设我们能计算发球者的条件获胜概率 $W_s(x, m, d)$。如果均衡是混合策略均衡，那么混合策略纳什均衡的一个关键含义是

均衡的可检验含义（1）

获胜概率相等　　在所有状态 (x, m) 下都有：

$$W_s(x, m, l) = W_s(x, m, b) = W_s(x, m, r)$$

评估非均衡发球策略的价值

- 令 $W_P(x, m)$ 为某个发球者的条件获胜概率，其（可能非均衡的）马尔可夫发球方向策略为 $P(d|x, m)$。我们有

$$W_P(x, m) = \sum_{d \in \{l, b, r\}} W_P(x, m, d) P(d|x, m)$$

  其中 $W_P(x, m, d)$ 是在策略 P 下、发球者在状态 (x, m) 向方向 d 发球时获胜的条件概率。
- $W_P(x, m, d)$ 的值由与上文 Bellman 方程中最优（均衡）发球策略相同的递归方程给出。

条件获胜概率的线性方程组

- 可以证明，$W_P(x, m)$ 是下列线性方程组的解

$$W_P = w_P(P, \Pi) + M_P(P, \Pi) W_P \tag{1}$$

其中 $P = \{P(d|x, m)\}$，$\Pi = \{\pi(in|x, m, d), \pi(win|x, m, d)\}$，$w_P(P, \Pi)$ 是直接赢下发球局的概率构成的 298×1 向量（除平分残局状态和发球方离赢下这一局只差一分的状态外，大多数状态下为零），$M_P(P, \Pi)$ 是 298×298 的马尔可夫子转移概率矩阵。

- 由于 $\|M_P(P, \Pi)\| < 1$，对任意 (P, Π)，该方程组都有唯一解 W_P。

- 注意，条件获胜概率 $W_P(x, m, d)$ 共有 $894 = 3 \times 298$ 个。因此，如果能用较少的参数较好地估计 (P, Π)，就能得到 $W_P(x, m, d)$ 更有效的估计。

非参数估计与递归计算的获胜概率

ESTIMATED WIN AND CONDITIONAL WIN PROBABILITIES AT FIRST SERVE OF SERVICE GAME

SERVER → RECEIVER	WIN PROBABILITY, FIRST SERVE	CONDITIONAL WIN PROBABILITY, FIRST SERVE			DHW TEST *p*-VALUE
		Left	Body	Right	
Federer → Nadal					.004
NP estimate	.796 (.026)	.816 (.025)	.650 (.030)	.803 (.025)	
RF estimate	.829 (.023)	.828 (.024)	.819 (.027)	.833 (.022)	
Nadal → Federer					.107
NP estimate	.786 (.026)	.748 (.028)	.896 (.020)	.762 (.028)	
RF estimate	.807 (.023)	.808 (.023)	.807 (.025)	.803 (.025)	
Federer → Djokovic					.504
NP estimate	.810 (.024)	.844 (.022)	.867 (.021)	.767 (.025)	
RF estimate	.818 (.020)	.826 (.020)	.812 (.023)	.813 (.021)	
Djokovic → Federer					.910
NP estimate	.782 (.025)	.769 (.026)	.710 (.028)	.815 (.024)	
RF estimate	.781 (.022)	.792 (.022)	.769 (.026)	.774 (.024)	
Nadal → Djokovic					.992
NP estimate	.712 (.035)	.685 (.036)	.726 (.035)	.750 (.034)	
RF estimate	.712 (.034)	.712 (.034)	.701 (.035)	.718 (.034)	

获胜概率相等的 Wald 检验

TABLE 6
WALD TESTS OF EQUAL SERVICE-GAME WIN PROBABILITIES, MUSCLE-MEMORY SPECIFICATION

Server → Receiver	Four Fixed Serve Strategies at Three States (9 df)	Reduced-Form Serve Strategy at Four States (12 df)
Federer → Nadal	1.4×10^{-11}	.605
Nadal → Federer	.873	.018
Federer → Djokovic	6.5×10^{-30}	1.6×10^{-68}
Djokovic → Federer	.0009	.220
Nadal → Djokovic	2.2×10^{-254}	.526
Djokovic → Nadal	4.0×10^{-91}	4.5×10^{-44}
Djokovic → Murray	1.4×10^{-69}	.018
Murray → Djokovic	9.1×10^{-91}	.00001
Sampras → Agassi	.787	.003
Agassi → Sampras	.764	.667

纳什均衡的第二个可检验含义

- 假设我们能在不施加最优性/均衡的条件下估计发球者的条件获胜概率 $W_P(x, m, d)$。那么混合策略纳什均衡的一个关键含义是

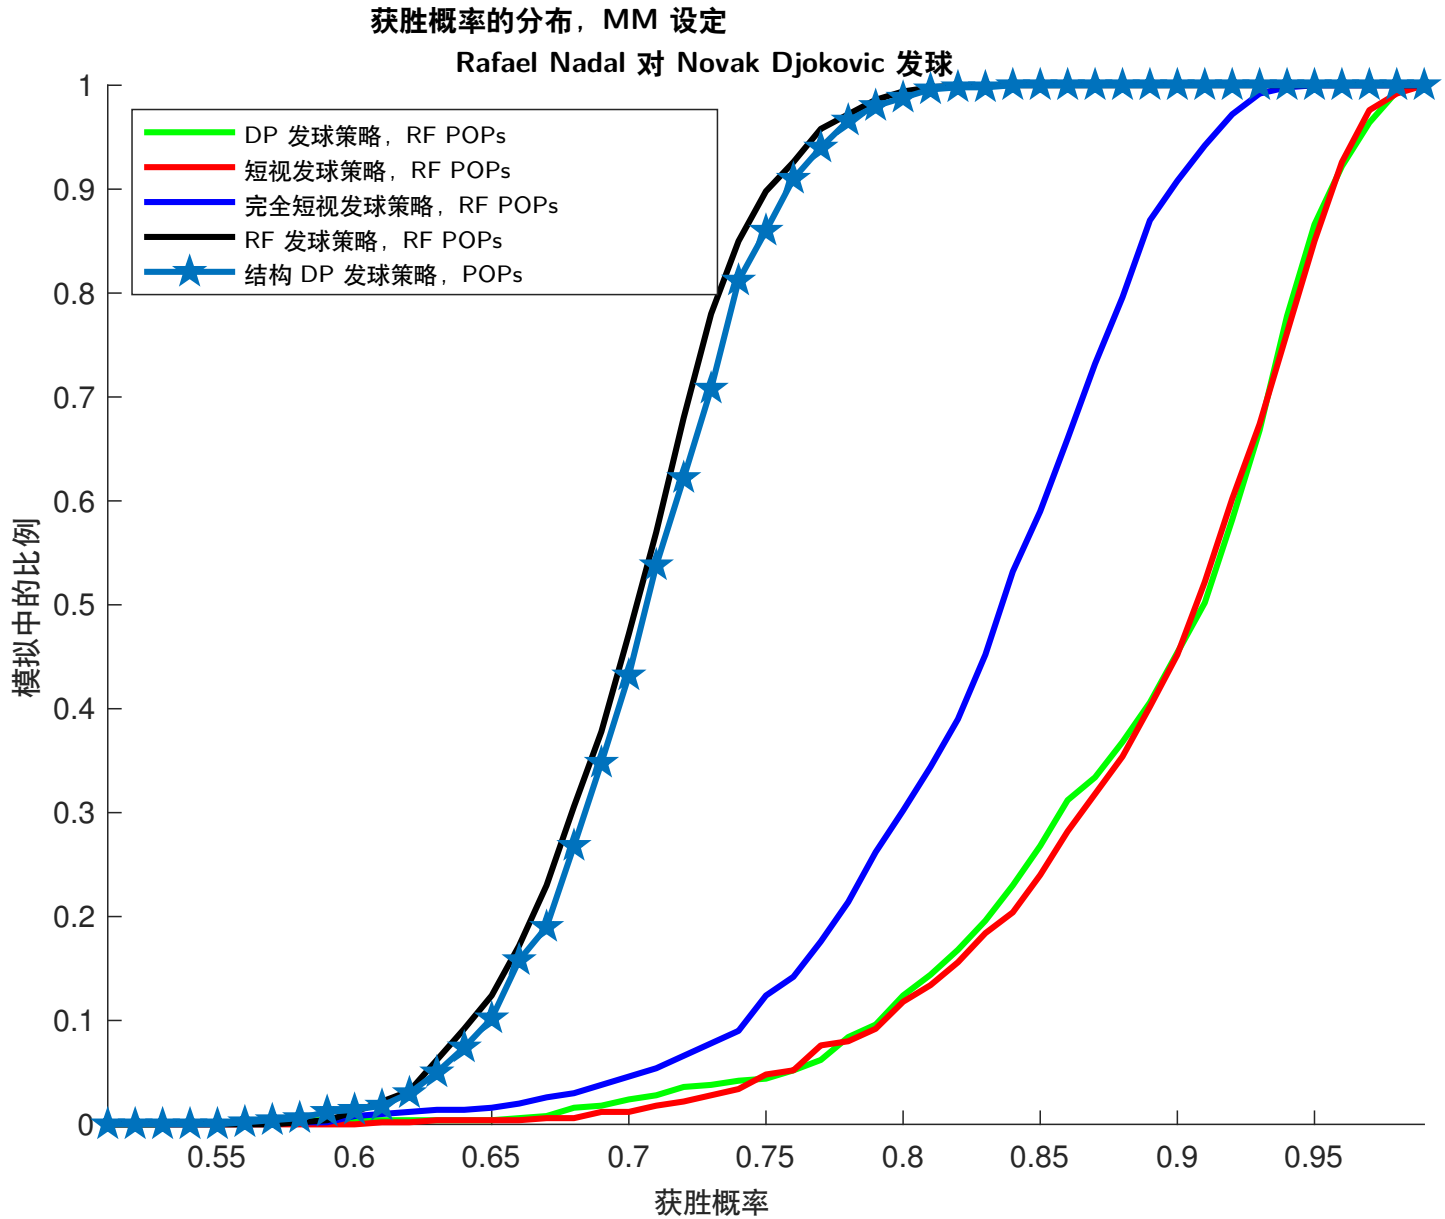
均衡的可检验含义（2）

单次偏离原则　　在所有状态 (x, m) 下，对所有发球方向 $d \in \{l, b, r\}$，都有：

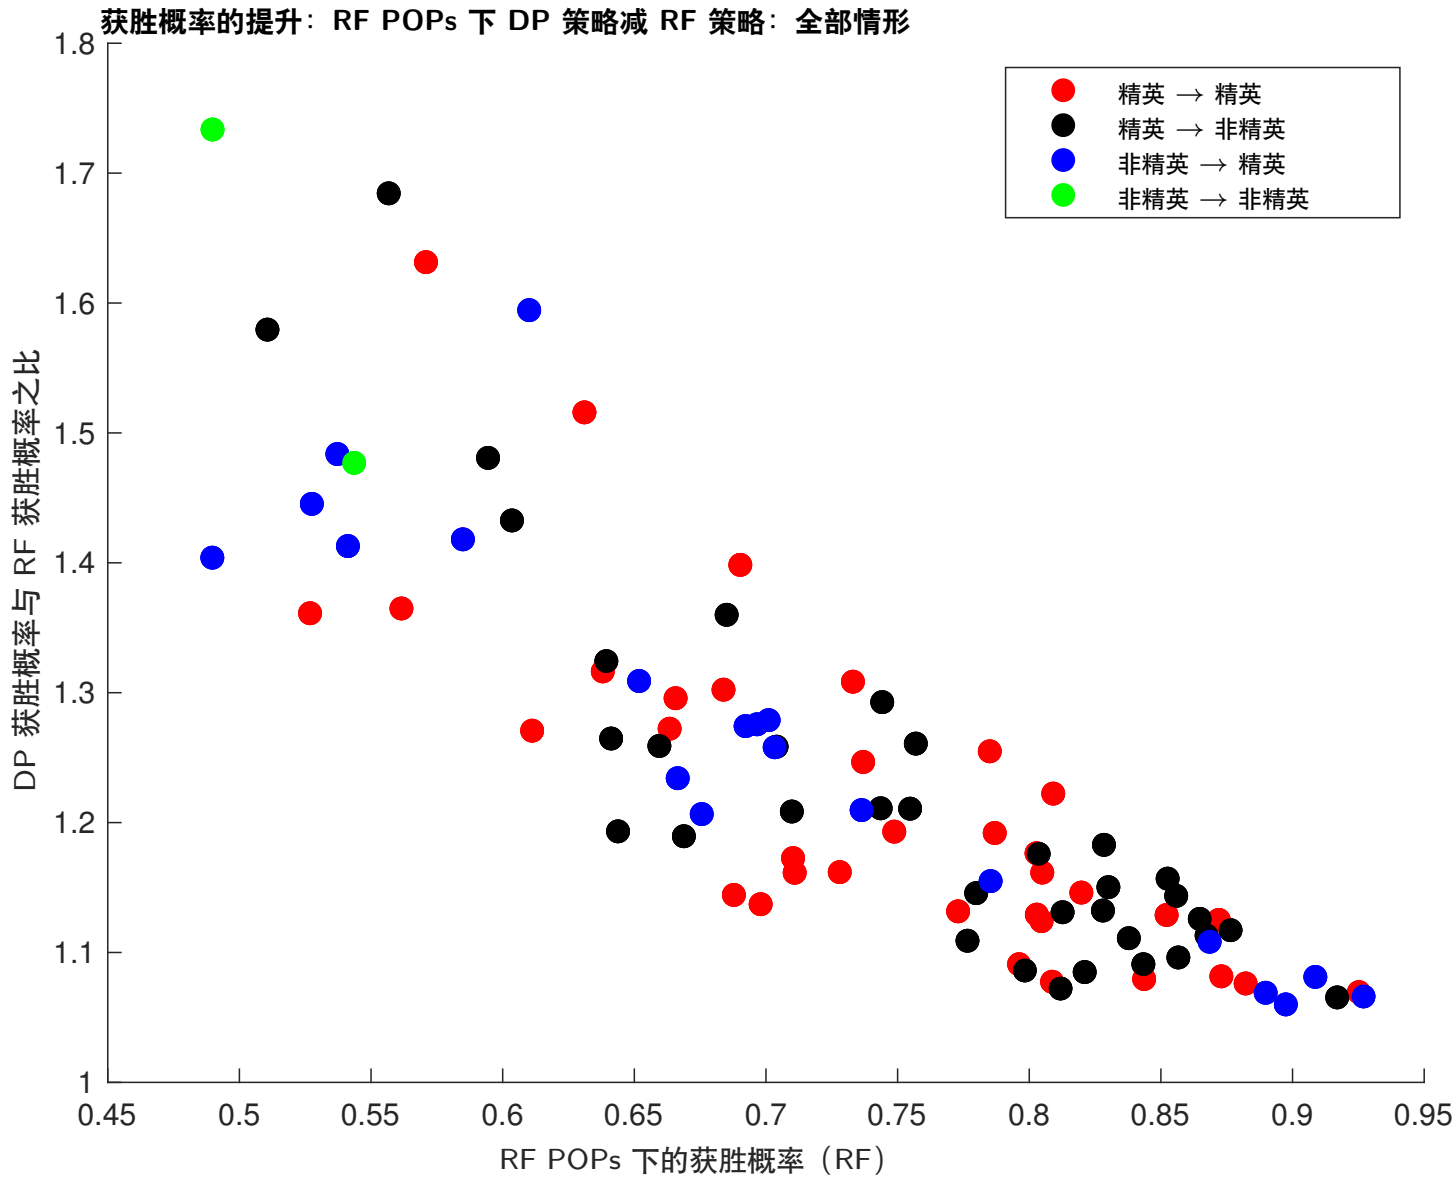
$$W_P(x, m, d) = W_s(x, m, d)$$

- 按照维基百科，单次偏离原则“就是把动态规划的最优性原理应用于博弈论。它指出：有限扩展式博弈的一个策略组合是子博弈完美均衡（SPE），当且仅当对每个子博弈和每个参与人都不存在有利可图的单次偏离。”

获胜概率的分布：Nadal 对 Djokovic 发球



精英与非精英职业选手都存在非均衡博弈



信息受限拍卖中的提前过度出价

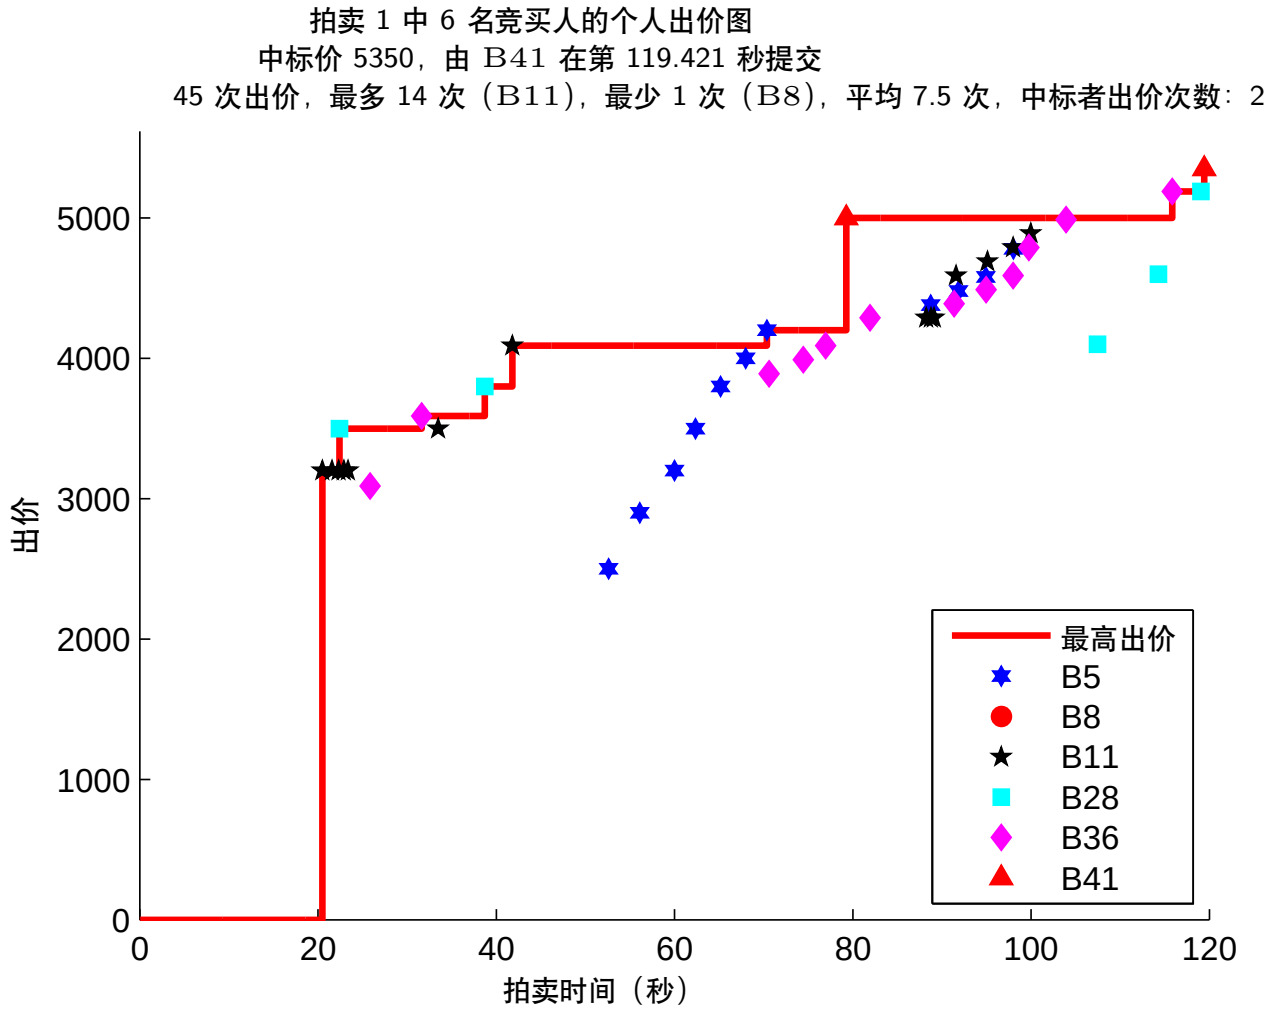
- 我们分析了大量在线进行、每场持续 2 分钟的租车连续时间升价拍卖。

- 出于对竞买人合谋的担忧，这家租车公司设计了一种独特的动态拍卖：韩国式拍卖。
- 竞买人只知道自己出价的金额，以及一个表示自己的出价是否为当前最高价的指示变量。
- 竞买人无法观察到其他竞买人的身份或出价，因此甚至不知道任一场拍卖中其他竞买人的数目。

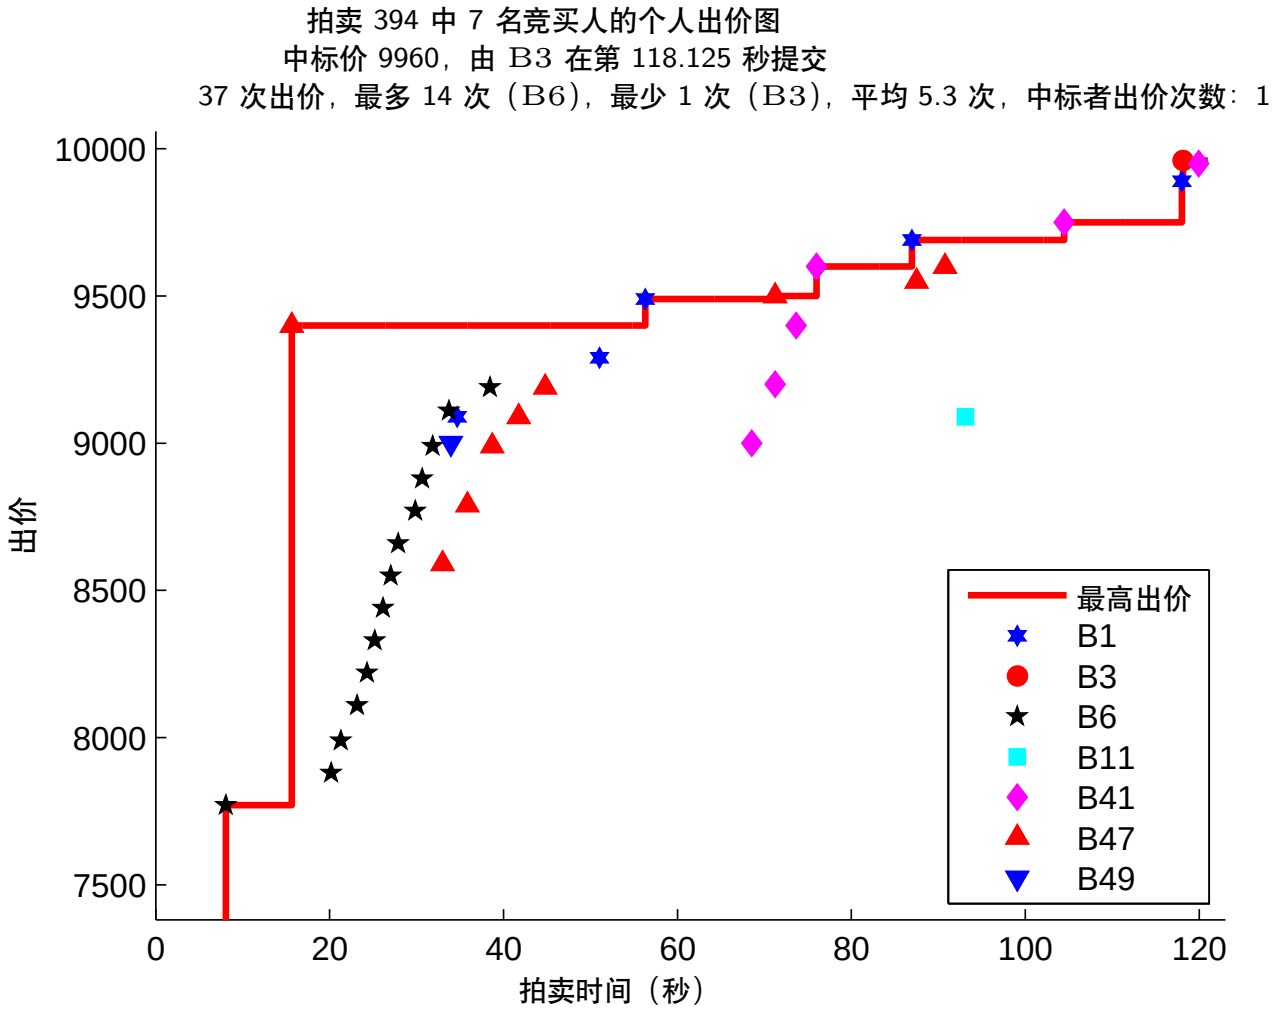
- 据我们所知，只有另一篇论文分析过信息限制与韩国式拍卖相似的拍卖：德克萨斯州的存单（CD）拍卖。

- Barkley、Groeger 与 Miller，Journal of Econometrics（2021），对这些拍卖中的出价进行了实证分析。
- 该市场的特点是频繁的跳跃出价，且中标价远高于最高的落选出价，这表明适用于升价拍卖的标准实证方法可能并不合适。

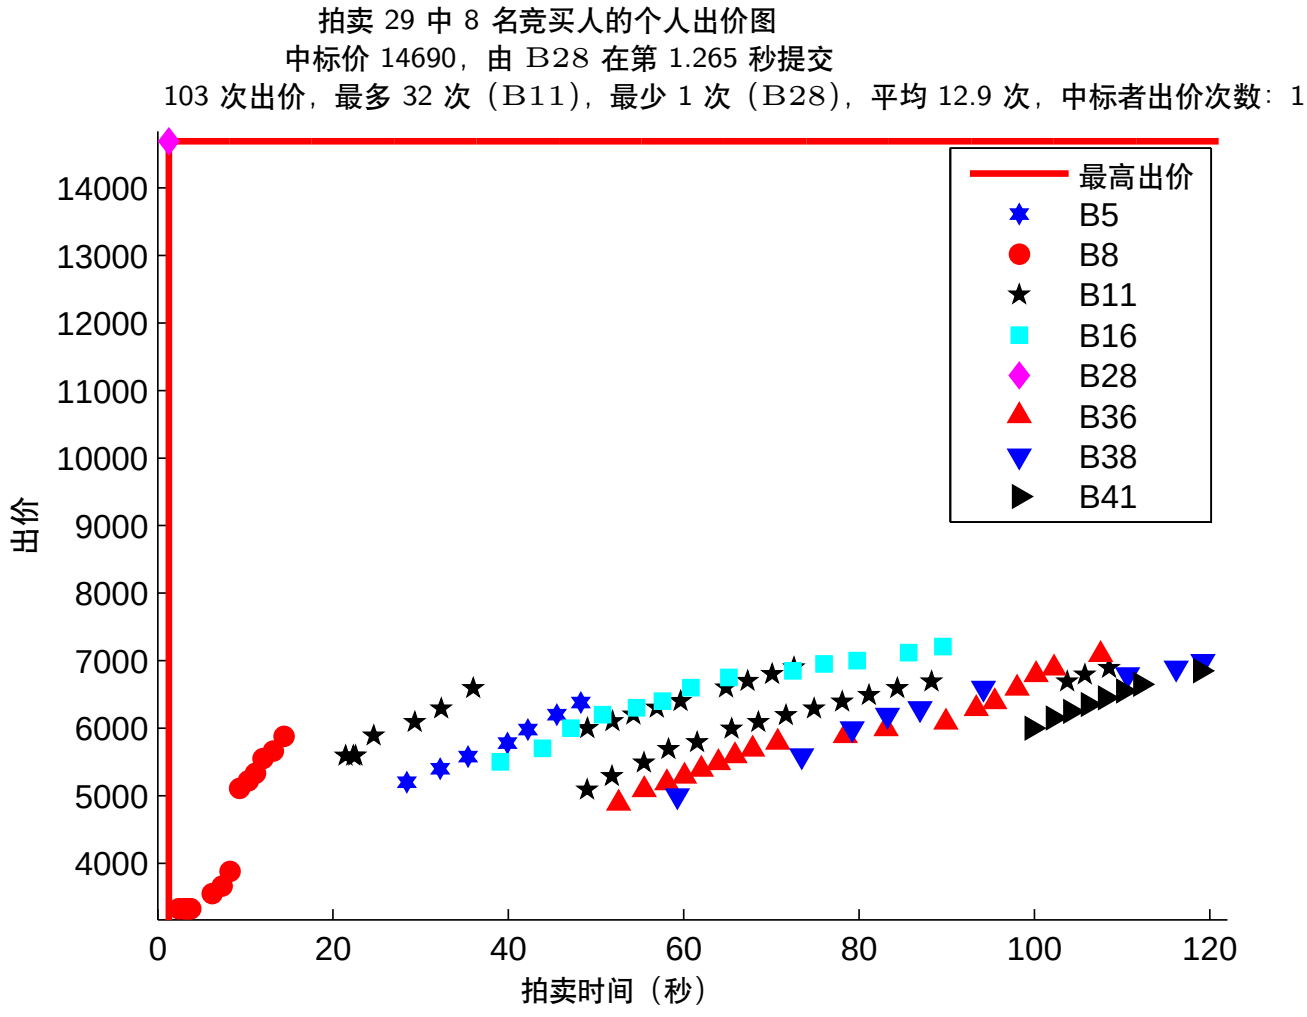
拍卖 1，2005 年 1 月 26 日



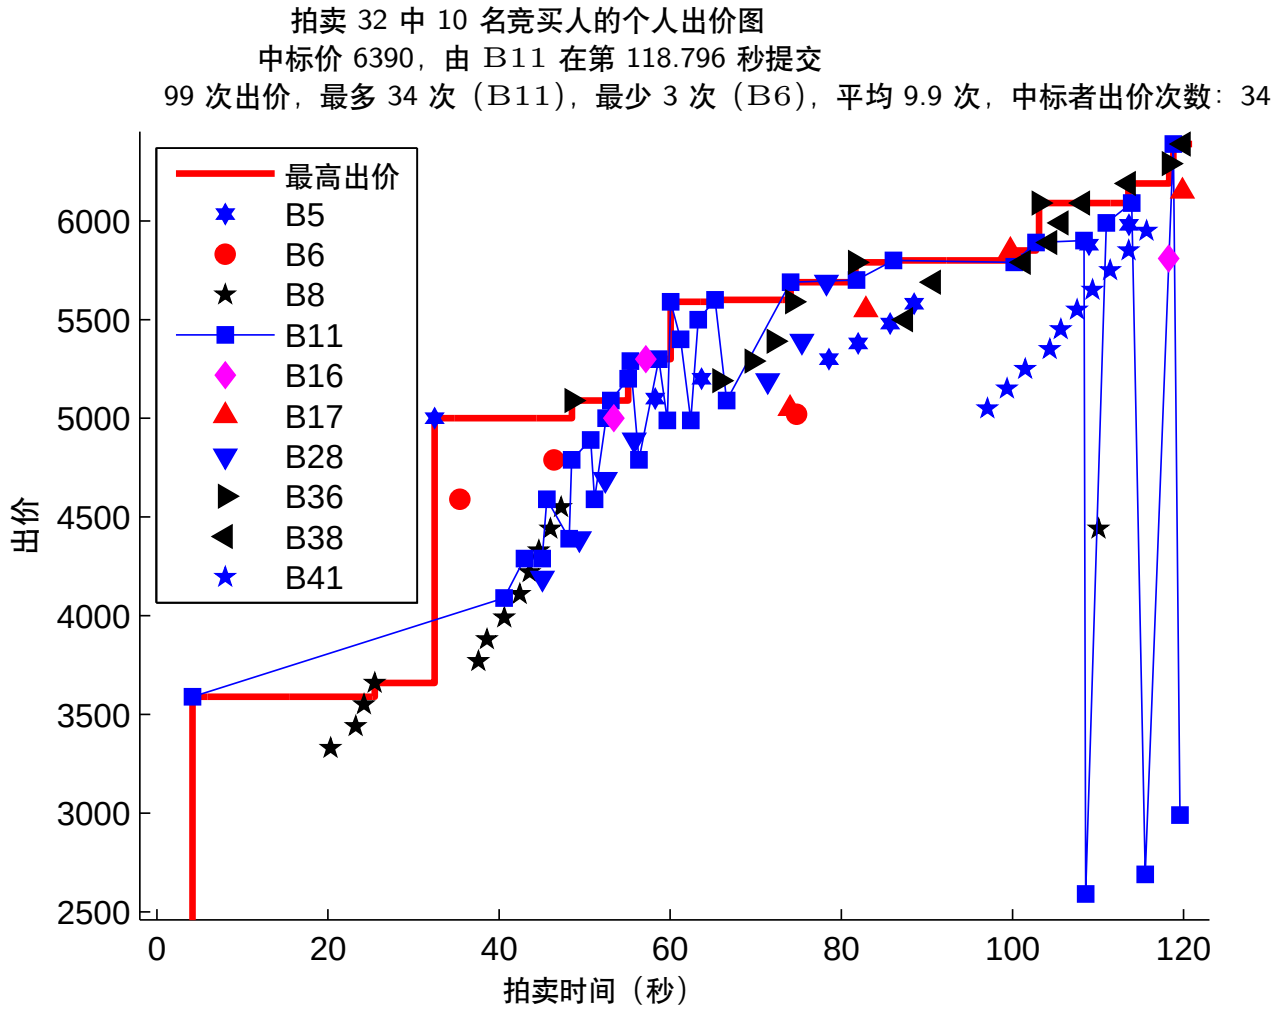
拍卖 394：狙击式出价


拍卖 394 中 7 名竞买人的个人出价图
中标价 9960，由 B3 在第 118.125 秒提交
37 次出价，最多 14 次（B6），最少 1 次（B3），平均 5.3 次，中标者出价次数：1
出价
拍卖时间（秒）
10000
9500
9000
8500
8000
7500
0
20
40
60
80
100
120
最高出价
B1
B3
B6
B11
B41
B47
B49

拍卖 29：提前出高价的竞买人



拍卖 32：一个疯狂的竞买人 B11



出价行为小结

- 渐进加价：最常见的行为，出于学习的愿望？
- 跳跃加价：与渐进加价类似，但出价次数更少、跳幅更大
- 狙击式出价：在 5% 的拍卖中观察到
- 先发制人的提前出价：在 3% 的拍卖中观察到
- 非单调出价：无聊还是愚蠢？

本文的关键发现与贡献

我们表明，先发制人的提前出价是这些拍卖中一种更常见现象的极端版本，我们称这种现象为“提前过度出价”。我们认为很难为提前过度出价找到理性的解释，但我们确实找到了一种：借助理性疏忽、出价摩擦，以及一个我们称为“匿名均衡”的较弱的均衡概念。

结论预览

- 我们猜想 PBE 中不会出现提前出价。我们给出一个简单的 2×2 例子，其中第一期没有出价。唯一的 PBE 是所有参与人都狙击出价的无信息 PBE，因此它在策略上等价于（匿名化版本的）静态第一价格密封拍卖。

- 我们引入一个在匿名均衡（AE）中、带出价摩擦的理性疏忽出价 DP 模型，它能够解释提前出价。

- 该 DP 模型刻画了竞买人提前出价的激励：了解当前最高价，并尽量在不多付钱的情况下赢得拍卖。
- 我们的理论表明，由于出价失误/低效与拍卖过程中的学习相结合，人类竞买人平均支付更少，但他们的利润也显著低于无摩擦的“出价机器人”在 AE 中所能获得的利润。

其他结果

- 我们的模型为这些拍卖中有信息含量的提前出价提供了定性解释，但 . . .
- 与模型预测相比，人类竞买人往往出价过高、过快，我们称这一现象为“提前过度出价”。
- 我们表明，就期望利润而言，我们的无摩擦 DP 出价策略优于人类竞买人。
- 我们把模型被拒绝归因于人类竞买人的有限理性：他们面对的是这些连续时间拍卖中困难的动态学习/DP 问题。
- 这造成了相当大的低效，导致竞买人的利润和拍卖成交价都低于静态第一价格密封拍卖形式下的水平。

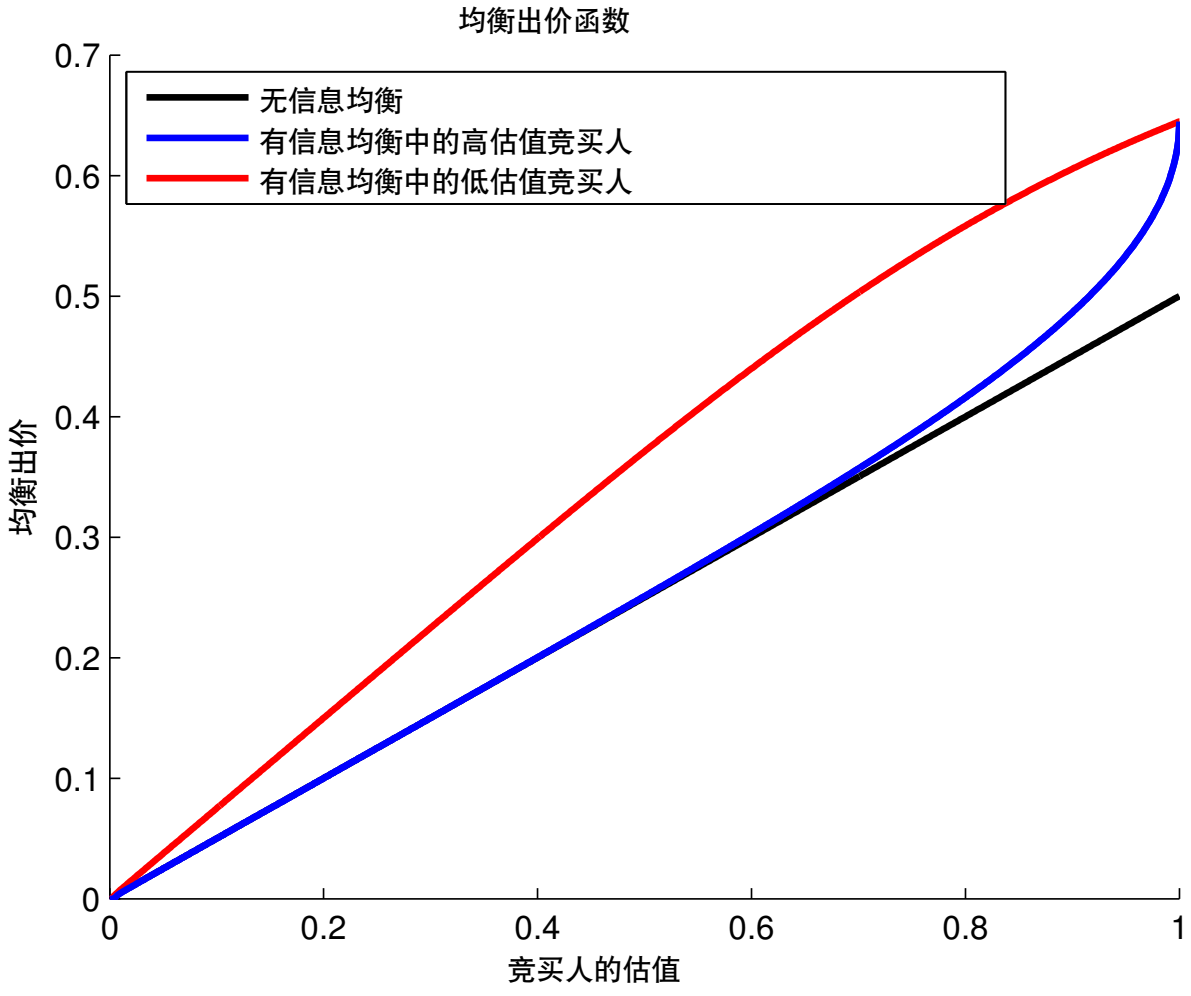
计算机化交易的收益

关键预测

我们表明，如果人类竞买人使用理性的计算机化出价算法作为其“出价代理”，拍卖成交价和竞买人利润都会提高。在韩国市场的匿名均衡中，使用理性的计算机化出价代理时，效率为 100%，竞买人利润几乎翻倍，拍卖成交价比人类竞买人参与的拍卖高 13%。

- 我们认为，在更简单的静态密封拍卖机制中，人类交易者可以获得与上述大致相同的效率和结果。
- 没有充分的理由采用更复杂的动态拍卖形式。

第 2 期的均衡出价函数


均衡出价函数
无信息均衡
有信息均衡中的高估值竞买人
有信息均衡中的低估值竞买人
均衡出价
竞买人的估值
0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.2
0.4
0.6
0.8
1

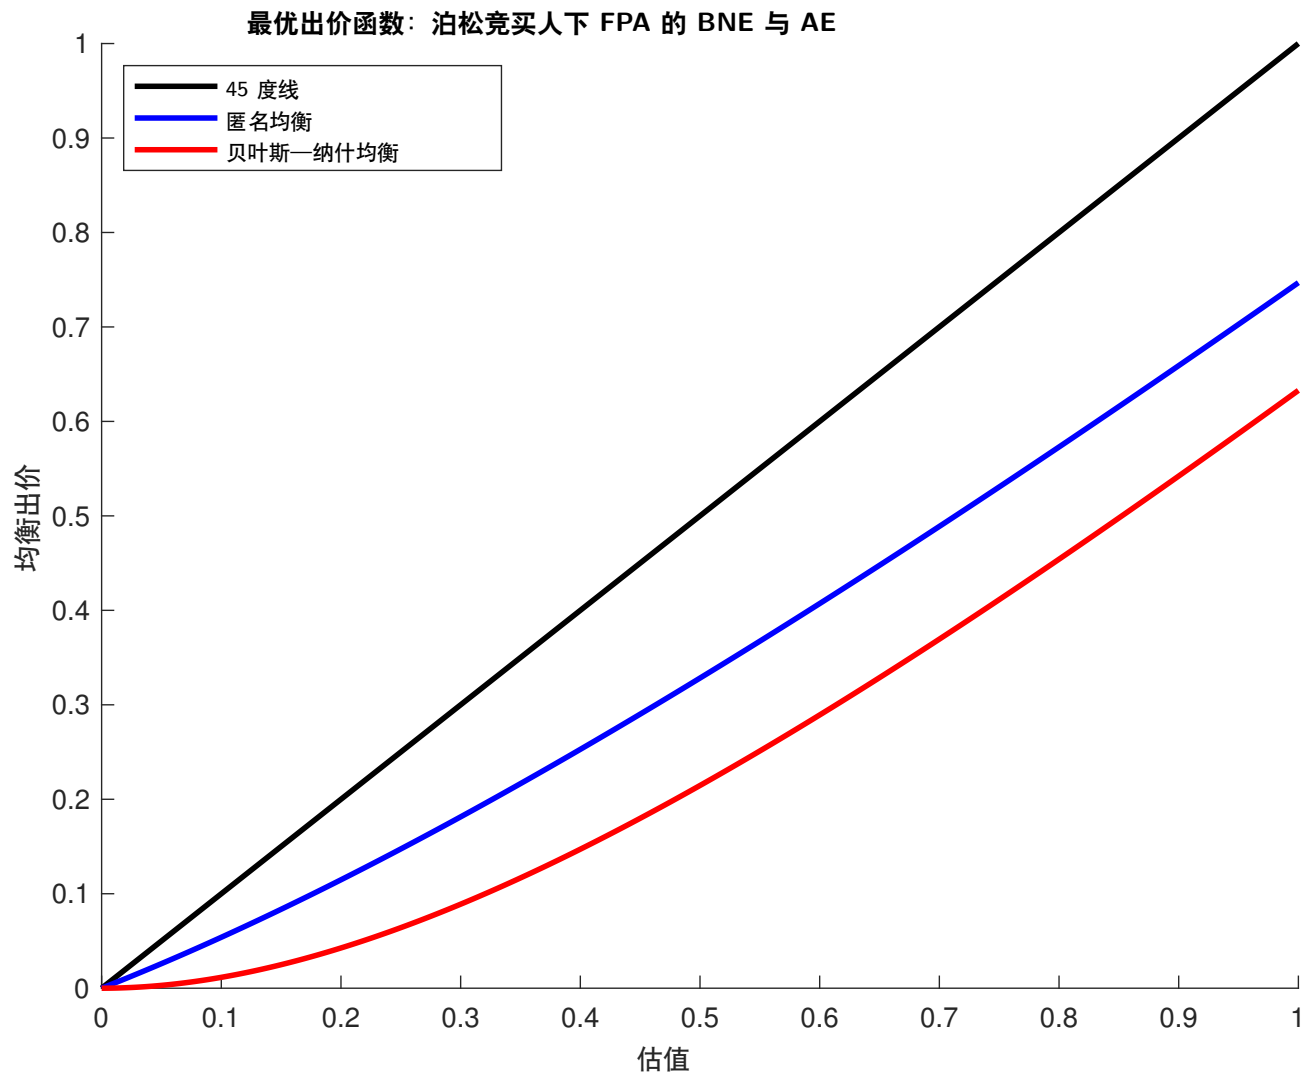
匿名均衡中的理性疏忽出价

- 由于 PBE 难以计算，而且也不清楚是否存在与我们在这些拍卖中观察到的出价行为相一致的有信息 PBE，我们采用另一种建模方法。

- 我们构建一个行为 DP 出价模型，假设竞买人对拍卖中最高价的随机过程持有理性信念。

- 利用这些信念，我们求解一个动态规划，以确定这些信念所隐含的最优出价策略。
- 我们定义 ϵ-匿名均衡的概念，用来刻画这些拍卖中竞买人近似自我确认的信念。
- 它类似于理性预期均衡，后者同样是一个自我确认的信念体系。在 ϵ-AE 中，拍卖期间最高出价的实际随机过程与竞买人对该随机过程的信念近似相等。

泊松到达下静态拍卖中的 AE 出价与 BNE 出价



考虑学习

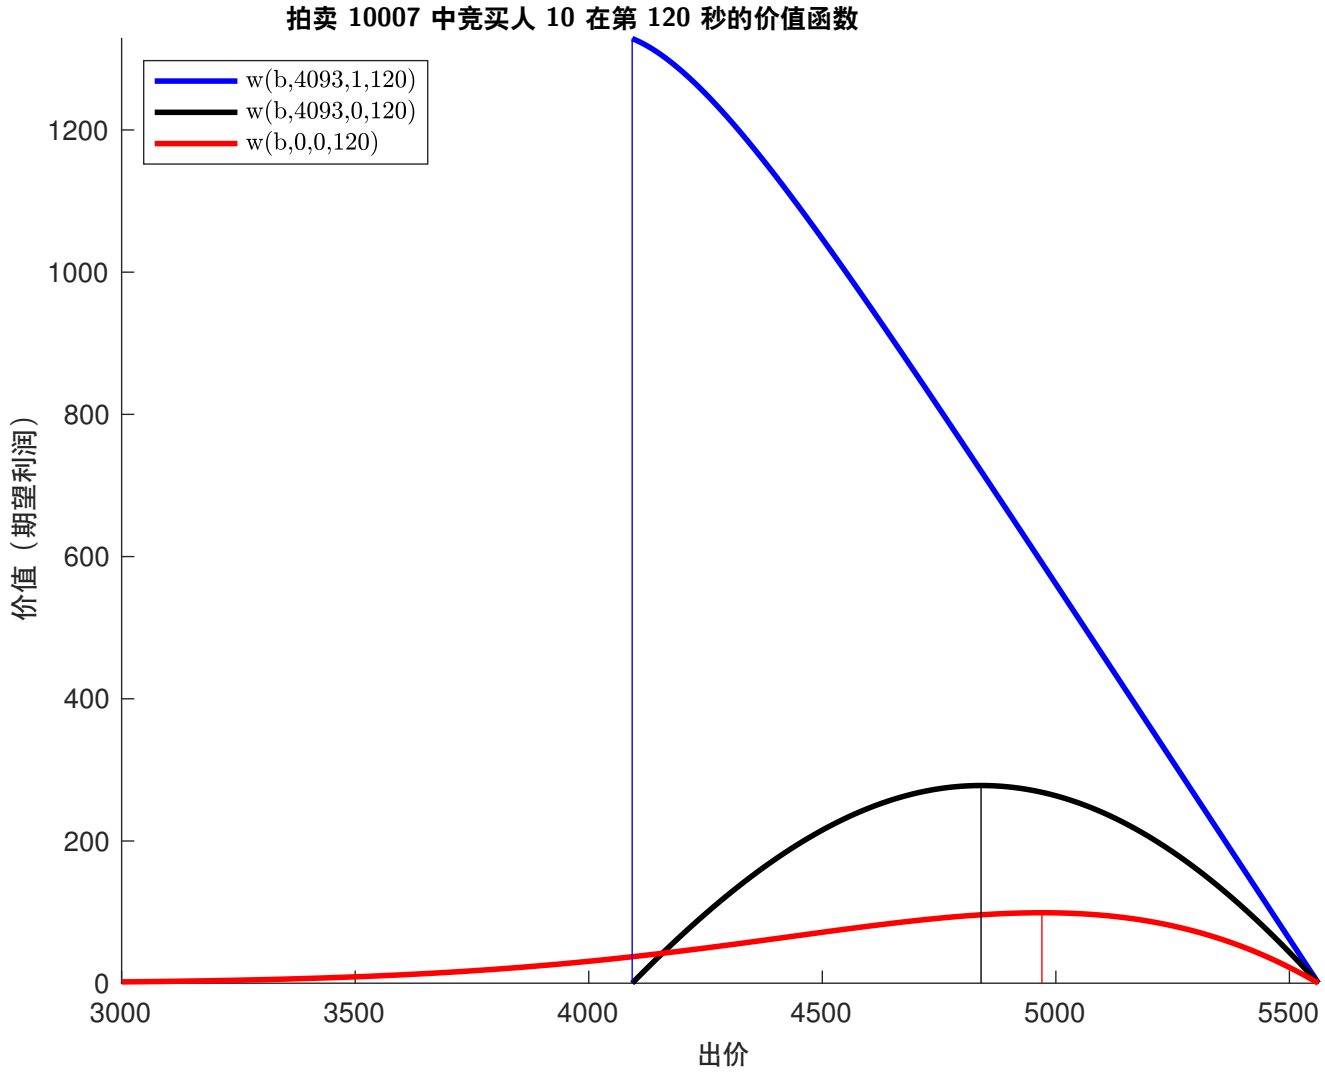
- 我们的方法包含学习，但采用的是更简单的经验学习模型，而不是完全的贝叶斯更新。
- 我们的模型适用于参加过许多场拍卖的有经验的竞买人，他们对拍卖中最高价的随机过程持有明确且固定的信念。

- 如果竞买人在 t 时持有最高出价，他们是知道的。但如果竞买人在 t 时并不持有最高出价，就必须根据对最高价概率分布的理性信念来预测它。

- 我们表明，在拍卖结束之前得知自己持有最高价，能显著减少不确定性。

- 因此，提前出价的动机是收集关于当前最高价的信息，帮助竞买人在不多付钱的情况下赢得拍卖。

通过提前出价进行学习的价值：无摩擦情形



从提前出价中学习的价值

- 竞买人通过出价获得有价值的信息：出价 $b_{120} = 4093$，相比于不出价、保持不知情（即狙击出价）时的 $b_{120} = 0$。

- 即使你不是最高出价者（因而 $h_{120} = 0$），这一点也成立。但显然，最好的情形是你知道自己在以下时刻是最高出价者：$t = 120$.

状态 $(v = 5562)$	$E\{\overline{b}_{121} \mid b_{120}, h_{120}\}$	$\beta_{120}(b_{120}, h_{120})$	$W_{120}(b_{120}, h_{120})$
$b_{120} = 0,\ h_{120} = 0$	5825	4970	99
$b_{120} = 4093,\ h_{120} = 0$	5173	4839	278
$b_{120} = 4093,\ h_{120} = 1$	4113	4093	1329

- 更多的信息：1）降低你对最终最高价的预期，2）降低你的最优出价，3）显著提高你在拍卖中的期望利润。

如果取消信息限制会怎样？

- 假设取消信息限制，使所有竞买人在任何时刻都能看到拍卖中的最高价，无论自己是否持有最高价。
- 不过，竞买人的身份仍然被隐去，因此它仍是一个匿名博弈。
- 由此得到的拍卖是公开喊价拍卖的匿名化电子版本。

定理 2

在匿名公开喊价拍卖的 AE 中，理性、无摩擦的竞买人不会提前出价。所有竞买人都等到最后一刻 T 才出价，因此该 AE 在策略上等价于匿名静态第一价格密封拍卖的 AE。

- 直觉：由于信息上的搭便车，在 AE 中没有理性的竞买人有提前出价的激励。

还需要出价摩擦才能解释提前出价

- 回到具有信息限制的韩国式拍卖。这些限制是否总能产生我们观察到的提前出价？

- 不能：可以找到没有提前出价的无信息 AE。

定理 3

假设韩国式拍卖中的所有竞买人都是理性且无摩擦的，并且拍卖有硬截止时间。那么存在一个无信息 AE，其中所有竞买人只在拍卖的最后一刻 T 提交出价。

含 4 个参数的理性疏忽出价 DP 模型

- 把两分钟的拍卖离散化为 $T = 120$ 个一秒的出价时点。

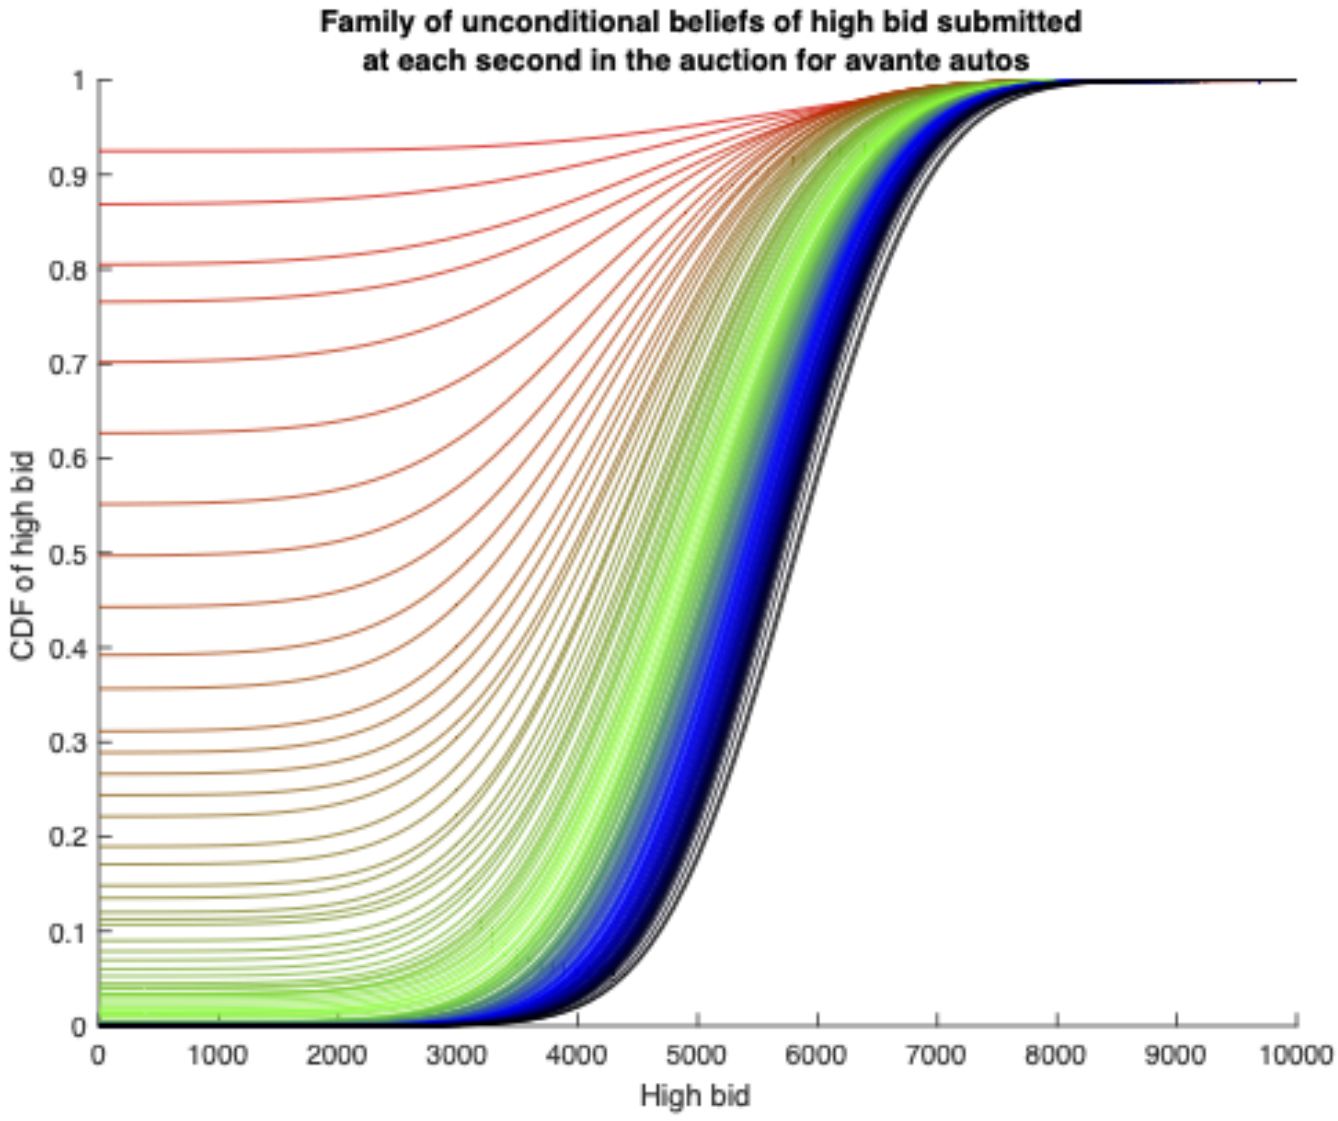
- 令 $\tau = (v, c, p, \sigma)$ 表示竞买人的类型，其中 v 是竞买人对所拍卖汽车的估值，c 是竞买人提交一次出价的心理成本，p 是竞买人分心而无法出价的概率，σ 是极值分布的尺度参数。

- 竞买人的信念 $\mathcal{B}$ 由一族条件概率分布 $\{\lambda_t(b|b_t, h_t)\}$ 刻画，其中 $\lambda_t(b|b_t, h_t)$ 是拍卖区间 $(t, t+1]$ 内最高价的 CDF，条件为 b_t（竞买人截至 t 时的最高出价；若尚未出价则为 0），h_t 是竞买人在 t 时是否持有最高价的指示变量。

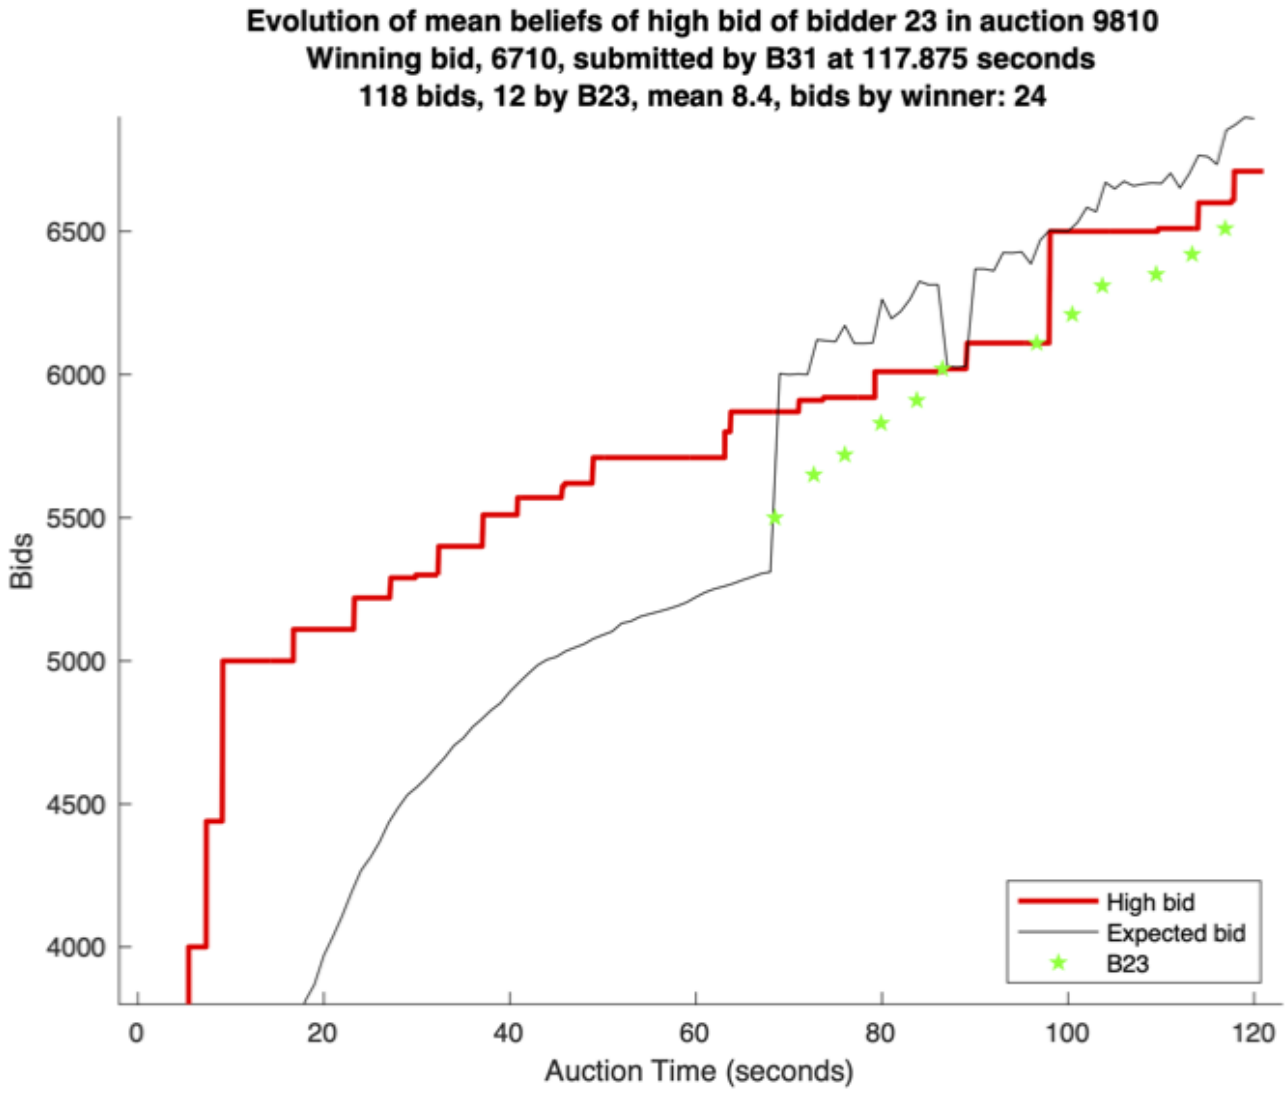
2005 款现代 Avante（Elantra）XD 1.6L



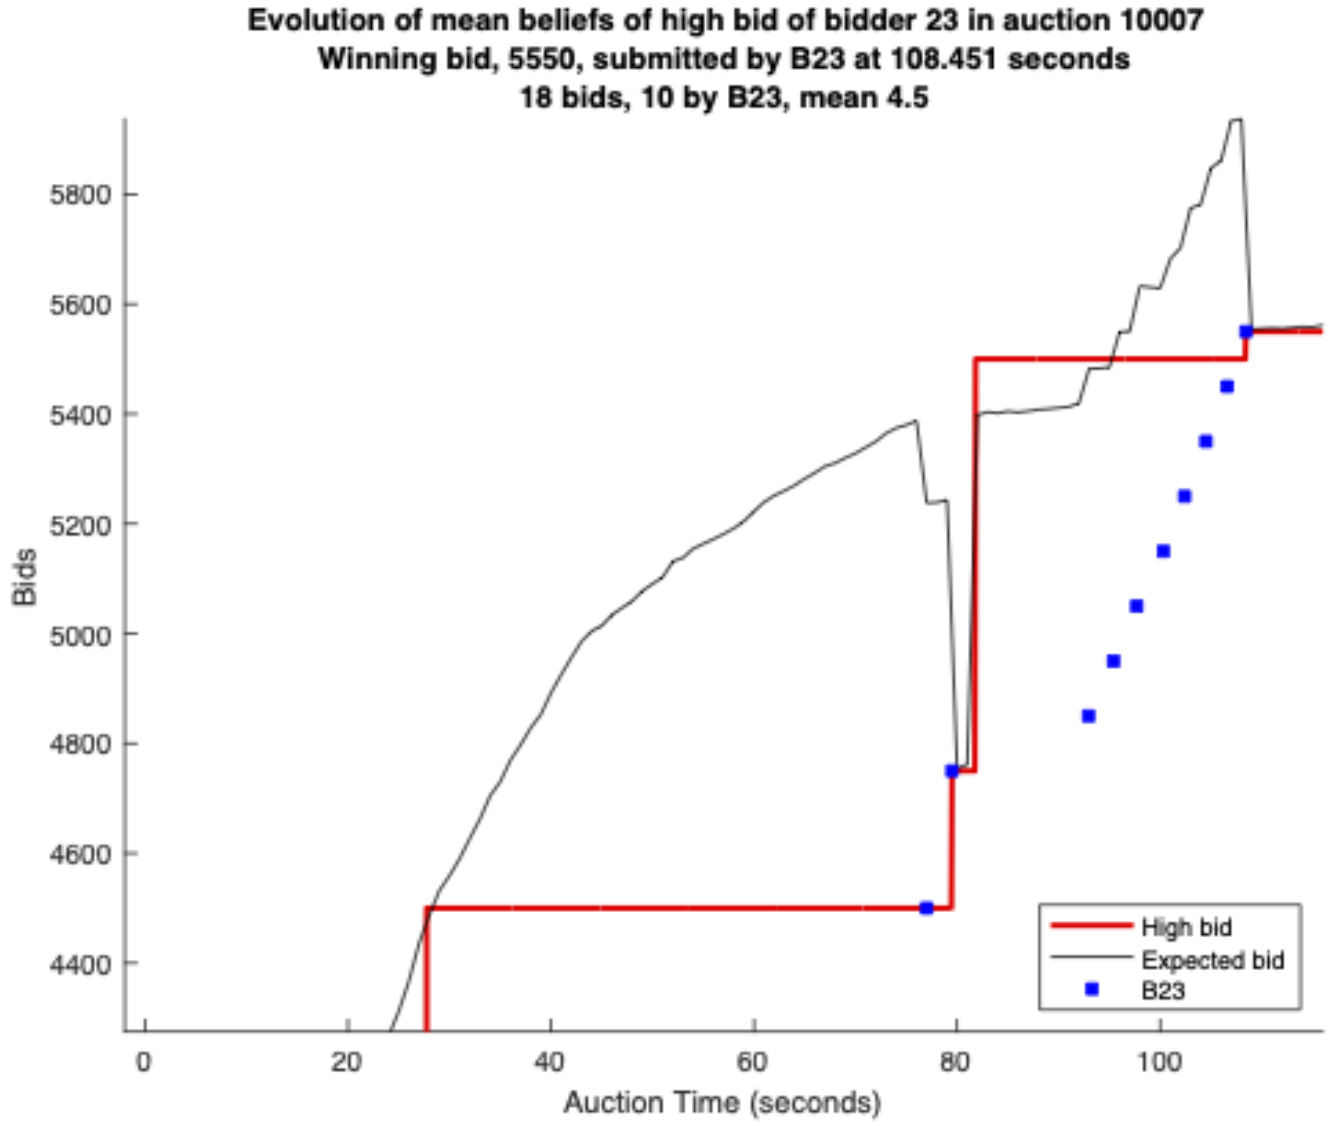
对拍卖最高价的无条件信念



拍卖 9810 中 B23 信念的演变



拍卖 10007 中 B23 信念的演变



两步估计策略

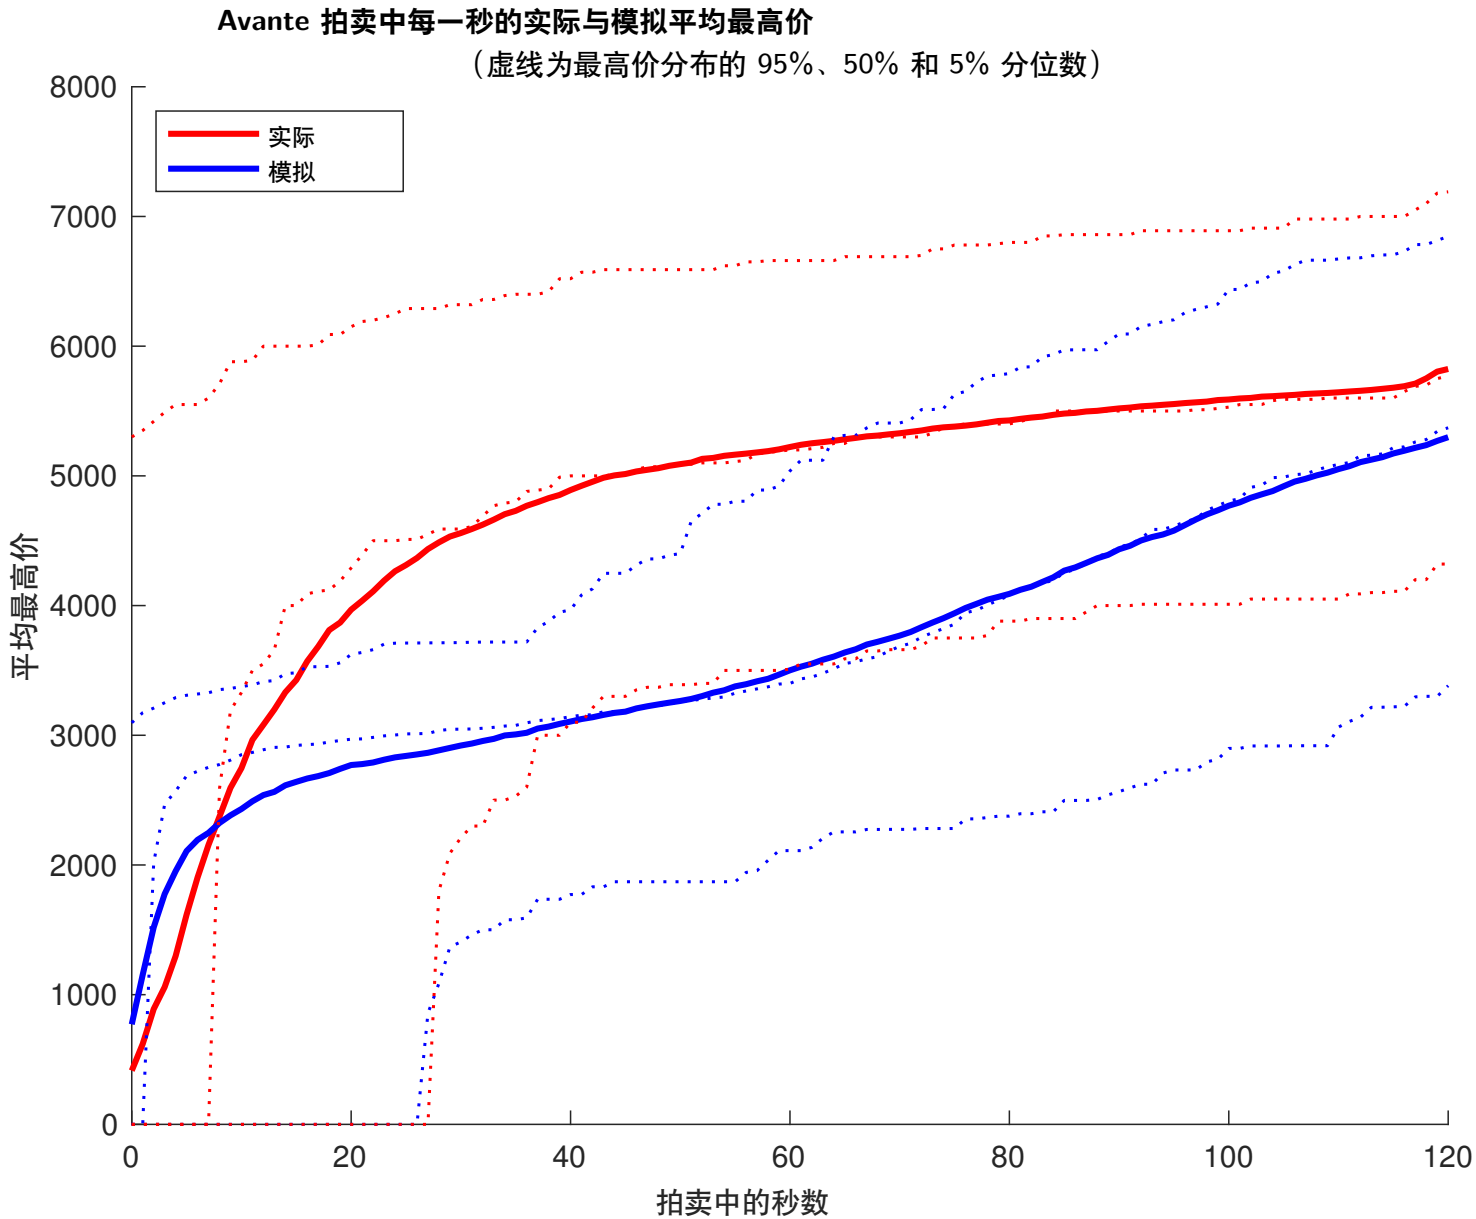
- 第 1 步：利用 533 场 Avante 汽车拍卖的数据，估计关于拍卖中最高价随机过程的信念族 $\{\lambda_t\}$。

- 第 2 步：利用 $\{\hat{\lambda}_t\}$ 求解一个离散动态规划问题，确定竞买人在拍卖每一秒的最优出价，得到一族出价函数 $\{\beta_t\}$，其中 $\beta_t(b_t, h_t)$ 是在拍卖第 t 秒开始时、竞买人迄今最高出价为 b_t 时的最优出价，h_t 是竞买人是否持有最高价的指示变量。

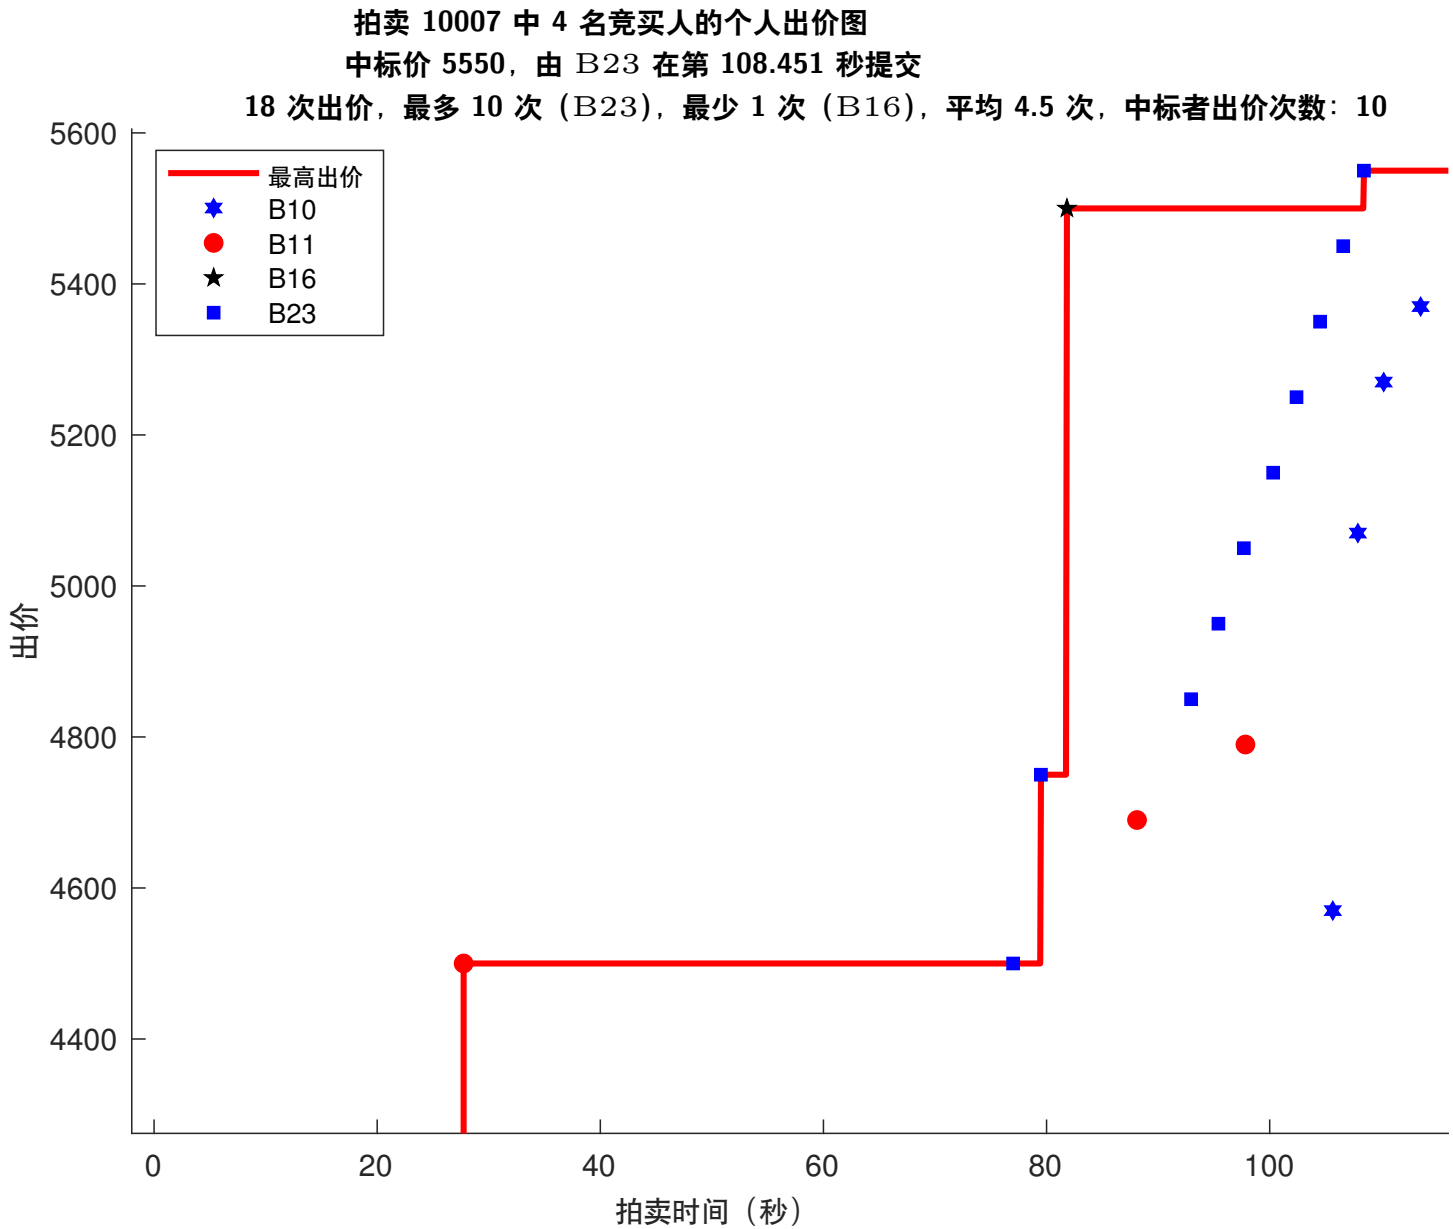
- 注意第 2 步中唯一的未知参数是 $\tau = (v, c, p, \sigma)$。因此我们为每场拍卖中的每个竞买人构造似然 $L(\tau)$，得到逐场拍卖、逐个竞买人的估值 v 以及刻画竞买人类型的其他参数 τ 的估计。

- 我们的目标是看这样的模型能否解释我们在这些拍卖中观察到的提前出价。

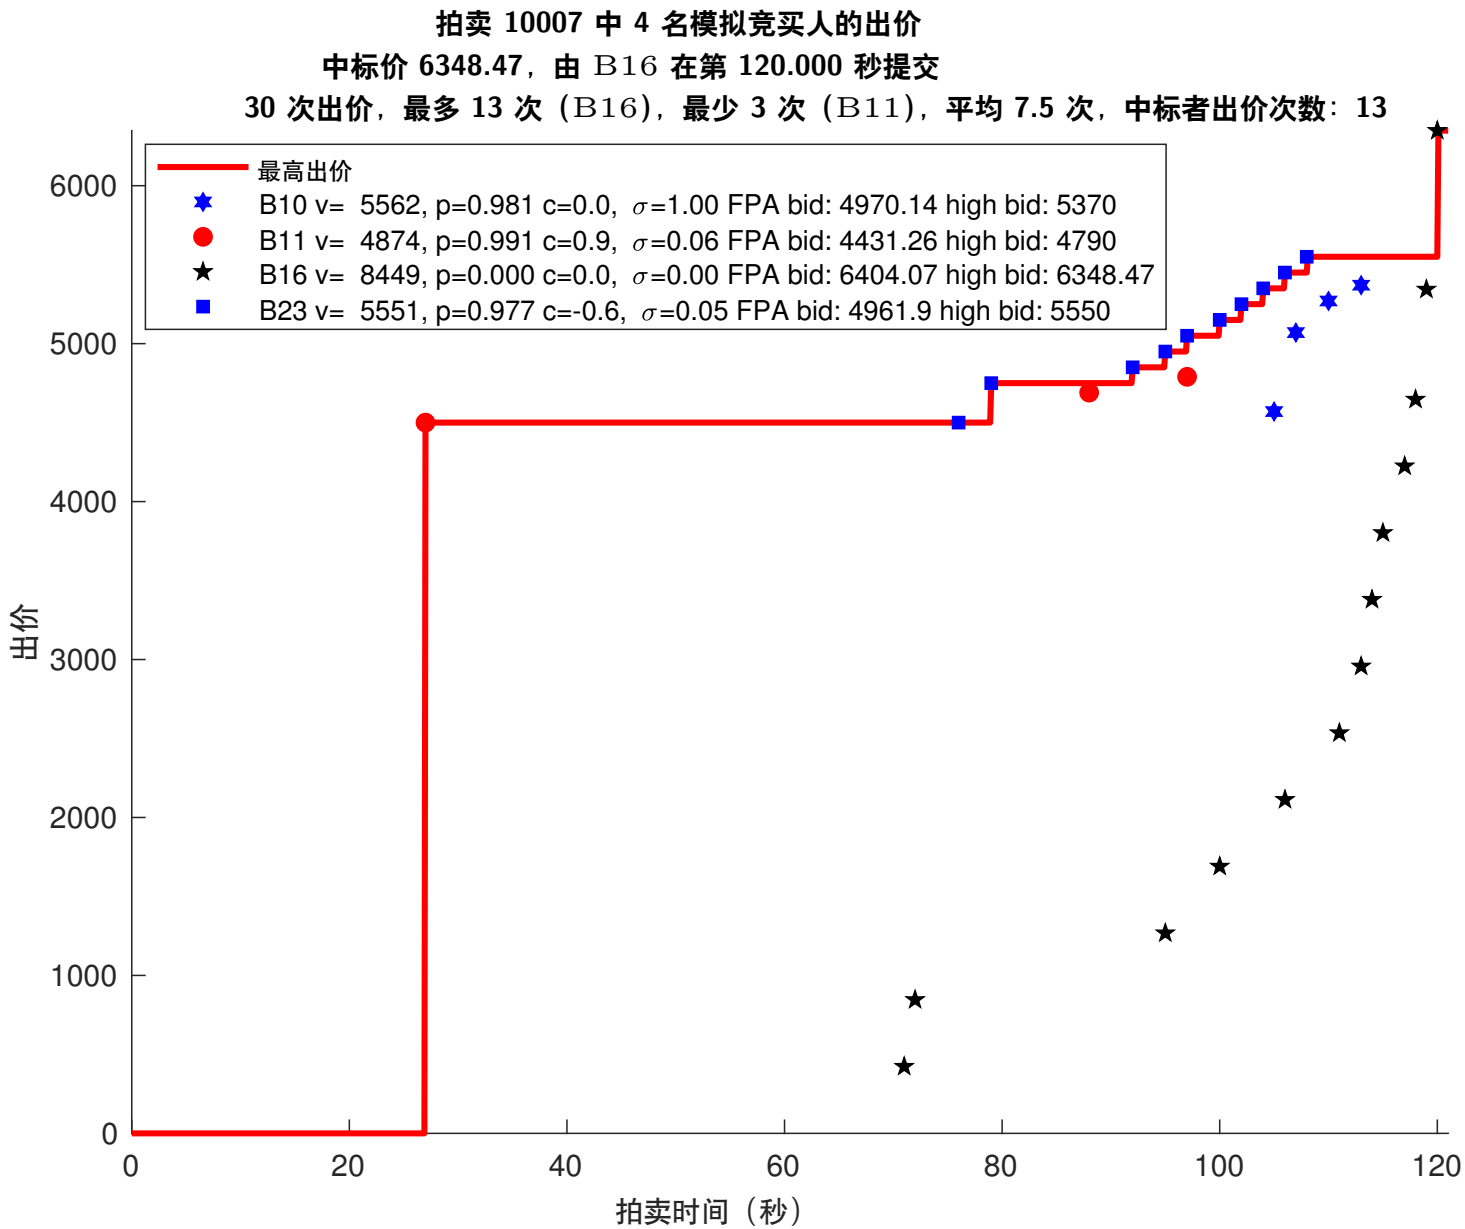
实际与模拟的最高价轨迹



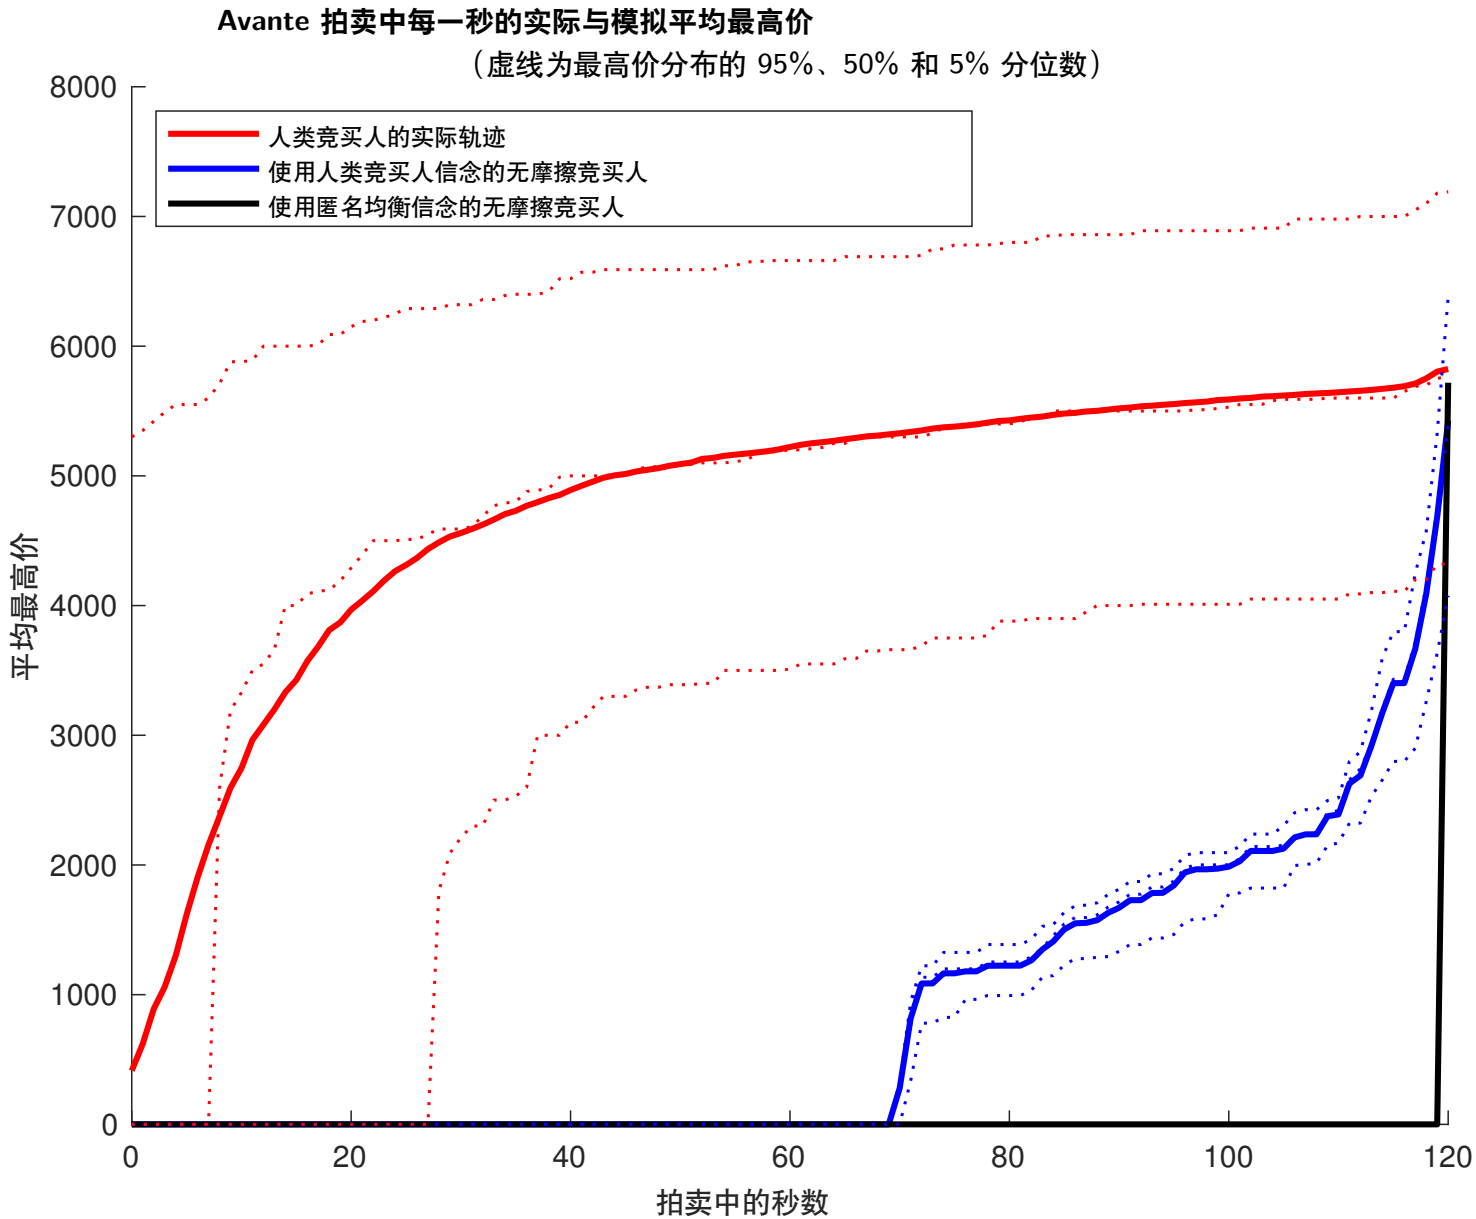
拍卖 10007 中 B16 的实际出价



拍卖 10007 中算法化的 B16 的反事实出价



信念向匿名均衡的收敛


Avante 拍卖中每一秒的实际与模拟平均最高价
（虚线为最高价分布的 95%、50% 和 5% 分位数）
人类竞买人的实际轨迹
使用人类竞买人信念的无摩擦竞买人
使用匿名均衡信念的无摩擦竞买人
平均最高价
拍卖中的秒数
0
1000
2000
3000
4000
5000
6000
7000
8000
0
20
40
60
80
100
120

有限理性下的实证拍卖设计

- 租车公司改用第二价格拍卖能否做得更好？
- 由定理 1 的推论，答案是否定的：第二价格拍卖的期望收入低于第一价格密封拍卖 AE 下的期望收入。竞买人在 AE 中压低出价的幅度小于在 BNE 中的幅度。
- 在 AE 中，竞买人不知道对手的分布，因此无法调整获胜概率，使其只考虑对手的影响，而不考虑自己对中标价分布的影响。
- 如果典型拍卖中的平均竞买人数量足够大，未作这一调整的影响是二阶的。

表：不同情景与拍卖机制下的期望中标价

	Mean valuations	Mean profits	Mean winning bid	Efficiency
实际	6843 (64)	659 (45)	5824 (38)	85.0%
第一价格	7888 (93)	1283 (41)	6604 (55)	100.0%
第二价格	7888 (93)	1355 (53)	6532 (72)	100.0%

谁更像贝叶斯者：人类还是 ChatGPT？

Tianshi Mu, Pranjal Rawat
John Rust、Chengjun Zhang 与 Qixuan Zhong
乔治城大学

2025 年 7 月 6 日

人是贝叶斯者吗？

- 未经训练的人是否像直觉统计学家那样行事，在不确定性下做决策时就好像懂得统计决策理论和贝叶斯法则一样？
- 这个问题至少在过去 60 年里一直备受争论，并催生了数十项实验室实验。
- 一句话的答案：视情况而定

Daniel Kahneman, 1934—2024

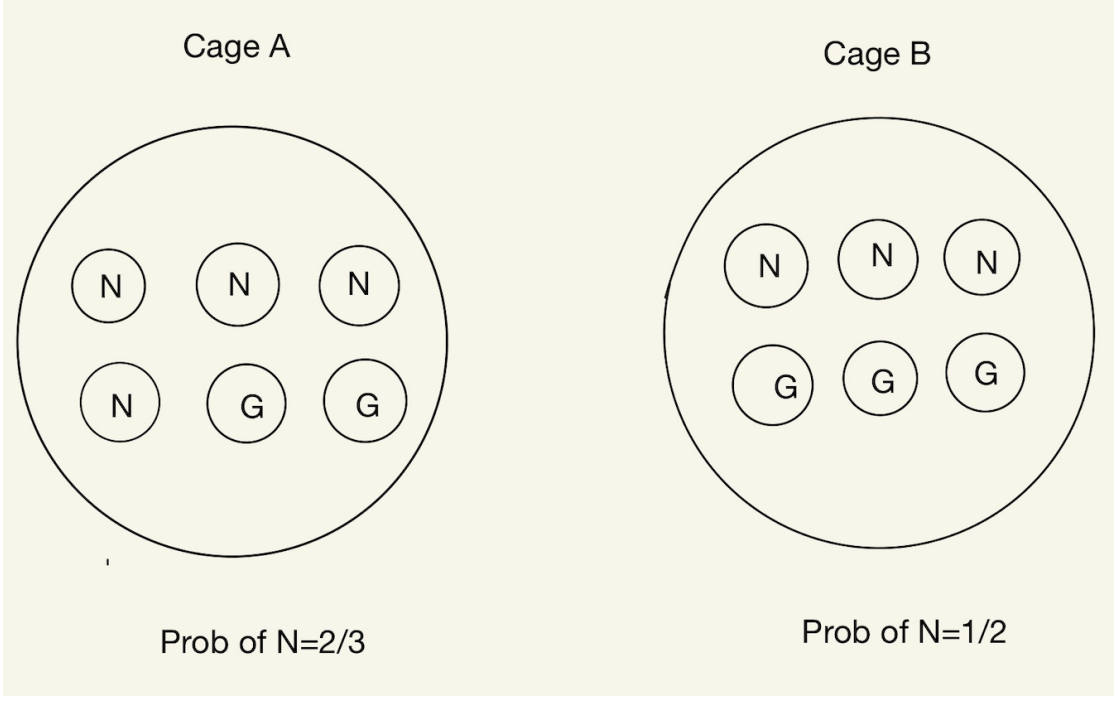


David Grether, 1938—2021



人是贝叶斯者吗？

- El-Gamal 与 Grether 1995 年发表于 Journal of the American Statistical Association 的经典论文的标题
- 实验共有 257 名被试，来自 4 所学校：UCLA、帕萨迪纳城市学院、西方学院和加州州立大学洛杉矶分校
- 向被试展示从两个笼子 A 或 B 之一中随机（有放回）抽出的 6 个球的样本，让他们预测样本来自哪个笼子。



人们为什么应当使用贝叶斯法则？

- 因为我们是贪婪的
- 理性的人应当使用选择 A 或 B 的最优决策规则，即使其选择的期望收益最大化的规则。
- 在数学上，它可以表示为一个函数 $\delta(d, \pi) \to \{A, B\}$，使选中样本实际来源笼子的概率最大化。

- 最优决策规则可以用贝叶斯法则表示，其中 $\Pi(A|d, \pi)$ 是给定 (d, π) 时 A 的后验概率。

定理 最优决策规则为

$$\delta(d, \pi) = \begin{cases} A & \text{若} \Pi(A|d, \pi) \geq 1/2 \\ B & \text{其他情形} \end{cases}$$

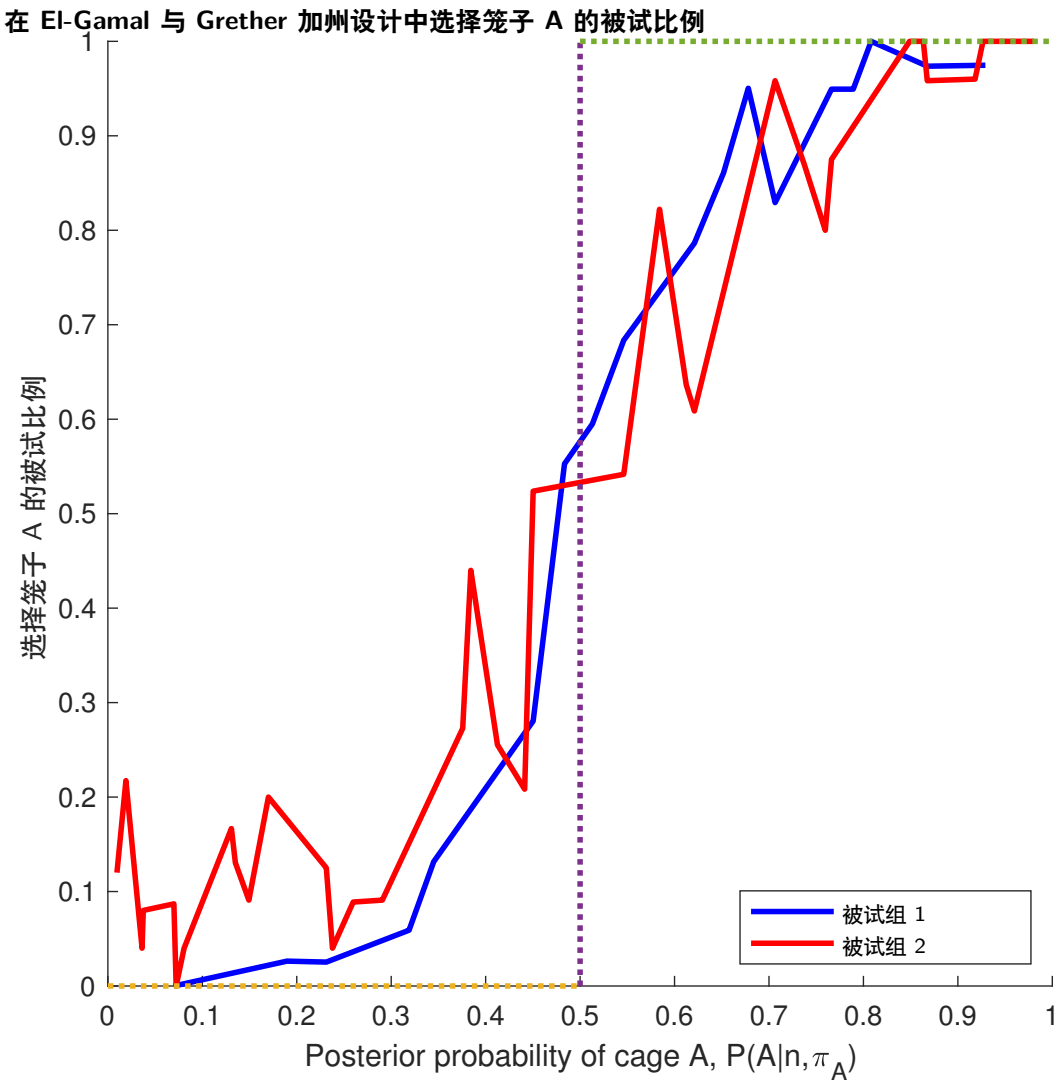
- 然而我们将说明：即使你的信念方式不像贝叶斯者，你的行为也可以像贝叶斯者一样

ChatGPT 是贝叶斯者吗？

- 我们复现了 El-Gamal 与 Grether 的实验（被试来自加州，以及 1999 年在威斯康星大学进行的后续实验），这些实验只涉及二元选择（哪个宾果笼的可能性更大）；还复现了 Holt 与 Smith（2009）的实验，后者使用 Becker-DeGroot-Marschak（BDM）机制诱导被试对每个宾果笼的主观后验概率。但我们使用的不是人类被试，而是不同版本的 ChatGPT。

- 我们研究的版本为
  1. ChatGPT 3.5（2022 年 11 月推出），
  2. ChatGPT 4（2023 年 3 月推出），
  3. ChatGPT 4o（2024 年 5 月推出）。
- 我们完全复现了 El-Gamal 与 Grether 以及 Holt 与 Smith 所用的被试人数和试验次数，作为精确匹配的对照组

哪些是人类，哪个是 ChatGPT？



谁更像贝叶斯者：人类还是 ChatGPT？

表：GPT 与人类在 6 球实验中的表现

模型编号	GPT 3.5	GPT-4	GPT-4o	智人
发布日期	11/2022	3/2023	5/2024	公元前 30 万年
权重数	175 billion	1.8 trillion	3 trillion?	100 trillion?
效率	84.9 (0.6%)	96.0 (0.3%)	97.5 (0.2%)	96.5 (0.5%)
准确率	59.4 (8.4%)	77.7 (7.4%)	85.5 (6.3%)	81.9 (9.1%)
类型数	2	1	1	3

为什么要关心 ChatGPT 是否比人类更像贝叶斯者？

- 因为 GPT 能力与推理能力的快速提升，正开始威胁人类的生计。机器——它们将取代我们!
- 宾果笼的例子是一个简单的隐喻或原型，代表更复杂、更重要的高风险决策问题，在这些问题上 GPT 也可能胜过人类。
- 例如，考虑医学上的鉴别诊断（DDx）：当多种不同的疾病或状况都可能导致患者身上观察到的一组症状时，所采用的诊断程序就叫鉴别诊断。
- 好的 DDx 是指医生确定与观察到的症状相一致的、最可能的疾病或医学问题
- 近期研究（例如 Goh 等（2024）和 McDuff 等（2023））表明，LLM 和 GPT 在鉴别诊断的质量和准确性上可以胜过人类医生。

logit 模型：最简单的神经网络

- 一个自然的、但属于简约形式的被试选择模型是二元 logit 模型，它是含 3 个参数的模型，被试选择笼子 A 的概率为

$$P(A|d,\pi) = \frac{1}{1+\exp\{\beta_0 + \beta_1 d + \beta_2 \pi\}}. \tag{1}$$

- logit 模型可以看作近似“选择笼子 A 的概率”的灵活函数形式。但它没有作为结构模型或人们如何学习的理论的直接解释。不过，它是单层前馈神经网络最简单的例子：2 个输入、1 个输出，以及 softmax 或 logistic 压缩函数。

- logit/NN 模型对数据的拟合显著优于 EG（单类型）模型：EG 模型（4 个参数）的对数似然为 -1942.63，而 logit/NN 模型的对数似然为 -1811.31。用 EC 拟合的 2 类型 EG 模型（7 个参数）拟合得更好：对数似然为 -1699.39。用 EC 拟合的 2 类型 logit/NN 模型（6 个参数）也拟合得更好，这从预测概率与非参数 CCP 的比较中可以明显看出。

决策规则的变化：威斯康星实验

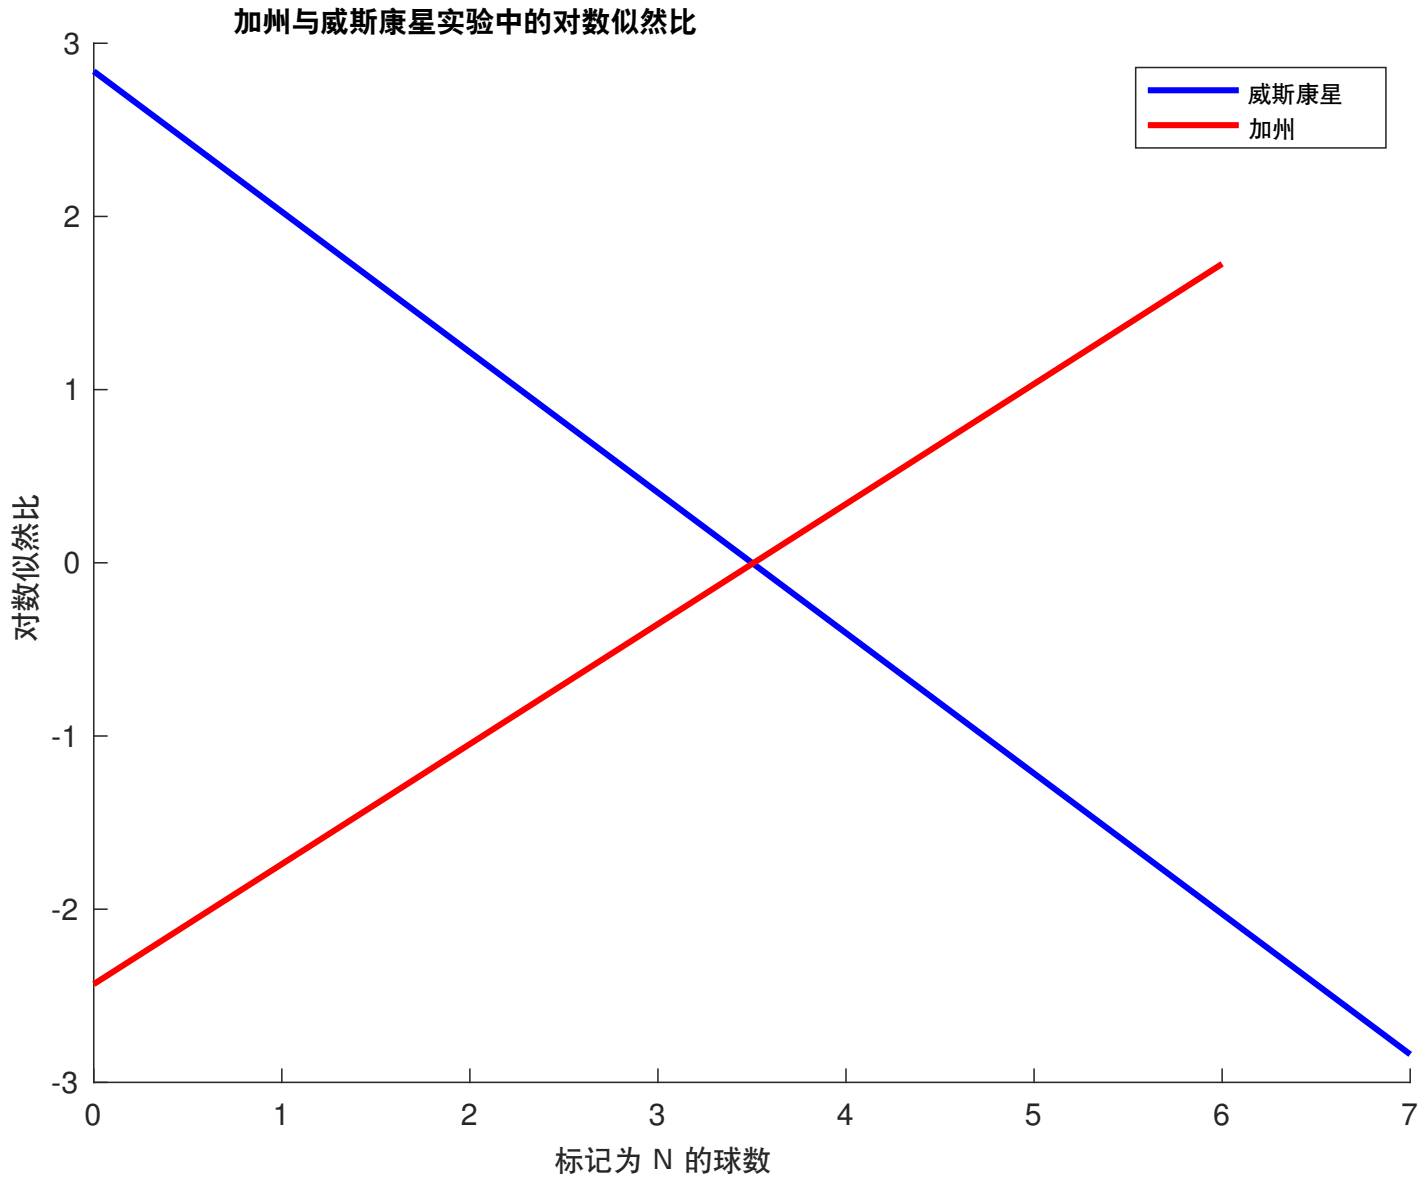
- 1999 年，El-Gamal 与 Grether 在威斯康星大学进行了关于学习与决策的进一步实验，共有 81 名被试。

- 被试在连续两天里参加两种不同的实验设计：

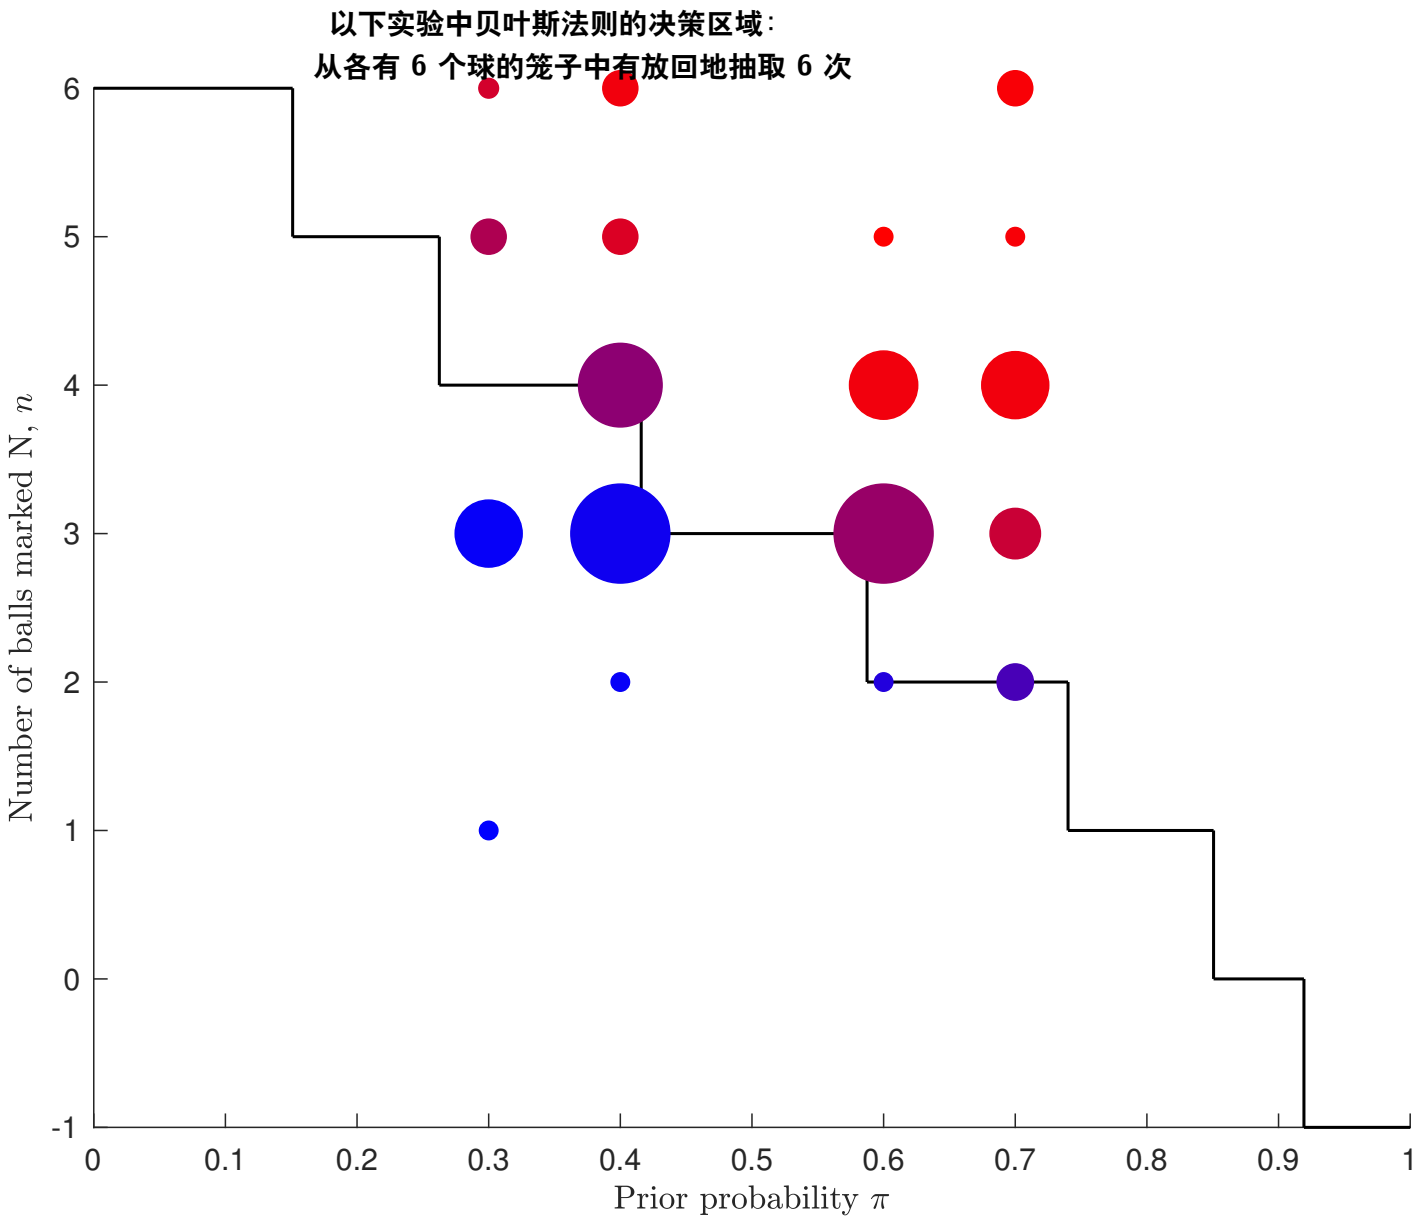
- 加州设计：从笼子 A（4 个 N 球和 2 个 G 球）或笼子 B（3 个 N 球和 3 个 G 球）中有放回地抽取 6 个球
- 威斯康星设计：从笼子 A（4 个 N 球和 6 个 G 球）或笼子 B（6 个 N 球和 4 个 G 球）中有放回地抽取 7 个球
- 笼子 A 根据掷一个 10 面骰子的结果选出，π 从 4 个值 $\pi \in \{.3, .4, .6, .7\}$ 中选取。
- 在加州设计下 $p_A = .6667$、$p_B = .5$，而在威斯康星设计下 $p_A = .4$、$p_B = .6$。

- 这使似然比反转：观察到较大的 d 时，在加州设计下笼子 A 更有可能，而在威斯康星设计下则更不可能。

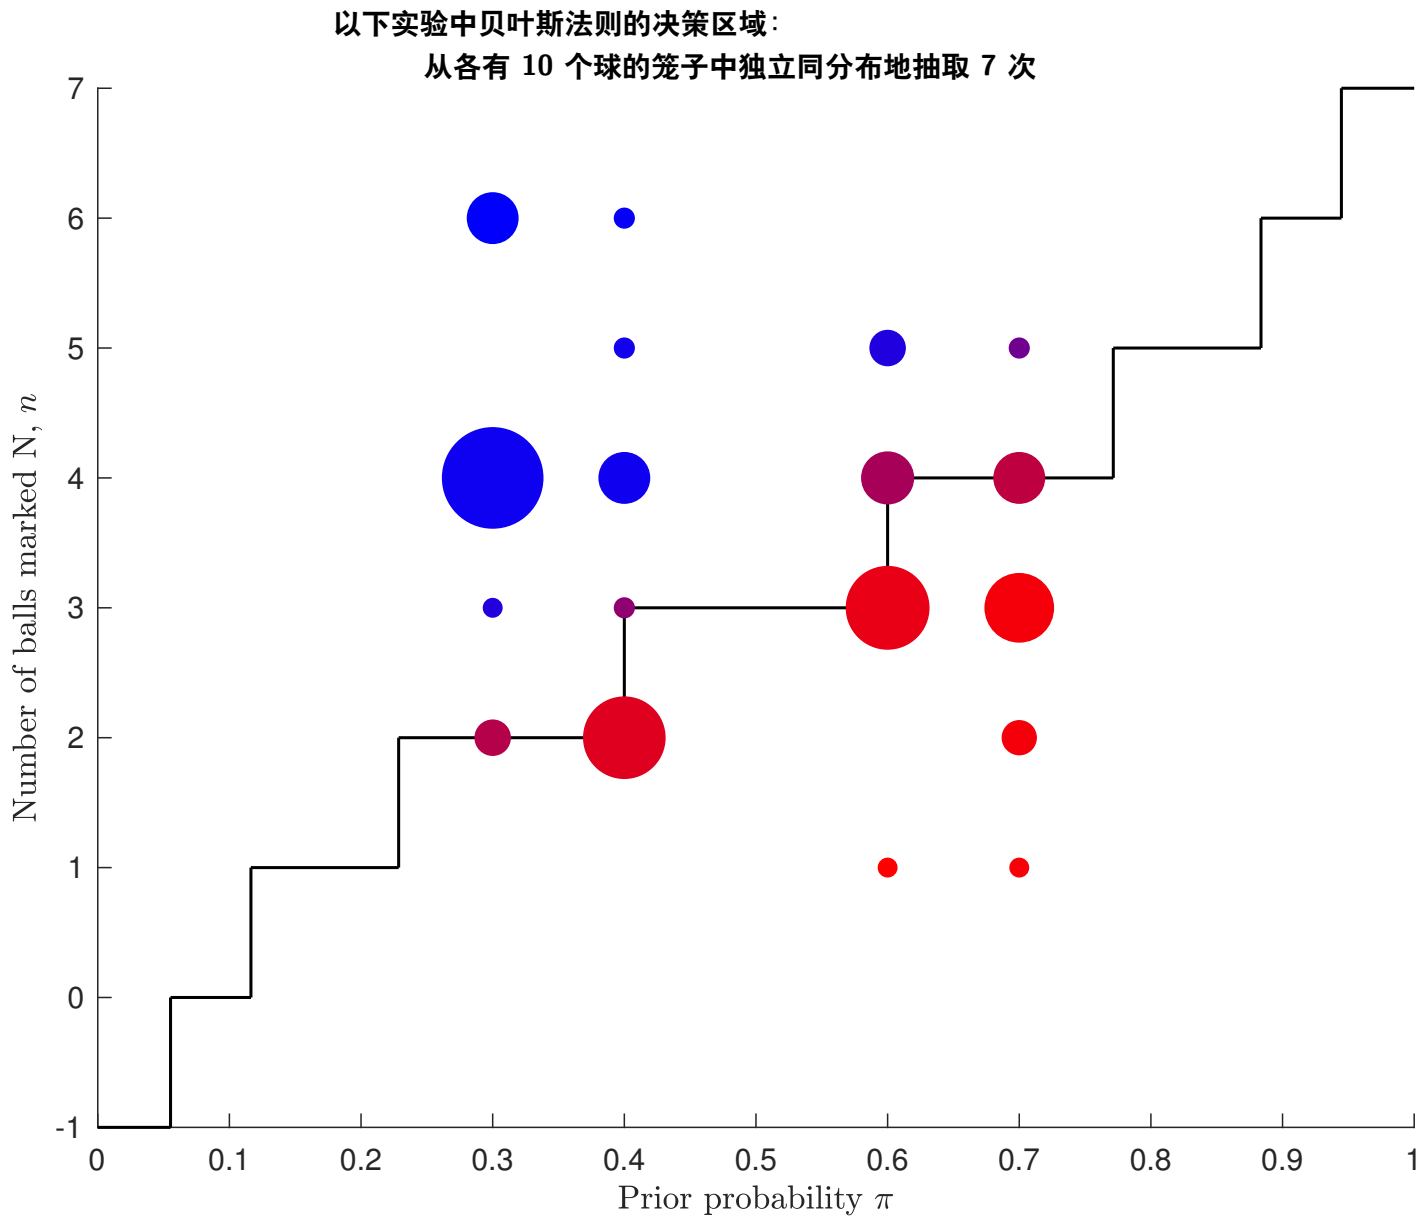
威斯康星实验中的似然比



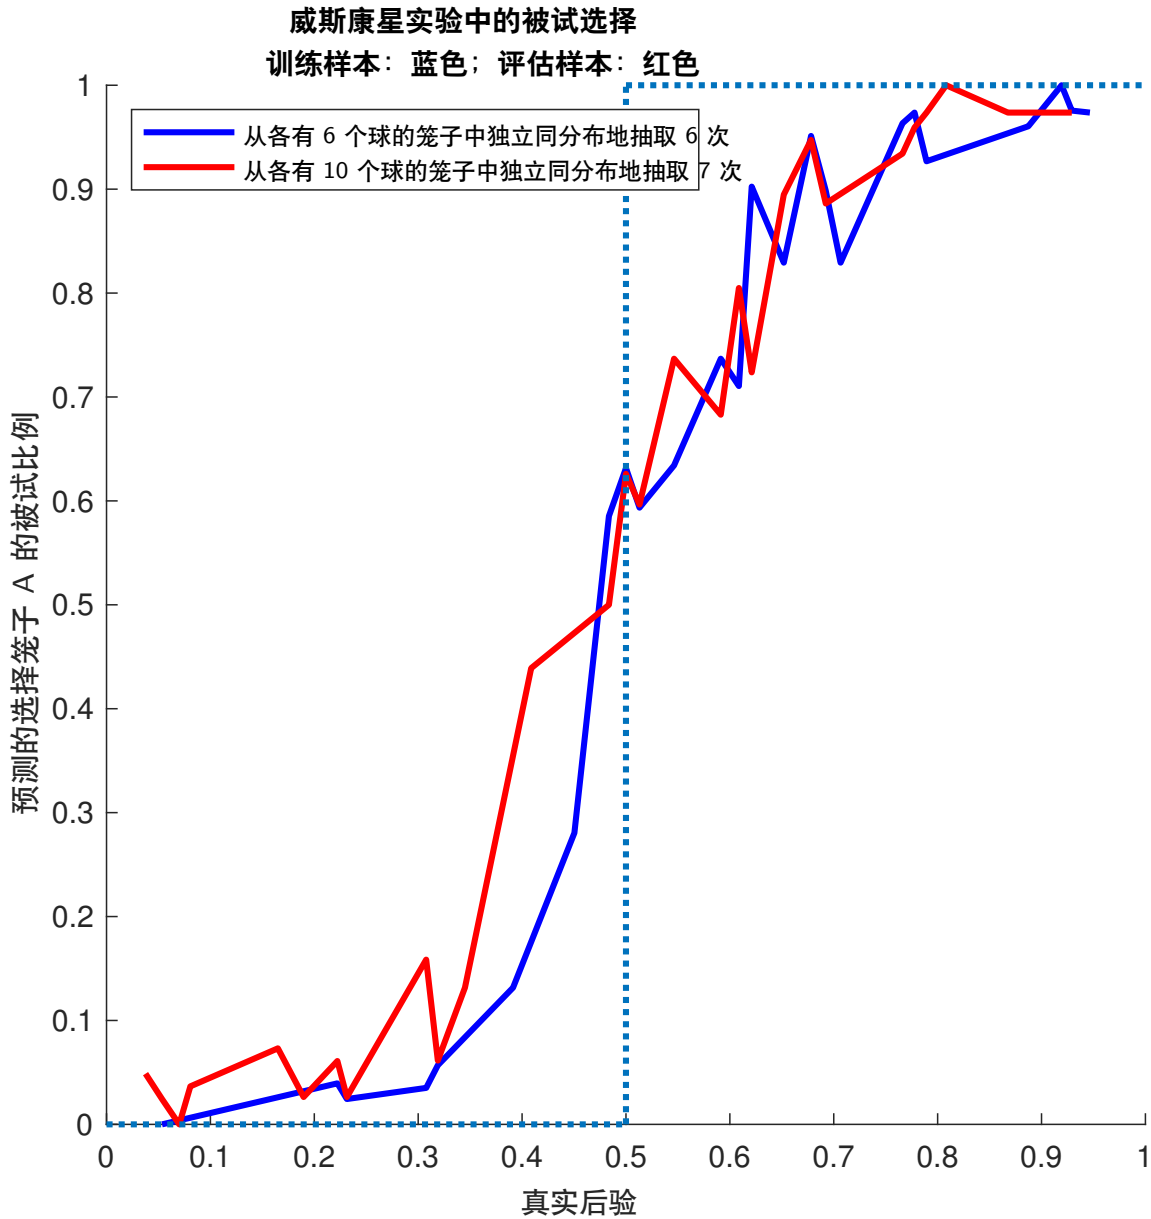
加州设计下的被试选择 $(D = 6)$



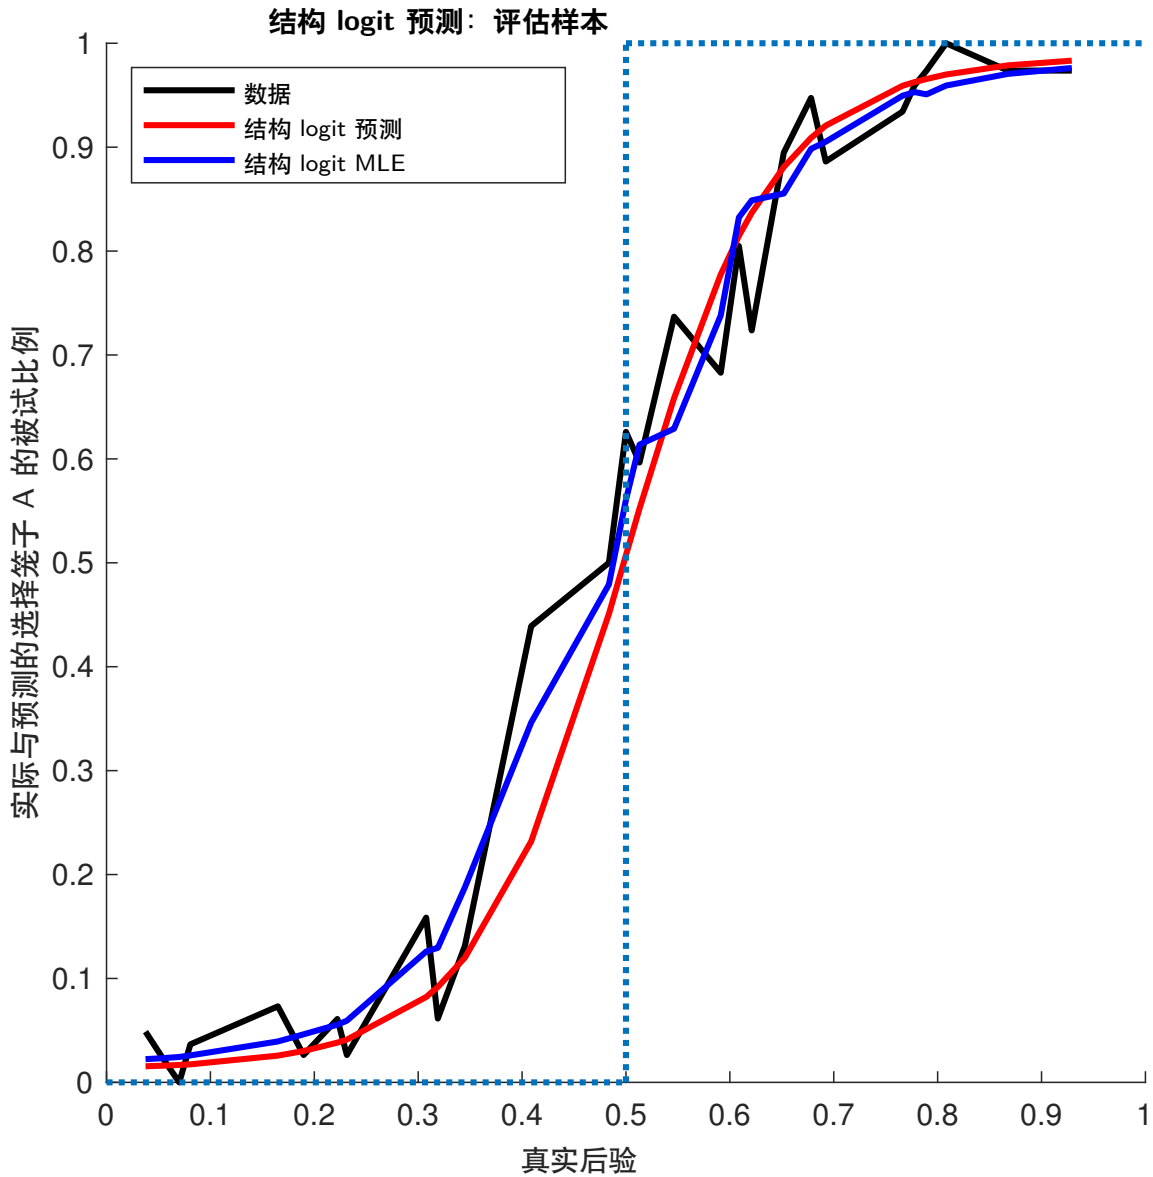
威斯康星设计下的被试选择 $(D = 7)$



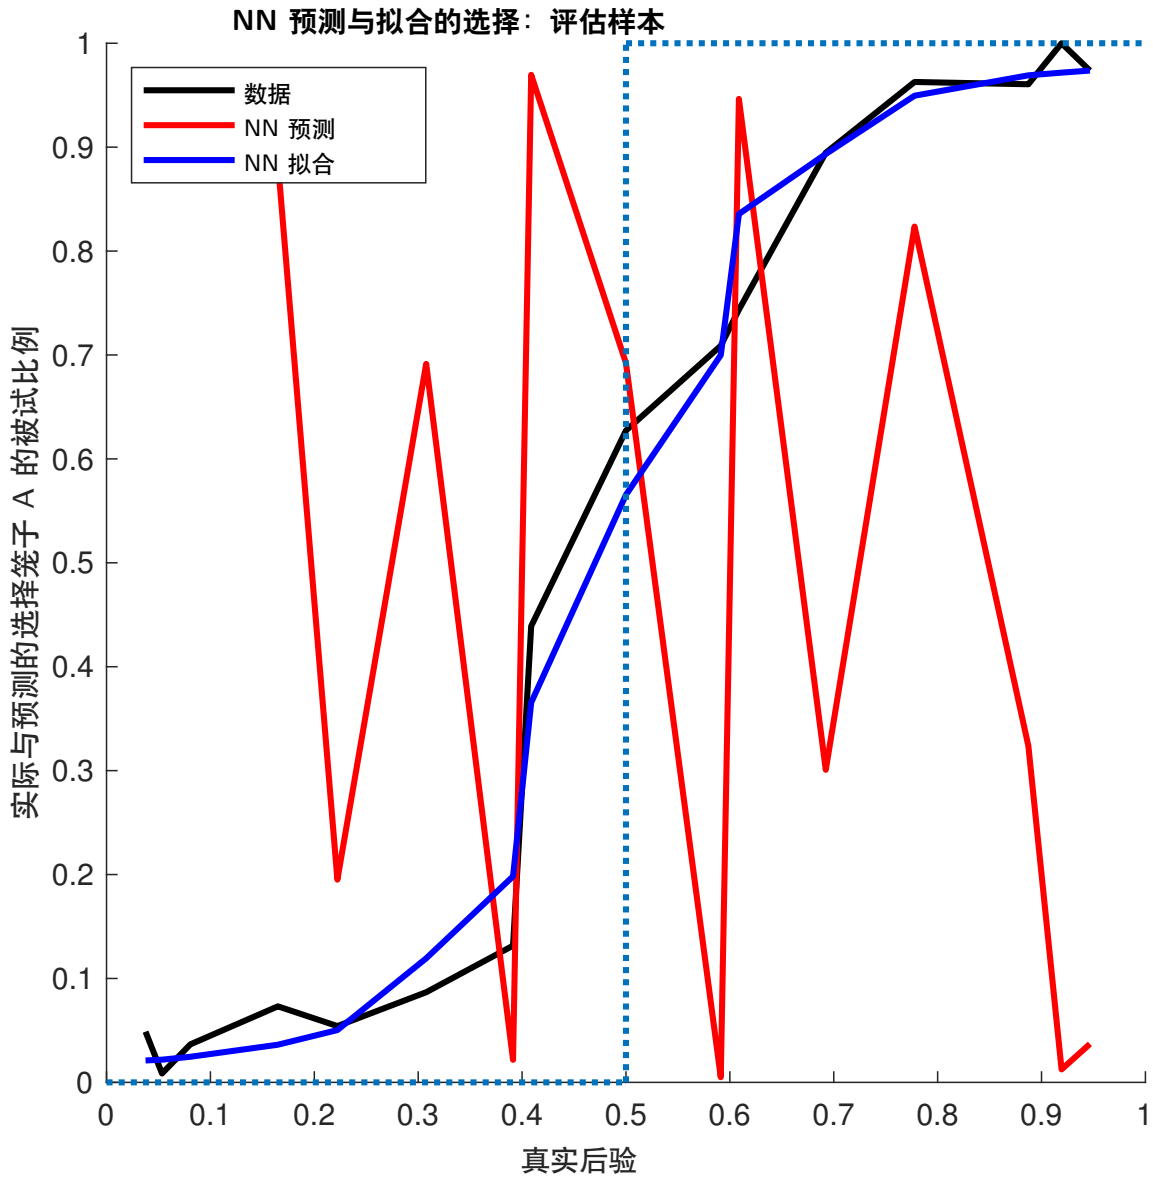
威斯康星实验中的被试选择



结构 logit 预测出了决策规则的变化



但简约形式的神经网络设定做不到



为什么 logit 模型表现如此之差？

- 因为被试关注的不只是 (d, π)，而简约形式的 logit/神经网络模型只以 (d, π) 为输入。
- 威斯康星实验令人信服地表明，人类被试关注 5 条信息

  (d, π, p_A, p_B, D)
- 在加州设计中，$D = 6$，$p_A = 2/3$，$p_B = 1/2$。
- 在威斯康星设计中，$D = 7$，$p_A = .4$，$p_B = .6$。
- 一个不使用全部 5 条信息的神经网络，无法在 D, p_A, p_B 发生变化的新实验设计（政策变化）中近似人类行为！

被试选择的结构 logit 模型

- 我们假定被试的信念及其选择是变换后输入 $(\mathrm{LLR}, \mathrm{LPR})$ 的函数，其中 LLR 是对数似然比，LPR 是对数先验比：

$$\begin{aligned} \mathsf{LLR} &= f(d|p_A, D)/f(d|p_B, D) \\ \mathsf{LPR} &= \pi/(1-\pi) \end{aligned}$$

- 注意，$(\mathrm{LLR}, \mathrm{LPR})$ 是全部 5 条信息的充分统计量，这 5 条信息是对抽样来源笼子作出知情预测所需的。

- 我们允许被试在由 5 个输入 (d, π, p_A, p_B, D) 计算 $(\mathrm{LLR}, \mathrm{LPR})$ 时出现计算误差。
- 我们假设被试的主观后验概率取决于随机计算误差 ν，形式为

$$\Pi_s(A|d, \pi, p_A, p_B, D, \nu) = \frac{\exp\{\beta_0 + \beta_1 \mathsf{LLR} + \beta_2 \mathsf{LPR} + \nu\}}{1 + \exp\{\beta_0 + \beta_1 \mathsf{LLR} + \beta_2 \mathsf{LPR} + \nu\}}.$$

- 注意，当 $(\beta_0, \beta_1, \beta_2) = (0, 1, 1)$ 且 $\nu = 0$ 的概率为 1 时，正确的贝叶斯后验嵌套于该设定之中。

被试选择的结构 logit 模型

- 给定主观后验信念，选择 A 还是 B 取决于哪一个给被试带来更高的期望收益。设正确选择的收益为 R，同时假设存在影响最终选择的额外个体性选择干扰 $(\epsilon(A), \epsilon(B))$。则决策规则为

$$\delta(I, \nu, \epsilon) = \begin{cases} A & \text{若} R\Pi_s(A|I,\nu) + \epsilon(A) \geq R\Pi_s(A|I,\nu) + \epsilon(B) \\ B & \text{其他情形} \end{cases}$$

  其中 $I = (d, \pi, p_A, p_B, D)$ 是每次试验中观察到的公共信息，(ν, ϵ) 是只有被试自己观察到的私人信息。

- 假设 ϵ 与 ν 相互独立，且 ϵ 服从尺度参数为 σ 的二元极值分布，得到如下 logit CCP（即决策规则）

$$P(A|d, \pi, p_A, p_B, D, \nu) = \frac{1}{1 + \exp\{[1 - 2\Pi_s(A|d, \pi, p_A, p_B, D, \nu)]\, R/\sigma\}}.$$

被试选择的结构 logit 模型

- 由于 ν 同样不可观测，需要把它从决策规则中积分掉，得到最终的 CCP（即混合决策规则）。假设 $\nu \sim N(0, \eta^2)$，则有

$$P(A|d, \pi, p_A, p_B, D) = \int_{\nu} P(A|d, \pi, p_A, p_B, D, \eta\nu)\phi(\nu)d\nu.$$

- 这是一个 5 参数模型，其中 $\theta = (\beta_0, \beta_1, \beta_2, \sigma, \eta)$ 是结构参数

- 若被试 s 在试验 t 中面对信息 (d_{ts}, π_{ts}) 时选择了笼子 A，令 $y_{ts} = 1$。则似然函数为

$$L(\theta) = \prod_{s=1}^{S}\prod_{t=1}^{T_s} P(A|d_{ts}, \pi_{ts}, p_A, p_B, D, \theta)^{y_{ts}} \times [1 - P(A|d_{ts}, \pi_{ts}, p_A, p_B, D, \theta)]^{1-y_{ts}}.$$

其中 (p_A, p_B, D) 是实验设计参数。

结构 logit 模型是一个两层神经网络

当 $\eta = 0$ 时，结构模型可以看作一个简单的两层前馈神经网络：logit 套 logit。

1. 第 1 层利用变换后的输入 $(\mathrm{LLR}, \mathrm{LPR})$ 产生主观后验 $\Pi_s(A|\mathrm{LLR}, \mathrm{LPR}, \beta)$ 作为输出，其中 β_0 是偏置项，(β_1, β_2) 是输入权重。

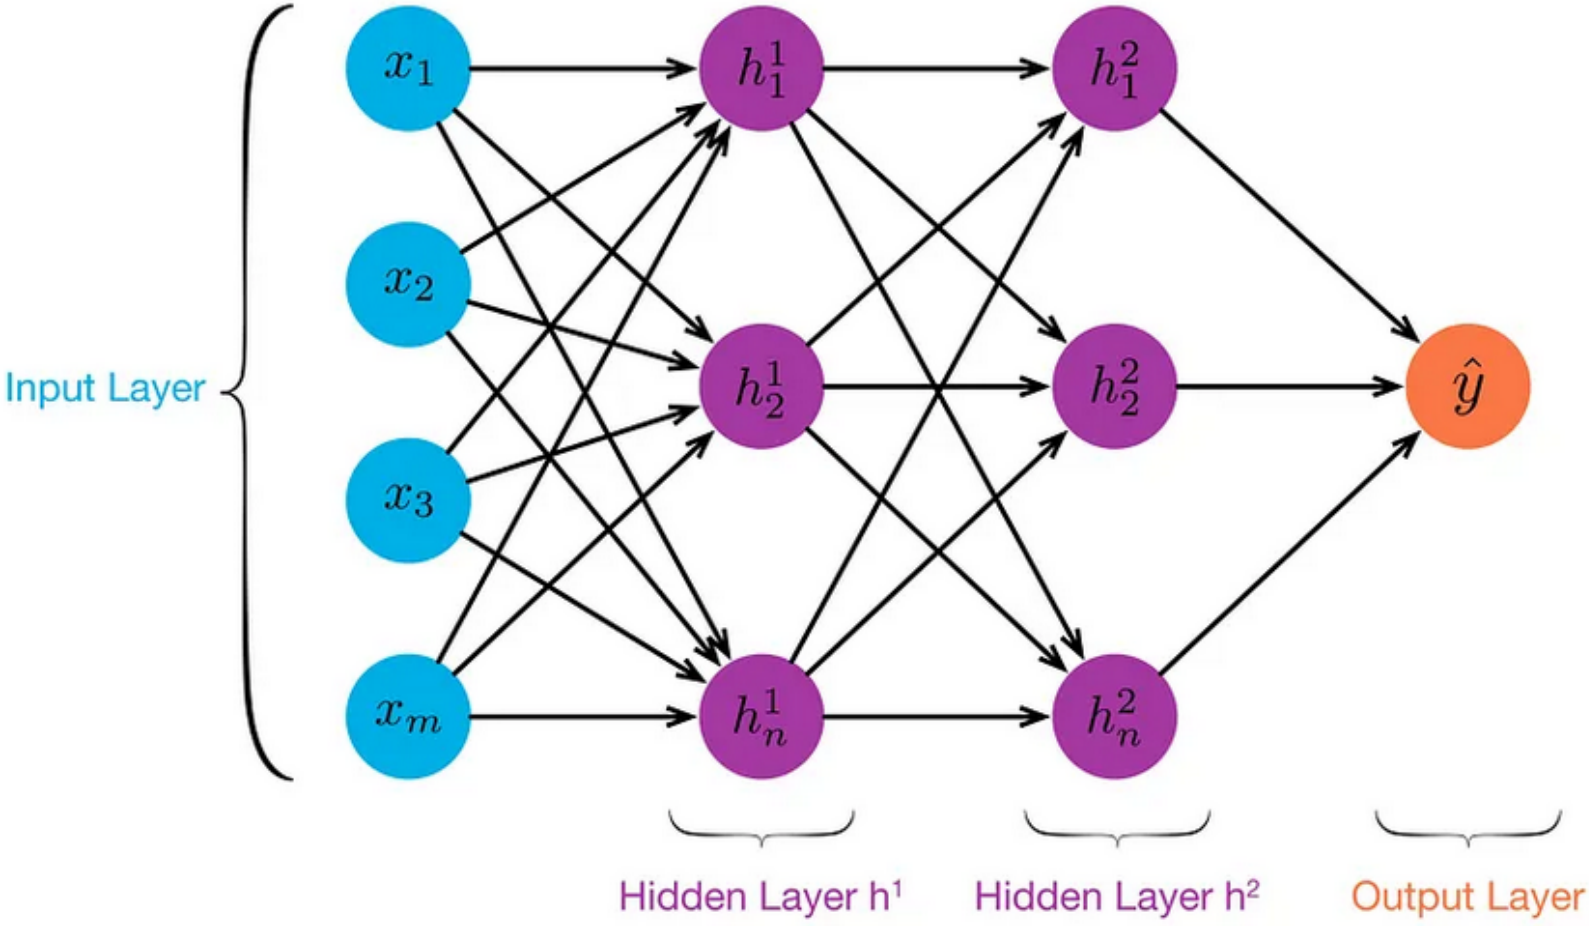
2. 第 2 层以第 1 层的输出为输入，生成 logit CCP 作为唯一输出。

$$P(A|\mathrm{LLR}, \mathrm{LPR}, \sigma, \beta) = P(A|\Pi_s(A|\mathrm{LLR}, \mathrm{LPR}, \beta), \sigma) \qquad (2)$$

其中第 2 层的偏置项为 R/σ，第 1 层输入的权重为 $2R/\sigma$。

3. 如果增加更多的层，就可以用它们从原始输入出发，近似变换后的输入 $(\mathrm{LLR}, \mathrm{LPR})$
(d, π, p_A, p_B, D).

学习贝叶斯法则的分类网络示例



主观信念的识别

- 结构 logit 模型的极大似然估计可以看作只利用被试二元选择的“显示信念”练习。这些信念是可识别的吗？

- 一般而言不可识别。例如，当 $\theta^* = (\beta_0, \beta_1, \beta_2, \sigma, \eta) = (0, 1, 1, 0, 0)$ 时，最优贝叶斯决策规则 δ^* 嵌套于结构 logit 模型中。但现在对任意 $\lambda > 0$，考虑参数为 $\theta_\lambda = (0, \lambda, \lambda, 0, 0)$ 的非贝叶斯决策者。不难证明，对任意 (d, π, p_A, p_B, D) 都有

$$\Pi(A|d, \pi, p_A, p_B, D) \leq 1/2 \iff \Pi_s(A|d, \pi, p_A, p_B, D, \theta_\lambda) \leq 1/2.$$

- 因此，不必像贝叶斯者那样相信，也能像贝叶斯者那样行动！

$\sigma > 0$ 时主观信念的识别

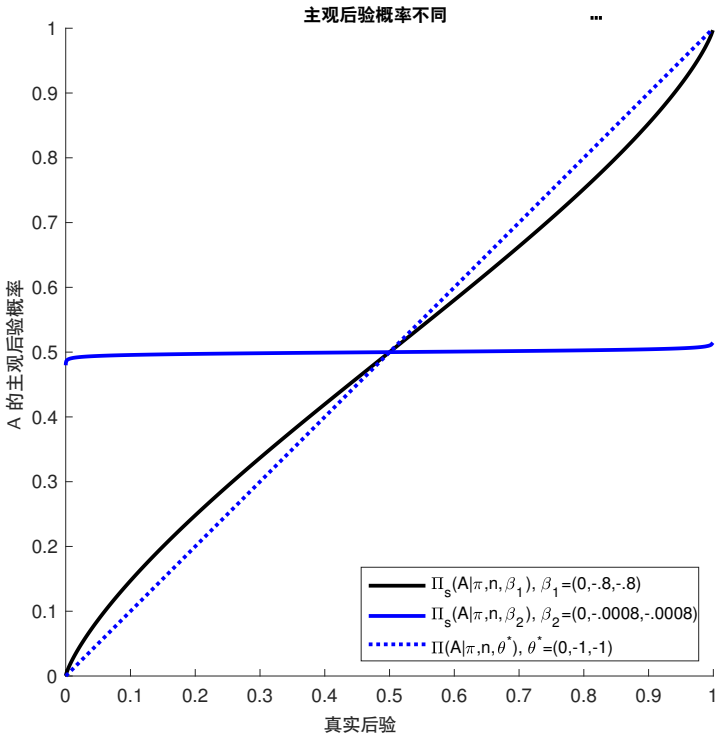
- 当 $\sigma > 0$ 时，可以利用随机的决策失误证明模型是可识别的，前提是在真实后验接近 0 或 1 的 π 极端值处有足够多的观测来识别 σ。

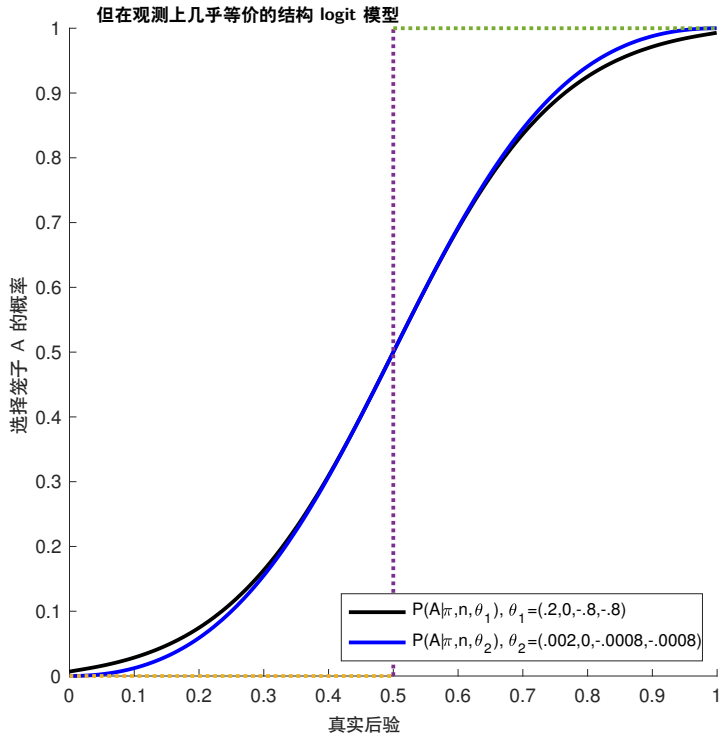
引理

$\sigma > 0$ 时被试信念的识别 假设 $\eta = 0$。当 $\sigma > 0$ 时，结构 logit 模型的全部四个参数都是可识别的，因此，只要知道被试的决策规则 $P(A|d, \pi, p_A, p_B, D)$，就能识别其主观信念；而只要有关于被试在不同 (d, π, p_A, p_B, D) 取值下选择的足够实验数据，该决策规则本身是可识别的。

- 但这一结果在实践中并不现实，因为无法对同一个被试做那么多的实验。

信念弱识别的例子

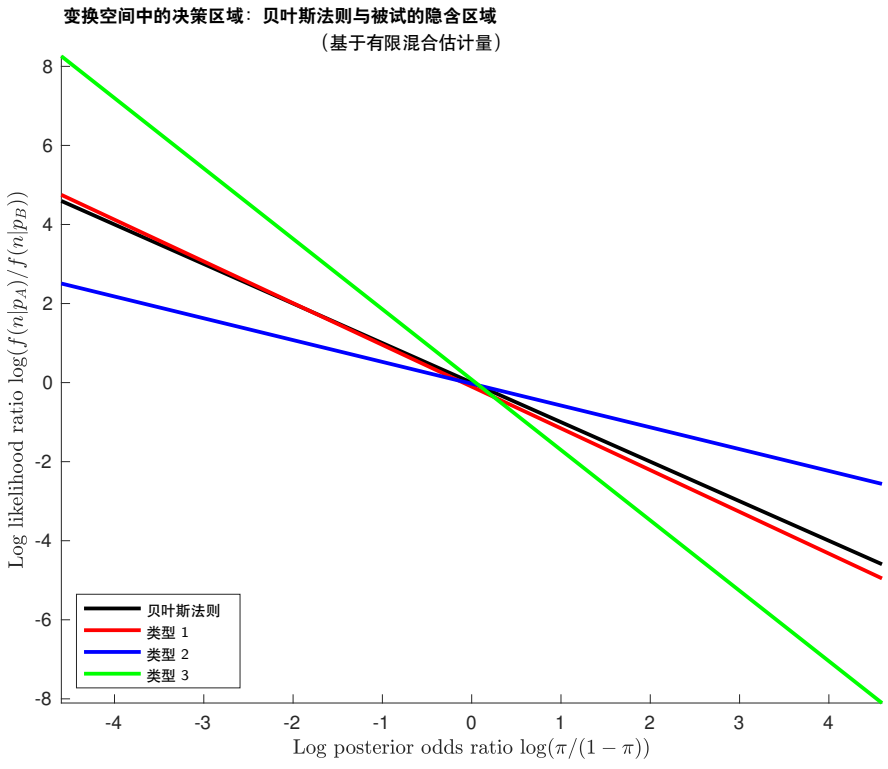

主观后验概率不同
A 的主观后验概率
真实后验
$\Pi_s(A|\pi,n,\beta_1)$, β_1=(0,-.8,-.8)
$\Pi_s(A|\pi,n,\beta_2)$, β_2=(0,-.0008,-.0008)
$\Pi(A|\pi,n,\theta^*)$, θ^*=(0,-1,-1)

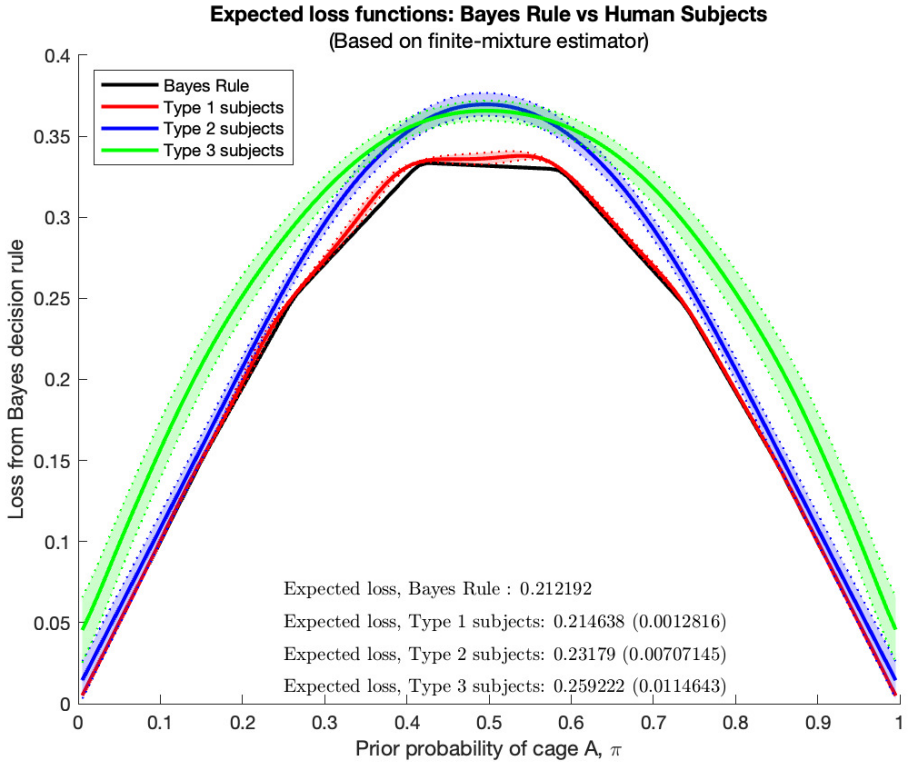

但在观测上几乎等价的结构 logit 模型
选择笼子 A 的概率
真实后验
P(A|π,n,θ_1), θ_1=(.2,0,-.8,-.8)
P(A|π,n,θ_2), θ_2=(.002,0,-.0008,-.0008)

对加州数据的重新分析结果

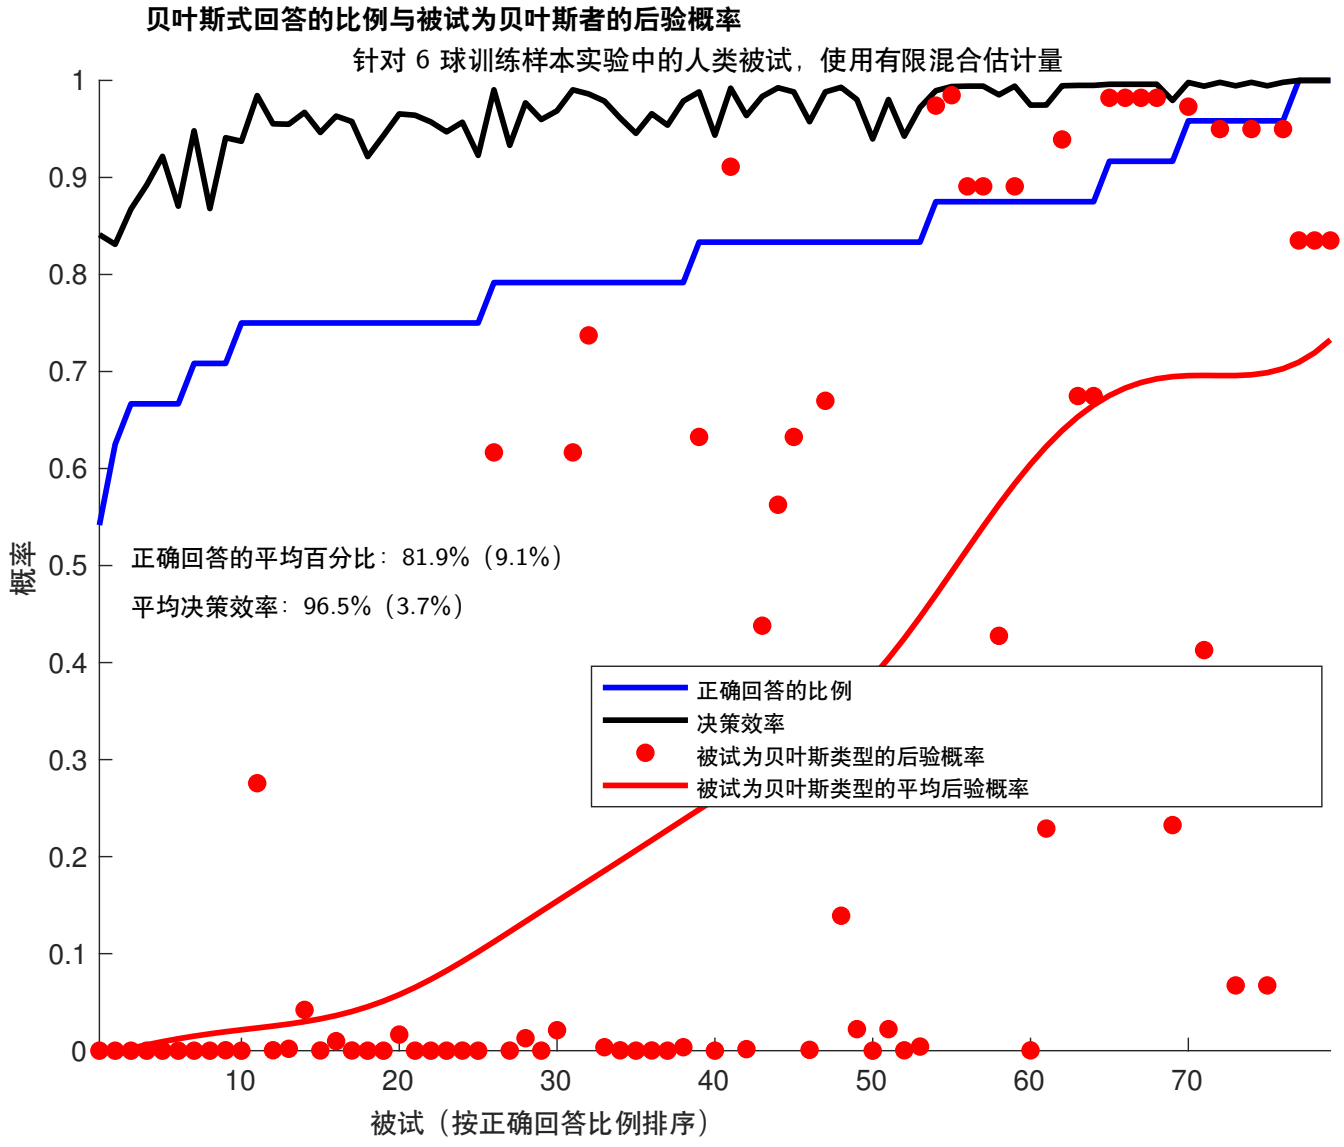
模型	Parameters	Log-likelihood	AIC
El-Gamal/Grether	4	-1952	3912
结构 probit	3	-1847	3700
简约形式 logit	3	-1821	3648
有噪声的贝叶斯	1	-1801	3604
结构 logit	4	-1773	3554
神经网络	5	-1772	3554

分类超平面与损失函数

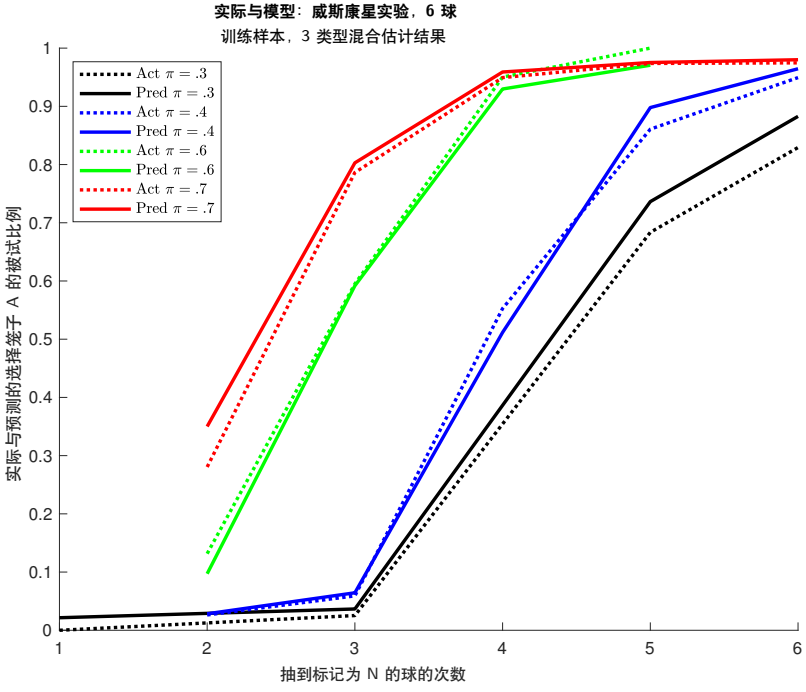

变换空间中的决策区域：贝叶斯法则与被试的隐含区域
（基于有限混合估计量）
Log likelihood ratio $\log(f(n|p_A)/f(n|p_B))$
Log posterior odds ratio $\log(\pi/(1-\pi))$
贝叶斯法则
类型 1
类型 2
类型 3

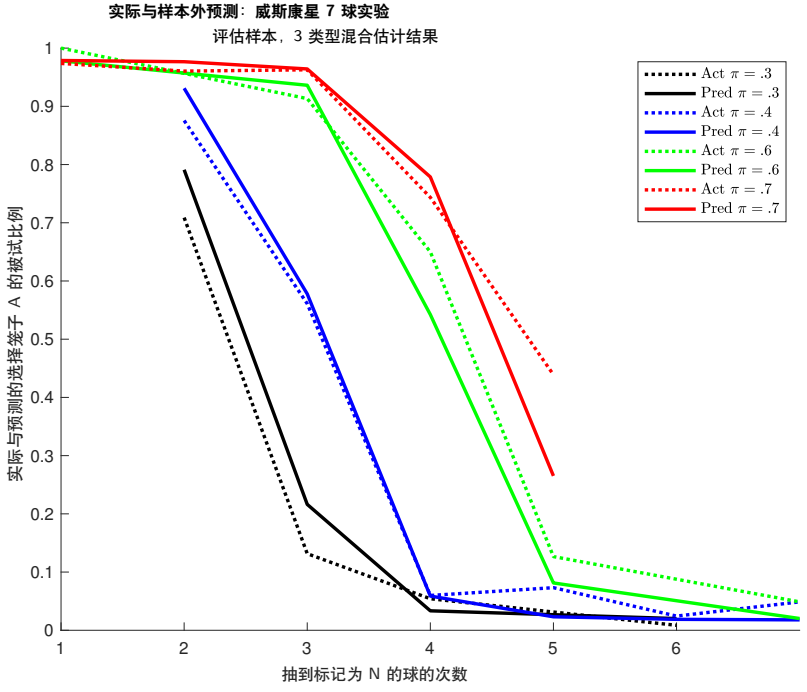

Expected loss functions: Bayes Rule vs Human Subjects
(Based on finite-mixture estimator)
Bayes Rule
Type 1 subjects
Type 2 subjects
Type 3 subjects
Loss from Bayes decision rule
Prior probability of cage A, π
Expected loss, Bayes Rule : 0.212192
Expected loss, Type 1 subjects: 0.214638 (0.0012816)
Expected loss, Type 2 subjects: 0.23179 (0.00707145)
Expected loss, Type 3 subjects: 0.259222 (0.0114643)

被试的准确率/效率：威斯康星 6 球实验



结构 logit 模型的样本外预测准确性





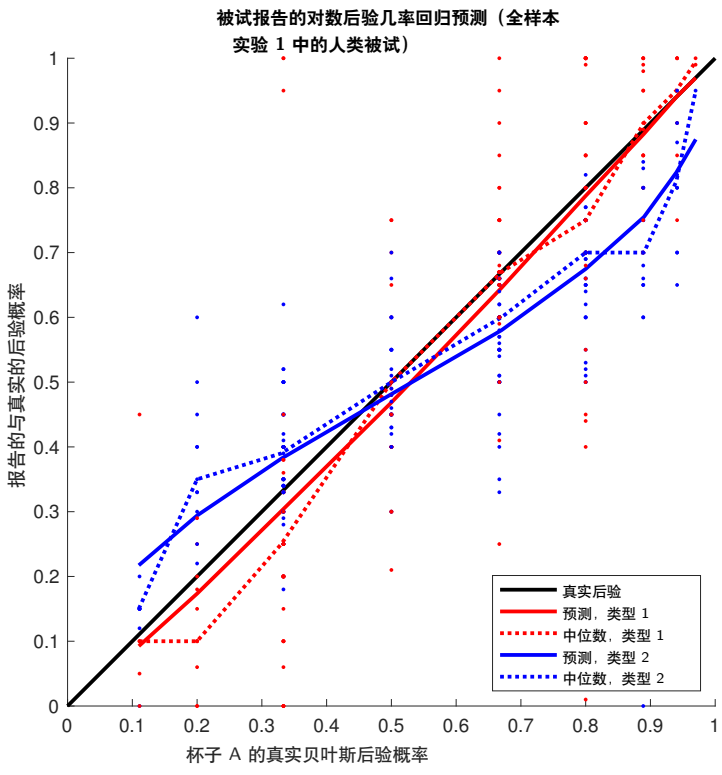
对 Holt 与 Smith 实验的重新分析

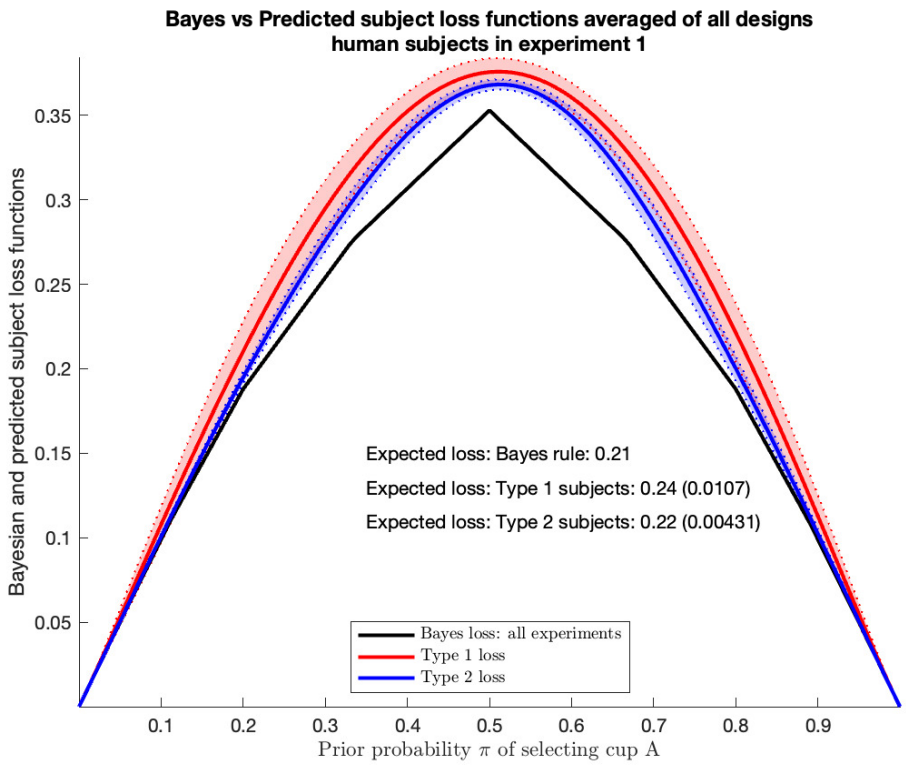
- 这些实验使用 Becker-DeGroot-Marschak（BDM）机制直接诱导主观后验概率。
- 它包含第二阶段的赌局，以激励被试如实报告主观后验 p。
- 如果被试报告笼子 A 为正确笼子的概率为 p_r，就会得到一个赌局 $\tilde{G}_R(p_r)$，它根据随机抽取的 $\tilde{p} \sim U(0,1)$ 支付金额 R。
  1. 若 $\tilde{p} \leq p_r$，则当真实笼子是笼子 A 时被试获得报酬 R
  2. 若 $\tilde{p} > p_r$，则被试以概率 $\tilde{p}$ 获得 R
- 被试报告 p_r 的期望收益为

$$E\{\tilde{G}_R | p_r, d, \pi, p_A, p_B, D\} = R\left[\frac{1-p_r^2}{2} + p_r \Pi_s(A|d, \pi, p_A, p_B, D, \nu)\right],$$

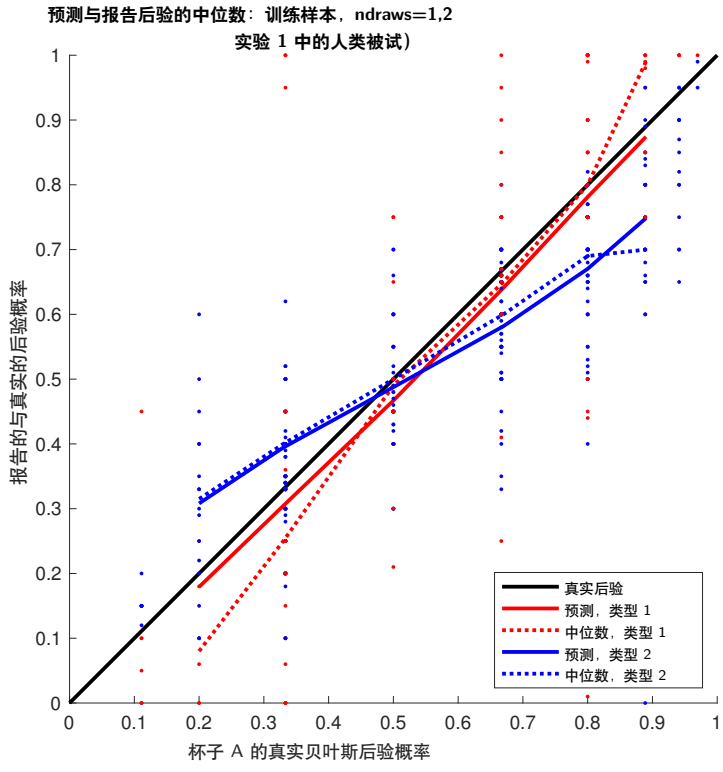
- 最优报告就是被试真实的后验概率
  $p_r^* = \Pi_s(A|d, \pi, p_A, p_B, D, \nu)$.

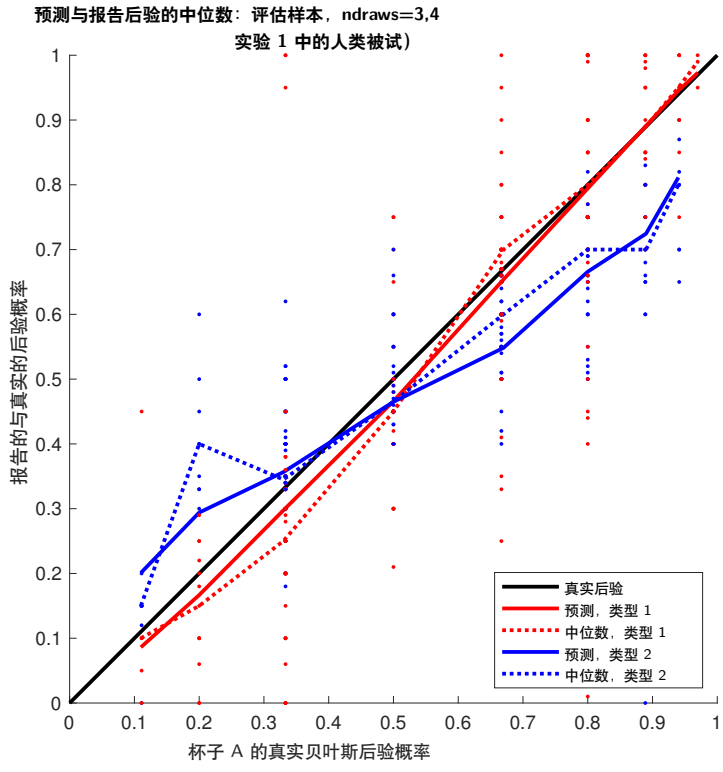
信念与损失函数：Holt 与 Smith 实验 1





信念的稳定性：Holt 与 Smith 实验 1





对人类被试数据重新分析的结论

- 我们拒绝“所有被试都是贝叶斯者，甚至都是有噪声的贝叶斯者”的假设
- 不过，我们确实发现相当比例的被试是有噪声的贝叶斯者
  1. El-Gamal 与 Grether 的加州实验中为 49% 到 79%
  2. 他们的威斯康星 6 球实验中为 32%
  3. 他们的威斯康星 7 球实验中为 77%
  4. Holt 与 Smith 的实验 1 中为 45%
  5. 但在他们基于网络的实验 2 中一个也没有
- 总体上决策效率很高
  1. El-Gamal 与 Grether 的加州实验中为 93%
  2. 他们的威斯康星 6 球实验中为 97%
  3. 他们的威斯康星 7 球实验中为 96%
  4. Holt 与 Smith 的实验 1 中为 96%
  5. 他们基于网络的实验 2 中为 91%

ChatGPT 在 6 球设计中的结果

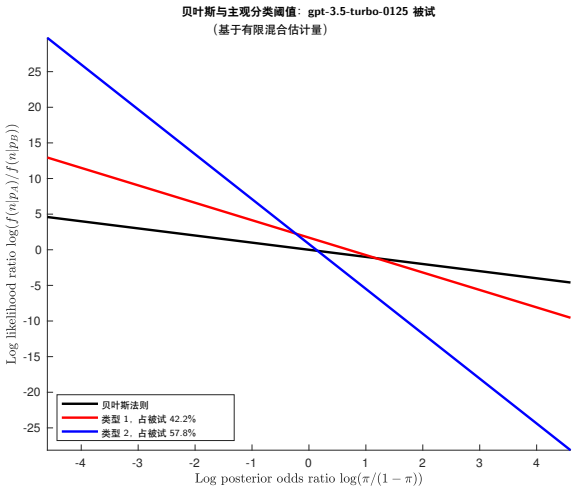
- 我们利用 El-Gamal 与 Grether（1995 和 1999）6 球设计的实际试验结果，为 GPT 被试构造了一组相匹配的试验

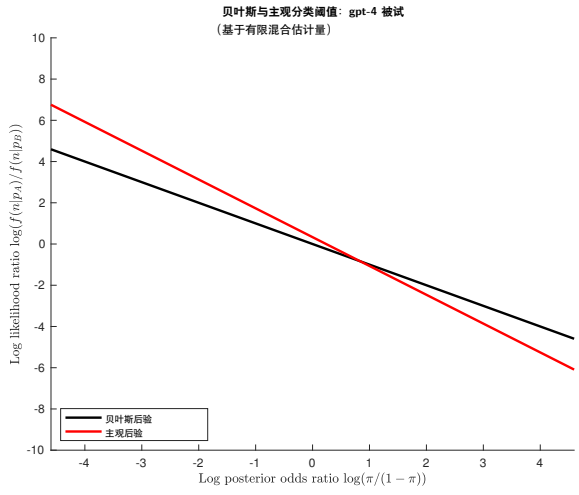
- 我们通过随机选择不同的温度设置，有意在 GPT 被试中引入被试特定的异质性。
- 温度越高，GPT 的回答越随机，因此这相当于在结构 logit 模型的 σ 或 η 噪声参数中加入异质性。

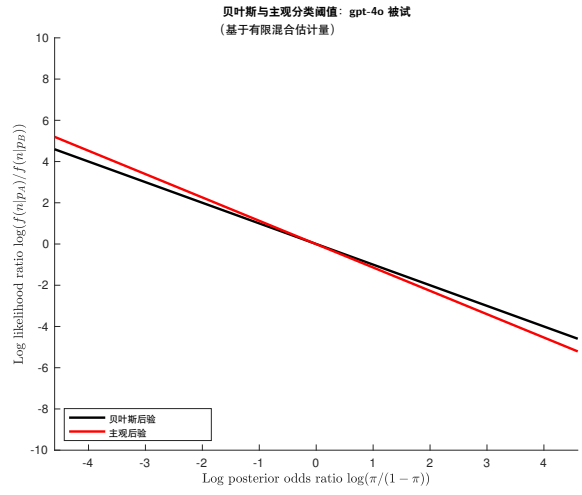
- 与人类被试不同，这是可观测的异质性。
- 不过，我们使用与处理人类被试不可观测异质性相同的方法来分析结果，即 EC 算法和针对不可观测异质性的有限混合方法。

估计的分类超平面

GPT 3.5、4 与 4o 的分类超平面

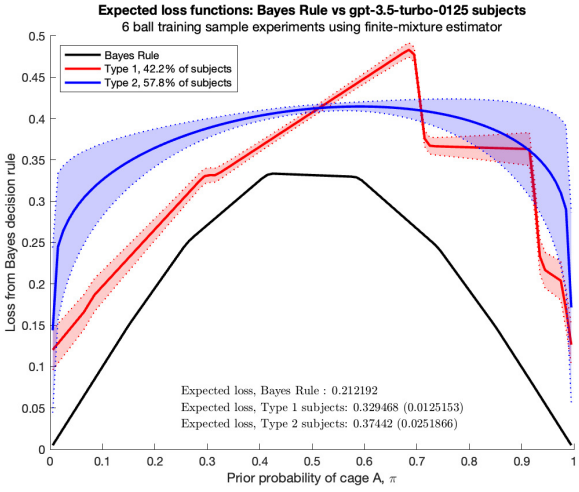


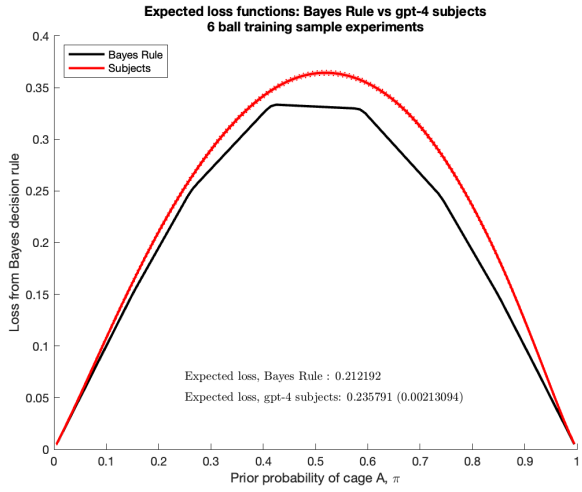


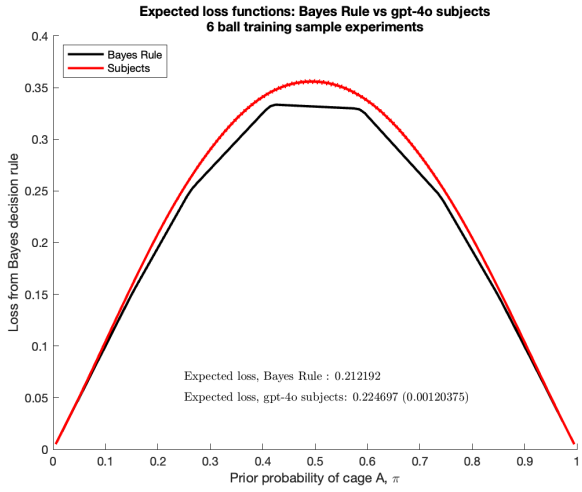


损失函数

GPT 3.5、4 与 4o 的估计损失函数

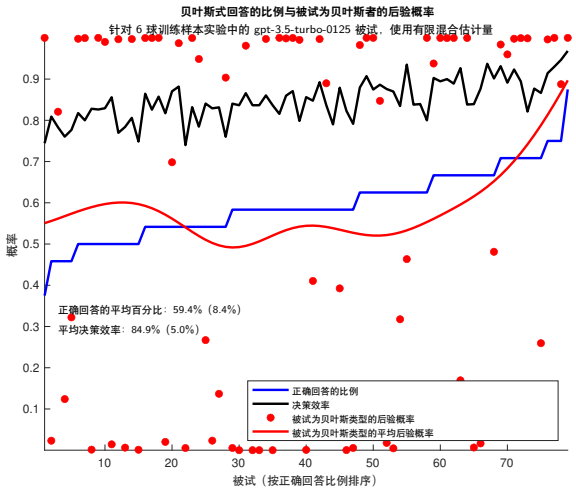


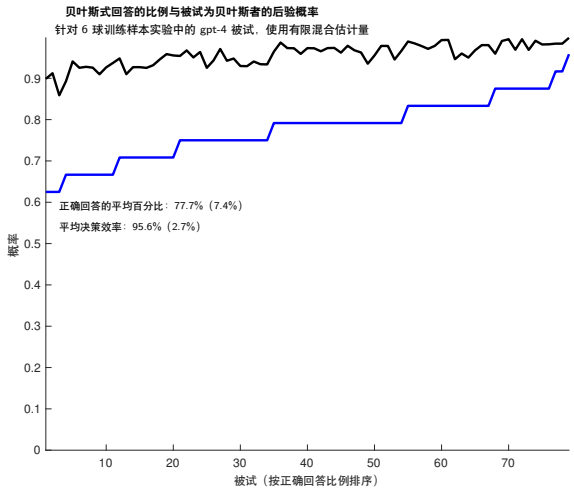


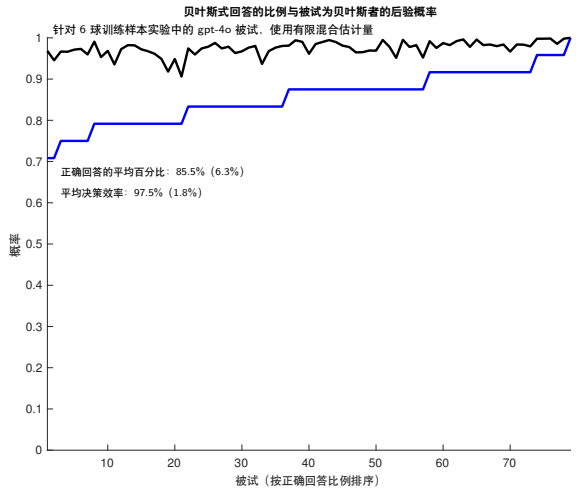


准确率与效率

GPT 3.5、4 与 4o 被试特定的准确率与效率







人类与 GPT 表现的比较

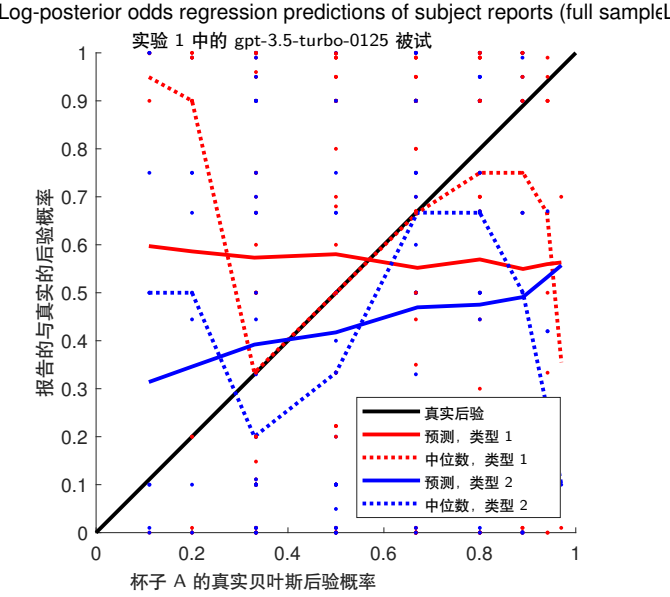
	GPT 3.5	GPT-4	GPT-4o	Humans
效率	84.9 (0.6%)	96.0 (0.3%)	97.5 (0.2%)	96.5 (0.5%)
准确率	59.4 (8.4%)	77.7 (7.4%)	85.5 (6.3%)	81.9 (9.1%)
类型数	2	1	1	3

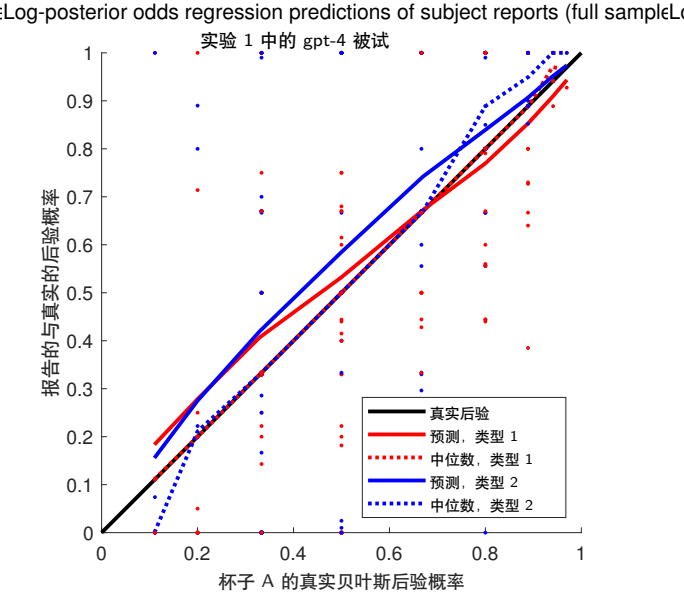
ChatGPT 在 Holt 与 Smith 设计中的结果

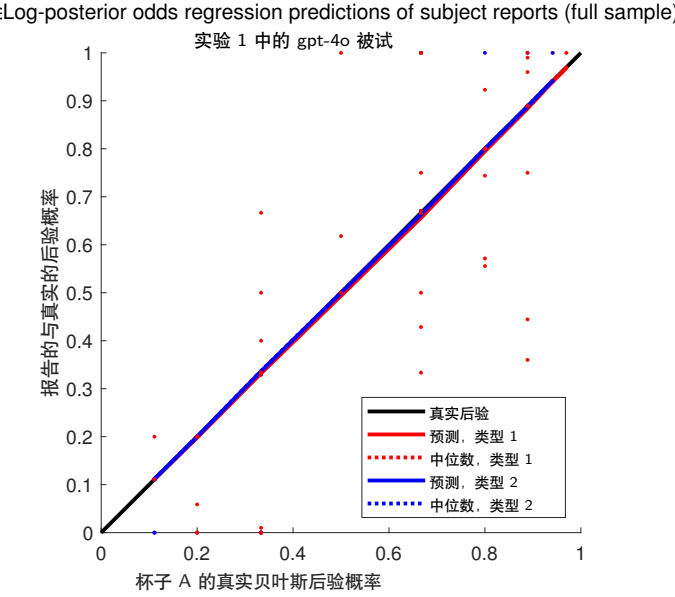
- 回顾一下，Holt 与 Smith 使用 BDM 机制直接诱导主观后验值
- 他们可能对人类被试做过一些指导：相信我们，报告你对样本来自杯子 A 的概率的最佳估计，最符合你的利益（能使你的报酬最大化）
- 但我们没有给 ChatGPT 这类指导。它必须自己会推算，弄清楚在第二阶段赌局 $\tilde{G}_R(p_r)$ 中的最优报告 p_r。

诱导出的主观后验

GPT 3.5、4 与 4o 的估计与实际诱导后验

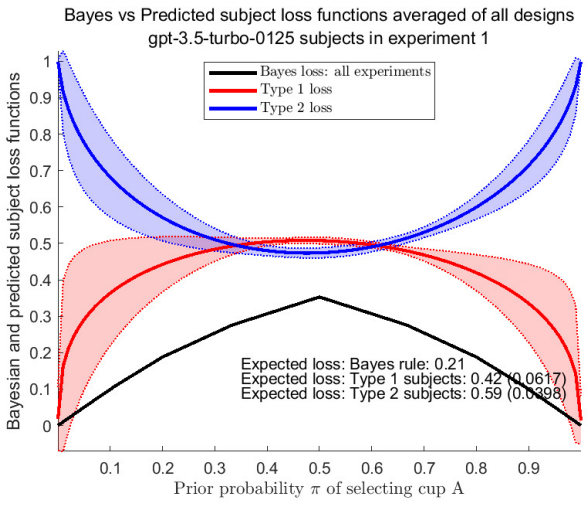


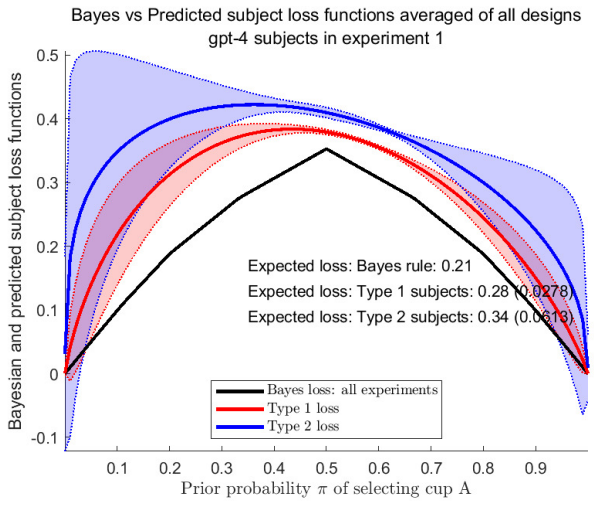


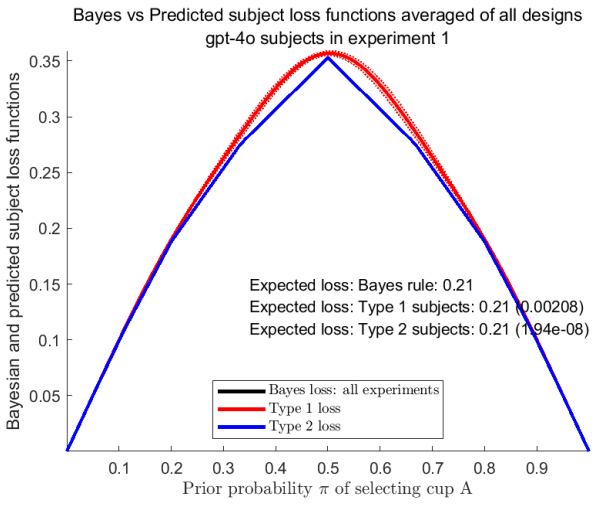


隐含的损失函数

GPT 3.5、4 与 4o 的隐含损失函数







人类与 GPT 表现的比较

	GPT 3.5	GPT-4	GPT-4o	Humans
效率	75.0 (1.0%)	93.0 (0.4%)	99.4 (0.3%)	96.0 (0.7%)
准确率	58.1 (0.1)	84.0 (0.1)	98.2 (0.02)	87.4 (0.1)
R^2	0.7	41.8	88.0	63.5
类型数	2	2	2	2

检验 GPT 回答中的情境效应

模型	Accuracy (Bingo)	Accuracy (Pond)	t-stat	p-value
GPT-4o	0.94	0.92	0.63	0.53
GPT-4	0.85	0.83	0.45	0.66
GPT-3.5	0.63	0.69	-0.84	0.40

人类与 GPT 比较的结论

- 我们发现，GPT 的准确率和决策效率随版本迭代迅速提升：GPT 3.5 低于人类水平，GPT-4 约与人类相当，GPT-4o 则超越人类。

- 这一提升背后有三个关键因素：(i) 偏差减小，
(ii) 对数据和先验的权重越来越均等，以及 (iii) 特质性的计算噪声和决策噪声水平更低。
- 在威斯康星实验中，我们发现 GPT 的不可观测异质性少于人类，GPT-4 和 4o 尤其如此：我们只发现了一种类型的被试，即有噪声的贝叶斯者。

- 在 Holt 与 Smith 实验中，40% 的被试被归类为完全贝叶斯者，其余 60% 最好被描述为有噪声的贝叶斯者。

- 对一代代 GPT 的行为，结构 logit 模型给出了越来越好的近似。

GPT 回答的误差分析

- 大多数计量模型把人当作黑箱；除了神经科学的一些研究外，我们并不确切知道人是如何处理信息的。
- 然而，对于 GPT，我们拥有独特的优势：既知道它们的神经“大脑”如何计算信息，也能看到包含其答案背后推理的文本回复。
- 因此，合乎逻辑的做法是尝试解析这些文本，以理解 GPT 犯错的方式和原因，建立误差分类体系，并得到各模型的误差分布。
- 这里有一些复杂之处。正确回答问题的方式不止一种，犯错的方式更多。我们采用的方法有两方面：(1) 使用更强的 GPT 模型 o1 建立自动评分流程；(2) 对 GPT4o 回答的一个较小样本进行人工评分。

用 GPT-o1 对 GPT 自动评分

1. 从原始提示和“学生”GPT 的回答开始。
2. 计算正确答案。
3. 把原始提示、回答与正确答案合在一起交给评分者。
4. 将其发送给评分 GPT，获得评分回复。
5. 从评分回复中提取评价并存储结果。

GPT 回答中的误差汇总

	Error Flag (Yes/No)	GPT 3.5 (%)	GPT 4 (%)	GPT 4o (%)
Panel A. Data read-in errors		1.3 [2.0]	1.0 [0.0]	0 [0.0]
1	Error reading the compositions of the two cages	1.0	0	0
2	Error reading the number of balls drawn from the two cages	0	1.0	0
3	Error reading the outcome of the draws	0.3	0	0
Panel B. Errors in the application of Bayes Rule		85.3 [76.0]	1.3 [0.0]	0.7 [0.0]
4	Ignoring the prior	85.0	1.3	0.7
5	Ignoring the likelihood	0.3	0	0
Panel C. Errors in computing the posterior probability		99.0 [98.0]	71.7 [75.0]	20.7 [20.0]
6	Error reading the prior probability	86.0	2.0	0.3
7	Error calculating the likelihood	67.0	65.0	11.3
8	Error calculating the posterior (or posterior odds)	98.3	68.7	20.3
Panel D. Errors in the final decision		6.3 [10.0]	1.3 [0.0]	6.3 [20.0]
9	Final decision contradicting the previous reasoning	6.3	1.3	6.3
Fraction of responses inconsistent with Bayes' rule		36.3	10.0	9.6

人工评分得出相似的结论

- 自动评分与人工评分相互补充。
- 人工评分没能发现阅读错误或未应用贝叶斯法则的错误。这是因为这些错误很少见，所以要靠自动评分者在大样本中把它们找出来。
- 人工评分能够区分（1）计算错误与（2）计算中断，以及二者的相对占比，而自动评分者没有发现这一点。
- 人工评分还发现了一例决策噪声，这一点也得到了自动评分的确认。
- 人工评分还能发现自动评分无法发现的、关于 GPT4o 的更细致的细节
- 两种方法的总体结论大体相似。

ChatGPT-o1 的自我纠错

GPT-o1 正确计算了后验

为了确定使你的期望报酬最大化的最优 P 值，我们将逐步拆解这个问题。

第 1 步：确定后验概率 给定样本 (D,D,D)，我们用贝叶斯定理更新关于球是从瓮 A 还是瓮 B 中抽出的信念：

$$P(\text{Urn A}|\text{D,D,D}) = \frac{\frac{1}{27} \times 0.5}{\frac{1}{27} \times 0.5 + \frac{8}{27} \times 0.5} = \frac{1}{9} \approx 0.1111 \tag{3}$$

并正确计算了 BDM 报酬

第 2 步：计算期望报酬 你的期望报酬取决于你选择的 P 值和随机抽取的数 U。

- 情形 1：$U \leq P$。期望报酬：$\frac{1}{9} \times 1000 = 111.11$。
- 情形 2：$U > P$。期望报酬：$1000 \times \frac{P+1}{2} = 500 \times (P+1)$

ChatGPT-o1 的自我纠错

但在计算最优报告时把公式抄错了

总的期望报酬

$$E(P) = P \times 111.11 + (1 - P) \times 500 \times \frac{P + 1}{2}. \tag{4}$$

为了最大化 $E(P)$，对 P 求导并令其为零：

$$\frac{dE}{dP} = -500P + 111.11 = 0. \tag{5}$$

求解得到

$$P = \frac{111.11}{500} = 0.2222. \tag{6}$$

但在最后一刻它意识到了自己的错误并自我纠正

然而，经过更仔细的检查和重新计算，使期望报酬最大化的最优 P 为：$P = \frac{1}{9} \approx .1111$。